



Centro UC
Encuestas y Estudios
Longitudinales

Imputaciones de Corte Transversal de la VI Ronda de la Encuesta de Protección Social

Diciembre, 2016.

Tabla de Contenidos

1	INTRODUCCIÓN	3
2	REVISIÓN DE LA LITERATURA	4
2.1	EL PROBLEMA DE LA NO RESPUESTA	4
2.2	MECANISMOS DE NO RESPUESTA	4
2.3	IMPUTACIÓN DE DATOS PERDIDOS EN ENCUESTAS DE HOGARES EN CHILE	7
3	ANÁLISIS DE LA NO RESPUESTA AL ÍTEM EPS 2015	8
3.1	EDICIÓN E IMPUTACIÓN DE DATOS EN LA EPS	8
3.2	PORCENTAJE DE NO RESPUESTA AL ÍTEM	9
3.3	DESCRIPCIÓN DE VARIABLES CON DATOS PERDIDOS A IMPUTAR	12
3.4	PATRONES DE NO RESPUESTA AL ÍTEM	16
3.5	MECANISMOS DE NO RESPUESTA AL ÍTEM	18
3.6	CONCLUSIÓN ANÁLISIS DE NO RESPUESTA AL ÍTEM	21
4	MÉTODOS DE IMPUTACIÓN APLICADOS EN EPS 2015	22
4.1	IMPUTACIÓN POR MEDIAS CONDICIONADAS	24
4.2	IMPUTACIÓN HOT DECK	27
4.3	IMPUTACIÓN COLD DECK	28
5	IMPUTACIÓN MONTO DE INGRESO LABORAL	29
5.1.	RESULTADOS DE IMPUTACIÓN DE CORTE TRANSVERSAL SIN PONDERAR	29
5.2.	COMPARACIÓN DE ESTIMACIONES DE CORTE TRANSVERSAL PONDERADAS	32
6	IMPUTACIÓN MONTO DE ALQUILER IMPUTADO	34
6.1.	RESULTADOS DE IMPUTACIÓN DE CORTE TRANSVERSAL SIN PONDERAR	34
6.2.	COMPARACIÓN DE ESTIMACIONES DE CORTE TRANSVERSAL PONDERADAS	36
7	IMPUTACIÓN DE TRAMO DE NIVEL EDUCACIONAL	38
7.1.	RESULTADOS DE IMPUTACIÓN LONGITUDINAL SIN PONDERAR	38
7.2.	RESULTADOS DE IMPUTACIÓN DE CORTE TRANSVERSAL SIN PONDERAR	43
7.3.	COMPARACIÓN DE ESTIMACIONES DE CORTE TRANSVERSAL PONDERADAS	45
8	CONCLUSIONES Y DISCUSIÓN	48
9	REFERENCIAS	53
10	ANEXO	55
12.1.	NÚMERO DE DONANTES POR CELDA, IMPUTACIONES YTRAB	55
12.2.	NÚMERO DE DONANTES POR CELDA, IMPUTACIONES ALQ	59
12.3.	DESCRIPCIÓN DE BASE DE DATOS IMPUTADA EPS 2015	62
12.4.	LIBRO DE CÓDIGOS DE BASE IMPUTADA EPS 2015	63

1 Introducción

El proceso de producción de una encuesta compleja y de gran envergadura como la Encuesta de Protección Social (EPS) no termina con la etapa de recolección de datos sino que continúa usualmente con la revisión y validación de los datos recolectados. Adicionalmente algunas encuestas incorporan también un proceso de imputación de datos, el que se desarrolla en coordinación con el proceso de edición y validación.

Es fundamental implementar estas actividades posteriores al trabajo de campo ya que se pueden presentar dos situaciones – (1) error en los datos recolectados, y (2) falla total (o parcial) en recolectar datos. La primera situación se conoce como “error de medición” y, dependiendo de la naturaleza del problema, puede contribuir a sesgar las estimaciones que se desarrollen a partir de los datos observados (recolectados). El proceso de edición y validación de datos tratar de corregir este problema. La segunda situación se conoce como “error de no respuesta al ítem” y, dependiendo de la magnitud y naturaleza del problema, puede repercutir tanto en el sesgo como en la varianza de las estimaciones desarrolladas. El proceso de imputación de datos busca hacerse cargo de este último problema.

En EPS 2015 se buscó evaluar alternativas para el tratamiento de la no respuesta al ítem (“datos perdidos”) para una selección de variables que fueran relevantes para la publicación de resultados de la VI ronda. En este documento se presenta la metodología y resultados de la evaluación de tres alternativas para el análisis con datos perdidos – imputación por medias condicionadas, imputación vía hot deck aleatorio e imputación vía cold deck.

Los métodos evaluados en este informe son relativamente sencillos de implementar y comunicar a los usuarios. Encuestas que ponen a disposición pública datos imputados, como por ejemplo la Casen¹ en Chile o la HRS² en Estados Unidos, utilizan (o partieron utilizando) variantes de estos métodos de imputación. Métodos de imputación (o análisis) más sofisticados como los que se basan en modelos bayesianos, ecuaciones encadenadas, o de imputaciones múltiples, entre otros, no son evaluados en este informe. Estos métodos, si bien cuentan con mayor soporte teórico, no están exentos de críticas y su uso se encuentra más extendido entre analistas que entre productores de datos. En atención a estas consideraciones, el presente informe se plantea como una instancia inicial de un proceso de investigación que debiera continuar profundizándose en el tiempo a través de (1) la evaluación de métodos más sofisticados para el tratamiento de datos perdidos, y (2) la incorporación al análisis de datos perdidos de las rondas anteriores del panel EPS³.

El presente informe se organiza como sigue - en la sección 2 se presenta el contexto general del problema de la no respuesta al ítem, mientras que en la sección 3 se presentan análisis de los porcentajes, los patrones y los mecanismos de no respuesta al ítem para una selección de variables de la EPS 2015. La sección 4 se describe las metodologías utilizadas para la

¹ Casen: Encuesta de Caracterización Socioeconómica Nacional.

² HRS: Health and Retirement Survey.

³ Para la EPS 2009 se desarrollaron imputaciones para una selección de variables relacionadas con ingresos y patrimonio de la ronda 2009, sin embargo no están a disposición pública ni los datos ni las metodologías implementadas.

imputación de variables y las secciones 5-7 presentan los resultados. La discusión de resultados y recomendaciones para investigación futura se presentan en la sección 8 y las referencias bibliográficas en la sección 9. Los programas estadísticos utilizados para el desarrollo de este informe se presentan en un archivo electrónico adjunto.

2 Revisión de la literatura

2.1 El problema de la no respuesta

A pesar de los esfuerzos y estrategias implementadas, todas las encuestas sufren de no respuesta. Hay dos tipos de no respuesta – no respuesta a la unidad (cuando no se logra que el individuo seleccionado conteste la encuesta), y la no respuesta al ítem (cuando no se logran respuestas para algunas de las preguntas de la encuesta). Ambos tipos de no respuesta tienen un doble impacto en la calidad de los datos que se recolectan: (1) potencial *sesgo* de no respuesta, y (2) reducción del tamaño efectivo de muestra (que genera disminución de la *precisión* de las estimaciones). Para reducir el impacto de la no respuesta a la unidad y al ítem los productores de datos utilizan ajustes estadísticos como la ponderación (*weighting*) y la imputación (*imputation*) respectivamente. Otras opciones incluyen “no hacer nada”, y usar sólo los datos de quienes responden (*complete case analysis*), o usar “sustitutos” durante el proceso de recolección de datos (Andridge y Littel, 2010).

Existen diversas razones por las que el informante no entrega toda la información solicitada, entre las que se pueden mencionar el desconocimiento sobre la utilidad de la información recolectada por la encuesta, aburrimiento, vergüenza, desconfianza, omisión involuntaria o simplemente el no querer responder temas sensibles para él o ella. No sólo la falta de información en algunas variables es un problema, sino también la presencia de datos anómalos o poco probables. Si bien, el primer resguardo para evitar estos problemas es el diseño correcto del cuestionario y el buen desarrollo del trabajo de campo, aun cumpliendo con esto, la falta de información en algunas variables o la presencia de datos anómalos estará presente en cualquier encuesta.

El fenómeno de la no respuesta al ítem está asociado a tres mecanismos (Beatty & Herman, 2002): (1) cuanto saben las personas acerca del tema, (2) sus juicios acerca de la precisión de su conocimiento y lo que la pregunta parece requerir, y (3) su voluntad de reportar la respuesta. Los primeros dos factores son cognitivos o informativos, mientras que el tercero es motivacional. Este modelo, aplicado a preguntas de ingreso, predice que los entrevistados no van a responder preguntas de ingresos cuando, por ejemplo, (1) no sepan el ingreso familiar, (2) tengan una idea vaga del monto, pero asuman que la pregunta exige una cantidad exacta, o (3) sepan la respuesta, pero no estén dispuestos a revelarla al encuestador o a la institución a cargo del estudio.

2.2 Mecanismos de no respuesta

El porcentaje de datos perdidos se encuentra relacionado, directamente, con la calidad de la inferencia estadística. A pesar de ello, no existe en la literatura un punto de corte que establezca un porcentaje aceptable de datos perdidos en una base de datos para garantizar

la validez de las inferencias estadísticas (Dong y Peng, 2013); Schafer (1999), por ejemplo, establece que una tasa de pérdida menor al 5% no tiene consecuencias; Bennet (2001), sostiene que los análisis estadísticos probablemente estarán sesgados cuando se tiene más de 10% de datos perdidos; Tabachnick y Fidell (2012), sostienen que el *mecanismo* y el *patrón de pérdida* de datos tienen un mayor impacto que la proporción de datos perdidos en los resultados de una investigación.

La Figura 2 permite ilustrar algunos “patrones de pérdida” de información, donde la base de datos se interpreta como una matriz en que las filas corresponden a las observaciones y las columnas las variables de interés. En la parte (a) de la figura podemos notar que la falta de información se concentra en una sola variable de interés Y , lo cual se conoce como patrón univariado. En la parte (b) se observa un patrón de omisión de información escalonado o monótono, que es característico de estudios longitudinales en donde Y_j representa el valor de la variable de interés en la j -ésima ronda. Finalmente, en la parte (c) se presenta un patrón aleatorio, donde en cualquier celda pueden existir datos faltantes, es decir la falta de información no está determinada por algún patrón en particular y conocido.

El concepto “mecanismo generador de la no respuesta” fue formalizado por Rubin en el año 1976 y distingue tres tipos:

1. No respuesta completamente aleatoria (MCAR)
2. No respuesta aleatoria (MAR)
3. No respuesta no aleatoria (NMAR)

A los registros sin información se le identifica con una variable binaria (Z), esta variable toma valor 1 si es que el dato existe y 0 si es que no existe. Sea $Y_{com} = (Y_{obs}, Y_{mis})$ la variable de interés, en donde Y_{obs} e Y_{mis} corresponde al vector de datos observados y faltantes, respectivamente; se afirma, que un proceso de datos faltantes se genera en forma aleatoria (MAR) si la distribución de los valores observados no depende del patrón de comportamiento de los registros sin información Y_{mis} :

$$\Pr(Z|Y_{com}) = \Pr(Z|Y_{obs})$$

Esta situación se presenta en las encuestas de hogares, pero no en cualquier variable. En los estudios de nivel de vida, por ejemplo, se reconoce que la falta de respuesta en las familias “ricas” está correlacionada con sus ingresos; y, por tanto, no se satisface el supuesto MAR. Sin embargo, cuando la omisión se presenta en la rama de actividad o en la categoría ocupacional, la falta de información no necesariamente guarda relación con el nivel de ingresos de las personas, y el supuesto MAR podría satisfacerse.

Un caso especial es el llamado proceso completamente aleatorio (MCAR), el cual ocurre cuando la omisión no depende de los datos observados:

$$\Pr(Z|Y_{com}) = \Pr(Z)$$

Por otra parte, cuando existe dependencia entre los datos completos y los faltantes (Y_{mis}), se dice que Y_{mis} no sigue un proceso aleatorio (*Missing not at Random*, MNAR). Es común referirse a los procesos MAR como mecanismos de no respuesta ignorable, en tanto que

MNAR significa que la falta de respuesta no puede ser ignorada en el proceso de construcción del estimador, ni al analizar las relaciones de causalidad entre variables.

En la práctica, es común que se presenten situaciones en que los datos faltantes no siguen un patrón completamente aleatorio (MCAR) y tampoco aleatorio (MAR). Está demostrado que la falta de respuesta se asocia, por ejemplo, al estatus económico de la familia, al área geográfica de residencia del hogar, al nivel de estudio de las personas, y en estas situaciones el patrón de datos omitidos no puede ni debe ser ignorado (MNAR).

En las encuestas de educación y del mercado de trabajo la omisión está asociada a las unidades de observación, ya que es habitual que después de algún tiempo los informantes se nieguen a participar, se cambien de casa, o los estudiantes emigren a otro establecimiento educativo.


Considere el patrón de datos faltantes en el que los valores de la variable $X = (X_1, X_2, \dots, X_p)$ existen en todas las observaciones, pero en algunos casos se desconoce el valor de Y . Cuando los datos provienen de una muestra aleatoria, los patrones de datos omitidos — MAR, MCAR y MNAR— pueden interpretarse a partir de X e Y . MCAR significa que la probabilidad de que falte Y no depende de los valores de X e Y (ni de los propios ni de las otras observaciones), MAR asume que la probabilidad de que falte Y puede depender de X pero no de Y , en tanto que MNAR se interpreta en el sentido de que la probabilidad de que existan datos omitidos depende de Y .

Cuando se explicita que la no respuesta es MCAR, entonces las unidades observadas tienen un comportamiento estadístico que se comparte con las unidades no observadas, por lo que la no respuesta se puede identificar solo gracias a las variables Z (conocidas y observadas). Si bien lo que se busca es que la no respuesta sea MCAR, trabajar y realizar consultas sobre la información parcial (ignorando las celdas vacías) puede llevar a un investigador a tomar decisiones y realizar informes con información errónea (o con un error efectivo mayor).

Una de las formas de combatir, y buscar soluciones para, la no respuesta es a través de la imputación de datos. Existen variados métodos de imputación, que se ajustan de acuerdo a las particularidades de la información contenida en una base de datos. Respecto a la forma para determinar cuáles son las mejores aproximaciones a los datos, existen numerosos documentos de trabajo y metodologías planteadas para las encuestas.

Por otra parte, en las encuestas con diseño complejo en general el porcentaje de datos faltantes es bajo y se concentra en una parte específica de la muestra con ciertas características; así, en estos casos, puede ser preferible utilizar metodologías simples de imputación de datos que las herramientas más sofisticadas. Los autores Medina y Galván (2007), señalan que un método de imputación simple potencialmente reproduce mejor las características de la subpoblación de interés que un algoritmo que considera a toda la muestra.

Figura 2. Ilustración de Patrones de datos faltantes.



Fuente: Series Estudios Estadísticos y Prospectivos N°54

2.3 Imputación de datos perdidos en encuestas de hogares en Chile

La imputación de datos no es una práctica común en las encuestas de hogares en Chile. Las excepciones son la encuesta de Caracterización Socioeconómica Nacional (Casen), la Encuesta Financiera de Hogares (EFH), la Encuesta Suplementaria de Ingresos (ESI) y la Encuesta de Presupuestos Familiares (EPF). Las encuestas ESI y EPF, levantadas por el INE, imputan ingresos (laboral y jubilaciones) y gastos utilizando variantes del método de Hot Deck⁴.

La encuesta Casen produce imputaciones para un conjunto importante de variables asociadas a diversas fuentes de ingresos de los hogares. El método utilizado para imputar los ingresos del trabajo, jubilaciones y rentas vitalicias corresponde a "medias condicionadas", mientras que para imputar el alquiler se utiliza el "hot deck secuencial". Para subsidios y transferencias del estado de montos fijos, se imputa el valor del monto fijo a los outliers que superan el monto fijo. Cada variable se imputa una sola vez (*single imputation*) y en forma independiente de las otras, por lo que las metodologías se pueden caracterizar como univariadas⁵.

La Encuesta Financiera de Hogares produce imputaciones para distintas fuentes de ingreso y patrimonio agregadas a nivel de hogar. Se utiliza el método de imputación encadenado (*chain equations*) disponible en el paquete estadístico Stata. Todas las variables se imputan en forma conjunta, lo cual se conoce en la literatura como imputación multivariada. Cada variable se imputa 30 veces, y los parámetros se estiman utilizando los métodos de combinación de Rubin para imputaciones múltiples (*multiple imputation*)⁶.

⁴ Ver mas antecedentes en documentos del trabajo de la EPF, INE (2014).

⁵ Ver detalles de los procedimientos de corrección de no respuesta en Cepal (2016) y Ministerio de Desarrollo Social (2016).

⁶ Ver detalles del procedimiento de imputación de datos en la EFH en Banco Central (2013).

3 Análisis de la No Respuesta al Ítem EPS 2015

Ante la presencia de datos faltantes en algunas variables clave de la EPS 2015 es importante evaluar ambos – tanto la prevalencia (severidad del problema), como la identificación de los mecanismos que explican los datos perdidos. Las secciones que siguen presentan la descripción del procesamiento de datos en la EPS (sección 3.1), resultados del análisis de la prevalencia de la no respuesta (sección 3.2), el patrón de datos perdidos (sección 3.3) y los mecanismos de no respuesta (sección 3.4) para una selección de variables de la EPS 2015.

3.1 Edición e imputación de datos en la EPS

El objetivo final del proceso de edición y validación de datos es producir una base de datos consistente y con la menor cantidad de errores posible. Notar los énfasis – (1) no es posible evaluar la validez de todos los reportes entregados por los entrevistados, en vez de eso se busca lograr que los reportes sean consistentes, y (2) nunca es posible eliminar todos los errores en los reportes, se busca minimizarlos. Restricciones de tiempo y costos inciden en la determinación de qué y cuanto editar. Resultados del proceso de edición/validación incluyen desde dejar los datos tal y como están (i.e., no modificar), modificar los datos observados con información auxiliar, o reemplazar los datos observados por datos perdidos.

En la EPS históricamente se han implementado acciones de validación y consistencia de datos tales como: revisión de la implementación de saltos de pregunta, revisión de rango y recorrido de variables, revisión de aplicación de códigos especiales (ej. 88 “No Sabe”, 99 “No Responde”) y revisión de valores extremos (*outliers*). En rondas anteriores de la EPS el proceso de edición/validación de datos ha sido exclusivamente de corte transversal, es decir, se revisa la consistencia de las respuestas solo al interior de la base de datos recolectada en la ronda actual sin considerar comparaciones con los datos recolectados en rondas anteriores. Para la VI Ronda 2015, sin embargo, se incorporó la revisión longitudinal de los datos para una selección de variables⁷. El Informe de Edición y Validación de datos EPS 2015 da cuenta de estos resultados.

Durante el proceso de edición/validación, los datos que son identificados con errores o inconsistencias se corrigen si es que se dispone de información externa que permita realizarlo. Por ejemplo, cuando se identifican casos con un alto nivel de inconsistencia o valores perdidos, se traspasa el caso al equipo de Supervisión, quien realiza un llamado telefónico a la vivienda para corroborar datos de la aplicación y, en caso de ser pertinente, completar información que no haya sido capturada en la aplicación presencial. Ahora bien, si no se cuenta con información adicional, se genera una variable indicadora de error y se deja el dato tal y como fue recolectado. Algunos de estos casos serán revisados en el proceso de imputación de datos. Por ejemplo, cuando se detectan ingresos laborales muy grandes o muy pequeños en una ronda (revisión corte transversal), o cuando se detectan

⁷ Las variables: edad, sexo y educación del entrevistado, se revisaron contra los datos de rondas anteriores para todos los entrevistados que participaron en, al menos, una ronda anterior a la VI Ronda 2015. Las variables: ingreso laboral e ingreso total del hogar, se revisaron contra las rondas anteriores para aquellos casos con respuestas extremas (*outliers*) en la VI Ronda 2015.

cambios muy severos en el nivel educacional reportado entre rondas del panel (revisión longitudinal).

El proceso de imputación de datos, consiste en generar datos plausibles para aquellos datos identificados con problemas durante el proceso de recolección y/o edición/validación de datos. Se pueden identificar dos tipos de problemas:

- (1) Los **valores perdidos** (*missing data*), que corresponden a los códigos asociados a las respuestas "No Sabe" y "No Responde" registrados durante el proceso de recolección de datos. La participación de los entrevistados en la encuesta es voluntaria y, de esta forma, ellos pueden optar por *no responder* cualquier pregunta del cuestionario. Si no conocen la información, entonces pueden responder "*no sabe*". Los códigos asociados a estas respuestas están incorporados en el cuestionario y generan vacíos de información para los analistas de los datos.
- (2) Los **valores inconsistentes**, corresponden a los datos identificados durante el proceso de edición/validación de datos. El problema acá no es la falta de información, como el caso anterior, sino que la sospecha de que la información existente sea errónea. Es el caso de las respuestas extremas (*outliers*), se pueden generar sesgos importantes en la estimación de los estadísticos de interés. La variabilidad también aumenta en presencia de valores extremos.

Si la proporción de datos perdidos por estas causas es alta, pueden constituir un problema serio para el análisis de los datos. Por una parte, se genera incremento en la varianza al contar con menos datos para el cálculo de los estadísticos de interés. Por otra parte, si los datos no están perdidos al azar, se puede generar también sesgo en la estimación de los parámetros de interés. Por esta razón, los datos perdidos son usualmente candidatos a imputación.

3.2 Porcentaje de No Respuesta al Ítem

En la base de datos EPS 2015 los valores identificados con el símbolo "." en Stata y con " " (blanco) en SPSS, corresponden a instancias válidas de datos perdidos asociadas a saltos de pregunta. Por ejemplo, la pregunta sobre "ingresos laborales" solo se aplica a las personas que trabajan remuneradamente - a todo el resto de las personas no se les hace esta pregunta y se deja marcado un "." o " " (blanco) para ellos. Este tipo de datos perdidos en la base de datos no constituye lo que se denomina "no respuesta al ítem", simplemente refleja el hecho de que distintas preguntas se aplican a distintas subpoblaciones dentro de la encuesta.

La no respuesta al ítem, que es el foco de nuestro interés, viene dada por las categorías "No Sabe" y "No Responde" que se registran en la base EPS 2015 con los códigos "8's" y "9's" respectivamente. A nivel general, las preguntas de la EPS 2015 presentaron tasas de no respuesta al ítem en un rango acotado. La Tabla 3.1 presenta el porcentaje de no respuesta al ítem para una selección de variables en la EPS 2015. Se puede observar que las tasas más altas de no respuesta están asociadas a preguntas sobre montos como el arriendo efectivo/estimado (17%), el ingreso total familiar (16,7%) y los ingresos laborales (8,5%). Preguntas como nivel educacional y otras sociodemográficas están en el rango de

2-5%, sin embargo la mayor parte de las preguntas presentan tasas mucho más bajas (<1%).

Preguntas sobre tramos monetarios, que se aplican solo a quienes no saben o no responden preguntas sobre montos, tienen una tasa de no respuesta en el rango de 2-5%. Por ejemplo, en la EPS 2015 se aplicó la pregunta sobre tramos de ingreso laboral (b12t) a las 761 personas que declararon No Sabe o No Responde a la pregunta de monto de ingreso laboral (b12) – de ellas 708 reportaron un tramo de ingreso y 53 optaron por no responder. La pregunta de tramos de ingreso es, para la EPS, una pregunta útil para rescatar información (parcial) que de otra manera estaría completamente perdida para el estudio.

Los resultados que aquí se presentan están en línea con los que se encuentran en la literatura para preguntas acerca de montos y tramos de ingresos, donde se pueden observar tasas de no respuesta al ítem entre 20-40% (Moore *et al.*, 1999; Olson *et al.*, 1999). En contraste, se observan tasas entre 1-4% para otro tipo de preguntas (De Leew, 1992). La Tabla 3.2 en Yang *et al.* (2010), con datos sobre tres grandes encuestas de hogares en Estados Unidos, también muestra datos de no respuesta a preguntas de ingresos en el rango de 12-35%. Sin embargo, aquí también se ilustra la reducción en el porcentaje de datos perdidos cuando se aplican preguntas de tramos de ingreso a los que no responden montos de ingreso. Para la CEQ 2003, por ejemplo, el porcentaje de no respuesta al monto de ingreso baja de 35% a 19% al utilizar tramos.

El uso de tramos de ingreso es una práctica habitual en encuestas con preguntas sobre montos de ingreso. En la EPS, las preguntas de ingresos se hacen en formato abierto, es decir, se pregunta directamente por el monto (ej. Cuál fue su ingreso líquido el mes pasado?). Para reducir la no respuesta, una de las estrategias utilizadas en la EPS consiste en reducir la demanda cognitiva del reporte (mecanismo #2 arriba) a través del uso de una pregunta de seguimiento sobre tramos de ingreso (ej. menos de 50.000? Entre 50.000 – 99.999? etc) que se aplica a quienes declaran no saber/no responden la pregunta directa de montos.

Tabla 3.1. Porcentaje de no respuesta al ítem, variables seleccionadas de la EPS 2015.

Ítem	tipo	Nombre variable	Sub poblacion	n miss	% miss
Preguntas sobre montos					
monto ing hogar (mensual)	Continua	c34	16.906	2825	16,71%
monto ing laboral (mensual)	Continua	ytrab	9.009	761	8,45%
monto alquiler vivienda (mensual)	Continua	NRalq	16.906	2876	17,02%
Preguntas sobre tramos					
tramo ing laboral (mensual)	Categórica	ytrabt	9.009	53	0,59%
tramo alquiler vivienda (mensual)	Categórica	NRalqt	16.906	466	2,76%
Preguntas sociodemográficas					
tramo educacional	Categórica	teduc	16.906	363	2,15%
años escolaridad	Continua	esc	16.906	132	0,78%
estado de salud	Categórica	a10	16.906	22	0,13%
trabajo permanente	Binaria	b6	9.037	7	0,08%
boletas trabajo	Binaria	b11	8.986	31	0,34%
parentesco	Categórica	a5	16.906	6	0,04%
etnia	Categórica	a10b	16.906	172	1,02%
categoría ocupacional	Categórica	b8	9.037	0	0,00%
sexo	Binaria	a8	16.906	0	0,00%
edad	Continua	a9	16.906	0	0,00%
region	Categórica	region	16.906	0	0,00%

Fuente: Elaboración propia.

Tabla 3.2. Tasas de respuesta a preguntas de ingreso en varios estudios.

Nombre del estudio	Tasas de no respuesta al ítem		Modo recolección datos	Tipo de pregunta
	Monto Ingreso	Tramo Ingreso		
CPS marzo 1990	18,4%	No reportado	En persona y Teléfono	Pregunta monto, varios tipos de ingreso
CPS marzo 1996	12,2%	No reportado	En persona y Teléfono	Pregunta monto, varios tipos de ingreso
CPS Marzo 2000	27,2%	No reportado	En persona y Teléfono	Pregunta monto, varios tipos de ingreso
CPS 2002-2003	14,2%		En persona y Teléfono	Pregunta monto, varios tipos de ingreso
NIS 4/97-1/98	17,1%	14,2%	Teléfono	Pregunta monto, Pregunta Tramo (NS/NR)
NIS 2/98-3/98	32,0%	13,9%	Teléfono	Pregunta monto, Pregunta Tramo (NS/NR)
NIS 2000	27,8%	14,2%	Teléfono	Pregunta monto, Pregunta Tramo (NS/NR)
CEQ 2002-2003	19,9%		En persona	Pregunta monto, Pregunta Tramo (NS/NR)
CEQ 2003	35,0%	19,0%	En persona	Pregunta monto, Pregunta Tramo (NS/NR)

Notas: CPS=Current Population Survey; NIS= National Immunization Survey; CEQ=Consumer Expenditure Quarterly Survey. Fuente: Yang *et al.* (2010).

3.3 Descripción de variables con datos perdidos a imputar

Lo que sigue de este informe se concentra en el análisis de tres variables – el monto (YTRAB) y tramos (YTRABT) de ingresos del trabajo, el monto (ALQ) y tramos (ALQT) de alquiler de vivienda, y los tramos de nivel educacional (TEDUC). Las estadísticas descriptivas de las variables a analizar y las originales se presentan en las Tablas 3.3 y 3.6 respectivamente.

La variable original “b12”, monto de ingresos laborales, se aplicó solo a quienes trabajan remuneradamente (n=9.009). En base a ella se crearon dos variables para estos análisis (ver en Tabla 3.4):

- La variable **YTRAB** es igual a b12 en los montos mayores a \$0. Los 761 casos asociados a No sabe (=8) y No responde (=9) en b12 se codificaron como perdidos (=.) en YTRAB. Los 7.897 casos perdidos originales, que corresponden a quienes no trabajan o trabajan sin remuneración y no se les hace esta pregunta, se mantienen como datos perdidos (=.). Así, YTRAB es una variable continua con 8248 observaciones válidas que van desde \$10.000 hasta \$9.000.000 y con media \$422.894.
- La variable **YTRAB0** es igual a YTRAB, pero se asignó valor \$0 a los 7.897 casos con datos perdidos en b12 (que corresponden a las personas que no trabajan remuneradamente). Así, YTRAB es una variable continua con 16.145 valores válidos que van desde \$0 hasta \$9.000.000 con media \$216.044.

La variable original “b12t”, tramo de ingresos laborales, se aplicó solo a las 761 personas que respondieron No Sabe o No responde en monto de ingresos laborales (b12) lo cual genera 8.248 datos perdidos (=.) para las personas que reportaron montos válidos de ingreso en b12. En base a b12t se crearon dos variables para estos análisis (ver en Tabla 3.4):

- La variable **YTRABT** se genera sobre la base de b12t, pero reemplaza los “datos perdidos” de b12t por tramos válidos a todas las personas que reportaron montos de ingresos en b12. Por ejemplo, a las personas que reportaron percibir \$450.000 de ingresos laborales en b12 se les asignó el tramo 6 “De \$ 400.001 a \$ 500.000” en YTRABT. Los 53 casos asociados a No sabe (=88) y No responde (=99) en b12t, sin embargo, se codificaron como perdidos (=.) ya que representan rechazos efectivos a responder la pregunta de tramos de ingresos. Los 7.897 casos perdidos originales, que corresponden a quienes no trabajan o trabajan sin remuneración y no se les hace esta pregunta, se mantienen como datos perdidos (=.) Así, YTRABT es una variable de 12 categorías, con 8.956 casos válidos, que van desde “Menos o igual a \$50.000” a “Más de \$1.000.000”.
- La variable **YTRABT0** es igual a YTRABT, pero se asignó el tramo 0 a los 7.897 casos con datos perdidos en b12t que corresponden a las personas que no trabajan remuneradamente. Así, YTRABT es una variable categórica de 13 categorías, con 16.853 casos válidos, que van desde “0” a “Más de \$1.000.000”.

La variable original d8⁸, monto efectivo/estimado del valor del alquiler de la residencia, se aplica a todas las personas (n=16.906). A partir de ella se creó la variable ALQ (ver en Tabla 3.5):

- La variable **ALQ** es prácticamente igual a d8 en los montos mayores a \$0. Se codificaron como perdidos (=.) los 1.886 casos que respondieron No sabe (=8), los 517 que No responde (=9) y los 441 casos que reportaron como valor "\$0". También se asignó código de perdido (=.) a los 8 casos con valores menores a \$10.000 y los 26 casos mayores a \$10.000.000. Los valores \$0 reportados se dejaron como perdidos para imputación, ya que se espera contar con un estimado del valor de arriendo de la residencia, y estos son por definición mayores a \$0. Los valores extremadamente pequeños o grandes de arriendo pueden ser reales o bien error en el registro de la información. Se revisó la distribución de variable arriendo estimado en la Encuesta Casen 2015 (v22⁹) y se determinó editar a "perdidos" los valores extremos reportados en EPS 2015 que van más allá de los observados en Casen 2015. Así, ALQ es una variable continua con 14.028 valores válidos que van desde \$10.000 hasta \$5.000.000 con media \$ 184.796.

La variable original d8t, tramo del valor del alquiler de la residencia, se aplicó solo a las 2.403 personas que respondieron No Sabe o No responde en monto de arriendo imputado (d8) lo cual genera 14.503 datos perdidos (=.) para las personas que reportaron montos válidos de alquiler en d8. A partir de d8t se creó la variable ALQT (ver en Tabla 3.5):

- La variable **ALQT** se genera sobre la base de d8t, pero reemplaza los 14.503 "datos perdidos" de d8t por tramos válidos para todas las personas que reportaron montos de arriendo en d8. Por ejemplo, a las personas que reportaron alquiler por \$130.000 en d8 se les asignó el tramo 3 "De \$ 100.001 a \$ 200.000" en ALQT. Los 25 casos asociados a No sabe (=88) y No responde (=99) en d8t, sin embargo, se codificaron como perdidos (=.) ya que representan rechazos efectivos a responder la pregunta de tramos de alquiler. También se codificaron como perdidos los 34 outliers (valores extremos altos y bajos) y los 441 casos que reportaron arriendo por valor \$0. Así, ALQT es una variable categórica de 13 categorías, con 16.406 casos válidos, que van desde "Menos o igual a \$15.000" a "Más de \$220.000".

La variable **TEDUC** se aplicó a todas las personas (n=16.906). Esta es una variable categórica y sus 8 categorías se construyen a partir de las preguntas asociadas al nivel de educación (a12n) y el último curso aprobado (a12c). Los 363 casos perdidos (=.) se generaron en forma automática debido a los códigos asociados a No sabe (=8) y No responde (=9) de las variables de origen (a12n, a12c). Ver en Tabla 3.6.

⁸ La pregunta d8 en la EPS 2015 es "Aproximadamente, cuánto paga (o tendría que pagar) al mes por el arriendo de esta vivienda o pieza?"

⁹ La pregunta v22 en la encuesta Casen 2015 es "Cuanto se paga de arriendo en este sector por viviendas similares a la suya?". El fraseo de la pregunta Casen 2015 no es igual al de EPS 2015, pero ambas buscan recolectar la misma información - el monto mensual estimado de arriendo del lugar de residencia del entrevistado. Hasta el año 2009, el fraseo de Casen era similar al de la EPS, sin embargo dada la gran cantidad de datos perdidos en esta pregunta se modificó el fraseo a la versión actual con el objetivo de aclarar mejor el significado y reducir la no respuesta a este ítem.

Tabla 3.3. Estadísticas descriptivas de variables originales y creadas para análisis de educación, ingreso laboral y alquiler imputado. ESP 2015.

Variable	Obs	Mean	Std. Dev.	Min	Max
b12	9,009	387172.7	439300.2	8	9000000
ytrab	8,248	422894.3	442362.4	10000	9000000
ytrab0	16,145	216044.1	380335.4	0	9000000
b12t	761	11.11695	21.24211	1	88
ytrabt	8,956	5.183452	2.443729	1	12
ytrabt0	16,853	2.754584	3.140746	0	12
d8	16,906	227989.7	2780458	0	2.50e+08
alq	14,028	184796.6	198257.5	10000	5000000
d8t	2,403	8.726176	9.812264	1	99
alqt	16,406	9.476228	3.135566	1	13
teduc	16,543	4.707913	1.785577	1	8

Tabla 3.4. Variable original y creadas para análisis de ingresos del trabajo, EPS 2015.

Monto de ingresos del trabajo	B12	YTRAB	YTRAB0
Igual a \$0	0	0	7.897
Mayor a \$0	8.248	8.248	8.248
No sabe / No responde	761	0	0
Perdidos (".")	7.897	8.658	761
Total	16.906	16.906	16.906
Tramo de ingresos del trabajo	B12T	YTRABT	YTRABT0
Tramo 0 (= \$0)	0	0	7.897
Tramos 1 a 12 (<=\$50.000 a >=\$1.000.000)	708	8.956	8.956
No sabe / No responde	53	0	0
Perdidos (".")	16.145	7.950	53
Total	16.906	16.906	16.906

Tabla 3.5. Variable original y creadas para análisis de alquiler imputado, EPS 2015.

Monto de alquiler imputado	D8	ALQ
Igual a \$0	441	0
Mayor a \$0	14.062	14.028
No sabe / No responde	2.403	0
Perdidos (".")	0	2.878
Total	16.906	16.906
Tramo de alquiler imputado	D8T	ALQT
Tramo 0 (= \$0)	0	0
Tramos 1 a 13 (<=\$15.000 a >=\$220.000)	2.378	16.406
No sabe / No responde	25	0
Perdidos (".")	14.503	500
Total	16.906	16.906

Tabla 3.6. Distribución de variables categóricas originales de ingreso laboral, alquiler imputado y tramos de nivel educacional, sin ponderar, EPS 2015.

// A. Distribución de variable creada TEDUC, nivel de educación en tramos.

TEDUC	Freq.	Percent	Cum.
Ninguna	296	1.75	1.75
BasicaInc	2,288	13.53	15.28
BasicaCom	1,719	10.17	25.45
MediaInc	2,427	14.36	39.81
MediaCom	4,761	28.16	67.97
TecnicaSup	2,214	13.10	81.07
UnivInc	1,647	9.74	90.81
UnivCom	1,191	7.04	97.85
NS/NR	363	2.15	100.00
Total	16,906	100.00	

// B. Distribución de variable original b12t, tramo de ingreso laboral.

B12T	Freq.	Percent	Cum.
Menos o igual a \$ 50.000	56	0.33	0.33
De \$ 50.001 a \$ 100.000	49	0.29	0.62
De \$ 100.001 a \$ 200.000	80	0.47	1.09
De \$ 200.001 a \$ 300.000	136	0.80	1.90
De \$ 300.001 a \$ 400.000	115	0.68	2.58
De \$ 400.001 a \$ 500.000	77	0.46	3.03
De \$ 500.001 a \$ 600.000	53	0.31	3.35
De \$ 600.001 a \$ 700.000	28	0.17	3.51
De \$ 700.001 a \$ 800.000	30	0.18	3.69
De \$ 800.001 a \$ 900.000	18	0.11	3.80
De \$ 900.001 a 1.000.000	16	0.09	3.89
Mas de \$ 1.000.000	50	0.30	4.19
No responde	53	0.31	4.50
.	16,145	95.50	100.00
Total	16,906	100.00	

// C. Distribución de variable original D8T, tramo de alquiler imputado.

D8T	Freq.	Percent	Cum.
Menos o igual a \$15.000	302	1.79	1.79
De \$15.001 a \$ 30.000	58	0.34	2.13
De \$30.001 a \$ 40.000	72	0.43	2.56
De \$40.001 a \$ 50.000	98	0.58	3.13
De \$50.001 a \$ 60.000	137	0.81	3.95
De \$ 60.001 a \$ 80.000	196	1.16	5.10
De \$80.001 a \$ 90.000	135	0.80	5.90
De \$90.001 a \$100.000	201	1.19	7.09
De \$100.001 a \$120.000	267	1.58	8.67
De \$120.001 a \$150.000	204	1.21	9.88
De \$150.001 a \$180.000	174	1.03	10.91
De \$180.001 a \$220.000	179	1.06	11.97
Mas de \$220.000	355	2.10	14.07
No responde	6	0.04	14.10
No sabe	19	0.11	14.21
.	14,503	85.79	100.00
Total	16,906	100.00	

Fuente: Elaboración propia.

3.4 Patrones de No respuesta al Ítem

Un primer análisis útil realizar es identificar los patrones de datos perdidos. Las Tablas 3.7 y 3.8 presentan los patrones de no respuesta para las variables TEDUC, YTRAB0¹⁰ y ALQ, donde "1" representa casos completos y "0" representa datos perdidos para cada variable.

La Tabla 3.7 presenta en patrón de datos perdidos para las variables originales de ingreso laboral y alquiler, ignorando el hecho de que se dispone de las variables auxiliares de tramo para asistir en la recuperación de los datos perdidos de estas variables. Como se puede observar en la primera línea de la Tabla 3.7 hay 13.337 observaciones con casos completos para las tres variables (patrón "1 1 1"), lo que corresponde al 79% de los datos. Este resultado es preocupante ya que, por ejemplo, si se quisiera hacer un análisis de regresión multivariada de arriendo imputado (ALQ) sobre ingreso laboral (YTRAB0) y nivel de educación (TEDUC) se perdería el 21% de los datos al no contarse con datos completos para alguna de las tres variables. El patrón de no respuesta más severo es cuando falta el alquiler (2.649 perdidos). El patrón general de pérdida de las tres variables es aleatorio, ya que no se puede clasificar como monótono o univariado.

La EPS implementa, sin embargo, una estrategia para recuperar los caso perdidos en las preguntas sobre montos que consiste en aplicar una pregunta sobre tramos. La Tabla 3.8 presenta el patrón de datos perdidos para las tres variables considerando que se utiliza la información en las variables de tramo para imputar los datos perdidos de ingresos laborales y alquiler. Como se puede observar, el total de casos completos sube a 16.004 para el patrón "1 1 1", lo que corresponde a un 95% de los datos. En este escenario, el análisis de regresión mutlivariada planteado anteriormente tendría un 5% de datos perdidos. En este escenario, los patrones de datos faltantes más severos se dan cuando falta el alquiler (488 casos) y el nivel educacional (350 casos).

Las variables sobre tramos tienen potencial para ayudar a recuperar parte importante de la información que se pierde en las preguntas sobre montos de ingreso laboral y alquiler. Las Tablas 3.9 y 3.10 presentan los patrones de respuesta para las preguntas de monto y tramos de ingreso laboral y alquiler respectivamente. La Tabla 3.9 presenta resultados para las 9.009 personas que trabajan por remuneración. Se puede observar que 761 personas no respondieron la pregunta de montos y de ellas 53 no respondieron la pregunta sobre tramos de ingreso. La Tabla 3.10 presenta resultados para todas las personas. Se puede observar que 2.378 personas no tienen valores válidos de montos y de ellas 500 tampoco tienen respuestas válidas de tramos de alquiler. Como se puede verificar, el patrón general de pérdida para ambos sets de variables es monótono *por diseño*, ya que solo se aplican las preguntas de tramos a quienes declaran "No Sabe" o "No Responde" la pregunta de montos.

Estos resultados tienen implicancias en los métodos de imputación a considerar. Los patrones monótonos, por ejemplo, pueden ser tratados con imputaciones secuenciales condicionales independientes, mientras que el patrón aleatorio requiere recursividad y

¹⁰ Se usa YTRAB0, en vez de YTRAB, para consignar con "0" los casos que no trabajan - de esta forma no se contabilizan los casos perdidos "por diseño" como casos perdidos por "no respuesta".

dependencia de las imputaciones, o bien de un modelo multivariado que explique su distribución conjunta.

Tabla 3.7. Patrones de datos perdidos para variables TEDUC, YTRAB0, ALQ. Todas las personas.

Variable	type	obs	mv	variable label
teduc	float	16543	363	Nivel Educacional - Categorica
ytrab0	float	16145	761	Monto Ingreso Laboral - Original con 0's
alq	float	14028	2878	Alquiler efectivo o imputado
Missing-value patterns(1 means complete)				
Frequency	Pattern	1	2	3
13,337	1	1	1	
2,469	1	1	0	
445	1	0	1	
292	1	0	0	
234	0	1	1	
105	0	1	0	
12	0	0	0	
12	0	0	1	
16,906				
Variables are (1) teduc (2) ytrab0 (3) alq				

Tabla 3.8. Patrones de datos perdidos para variables TEDUC, YTRABT0, ALQT. Todas las personas.

Variable	type	obs	mv	variable label
teduc	float	16543	363	Nivel Educacional - Categorica
ytrabt0	float	16853	53	Tramo Ingreso Laboral - Original con 0's
alqt	float	16406	500	Tramo de Alquiler efectivo o imputado
Missing-value patterns(1 means complete)				
Frequency	Pattern	1	2	3
16,004	1	1	1	
488	1	1	0	
350	1	0	1	
51	0	1	1	
11	1	0	0	
1	0	0	0	
1	0	0	1	
16,906				
Variables are (1) ytrabt0 (2) teduc (3) alqt				

Tabla 3.9. Patrones de datos perdidos para variables YTRAB, YTRABT0. Solo personas que trabajan remuneradamente.

Variable	type	obs	mv	variable label
ytrab	float	8248	761	Monto Ingreso Laboral - Original
ytrabt	float	8956	53	Tramo Ingreso Laboral - Original
Missing-value patterns (1 means complete)				
	Frequency	Pattern		
		1	2	
	8,248	1	1	
	708	1	0	
	53	0	0	
	9,009			
Variables are (1) ytrabt (2) ytrab				

Tabla 3.10. Patrones de datos perdidos para variables ALQ, ALQT. Todas las personas.

Variable	type	obs	mv	variable label
alq	float	14028	2878	Alquiler efectivo o imputado
alqt	float	16406	500	Tramo de Alquiler efectivo o imputado
Missing-value patterns (1 means complete)				
	Frequency	Pattern		
		1	2	
	14,028	1	1	
	2,378	1	0	
	500	0	0	
	16,906			
Variables are (1) alqt (2) alq				

3.5 Mecanismos de No Respuesta al Ítem

Según la teoría, la estrategia de imputar los datos perdidos solo es capaz de corregir los sesgos de no respuesta cuando el mecanismo que subyace al fenómeno de datos perdidos es Missing at Random (MAR). Una forma de cotejar la plausibilidad del supuesto de MAR es verificar si el indicador del patrón de no respuesta está asociado con variables (mecanismos) observadas en la base de datos.

Los indicadores de no respuesta de las variables de educación, ingreso y alquiler se denominan NRteduc, NRYtrab y NRalq respectivamente, donde "1"=dato perdido, "0"=dato válido y "."=no aplica. La Tabla 3.11 presenta las estadísticas descriptivas de los indicadores de no respuesta. La Tabla 3.12 presenta la distribución del porcentaje de no respuesta según variables observadas que se sospecha están relacionadas con el patrón de no respuesta para cada uno de los ítems. Como se puede observar, varias de las variables

examinadas están asociadas al patrón de respuesta de manera estadísticamente significativa al 95% de confianza (ver Test F en tabla):

- Personas de mayor edad, jefes de hogar, identificados con alguna etnia, que no trabajan, que declaran mala salud y que residen en la zona norte tienen más probabilidad de no responder las preguntas de nivel educacional.
- Personas de mayor edad, que son jefes de hogar y que residen en las regiones del norte del país tienen más probabilidad de no responder la pregunta de monto ingreso laboral.
- Personas jóvenes y de mayor edad, identificados con alguna etnia, que no trabajan, que declaran mala salud, que residen en la zona norte tienen más probabilidad de no responder las preguntas de monto de alquiler. Mientras que personas que viven en departamento o en viviendas arrendadas tienen menor probabilidad de responder las preguntas de monto de alquiler.

Estos resultados son parcialmente consistentes con la literatura, donde variables como la edad, el sexo, la educación y la raza han mostrado influencia en la probabilidad de que los entrevistados entreguen datos perdidos en preguntas de encuestas (Bell, 1994; Craig y McCann, 1978; Ferber, 1996; Riphahan y Serfling, 2005).

Tabla 3.11. Estadísticas descriptivas de variables indicadoras del patrón de no respuesta de las variables de educación, ingreso laboral y alquiler imputado. ESP 2015.

Variable	Obs	Mean	Std. Dev.	Min	Max
NRteduc	16,906	.0214717	.1449547	0	1
NRytrab	9,009	.0844711	.2781084	0	1
NRalq	16,906	.1702354	.3758506	0	1

Tabla 3.12. Porcentaje de no respuesta al ítem, según variables observadas en EPS 2015.

ítem	categorías	TEDUC		YTRAB		ALQ	
		% perdidos	Test F (pvalue)	% perdidos	Test F (pvalue)	% perdidos	Test F (pvalue)
Todos		2,15%		8,45%		17,02%	
edad	15-24	0,87%	80,68	5,9%	54,32	18,6%	125,96
	25-34	1,49%	0,0000	7,1%	0,0000	14,4%	0,0000
	35-44	1,65%		9,1%		13,2%	
	45-54	2,84%		9,4%		14,2%	
	55-64	3,19%		9,0%		17,1%	
	65+	3,46%		15,4%		22,9%	
sexo	Hombre	2,14%	0,01	8,9%	3,14	17,5%	2,05
	Mujer	2,16%	0,9218	7,8%	0,0764	16,6%	0,1523
etnia	no	1,94%	32,72	8,4%	0,75	16,7%	14,89
	si	4,14%	0,0000	9,2%	0,3872	20,5%	0,0001
jefe hogar	no	1,26%	64,91	7,3%	11,43	17,4%	1,39
	si	3,05%	0,0000	9,3%	0,0007	16,7%	0,2391
trabaja	no	2,39%	4,10	na	na	20,3%	109,80
	si	1,94%	0,0428	8,4%		14,2%	0,0000
salud	regular a mala	2,87%	22,45	7,5%	3,65	18,4%	12,39
	buena a excelente	1,76%	0,0000	8,8%	0,0560	16,3%	0,0004
macrozona	Centro	1,52%	135,15	6,9%	19,23	15,6%	190,41
	Norte	5,44%	0,0000	11,3%	0,0002	24,5%	0,0000
	RM	1,55%		8,1%		13,0%	
	Sur	1,88%		8,9%		19,9%	
Tipo vivienda	Pieza	1,6%	5,22	4,4%	10,15	18,1%	25,80
	Casa	2,2%	0,0735	8,7%	0,0062	17,4%	0,0000
	Departamento	1,3%		8,1%		11,4%	
Situación de ocupación de la vivienda	Otro	2,2%	5,21	7,3%	5,43	18,7%	190,09
	Arrendada	1,4%	0,0737	7,9%	0,0661	5,6%	0,0000
	propia	2,3%		8,9%		18,3%	
n		16.906		9.009		16.906	

3.6 Conclusión análisis de No Respuesta al Ítem

Los análisis del porcentaje y el mecanismo de no respuesta permiten informar la decisión de implementar o no alguna estrategia de imputación de datos para tratar el problema de los datos perdidos en la EPS 2015.

Si el porcentaje de datos perdidos es relativamente pequeño, de 1-2%, la recomendación más común en la literatura es no hacer nada ya que la baja incidencia del problema hace contraproducente el esfuerzo necesario (de desarrollar modelos de imputación) para corregirlo. Las variables TEDUC, YTRAB y ALQ presentan porcentajes de datos perdidos de 2,15%, 8,45% y 17% respectivamente, lo cual sugiere que sería adecuado implementar alguna estrategia de imputación.

El análisis del mecanismo de no respuesta también permite informar la decisión acerca de imputar o no. Si el mecanismo de no respuesta es completamente aleatoria (MCAR), entonces el riesgo de *sesgo* de no respuesta es relativamente menor, aunque si el porcentaje de no respuesta es elevado de todas formas se pierde *precisión* de las estimaciones debido a la disminución del tamaño muestral. Si el mecanismo de no respuesta es aleatorio (MAR), es decir depende de observables, entonces es recomendable imputar condicionando en los predictores del patrón de no respuesta. El supuesto de MCAR se considera muy fuerte y difícil de sostener. Para evaluar el supuesto de MAR se testeó la evidencia de asociación entre cada uno de los indicadores de no respuesta y un set de variables observadas. Los resultados de este análisis en esta sección permiten rechazar la hipótesis “perdidos completamente al azar” (MCAR) para las variables TEDUC, YTRAB y ALQ ya que se identifican varias variables asociadas al patrón de no respuesta. Esto significa que se descarta la opción de realizar análisis de casos completos con las variables TEDUC, YTRAB y ALQ.

Dado que la no respuesta en TEDUC, YTRAB y ALQ está, al menos, asociada a los observables que se presentan en la Tabla 3.12, se asumirá para efectos de este informe que la no respuesta es MAR – perdidos al azar. Bajo este escenario tiene sentido evaluar distintos métodos de imputación para tratar de corregir, aunque sea parcialmente, el sesgo asociado a la no respuesta en estos ítems.

En atención a los resultados del análisis de los patrones de no respuesta, que confirman el patrón monótono de pérdida de datos entre YTRA e YTRABT y entre ALQ y ALQT, se procederá a imputar primero las variables de montos (YTRAB, ALQ) a partir de las variables de tramos (YTRABT, ALQT). A continuación se procederá a imputar la variable TEDUC y lo que quede de imputar en las variables YTRAB y ALQ. La sección que sigue describe las distintas variantes de las metodologías de imputación evaluadas en la EPS 2015.

4 Métodos de Imputación aplicados en EPS 2015

Las variables focales de interés para esta investigación son las variables tramo de nivel educacional (TEDUC), el monto de ingreso laboral (YTRAB) y el monto de alquiler imputado (ALQ). Estas variables tienen particularidades que las hacen ejemplos interesantes para este primer análisis de las imputaciones en la EPS.

- La información auxiliar contenida en los datos históricos puede ser de gran ayuda para el proceso de imputación de esta y otras variables de similar estabilidad en el tiempo. Para las personas que han sido entrevistadas en rondas anteriores del panel EPS, se hará uso de información histórica acerca de TEDUC para imputar los datos perdidos en TEDUC de la ronda 2015. Esto es posible bajo el supuesto de que el nivel de educación alcanzado es una característica de los entrevistados que no debiera variar mucho en el tiempo, o si lo hace debiera ser en forma ascendente (y no descendiente o errática). A quienes no cumplan con las condiciones para el uso de información histórica, y a quienes participen por primera vez en el estudio, se les aplicará otro método de imputación. La Figura 4.1 ilustra este procedimiento.
- Las variables YTRAB y ALQ cuentan con información auxiliar relevante recolectada en la misma ronda 2015 - la información acerca de tramos que reportan los entrevistados que No saben o No responden la pregunta sobre ingreso laboral o alquiler imputado respectivamente. Dado que el patrón de no respuesta de las variables monto y tramo es monótono por diseño, se procederá a imputar primero los tramos y a continuación los montos. La Figura 4.2 ilustra este procedimiento para las variables YTRABT e YTRAB. El mismo procedimiento se sigue para las variables ALQ y ALQT.

Para las variables YTRAB y ALQ se aplicaron dos métodos distintos de imputación con algunas variantes: (1) método de media condicionada y (2) método hot deck aleatorio estratificado. Para la imputación de TEDUC se aplicaron tres métodos distintos con algunas variantes: (1) método de mediana condicionada, (2) método hot deck aleatorio estratificado, y (3) método cold deck.

La sección que sigue describe en mayor detalle los métodos implementados para cada una de las estrategias de imputación y sus variantes. Algunas características generales a las estrategias de imputación implementadas:

1. Las variables TEDUC, YTRAB y ALQ se imputaron en forma independiente (imputación *univariada*, no *multivariada*);
2. Se realizó un único ciclo de imputaciones para cada método (imputación *simple*, no *múltiple*);
3. Todas las variables auxiliares utilizadas para imputar corresponden a variables observadas en la ronda actual de la EPS (imputación de *corte transversal*, no *longitudinal*).

Figura 4.1. Diagrama de proceso de imputación MIXTO de variable tramos de nivel educativo (TEDUC) en la EPS 2015.





Figura 4.2. Diagrama del procedimiento de imputación de la variable YTRAB en la EPS 2015.



4.1 Imputación por medias condicionadas

El método de imputación conocido como medias/medianas condicionadas consiste en dividir la muestra total en clases (celdas) de acuerdo a los valores de las variables auxiliares utilizadas para la imputación. En cada clase/celda de imputación se asigna la media/mediana de los que responden a todos los casos perdidos en la misma celda (Kalton y Kasprzyk, 1986).

En esta investigación se utilizó la mediana para la variable categórica TEDUC y la media para las variables continuas YTRAB y ALQ. Para comparar alternativas se crearon 4 celdas de ajuste para las imputaciones de TEDUC y 7 celdas para las imputaciones de YTRAB y ALQ. La Tabla 4 presenta las especificaciones para cada celda y variable a imputar, las cuales representan opciones típicamente utilizadas en la literatura y en la práctica para la imputación de datos perdidos:

- La "Celda 0", por ejemplo, corresponde a la opción más básica que consiste en calcular la media (o mediana) en la muestra completa - sin particiones (= 1 celda) – para luego imputar ese único valor estimado a todos los casos con datos perdidos.
- La "Celda 1" corresponde a la opción demográfica básica que consiste en calcular la media (mediana) en cada una de las 12 particiones de la muestra que vienen dados por el cruce de las categorías de sexo y edad definidas. A continuación se imputa el valor que corresponda a cada caso perdido según su clasificación demográfica de sexo y edad correspondiente. Dado que estas variables demográficas están usualmente relacionadas con muchos fenómenos de interés medido en las encuestas, la configuración de la Celda 1 tiene la ventaja de que puede ser utilizada para imputar a muchas variables de interés.
- La "Celda 2" se genera a partir de los ventiles de la predicción de la probabilidad de responder el ítem de interés. Este método, conocido como estratificación en la probabilidad de responder (*response propensity stratification*) consiste en estimar la probabilidad de responder de cada persona, $p(x)$, a partir de la regresión del indicador de respuesta en las covariables x , para luego crear celdas (estratos) homogéneas en la probabilidad de responder (Little, 1986). La predicción de la probabilidad de responder (el *propensity score*, $\hat{p}(x)$) se puede calcular para todas las personas y es en sí mismo una medida de distancia. En esta aplicación se incluyen tres tipos de predictores en el modelo: (1) predictores de la probabilidad de responder el ítem analizado; (2) variables que reflejan el diseño muestral complejo de la EPS; y (3) variables que reflejan dominios de interés para publicación de resultados EPS.
- La "Celda 3" se genera a partir de los ventiles de la predicción lineal del ítem de interés. Este método, conocido como *predictive mean metric*, consiste en estimar la predicción lineal, $x_i^T \hat{\beta}$, del valor del ítem y , para la persona i que no responde, a partir de la regresión de y en x que utiliza solo los datos de los que responden. En la literatura, la estratificación via medias predictivas o la propensión a responder han sido comparadas en el contexto del método hot-deck (Haziza y Beaumont, 2007) y del método de medias condicionadas (Little, 1986). En ambos contextos se ha

demostrado que cualquier de las dos métricas puede ser utilizada para reducir el sesgo de no respuesta, sin embargo solo la métrica de la media predictiva tiene el potencial de reducir además la varianza (Andridge y Little, 2010). En esta aplicación se incluyen tres tipos de predictores en el modelo: (1) predictores del ítem analizado; (2) variables que reflejan el diseño muestral complejo de la EPS; y (3) variables que reflejan dominios de interés para publicación de resultados EPS.

- Las Celdas “4”, “5” y “6” se generaron para la imputación de YTRAB. La Celda 4 corresponde a los 12 tramos de ingreso de la variable YTRABT. La Celda 5 corresponde a la clasificación cruzada de 8 tramos de ingreso y los quintiles de la misma propensión a responder estimada para la Celda 2, lo que termina generando 40 celdas de ajuste. La Celda 6 corresponde a la clasificación cruzada de 8 tramos de ingreso y los quintiles de la misma predicción lineal estimada para la celda 3, lo que termina generando 40 celdas de ajuste.
- La Celda “7” se genera a partir de la clasificación cruzada del tipo de vivienda (3 categorías) y el número de piezas de la vivienda (5 categorías), lo que genera 15 celdas de ajuste para el análisis de la variable ALQ.
- Las Celdas “8”, “9” y “10” se generaron para la imputación de ALQ. La Celda 8 corresponde a los 13 tramos de alquiler de la variable ALQT. La Celda 9 corresponde a la clasificación cruzada de 9 tramos de alquiler y los quintiles de la misma propensión a responder estimada para la variable ALQ, lo que termina generando 45 celdas de ajuste. La Celda 10 corresponde a la clasificación cruzada de 9 tramos de ingreso y los quintiles de la misma predicción lineal estimada para ALQ, lo que termina generando 45 celdas de ajuste.

Las variables que caracterizan el diseño muestral de la EPS, como el factor de expansión, el tipo de afiliado y el tipo de muestra, se incluyeron como covariables en los modelos de la probabilidad de responder y la media predictiva. También se incluyeron variables que identifican dominios de interés de la EPS, como las subpoblaciones dadas por sexo, edad y situación ocupacional. Esta lista no es exhaustiva, pero de todas maneras sirve para hacer el punto de que es útil incorporar a los modelos de imputación variables utilizadas en los análisis planeados de la encuesta.

Tabla 4. Definición de la composición de las celdas de ajuste utilizadas en el procedimiento de imputación por medias/medianas condicionadas y hot deck aleatorio estratificado.

Nombre	Número de celdas	Variables incluidas en imputaciones TEDUC	Variables incluidas en imputaciones YTRAB	Variables incluidas en imputaciones ALQ
Celda 0	1	Constante=1	Constante=1	Constante=1
Celda 1	12	Sexo (2 categorías) * Edad (6 categorías)	Sexo (2 categorías) * Edad (6 categorías)	--
Celda 2	20	Ventiles de la probabilidad de responder al ítem, según edad (continua), etnia (binaria), jefe de hogar (binaria), ocupado (binaria), salud (binaria), macrozona (4 categorías)	Ventiles de la probabilidad de responder al ítem, según edad (continua), jefe de hogar (binaria), asalariado (binaria), macrozona (4 categorías)	Ventiles de la probabilidad de responder al ítem, según edad (continua), jefe de hogar (binaria), asalariado (binaria), macrozona (4 categorías)
Celda 3	20	Ventiles de la predicción lineal del ítem, según edad (continua), edad al cuadrado (continua), jefe de hogar (binaria), ocupado (binaria), salud (binaria), macrozona (4 categorías) , factor_EPS2015, tipomuestra, afiliado, etc.	Ventiles de la predicción lineal del ítem, según edad, nivel educacional (12 categorías), jefe de hogar (binaria), sexo (binaria), etnia (binaria), asalariado (binaria), salud (binaria), macrozona (4 categorías), factor_EPS2015, tipomuestra, afiliado, etc.	Ventiles de la predicción lineal del ítem, según edad (continua), edad al cuadrado (continua), nivel educacional (12 categorías), jefe de hogar (binaria), sexo (binaria), etnia (binaria), asalariado (binaria), salud (binaria), macrozona (4 categorías) , factor_EPS2015, tipomuestra, afiliado, etc.
Celda 4	12	--	Tramos de ingreso (12 categorías)	--
Celda 5	40	--	Tramos de ingreso (8 categorías) * Quintiles PScore (5 categorías)	--
Celda 6	40	--	Tramos de ingreso (8 categorías) * Quintiles PredMean (5 categorías)	--
Celda 7	15	--	--	Tipo de vivienda (3 categorías) * Número de Piezas (5 categorías)
Celda 8	9	--	--	Tramos de alquiler (9 categorías)
Celda 9	45	--	--	Tramos de alquiler (9 categorías) * Quintiles PScore (5 categorías)
Celda 10	45	--	--	Tramos de alquiler (9 categorías) * Quintiles PredMean (5 categorías)

4.2 Imputación Hot Deck

El procedimiento de imputación no paramétrico denominado *hot-deck* fue desarrollado con el propósito de preservar la distribución de probabilidad de las variables con datos incompletos (Madow, Nisselson y Olkin, 1983). El método tiene como objetivo llenar los registros vacíos (receptores) con información de campos con información completa (donantes), y los datos faltantes se reemplazan a partir de una selección aleatoria de valores observados, lo cual no introduce sesgos en la varianza del estimador. Históricamente, el nombre del método viene del uso de tarjetas perforadas para almacenar información en los computadores antiguos. El término “deck” hace referencia a la baraja de tarjetas de información donante disponible para un non-respondent, y el término “hot” hace referencia a que la baraja está caliente pues actualmente está siendo procesada; ésta característica, contrasta con el método cold-deck donde se utiliza información procesada anteriormente como donante (ejemplo, datos de la ronda anterior de una encuesta longitudinal).

El algoritmo consiste en ubicar registros completos e incompletos, identificar características comunes de donantes y receptores, y decidir los valores que se utilizarán para imputar los datos omitidos. Para la aplicación del procedimiento es fundamental generar agrupaciones que garanticen que la imputación se llevará a cabo entre observaciones con características comunes, y la selección de los donantes se realiza en forma aleatoria evitando que se introduzcan sesgos en el estimador de la varianza.

Existen variantes del procedimiento *hot-deck*; el “algoritmo secuencial”, parte de un proceso de ordenación de los datos en cada subgrupo y selecciona donantes en la medida que recorre el archivo de datos. Su aplicación supone que la falta de respuesta se distribuye en forma aleatoria en cada una de las categorías, pero en caso de que la falta de respuesta se concentre en un estrato con pocas observaciones es posible que se generen estimadores sesgados en la medida que el procedimiento seleccione varias veces el mismo donante. Por su parte, el “método aleatorio” identifica registros sin datos y elige en forma estocástica al donante; también, existe la posibilidad de que el donante sea el “vecino más cercano” al registro sin datos y la selección se efectúa a partir de la definición de criterios de distancia.

Para esta investigación se utilizó una de las variantes del método – el *hot deck aleatorio* – implementado en el comando “hotdeckvar” desarrollado por Matthias Schonlau para el paquete estadístico Stata (Schonlau, 2006)¹¹. El algoritmo implementado en hotdeckvar identifica como observaciones “donantes” a todas aquellas que no tienen datos perdidos en todas las variables especificadas para la construcción de los estratos (celdas) de imputación. Si una misma unidad “receptora” tiene varios datos perdidos, estos son reemplazados con valores de una misma observación “donante” con el objetivo de preservar las correlaciones entre las variables imputadas. Los donantes son elegidos al azar entre el set de posibles donantes al interior de las celdas de imputación¹².

¹¹ El programa `hotdeckvar` se puede descargar directamente en Stata a través del comando “net install”.

¹² Si se especifica [in] o [if], tanto los valores a ser imputados como los donantes serán especificados en función de los condicionantes [in] o [if]. También, es posible utilizar el comando [by] para imputar dentro de las categorías definidas por [by].

Para comparar alternativas, tanto en el contexto del *hot deck aleatorio* como en contraste con el método de medias condicionadas, se utilizaron las mismas celdas de ajuste ya presentadas en la Tabla 4. De esta manera, el método de imputación implementado se puede caracterizar como *hot deck aleatorio estratificado* (*stratified random hot deck*) ya que la implementación del procedimiento considera la utilización de celdas de ajuste (estratos) a través de la opción [by].

4.3 Imputación Cold Deck

El método de imputación Cold-Deck considera valores de imputación que son independientes a los datos de la base de datos analizada. En este sentido, se utilizan otras fuentes de información complementarias para corregir los problemas de no respuesta, como lo son parámetros poblacionales conocidos, datos administrativos, o datos de mediciones anteriores (Grittner et al., 2012).

Dado el carácter longitudinal de la encuesta, en esta aplicación se toma como referencia ("donantes") los datos de últimas mediciones, los que son utilizados para reemplazar ítems con valores perdidos. Por este motivo la implementación de Cold Deck en la EPS 2015 debe considerar variables que tengan estabilidad en el tiempo, por lo que se define utilizar como variable a imputar el tramo educacional de los encuestados ("teduc"), el cual refleja el nivel de educación más alto alcanzado. Esta es una variable que debe ser constante o aumentar en el tiempo, por lo que se puede establecer que mediante el método de imputación se contará con un valor que pertenece a la trayectoria educacional del encuestado reportada en una medición anterior. Cabe señalar que este mecanismo sólo será evaluado en aquellos casos que pertenecen a la muestra panel, el resto de los casos pertenecientes a la muestra de refresco serán imputados con otros métodos. De esta forma, el método propuesto se puede caracterizar como "mixto" ya que considera dos métodos de imputación para la misma variable (ver Figura 5.1).

El método Cold Deck será aplicado solo a los casos del panel EPS que cuenten con datos históricos de educación que sean *confiables*, es decir, en aquellos casos donde se cuente con una *secuencia plausible* de los reportes del nivel educacional pasados. Los casos con secuencias de educación histórica inconsistentes, así como también los casos que participan por primera vez en el panel, serán imputados con otros métodos.

Para esta investigación se utilizaron criterios similares a los presentados por Fitzenberger, Osikominu y Völter (2006) para elaborar una definición operativa de "secuencia plausible". Primero, se estableció que el nivel educacional de las personas puede poseer variaciones en el tiempo, siempre y cuando estas sean ascendentes. Por ejemplo, un valor inconsistente se obtiene cuando, por ejemplo, en una primera medición se reporta "Educación Superior" y en una medición posterior un nivel menor (por ejemplo: "Básica completa"). Dado que la pregunta refleja el nivel mayor nivel educacional del encuestado, un retroceso sería una inconsistencia. No obstante, no se sabe si el error se produjo en la primera medición (sobre-reporte), en la segunda medición (sub-reporte), o en ambas. Dada esta incertidumbre, en este apartado se revisarán aquellos casos que poseen valores perdidos en tramo educacional y cuentan con una secuencia válida (consistente) a través del tiempo.

Para que un caso sea parte de una secuencia válida, se establece lo siguiente:

- a. Posee información en, al menos, tres mediciones,
- b. Escolaridad no presenta variación en el tiempo,
- c. Escolaridad presenta variación ascendente en el tiempo.

Los casos analizados en esta aproximación cold deck deben cumplir la consideración “a”; dado que la muestra de la EPS 2015 incluyó muestra de refresco, estos casos fueron automáticamente descartados de esta fase. El resto de los casos se consideraron como secuencia válida si cumplían la condición “b” o “c”, en caso contrario se catalogaron como inválidos.

5 Imputación Monto de Ingreso Laboral

Para la imputación de YTRAB se aplicaron dos métodos distintos con algunas variantes: (1) método de media condicionada y (2) método hot deck aleatorio estratificado. A continuación se presentan estos resultados.

5.1. Resultados de imputación de corte transversal sin ponderar

Las Tablas 5.1 y 5.2 presentan estadísticas descriptivas univariadas de la variable original YTRAB y las 7 variantes de los métodos de imputación bajo análisis. La primera tabla presenta datos solo para los datos imputados ($n=761$), mientras que la segunda presenta datos para la muestra completa ($n=16.906$). Algunos resultados de interés a partir de las primeras 4 variantes de imputación que no hicieron uso de la información acerca de tramos de ingreso (sin tramos) en la Tabla 5.1:

- Las 4 variantes de la imputación media asignaron valores en torno al centro de masa, mientras que las 4 variantes del hot deck aleatorio hicieron uso de un rango más amplio de dispersión de los datos (ver mínimos y máximos observados).
- Como consecuencia del punto anterior se observa mayor dispersión de las variantes hot deck, lo cual se ve reflejada en desv estándar mayores que las observadas para la imputación de medias. El caso más extremo corresponde a la imputación global de la media (Celda 0), con cero variabilidad en los datos imputados ($d.e.=0$), ya que asigna el mismo valor (“ytrab=422.894 pesos”) a los 761 casos perdidos.

Cuando se comparan los resultados con las 3 variantes que si hicieron uso de la información de tramos de ingreso para la conformación de celdas de imputación (con tramos) se tiene lo siguiente:

- Bajo ambos métodos (hot deck o media condicionada), tanto el valor promedio de las imputaciones como la dispersión es mayor cuando se usa información sobre los tramos de ingreso en el proceso de imputación.

- Dado que la variable tramos de ingreso entrega información mucho más cercana a la variable de interés, ignorarla en el proceso de imputación produce imputaciones sesgadas a la baja (subestimadas).
- Al menos 51 de los 761 casos perdidos recibió un monto imputado con más de un millón de pesos, ya que pertenecían a la celda de ajuste con el mayor tramo de ingreso. De estos 51 casos, 50 corresponden a tramos reportados directamente por el entrevistado y 1 corresponde a tramo imputado.

Si bien es cierto el análisis de los datos imputados ($n=761$) muestra con claridad los efectos de las distintas variantes implementadas, estas diferencias se ven algo atenuadas al replicar el análisis con toda la muestra ($n=16.609$). La Tabla 5.2 muestra estos resultados:

- Los métodos de medias condicionadas “sin tramos” reducen la dispersión original de los datos pasando de d.e. = 442.362, para los casos completos, a d.e. = 423.000 aprox. para las 4 variantes de medias condicionadas sin tramos.
- Las variantes 7 variantes hot deck y las 3 variantes de las medias condicionadas “con tramos” mantienen niveles de dispersión en torno al nivel de la variable original sin imputar.
- También se puede observar un ligero aumento de la media en las variantes que utilizaron la información acerca de los tramos de ingreso.

Tabla 5.1. Estadísticas descriptivas univariadas, sin ponderar, de la variable original YTRAB y las 12 variantes imputadas. Solo para el conjunto de datos perdidos imputados (n=761 casos).

	n	media	desv. est.	min	max
Variable Original					
ytrab	0	.	.	.	.
Imputación Medias Condicionadas					
Sin tramos					
Celda 0: Global	761	422.894	0	422.894	422.894
Celda 1: Sex*Edad	761	429.686	84.639	235.527	532.027
Celda 2: PScore20	761	417.278	43.559	286.560	474.633
Celda 3: PredMean20	761	452.173	215.702	171.678	954.173
Con tramos					
Celda 4: Tramos	761	467.200	461.659	37.105	1.972.381
Celda 5: Tramos*PScore5	761	463.091	417.935	66.761	2.032.500
Celda 6: Tramos*PredMean5	761	456.012	396.498	65.270	1.783.949
Imputación Hot Deck					
Sin tramos					
Celda 0: Global	761	388.917	348.592	15.000	6.000.000
Celda 1: Sex*Edad	761	416.421	429.202	10.000	6.000.000
Celda 2: PScore20	761	412.544	406.163	15.000	5.000.000
Celda 3: PredMean20	761	440.688	400.448	20.000	4.250.000
Con tramos					
Celda 4: Tramos	761	468.801	577.665	10.000	9.000.000
Celda 5: Tramos*PScore5	761	452.618	488.964	14.000	6.400.000
Celda 6: Tramos*PredMean5	761	450.401	444.633	10.000	4.000.000

Tabla 5.2. Estadísticas descriptivas univariadas, sin ponderar, de la variable original YTRAB y las 12 variantes imputadas. Todos los casos en la muestra EPS 2015 (n=16.906 casos).

	n	media	desv. est.	min	max
Variable Original					
ytrab	8.248	422.894	442.362	10.000	9.000.000
Imputación Medias Condicionadas					
Sin tramos					
Celda 0: Global	9.009	422.894	423.265	10.000	9.000.000
Celda 1: Sex*Edad	9.009	423.468	423.982	10.000	9.000.000
Celda 2: PScore20	9.009	422.420	423.457	10.000	9.000.000
Celda 3: PredMean20	9.009	425.368	427.954	10.000	9.000.000
Con tramos					
Celda 4: Tramos	9.009	426.637	444.169	10.000	9.000.000
Celda 5: Tramos*PScore5	9.009	426.290	440.471	10.000	9.000.000
Celda 6: Tramos*PredMean5	9.009	425.692	438.750	10.000	9.000.000
Imputación Hot Deck					
Sin tramos					
Celda 0: Global	9.009	420.024	435.310	10.000	9.000.000
Celda 1: Sex*Edad	9.009	422.348	441.246	10.000	9.000.000
Celda 2: PScore20	9.009	422.020	439.408	10.000	9.000.000
Celda 3: PredMean20	9.009	424.397	438.984	10.000	9.000.000
Con tramos					
Celda 4: Tramos	9.009	426.772	455.489	10.000	9.000.000
Celda 5: Tramos*PScore5	9.009	425.405	446.534	10.000	9.000.000
Celda 6: Tramos*PredMean5	9.009	425.218	442.596	10.000	9.000.000

5.2. Comparación de estimaciones de corte transversal ponderadas

La Tabla 5.3 muestra los percentiles 5, 25, 50, 75 y 95 de la variable original YTRAB sin imputar en la columna (2), y los percentiles asociados a las variables imputadas mediante el método de las medias condicionadas en las columnas (3) a (9). Como se puede observar en las columnas (7) a (9), el valor en la parte baja de la distribución (p05) cae de \$100.000 a \$80.000 cuando se incorporan los “tramos de ingreso” como variable de ajuste para desarrollar las imputaciones. En la parte alta de la distribución, por otra parte, se observa el fenómeno contrario. En las columnas (7) a (9) se puede ver como los valores asociados a los percentiles p75 y p95 suben de \$500.000 a \$540.000 y de \$1.100.000 a 1.400.000 respectivamente cuando se utilizan los tramos de ingreso en el proceso de imputación.

La Tabla 5.4 muestra los percentiles asociados a las variables imputadas mediante el método hot deck. Como se puede observar, el mismo fenómeno se repite con la parte baja de la distribución disminuyendo y la parte alta aumentando. Todas las estimaciones están ponderadas con el factor de expansión de corte transversal de la EPS 2015. Se utilizó el comando svy en Stata 14 para informar acerca del diseño de la muestra.

Este resultado es consistente con lo observado en las tablas descriptivas univariadas. A diferencia de lo observado con la variable nivel educacional, aquí si se observan diferencias en los resultados bajo distintos métodos de imputación. La diferencia fundamental la hace el uso de la variable “tramos de ingreso” en la conformación de las celdas de imputación. Si tomamos la información contenida en la variable tramos como una buena proxy del valor verdadero del monto del ingreso laboral, entonces tenemos que cuando el método de imputación ignora esta variable se subestima la parte alta de la distribución (p75, p95) y se sobreestima la parte más baja (p05).

Cabe recordar que, a diferencia de la variable TEDUC – que presenta solo un 2% de datos perdidos – la variable YTRAB presenta un 17% de datos perdidos. Por esta razón, es razonable esperar que las imputaciones tengan un efecto en las estimaciones.

Tabla 5.3. Percentiles de ingresos del trabajo para la variable original sin imputar y para las variables imputadas con el método de medias condicionadas. Estimaciones ponderadas.

Pcentil (1)	Sin imputar (2)	Imputados Medias Condicionadas						
		Global (3)	Sex*Edad (4)	PScore20 (5)	PredMea n20 (6)	Tramo (7)	Tramo*P Score5 (8)	Tramo*Pr edMean5 (9)
p05	100.000	100.000	100.000	100.000	100.000	85.897	80.000	80.000
p25	250.000	250.000	250.000	250.000	250.000	250.000	250.000	250.000
p50	350.000	370.000	350.000	357.187	350.000	350.000	350.000	350.000
p75	510.000	500.000	510.000	500.000	540.000	540.000	540.000	540.000
p95	1.100.000	1.100.000	1.100.000	1.100.000	1.100.000	1.200.000	1.332.395	1.400.000
N	8.248	9.009	9.009	9.009	9.009	9.009	9.009	9.009

Tabla 5.4. Percentiles de ingresos del trabajo para la variable original sin ponderar y para las variables imputadas con el método hot deck aleatorio estratificado. Estimaciones ponderadas.

Pcentil (1)	Sin imputar (2)	Imputados Hot Deck Aleatorio Estratificado						
		Global (3)	Sex*Edad (4)	PScore20 (5)	PredMea n20 (6)	Tramo (7)	Tramo*P Score5 (8)	Tramo*Pr edMean5 (9)
p05	100.000	100.000	100.000	100.000	100.000	80.000	80.000	80.000
p25	250.000	250.000	250.000	250.000	250.000	250.000	250.000	250.000
p50	350.000	350.000	350.000	350.000	350.000	350.000	350.000	350.000
p75	510.000	500.000	500.000	500.000	520.000	540.000	540.000	540.000
p95	1.100.000	1.100.000	1.100.000	1.100.000	1.100.000	1.200.000	1.200.000	1.200.000
N	8.248	9.009	9.009	9.009	9.009	9.009	9.009	9.009

6 Imputación Monto de Alquiler Imputado

Para la imputación de ALQ se aplicaron dos métodos distintos con algunas variantes: (1) método de media condicionada y (2) método hot deck aleatorio estratificado. A continuación se presentan estos resultados.

6.1. Resultados de imputación de corte transversal sin ponderar

Las Tablas 6.1 y 6.2 presentan estadísticas descriptivas univariadas de la variable original ALQ y las 7 variantes de los métodos de imputación bajo análisis. La primera tabla presenta datos solo para los datos imputados ($n=2.878$), mientras que la segunda presenta datos para la muestra completa ($n=16.906$). Algunos resultados de interés en la Tabla 6.1:

- El promedio del valor del alquiler es menor cuando se usa el dato del tramo de alquiler en la conformación de las celdas de ajuste.
- La dispersión de los datos es menor con el método de Media Condicionada que con el método Hot Deck.
- Las imputaciones hot deck generan un rango más amplio que las medias condicionadas.

La Tabla 6.2 muestra los resultados para todos los casos en la muestra ($n=16.609$). Acá también se puede observar que el monto promedio de alquiler es menor cuando se utiliza información acerca de tramos de ingreso para conformar las celdas de imputación, tanto para el método de medias condicionadas como para el hotdeck. De la misma forma se puede verificar que las variantes hot deck presentan mayor variabilidad que el resto.

Tabla 6.1. Estadísticas descriptivas univariadas, sin ponderar, de la variable original ALQ y las 14 variantes imputadas. Solo para el conjunto de datos perdidos imputados (n=2.878 casos).

	n	media	desv. est.	min	max
Variable Original					
alq	0	.	.	.	.
Imputación Medias Condicionadas					
Sin tramos					
Celda 0: Global	2.878	184.797	0	184.797	184.797
Celda 7: TipoViv*Piezas	2.878	188.190	56.786	93.642	451.029
Celda 2: PScore20	2.878	182.385	10.914	162.388	199.509
Celda 3: PredMean20	2.878	182.464	76.348	82.705	405.493
Con tramos					
Celda 8: Tramos	2.878	149.565	108.411	48.037	368.705
Celda 9: Tramos*PScore5	2.878	149.713	108.603	46.912	381.108
Celda 10: Tramos*PredMean5	2.878	149.941	110.594	44.510	473.472
Imputación Hot Deck					
Sin tramos					
Celda 0: Global	2.878	180.967	186.327	10.000	5.000.000
Celda 7: TipoViv*Piezas	2.878	180.967	186.327	10.000	5.000.000
Celda 2: PScore20	2.878	176.783	168.165	10.000	3.000.000
Celda 3: PredMean20	2.878	184.016	192.045	10.000	4.000.000
Con tramos					
Celda 8: Tramos	2.878	147.092	153.475	10.000	3.500.000
Celda 9: Tramos*PScore	2.878	151.971	207.638	10.000	4.000.000
Celda 10: Tramos*PredMean	2.878	154.114	205.743	10.000	5.000.000

Tabla 6.2. Estadísticas descriptivas univariadas, sin ponderar, de la variable original ALQ y las 14 variantes imputadas. Todos los casos en la muestra EPS 2015 (n=16.906 casos).

	n	media	desv. est.	min	max
Variable Original					
alq	14.028	184.797	198.258	10.000	5.000.000
Imputación Medias Condicionadas					
Sin tramos					
Celda 0: Global	16.906	184.797	180.595	10.000	5.000.000
Celda 7: TipoViv*Piezas	16.906	185.374	182.112	10.000	5.000.000
Celda 2: PScore20	16.906	184.386	180.653	10.000	5.000.000
Celda 3: PredMean20	16.906	184.400	183.323	10.000	5.000.000
Con tramos					
Celda 8: Tramos	16.906	178.799	186.521	10.000	5.000.000
Celda 9: Tramos*PScore5	16.906	178.824	186.536	10.000	5.000.000
Celda 10: Tramos*PredMean5	16.906	178.863	186.729	10.000	5.000.000
Imputación Hot Deck					
Sin tramos					
Celda 0: Global	16.906	184.145	196.278	10.000	5.000.000
Celda 7: TipoViv*Piezas	16.906	185.634	199.161	10.000	5.000.000
Celda 2: PScore20	16.906	183.432	193.485	10.000	5.000.000
Celda 3: PredMean20	16.906	184.664	197.208	10.000	5.000.000
Con tramos					
Celda 8: Tramos	16.906	178.378	191.895	10.000	5.000.000
Celda 9: Tramos*PScore	16.906	179.209	200.260	10.000	5.000.000
Celda 10: Tramos*PredMean	16.906	179.573	199.878	10.000	5.000.000

6.2. Comparación de estimaciones de corte transversal ponderadas

La Tabla 6.3 muestra los percentiles 5, 25, 50, 75 y 95 de la variable original ALQ sin imputar en la columna (2), y los percentiles asociados a las variables imputadas mediante el método de las medias condicionadas en las columnas (3) a (9). Como se puede observar, no se producen mayores cambios en los percentiles a excepción de los asociados a los métodos de imputación de la media condicionada Global (Celda 0) y según la propensión a responder (Celda 2) en las columnas (3) y (4) de la Tabla 6.3. En estas dos columnas se observa:

- un abultamiento del valor de la mediana (percentil 50, p50);
- que el valor en la parte baja de la distribución (p05) sube de \$50.000 a \$60.000 y luego vuelve en torno al valor inicial cuando se incorporan los “tramos de ingreso” como variable de ajuste para desarrollar las imputaciones (columnas (7) a (9));

- Que en la parte alta de la distribución los valores asociados al percentil 75 (p75) bajan de \$250.000 a \$200.000 cuando se ignoran los tramos de ingreso en el proceso de imputación.

La Tabla 5.4 muestra los percentiles asociados a las variables imputadas mediante el método hot deck. Como se puede observar, no se producen mayores cambios en los percentiles a excepción de los asociados a los métodos de imputación hot deck que hacen uso de la información sobre tramos de alquiler imputado en las columnas (7) a (9), donde se observa una ligera disminución en el percentil 75 que pasa de \$250.000 a \$240.000.

Todas las estimaciones están ponderadas con el factor de expansión de corte transversal de la EPS 2015. Se utilizó el comando svy en Stata 14 para informar acerca del diseño de la muestra.

Tabla 6.3. Percentiles de alquiler imputado para la variable original sin imputar y para las variables imputadas con el método de medias condicionadas. Estimaciones ponderadas.

Pcentil (1)	Sin imputar (2)	Imputados Medias Condicionadas						
		Global (3)	Sex*Edad (4)	PScore20 (5)	PredMea n20 (6)	Tramo (7)	Tramo*P Score5 (8)	Tramo*Pr edMean5 (9)
p05	50.000	60.000	60.000	60.000	60.000	48.037	47.486	48.767
p25	100.000	110.000	110.000	100.000	100.000	100.000	100.000	100.000
p50	150.000	184.797	173.866	150.000	165.235	150.000	150.000	150.000
p75	250.000	200.000	200.000	250.000	250.000	240.000	240.000	240.000
p95	400.000	400.000	400.000	405.493	400.000	400.000	400.000	402.834
N	14.028	16.906	16.906	16.906	16.906	16.906	16.906	16.906

Tabla 6.4. Percentiles de alquiler imputado para la variable original sin ponderar y para las variables imputadas con el método hot deck aleatorio estratificado. Estimaciones ponderadas.

Pcentil (1)	Sin imputar (2)	Imputados Hot Deck Aleatorio Estratificado						
		Global (3)	Sex*Edad (4)	PScore20 (5)	PredMea n20 (6)	Tramo (7)	Tramo*P Score5 (8)	Tramo*Pr edMean5 (9)
p05	50.000	50.000	50.000	50.000	50.000	50.000	50.000	50.000
p25	100.000	100.000	100.000	100.000	100.000	100.000	100.000	100.000
p50	150.000	150.000	150.000	150.000	150.000	150.000	150.000	150.000
p75	250.000	250.000	250.000	250.000	250.000	240.000	240.000	240.000
p95	400.000	400.000	400.000	445.000	400.000	400.000	400.000	400.000
N	14.028	16.906	16.906	16.906	16.906	16.906	16.906	16.906

7 Imputación de Tramo de Nivel Educativo

Para la imputación de TEDUC se aplicaron tres métodos distintos con algunas variantes: y (1) método cold deck, (2) método de mediana condicionada, y (3) método hot deck aleatorio estratificado. Aquí se presentan los resultados de estas estrategias.

7.1. Resultados de imputación longitudinal sin ponderar

El método de imputación Cold Deck utilizado aquí consiste en imputar los datos perdidos de TEDUC en EPS 2015 utilizando información reportada en rondas anteriores para TEDUC por los miembros antiguos del panel. Previo a imputar los casos, sin embargo, se deben evaluar los datos disponibles para identificar aquellos que cumplen con criterios de calidad establecidos para ser utilizados para estos fines.

La Tabla 7.1 muestra los resultados de la revisión longitudinal de los datos disponibles para los 16.906 personas entrevistadas en la EPS 2015. Para estos efectos se considera "miembros nuevos" a las personas que ingresan por primera vez a la muestra EPS en la VI ronda (EPS 2015) y "miembros antiguos" a las personas que ingresaron al panel EPS en alguna de las 4 rondas anteriores del panel (EPS 2002, EPS 2004, EPS 2006 o EPS 2009).

Los resultados en la tabla muestran que un 40% de los 16.906 entrevistados en EPS 2015 corresponden a "miembros nuevos" y 60% a "miembros antiguos". Entre quienes no responden TEDUC en 2015, sin embargo, se puede observar que son más los miembros antiguos (80%) que los miembros nuevos (20%).

De los 10.128 miembros antiguos del panel, se puede observar que 98% ha reportado TEDUC en 2 o más oportunidades (rondas) y solo un 2% lo ha hecho en solo 1 oportunidad. La misma tendencia se observa entre los casos perdidos con 97% y 3% de los casos respectivamente.

De los 9.964 miembros antiguos con 2 o más reportes de TEDUC en la historia del panel, se tiene que 52% fueron clasificados como con "secuencias consistentes" según las reglas establecidas para este análisis - es decir, secuencias donde el nivel de educación reportado entre 2002 y 2009 (1) se mantuvo constante en el tiempo o (2) aumentó en el tiempo. El restante 48% corresponde a "secuencias inconsistentes" donde se observa (1) decrecimiento o (2) alzas y bajas en el nivel de educación reportado en el tiempo. Entre quienes reportaron datos perdidos en TEDUC el 2015, sin embargo, el porcentaje de secuencias consistentes es ligeramente mayor alcanzando un 61%.

La Tabla 7.2 ilustra la base de datos longitudinal utilizada para analizar el tipo de secuencias de los miembros antiguos del panel, donde cada observación (IdEnc) corresponde a un miembro del panel que respondió en EPS 2015. Las variables teduc02 a teduc15 muestran el tramo de educación reportado en las 5 rondas del panel, la variable NRteduc15 indica con "1" la no respuesta a TEDUC en EPS 2015, la variable miss_teduc identifica el número de datos perdidos para la variable TEDUC en las 4 rondas previas del panel (2002 a 2009), y la variable sec_inv identifica con un "1" las secuencias inválidas y con un "0" las secuencias válidas.

De acuerdo a esta ilustración, se observa que el IdEnc = 121 tiene dato perdido (=.) en la variable teduc15, no obstante, sí reportó nivel de educación en las 4 rondas anteriores. Al analizar el patrón de respuesta, sin embargo, no se encuentra una secuencia válida puesto que existe una evolución inconsistente del nivel educacional reportado por el encuestado, pasando de educación "Media Completa" en el 2002 a "Media Incompleta" en 2004, para volver a "Media Completa" el 2009. Por otra parte, se observa que el IdEnc = 234 sí posee una secuencia válida ya que todos los valores reportados en rondas anteriores corresponden a educación "Media Completa".

Siguiendo con la metodología propuesta, los datos perdidos en TEDUC 2015 que estaban asociados a miembros del panel con secuencias válidas se completaron (imputaron) utilizando el nivel de educación más recientemente reportado por el entrevistado. Para el IdEnc = 234, por ejemplo, se imputó en EPS2015 la categoría "Media Completa" reportada en EPS 2009, mientras que para el caso IdEnc = 17034, se imputó en EPS2015 la categoría "Media Completa" reportada en EPS 2004. Los casos con secuencias inválidas como IdEnc = 121, por otra parte, se dejaron con dato perdido para EPS 2015.

En total se imputaron 171 de los 363 datos perdidos en TEDUC 2015 y se dejaron como perdidos los restantes 110. El procedimiento aquí descrito permitió reducir la tasa de no respuesta al ítem de 2,82% (n=363) a un 1,1% (n=110).

La Tabla 7.3 presenta la distribución del nivel educacional para los casos imputados (n=171) y para el total de los casos disponibles en 2015 antes (n=16.543) y después (n=16.714) de imputación. Los paneles A y B muestran perfiles distintos para la distribución del nivel educacional de los casos imputados y los casos completos antes de imputación. Tomando las 2 categorías de educación básica en conjunto (ed. básica completa + incompleta), se tiene que los casos imputados tienen mucha más educación básica (46%) que los casos completos (24%) del 2015. Tomando las tres categorías de educación superior en su conjunto (ed. técnica superior, ed. universitaria completa e incompleta), se tiene que los casos imputados tienen mucha menos educación superior (11%) que los casos completos (30%) del 2015.

Estas diferencias, sin embargo, desaparecen cuando se analiza la distribución del nivel educacional para los casos completos después de imputación (n=16.714). Esto se puede observar al comparar la distribución de los casos del panel A y C en la Tabla 7.3. Las estadísticas descriptiva de los datos imputados y los casos completos después de imputación se presentan también en las Tablas 7.4 y 7.5, junto con los resultados de los métodos de imputación de medias condicionadas y hot deck que se describen a continuación.

Tabla 7.1. Distribución de los casos perdidos de TEDUC en EPS 2015 según número de rondas anteriores con datos completos y tipo de secuencia.

Tipo muestra	Todos los casos en EPS 2015		Solo casos perdidos en EPS 2015	
	n	%	n	%
Miembros Nuevos EPS 2015	6.778	40%	74	20%
Miembros Antiguos del Panel EPS	10.128	60%	289	80%
Total	16.906	100%	363	100%
Respondió TEDUC en 1 ronda anterior	164	2%	8	3%
Respondió TEDUC en 2+ rondas anteriores	9.964	98%	281	97%
Subtotal 1	10.128	100%	289	100%
Secuencia Inconsistente	4.752	48%	110	39%
Secuencia Consistente	5.212	52%	171	61%
Subtotal 2	9.964	100%	281	100%

Fuente: Elaboración propia.

Tabla 7.2. Ejemplo de base de datos utilizada para identificar los casos con reportes longitudinales confiables de nivel de educación (TEDUC) para los miembros del panel EPS entrevistados en 2015.

IdEnc	tipo_muestra	teduc02	teduc04	teduc06	teduc09	teduc15	NRteduc15	miss_teduc	sec_inv
121	1	MediaCom	Media Incompleta	MediaInc	MediaCom	.	1	0	1
205	1	MediaCom	.	MediaCom	UnivCom	.	1	1	0
234	1	MediaCom	Media completa	MediaCom	MediaCom	.	1	0	0
242	1	MediaInc	Media Incompleta	MediaCom	MediaCom	.	1	0	0
259	1	MediaCom	Media completa	MediaCom	MediaCom	.	1	0	0
493	1	MediaCom	Media completa	MediaCom	MediaCom	.	1	0	0
496	1	BasicaInc	Ninguna	Ninguna	.	.	1	1	1
497	1	MediaCom	Media completa	MediaCom	MediaCom	.	1	0	0
498	1	TecnicaSup	.	BasicaCom	.	.	1	2	1
517	1	MediaInc	Media Incompleta	MediaInc	MediaInc	.	1	0	0
16731	1	BasicaInc	Basica Incompleta	.	BasicaInc	.	1	1	0
16817	1	BasicaInc	Media completa	.	MediaInc	.	1	1	1
16819	1	BasicaInc	Basica Incompleta	.	.	.	1	2	0
17034	1	BasicaCom	Media completa	.	.	.	1	2	0
17056	1	MediaInc	Media Incompleta	.	.	.	1	2	0

Tabla 7.3. Distribución de nivel educacional para todos los casos antes y después de imputación, y solo para los casos imputados. EPS 2015.

// (A) Distribución de TEDUC antes de imputación

Nivel			
Educacional			
-			
Categorica	Freq.	Percent	Cum.
Ninguna	296	1.79	1.79
BasicaInc	2,288	13.83	15.62
BasicaCom	1,719	10.39	26.01
MediaInc	2,427	14.67	40.68
MediaCom	4,761	28.78	69.46
TecnicaSup	2,214	13.38	82.84
UnivInc	1,647	9.96	92.80
UnivCom	1,191	7.20	100.00
Total	16,543	100.00	

// (B) Distribución de TEDUC solo para los casos imputados

Tramo Nivel			
Educacional			
- Imp. Cold			
Deck	Freq.	Percent	Cum.
Ninguna	1	0.58	0.58
BasicaInc	53	30.99	31.58
BasicaCom	28	16.37	47.95
MediaInc	27	15.79	63.74
MediaCom	43	25.15	88.89
TecnicaSup	11	6.43	95.32
UnivInc	6	3.51	98.83
UnivCom	2	1.17	100.00
Total	171	100.00	

// (C) Distribución de TEDUC después de imputación

Tramo Nivel			
Educacional			
- Imp. Cold			
Deck	Freq.	Percent	Cum.
Ninguna	297	1.78	1.78
BasicaInc	2,341	14.01	15.78
BasicaCom	1,747	10.45	26.24
MediaInc	2,454	14.68	40.92
MediaCom	4,804	28.74	69.66
TecnicaSup	2,225	13.31	82.97
UnivInc	1,653	9.89	92.86
UnivCom	1,193	7.14	100.00
Total	16,714	100.00	

7.2. Resultados de imputación de corte transversal sin ponderar

Los métodos de imputación de Medias Condicionadas y Hot Deck Aleatorio utilizados aquí consisten en imputar los datos perdidos de TEDUC en EPS 2015 utilizando, en distinta medida, información auxiliar recolectada en la misma EPS 2015 para conformar celdas de imputación. Las Tablas 7.4 y 7.5 presentan estadísticas descriptivas de los resultados de los distintos métodos de imputación bajo análisis. La primera tabla presenta datos solo para los datos imputados ($n=363$), mientras que la segunda presenta datos para la muestra completa ($n=16.906$). Se incluyen también las estadísticas asociadas al método cold deck a modo de comparación.

Algunos resultados de interés a partir de la Tabla 7.4:

- Las 4 variantes de la imputación mediana asignaron valores en torno al centro de masa, en el rango de las categorías 3 a 6. Las 4 variantes del hot deck aleatorio, por otra parte, hicieron uso del rango completo de dispersión observado de los datos con rangos entre 1 y 8.
- La mayor dispersión de las variantes hot deck también se ve reflejada en mayores niveles de desv estándar que las variantes de imputación mediana. El caso más extremo corresponde a la imputación global de la mediana (Celda 0), con cero variabilidad en los datos imputados ($d.e.=0$), ya que asigna el mismo valor ("teduc=5") a los 363 casos perdidos.
- En cuanto al valor promedio, se observan niveles más altos en ambos ajustes globales (Celda 0) y niveles más bajos en el resto de las variantes que hacen uso de información auxiliar para la conformación de las celdas de imputación. Estos resultados parecen indicar que los datos perdidos están asociados a personas con menor educación, y que el uso de información auxiliar es relevante para reducir parte del sesgo de no respuesta observado.
- Los resultados de la imputación cold deck van en la misma línea del punto anterior. Como se puede observar en la tabla el nivel promedio de educación imputado a partir de los reportes históricos es mucho menor ($=3,73$) que cualquiera de las variantes de medias condicionadas y hot deck. Cabe recordar, sin embargo, que los resultados cold deck solo representan a los miembros antiguos del panel, ya que para los miembros nuevos no se dispone de información histórica en el panel.

Si bien es cierto el análisis de los datos imputados ($n=363$) muestra con claridad los efectos de los distintos métodos implementados, estas diferencias se ven completamente atenuadas al replicar en análisis con toda la muestra ($n=16.609$). La Tabla 7.5 muestra las mismas estadísticas univariadas y, como se puede observar, no se distinguen diferencias en la dispersión de los datos, en el promedio, ni tampoco en el recorrido (rango) de las variables imputadas.

Tabla 7.4. Estadísticas descriptivas univariadas, sin ponderar, de la variable original TEDUC y las 8 variantes imputadas. Solo para el conjunto de datos perdidos imputados (n=363 casos) en la muestra EPS 2015.

	n	media	desv. est.	min	max
Variable original					
teduc	0	.	.	.	.
Imputación Mediana Condicionada					
Celda 0: Global	363	5,00	0,00	5	5
Celda 1: Sex*Edad	363	4,25	0,96	3	6
Celda 2: PScore	363	4,08	0,87	3	6
Celda 3: PredMean	363	4,21	1,18	2	6
Imputación Hot Deck					
Celda 0: Global	363	4,69	1,84	1	8
Celda 1: Sex*Edad	363	4,35	1,93	1	8
Celda 2: PScore	363	4,14	1,80	1	8
Celda 3: PredMean	363	4,00	1,75	1	8
Imputación Cold Deck					
teduc_cd	171	3,73	1,55	1	8

Tabla 7.5. Estadísticas descriptivas univariadas, sin ponderar, de la variable original TEDUC y las 8 variantes imputadas. Todos los casos (n=16.906 casos) en la muestra EPS 2015.

	n	media	desv. est.	min	max
Variable original					
teduc	16.543	4,71	1,79	1	8
Imputación Mediana Condicionada					
Celda 0: Global	16.906	4,71	1,77	1	8
Celda 1: Sex*Edad	16.906	4,70	1,77	1	8
Celda 2: PScore	16.906	4,69	1,77	1	8
Celda 3: PredMean	16.906	4,70	1,78	1	8
Imputación Hot Deck					
Celda 0: Global	16.906	4,71	1,79	1	8
Celda 1: Sex*Edad	16.906	4,70	1,79	1	8
Celda 2: PScore	16.906	4,70	1,79	1	8
Celda 3: PredMean	16.906	4,69	1,79	1	8
Imputación Cold Deck					
teduc_cd	16.714	4,70	1,79	1	8

7.3. Comparación de estimaciones de corte transversal ponderadas

Los análisis de la sección anterior permiten hacerse una idea preliminar del funcionamiento de las distintas estrategias de imputación. Para realizar un análisis más acabado, sin embargo, se deben (1) evaluar estadísticos de interés para la EPS y (2) tomar en cuenta el diseño muestral complejo de la encuesta EPS al momento de producir las estimaciones de interés. Para efectos de este análisis, se compararon resultados de la distribución porcentual de casos para las 8 categorías de nivel educacional. Se utilizó el comando `svy` en Stata 14 para informar acerca del diseño de la muestra.

La Tabla 7.6 muestra los resultados de la estimación del porcentaje de personas en distintos niveles educacionales utilizando distintos métodos de imputación. Las columnas (1) y (2) presentan estimaciones sin imputar (análisis de casos completos) para las 16.543 casos sin datos perdidos en TEDUC. La columna (1) presenta estimaciones sin ponderar y la columna (2) las estimaciones ponderadas utilizando el factor de expansión de corte transversal de la EPS 2015. Algunos resultados de la Tabla 7.6.:

- No se observan mayores diferencias entre las distribuciones en las columnas (1) y (2), pero como es de esperar se observa la subestimación de los errores estándares de las estimaciones sin ponderar de la columna 2. Dado el diseño muestral complejo de la EPS 2015, las estimaciones de referencia para comparar los métodos alternativos de imputación corresponden a las ponderadas que se presentan en la columna (3).
- Las columnas (4) a (7) presentan las estimaciones asociadas a las 4 variantes del método de mediana condicionada. A nivel general, no se observan mayores diferencias con la distribución de casos completos de la columna (2). La única estimación que se diferencia ligeramente corresponde al porcentaje con educación media completa, que pasa de 28,9% en la columna (3) a 30,6% en la columna (4). Este resultado se explica porque el método en la columna (4) imputa la mediana de la muestra completa, que corresponde a la categoría "5=educ. media completa", a todos los casos perdidos.
- Las columnas (8) a (11) presentan las estimaciones asociadas a las 4 variantes del método hot deck aleatorio. A nivel general, no se observan mayores diferencias con la distribución de casos completos de la columna 2, ni tampoco entre sus 4 variantes o las 4 variantes del método de medias condicionadas. Los errores estándar tampoco cambian en comparación con los casos completos, probablemente porque la potencial reducción del error de muestreo asociada a la recuperación de casos no se ve compensada por el pequeño porcentaje de "recuperación" de casos perdidos.
- La columna (12) presenta los resultados imputados via cold deck. Tampoco se observan diferencias con respecto a los datos sin imputar o a los datos imputados con los otros métodos.

Podemos concluir entonces que, para efectos de la estimación de la distribución del nivel de educación, cualquiera de los métodos revisados entrega sustantivamente los mismos resultados. Este resultado se podría explicar debido a que el porcentaje de casos imputados

es relativamente pequeño – 2,3% - y por lo tanto no afecta de forma relevante estadísticas descriptivas para la muestra completa. Se debe tener cuidado de no generalizar este resultado, ya que este solo dice relación con la estimación de la distribución porcentual del nivel de educación, sin embargo habría que evaluar cómo se ven afectados otros estimadores de interés - como cuantiles o coeficientes de regresión - ya sea a nivel de la muestra completa o de subgrupos poblacionales de interés.

Tabla 7.6. Estimación del porcentaje de personas según nivel educacional (TEDUC), según distintos métodos de imputación.

Nivel de Educación	Sin Ponderar	Ponderado	Ponderados				Ponderados				Ponderado
	Sin imputar	Sin imputar	Medias Condicionadas				Hot Deck Aleatorio				Cold Deck
			Global	Sex*Edad	PScore20	PredMean20	Global	Sex*Edad	PScore20	PredMean20	
(1)	(2) b/se*	(3) b/se	(4) b/se	(5) b/se	(6) b/se	(7) b/se	(8) b/se	(9) b/se	(10) b/se	(11) b/se	(12) b/se
Ninguna	1,79	1,73	1,69	1,69	1,69	1,69	1,72	1,76	1,72	1,75	1,71
	0,10	0,12	0,12	0,12	0,12	0,12	0,12	0,12	0,12	0,12	0,12
Básica Inc	13,83	14,04	13,70	13,70	13,70	13,90	13,98	14,17	14,21	14,23	14,21
	0,27	0,35	0,34	0,34	0,34	0,35	0,35	0,35	0,35	0,35	0,35
Básica Com	10,39	10,70	10,44	11,05	11,25	10,79	10,68	10,66	10,79	10,79	10,74
	0,24	0,34	0,33	0,34	0,35	0,33	0,33	0,33	0,33	0,34	0,34
Media Inc	14,67	14,79	14,43	15,09	15,38	15,08	14,71	14,83	14,81	14,82	14,80
	0,28	0,38	0,37	0,38	0,38	0,38	0,38	0,38	0,38	0,38	0,38
Media Com	28,78	28,89	30,61	29,23	28,76	29,14	28,77	28,93	28,93	28,70	28,82
	0,35	0,50	0,51	0,50	0,50	0,50	0,49	0,50	0,50	0,49	0,50
Técnica Sup	13,38	12,56	12,25	12,36	12,34	12,53	12,66	12,45	12,35	12,59	12,52
	0,26	0,39	0,38	0,38	0,38	0,39	0,39	0,38	0,38	0,39	0,39
Univ Inc	9,96	8,26	8,06	8,06	8,06	8,06	8,44	8,19	8,15	8,22	8,25
	0,23	0,35	0,34	0,34	0,34	0,34	0,36	0,34	0,34	0,35	0,35
Univ Com	7,20	9,04	8,83	8,83	8,83	8,83	9,04	9,01	9,04	8,91	8,94
	0,20	0,40	0,39	0,39	0,39	0,39	0,39	0,39	0,40	0,39	0,39
N	16.543	16.543	16.906	16.906	16.906	16.906	16.906	16.906	16.906	16.906	16.714

Nota: (*) b= proporción, se=error estándar de la proporción. (**) Estimaciones ponderadas utilizan el factor de expansión "factor_EPS2015". Errores estándar en columnas (3) a (12) calculados con método de Linearización de Taylor, utilizando comando svy en Stata 14.

8 Conclusiones y Discusión

Acerca de la imputación de nivel educacional

El porcentaje de datos perdidos es relativamente bajo para TEDUC (2,15%), y la literatura recomienda usualmente “no hacer nada” cuando la tasa de pérdida está en torno al 1-2%. Sin embargo el mecanismo de pérdida de TEDUC en la EPS 2015 no es completamente al azar y, dada la relevancia de esta variable en los análisis de la EPS, es recomendable imputar datos perdidos a pesar de la baja prevalencia del problema.

Dada la existencia de información histórica para los antiguos afiliados, y bajo supuestos razonables para las trayectorias de educación, es posible determinar un conjunto de reglas que permitan recuperar información individual de los miembros antiguos del panel para imputar datos perdidos. La estrategia implementada aquí permitió reducir la tasa de no respuesta al ítem de 2,15 a 1,1% con esta estrategia.

- La estrategia propuesta para identificar casos válidos para imputación con datos del panel fue conservadora al exigir reporte constante en el tiempo o en ascenso. A futuro, se debieran evaluar reglas alternativas que consideren otras variables auxiliares, como por ejemplo la edad de los entrevistados, para determinar cuando una secuencia es válida. O bien examinar con más detalle las secuencias y tomar acciones distintas cuando las inconsistencias son relativamente “menores” (ej. solo 1 de 4 reportes inconsistentes en la secuencia).
- En la misma línea anterior, también se podría complementar la información faltante – tanto para los casos del panel como para los miembros nuevos - con datos de registros administrativos en educación.
- Es importante también identificar qué otras variables en la EPS podrían verse beneficiadas de una estrategia similar de edición/imputación de datos en base a reportes históricos del panel. Características como la Ocupación/Oficio, por ejemplo, suelen ser relativamente constantes en el tiempo y podrían ser revisadas en el contexto del panel.

Los análisis aquí presentados también se hicieron cargo de evaluar alternativas para tratar con los casos que no disponen de información longitudinal para imputación, como es el caso de los miembros nuevos del panel (muestras de refresco) y los miembros del panel con secuencias de educación inconsistentes en el tiempo.

- Los métodos de medias condicionadas y hot deck aleatorio evaluados no arrojaron diferencias significativas en la estimación de la distribución del nivel educacional. La consistencia entre los métodos es una señal positiva, ya que no es deseable que los resultados sean demasiado dependientes del método de imputación implementado.
- Sin embargo, se pudo observar que las imputaciones vía hot deck permiten reflejar de manera más cercana el comportamiento de los datos observados. Por esta razón, se recomienda su uso para análisis univariados como los presentado en este informe.

- Entre las 4 variantes analizadas para TEDUC, se recomienda utilizar la variante que conformó las celdas de imputación en base a la media predictiva ya que esta permite mayor flexibilidad para acomodar un amplio número de predictores, tanto continuos como categóricos. Este método, además, ha demostrado reducir el sesgo y la varianza en estudios de simulación en el contexto de la imputación univariada examinada en este informe (ver Haziza y Beaumont, 2007).

El análisis de las secuencias de TEDUC para el panel 2002-2009, por otra parte, dejó en evidencia un problema aún mayor al de los datos perdidos (2,3%) que es la inconsistencia de las secuencias para casi la mitad de los casos del panel (48%). Si bien el foco de este informe fue implementar una estrategia para reducir el potencial sesgo de no respuesta, es importante levantar el punto del error de medición que presenta la variable TEDUC e identificar estrategias para reducirlo.

Una estrategia utilizada por encuestas longitudinales para resolver el problema de la inconsistencia de los reportes en el tiempo es la “entrevista dependiente”. Para variables que se asumen relativamente constantes en el tiempo, pero que pueden cambiar como educación u ocupación, se precargan las respuestas entregadas en rondas anteriores y se pide al entrevistado que confirme si ha habido cambio o no en la aplicación actual. De esta forma, cualquier inconsistencia registrada en rondas anteriores se puede resolver en forma directa con el entrevistado y bases de datos con rectificaciones longitudinales se ponen a disposición de los usuarios.

Acerca de la imputación de montos de ingreso laboral y alquiler imputado

En esta implementación se utilizaron modelos distintos para la imputación de las dos variables de montos evaluadas – ingreso laboral y alquiler imputado. En este contexto de análisis exploratorio es una estrategia razonable, sin embargo si se planea a futuro optar por implementar un ejercicio de imputación más masivo, con tal vez decenas de variables siendo imputadas, es importante evaluar los pros y contras de customizar modelos para cada variable versus identificar un set de predictores comunes para ciertos grupos de variables.

- La *Health and Retirement Survey*, por ejemplo, reduce la información de más de 70 predictores extrayendo los 20 componentes principales para sus modelos de imputación de dos grandes grupos de variables – los ingresos por una parte y el patrimonio por otra parte.
- Otro punto relevante interesante de la HRS es que se desarrollan dos sets de imputaciones para cada variable – un set de “corte transversal” y otro set “longitudinal”. La diferencia más importante entre ambos modelos es el uso de los datos pasados (y_{t-1}) y futuros (y_{t+1}) de la variable objeto de imputación (y_t). En la práctica, esto implica que la base de datos con las imputaciones longitudinales está siempre disponible con un desfase de una ronda hacia atrás.

Los análisis aquí presentados se hicieron cargo de evaluar alternativas de imputación que solo usan datos de corte transversal para imputación. En particular, se buscó comparar resultados que hicieran uso (y no) de una variable auxiliar altamente predictiva de los datos

perdidos - las preguntas sobre “tramos” que se hace a quienes optan por no responder la pregunta principal sobre “montos” monetarios.

- Los métodos de medias condicionadas y hot deck aleatorio evaluados arrojaron diferencias significativas en la estimación de la distribución (percentiles) del ingreso laboral y del alquiler imputado.
- Los métodos que no hacían uso de la información sobre los tramos de ingreso laboral, por ejemplo, subestimaron la parte alta de la distribución (p75, p95) y sobreestimaron la parte más baja (p05).
- Si se trabaja bajo el supuesto de que la información contenida en la variable tramos es una buena proxy del valor verdadero del monto del ingreso laboral, entonces es recomendable utilizar métodos que incorporen esta información en los modelos de imputación.
- Entre las 7 variantes analizadas para YTRAB y ALQ, se recomienda utilizar la variante que conformó las celdas de imputación en base a la media predictiva ya que esta permite mayor flexibilidad para acomodar un amplio número de predictores, tanto continuos como categóricos. Este método, además, ha demostrado reducir el sesgo y la varianza en estudios de simulación en el contexto de la imputación univariada examinada en este informe (ver Haziza y Beaumont, 2007).

Comentarios Generales

Los métodos evaluados aquí corresponden a las opciones metodológicas más sencillas de implementar en el contexto de los análisis de datos perdidos, sin embargo son varias las variantes de estos mismos métodos que no fueron revisadas en esta oportunidad y que debieran considerarse a futuro.

- En este ejercicio se consideró solo la implementación del hot deck aleatorio, sin embargo existen métodos alternativos de selección de donante como la selección del vecino mas cercano (*nearest neighbor*).
- La confirmación de las celdas de imputación se hizo en base a variables ya existentes o bien en base a cuantiles de la propensión de responder o la media predictiva. Otras opciones a evaluar para la conformación de celdas incluyen los árboles de decisión (CHAID) o la extracción de componentes principales. Este último método es utilizado en la *Health and Retirement Survey* para la conformación de predictores para los modelos multivariados de imputación de ingresos y patrimonio.
- Variantes más sofisticadas del hot deck incluyen el *hot deck hierárquico*, que va creando y colapsando las celdas de ajuste en atención a la priorización de variables

establecida y otros parámetros como el mínimo de donantes por celda o máximo de veces de uso del mismo donante para imputación.

En esta oportunidad se optó por evaluar estas estrategias para privilegiar la discusión y comunicación de resultados con todo el espectro de usuarios de las bases de datos EPS. Sin embargo, es importante seguir profundizando el estudio del fenómeno de los datos perdidos en la EPS con metodologías más sofisticadas de imputación y/o análisis de datos.

- Las variables YTRAB, TEDUC y ALQ se imputaron en forma independiente una de otra, lo que se conoce como imputación univariada. A futuro, se debieran evaluar alternativas de imputación multivariadas, que imputen en forma conjunta todas las variables bajo evaluación, de manera de preservar las correlaciones entre las variables imputadas. En el contexto del hot deck una extensión natural es el hot deck multivariado que usa el “mismo donante” para imputar todos los datos perdidos de una misma observación. Otras alternativas más sofisticadas son los métodos paramétricos multivariados (*Bayesian*) o los métodos de ecuaciones encadenadas (*Chained Equations*).
- Se realizó un único ciclo de imputaciones para cada método, lo que se conoce como imputación simple. Futuras extensiones debieran producir imputaciones múltiples para cada variable imputada y producir estimaciones utilizando las reglas de combinación de Rubin. El uso de imputaciones múltiples permite dar cuenta del componente de variabilidad asociado al proceso de imputación – estimaciones de varianza (y test estadísticos) desarrollados en base a imputaciones simples están subestimados. Actualmente paquetes estadísticos como Stata (comando MI) y SPSS (comando MI IMPUTE), extensamente utilizados en Chile, cuentan con módulos tanto para implementar como analizar datos con imputaciones múltiples.
- A excepción del método cold deck, los métodos implementados hicieron uso exclusivamente de variables observadas en la EPS 2015. Para variables que están correlacionadas en el tiempo, como podrían ser los ingresos y patrimonio en el caso de la EPS, es razonable plantearse modelos de imputación inter-temporales que hagan uso de los datos de rondas pasadas y futuras. Encuestas como la *Health and Retirement Survey* (HRS) y la *Survey of Consumer Finances* (SCF) en Estados Unidos, hacen uso de modelos de series de tiempo para imputar este tipo de variables con el objetivo de mejorar la precisión de las imputaciones. El adecuado modelamiento de los datos es fundamental en estas encuestas que pueden llegar a presentar porcentajes de datos perdidos en torno al 40% para este tipo de variables.

En Chile, la encuesta Financiera de Hogares (Banco Central) y la Encuesta de Presupuestos Familiares (INE) tienen experiencia en la implementación de metodologías más sofisticadas de imputación de datos para variables relacionadas con ingreso, gasto y patrimonio de los hogares en Chile. Sería recomendable intercambiar experiencias y recomendaciones con los equipos de trabajo de estas instituciones para avanzar en un tema que es complejo y sin mucha visibilidad en el contexto de la publicación de estadísticas oficiales.

En este informe, y a modo de análisis exploratorio, se optó enfocar los esfuerzos del ejercicio de imputación en tres variables con características útiles para explorar ciertos aspectos de los métodos a evaluar:

- La variable categórica TEDUC se seleccionó para evaluar la factibilidad de utilizar la información histórica del panel para imputar datos. Se optó por TEDUC categórica y no los años de escolaridad continua porque la variable categorizada es la más utilizada en la publicación de estadísticas oficiales de la EPS.
- Las variables continuas YTRAB y ALQ se seleccionaron por su alto porcentaje de datos perdidos (17% aprox) y a la disponibilidad de información auxiliar relevante – el reporte de “tramos” para quienes optan por no responder a la pregunta sobre montos de ingreso y alquiler.

A futuro, sin embargo, es importante identificar las variables – o grupos de variables – que son prioritarias para imputar en la EPS. Para considerar:

- Dada la correlación entre fenómenos de interés, tiene sentido imputar ciertos conjuntos de variables en forma simultánea. Por ejemplo, la asociación entre los ingresos del trabajo y el nivel educacional. O más evidentemente los componentes de partidas de ingreso/gasto que luego se suman para formar un total. Encuestas como la HRS y la SCF imputan familias completas de variables de ingreso, patrimonio y gasto en forma conjunta.
- Dado el interés en publicar estadística para subgrupos específicos de la población, como las aperturas por nivel educaciones, situación ocupacional o tipo de afiliación al sistema, las variables que identifican estos subgrupos (dominios de interés) son también candidatas para imputación.

Para terminar, cabe recordar que lo más relevante es que el modelo de imputación tiene que ser coherente con el modelo que será ocupado por el investigador en sus análisis (Schafer, 1997). Siendo tantas y tan diversas las preguntas de investigación de los analistas de la EPS, y tantas las alternativas disponibles para el tratamiento de los datos perdidos, se hace necesario establecer una agenda de investigación permanente en torno a este tópico que se desarrolle de manera independiente al proceso bianual de recolección de datos de la EPS.

En este punto, la estrategia implementada por la *Health and Retirement Survey* es nuevamente relevante. Inicialmente, las imputaciones de datos estuvieron a cargo del mismo recolector de datos – el Institute for Social Research de la Universidad de Michigan, quien implementó imputaciones de corte transversal, univariadas, utilizando métodos hot deck y medias condicionadas para las primeras rondas de la HRS. Actualmente, sin embargo, la tarea de imputación de los datos de la HRS está a cargo de la Corporación RAND, quien pone a disposición de los usuarios imputaciones múltiples de corte transversal y longitudinales para un amplio número de variables utilizando modelos más sofisticados. Este debiera ser un modelo a evaluar para futuras implementaciones de imputaciones de datos en la EPS. Para más antecedentes acerca de la estrategia seguida por la HRS ver Pantoja *et al.* (2016) y Hurd *et al.* (2016).

9 Referencias

- Andridge, R. R., & Little, R. J. (2010). A review of hot deck imputation for survey non-response. *International statistical review*, 78(1), 40-64.
- Barzi, F., & Woodward, M. (2004). Imputations of missing values in practice: results from imputations of serum cholesterol in 28 cohort studies. *American Journal of Epidemiology*, 160(1), 34-45.
- Bennett DA. How can I deal with missing data in my study? *Aust N Z J Public Health*. 2001;25(5):464-469.
- Dong, Y., & Peng, C.-Y. J. (2013). Principled missing data methods for researchers. *SpringerPlus*, 2, 222. <http://doi.org/10.1186/2193-1801-2-222>
- Durrant, G. B. (2005). Imputation methods for handling item-nonresponse in the social sciences: a methodological review. *ESRC National Centre for Research Methods and Southampton Statistical Sciences Research Institute. NCRM Methods Review Papers NCRM/002*.
- Eurostat yearbook 2003. *The Statistical guide to Europe, European Commission, Eurostat. ISSN*, 1681-4789.
- Fitzenberger, B., Osikominu, A. & R. Völter (2006). Imputation Rules to Improve the Education Variable in the IAB Employment Subsample. Discussion Paper No. 05-10. Disponible en: <http://doku.iab.de/fdz/events/2005/Osikominu.pdf>
- Grittner, U., Gmel, G., Ripatti, S., Bloomfield, K., & Wicki, M. (2011). Missing value imputation in longitudinal measures of alcohol consumption. *International journal of methods in psychiatric research*, 20(1), 50-61.
- Haziza, D. and Beaumont, J.-F. (2007), *On the Construction of Imputation Classes in Surveys*. *International Statistical Review*, 75: 25-43. doi:10.1111/j.1751-5823.2006.00002.x
- Hurd, M., Meijer, E., Maldoff, M., and Rohwedder, S. (2016). *Improved wealth measures in the Health and Retirement Study*. RAND Labor and Population.
- Little, R. J. (1988). A test of missing completely at random for multivariate data with missing values. *Journal of the American Statistical Association*, 83(404), 1198-1202.
- Madow, W., Nisselson, H., Olkin, I., & Rubin, D. (1983). *Incomplete Data in Sample Surveys*, vols 1-3. *New York*.
- Medina, F., & Galván, M. (2007). estudios estadísticos y prospectivos. *Imputación de datos: Teoría y práctica*. División Estadística y proyecciones Económicas Naciones Unidas. CEPAL.
- Philip Pantoja, Delia Bugliari, Nancy Campbell, Chris Chan, Orla Hayden, Michael Hurd, Regan Main, Joshua Mallett, Colleen McCullough, Erik Meijer, Michael Moldoff, Susann Rohwedder, Patricia St.Clair (2016). *RAND HRS Income and Wealth Imputations, Version P*. RAND Center for the Study of Aging.
- Perez, A., Dennis, R. J., Gil, J. F., Rondón, M. A., & López, A. (2002). Use of the mean, hot deck and multiple imputation techniques to predict outcome in intensive care unit patients in Colombia. *Statistics in medicine*, 21(24), 3885-3896.
- Tang, L., Song, J., Belin, T. R., & Unützer, J. (2005). A comparison of imputation methods in a longitudinal randomized clinical trial. *Statistics in medicine*, 24(14), 2111-2128.

Schonlau, M. (2006), *hotdeckvar*, Stata Program. Version 1.1.0. Downloadable from Stata using "net install".

Schafer JL. Multiple imputation: a primer. *Stat Methods in Med.* 1999;8(1):3–15.

Tabachnick BG, Fidell LS. *Using multivariate statistics*. 6. Needham Heights, MA: Allyn & Bacon; 2012.

The American Association for Public Opinion Research. 2011. *Standard Definitions: Final Dispositions of Case Codes and Outcome Rates for Surveys*. 7th edition. AAPOR.

Twisk, J., & de Vente, W. (2002). Attrition in longitudinal studies: how to deal with missing data. *Journal of clinical epidemiology*, 55(4), 329-337.

10 Anexo

12.1. Número de donantes por celda, imputaciones YTRAB

```
.      table celda0, c(count NRytrab sum NRytrab mean NRytrab)
```

celda0	N(NRytrab)	sum(NRytrab)	mean(NRytrab)
1	9,009	761	.0844711

```
.      table celda1, c(count NRytrab sum NRytrab mean NRytrab)
```

group(eda d_cat sex)	N(NRytrab)	sum(NRytrab)	mean(NRytrab)
1	653	40	.0612557
2	882	50	.0566893
3	1,065	73	.0685446
4	1,249	91	.0728583
5	643	52	.0808709
6	762	76	.0997375
7	832	64	.0769231
8	1,016	110	.1082677
9	518	49	.0945946
10	875	77	.088
11	150	25	.1666667
12	364	54	.1483517

```
.      table celda2, c(count NRytrab sum NRytrab mean NRytrab)
```

20 quantiles of psytrab	N(NRytrab)	sum(NRytrab)	mean(NRytrab)
1	832	42	.0504808
2	745	34	.0456376
3	765	51	.0666667
4	696	46	.066092
5	734	46	.0626703
6	661	37	.0559758
7	635	39	.0614173
8	534	48	.0898876
9	419	31	.0739857
10	393	37	.0941476
11	419	54	.1288783
12	279	39	.1397849
13	353	39	.1104816
14	369	43	.1165312
15	305	31	.1016393
16	278	32	.1151079
17	220	34	.1545455
18	156	30	.1923077
19	137	29	.2116788
20	79	19	.2405063

```
.      table celda3, c(count NRytrab sum NRytrab mean NRytrab)
```

20 quantiles of pmytrab		N (NRytrab)	sum(NRytrab)	mean(NRytrab)
1		337	33	.0979228
2		277	23	.0830325
3		306	22	.0718954
4		324	22	.0679012
5		352	27	.0767045
6		290	29	.1
7		368	19	.0516304
8		379	22	.0580475
9		345	32	.0927536
10		401	31	.0773067
11		489	39	.0797546
12		499	38	.0761523
13		470	45	.0957447
14		524	38	.0725191
15		530	46	.0867925
16		468	31	.0662393
17		629	49	.0779014
18		661	64	.096823
19		692	67	.0968208
20		668	84	.1257485

```
.      table celda4, c(count NRytrab sum NRytrab mean NRytrab)
```

group(ytr abt_hd1)		N (NRytrab)	sum(NRytrab)	mean(NRytrab)
1		249	58	.2329317
2		426	52	.1220657
3		1,024	89	.0869141
4		2,762	151	.0546705
5		1,678	129	.0768772
6		979	81	.0827375
7		560	55	.0982143
8		351	29	.0826211
9		267	31	.1161049
10		164	19	.1158537
11		179	16	.0893855
12		370	51	.1378378

```
.      table celda5, c(count N Rytrab sum N Rytrab mean N Rytrab)
```

group(xti le5 ytrabt_8c)	N (N Rytrab)	sum(N Rytrab)	mean(N Rytrab)
1	79	12	.1518987
2	270	14	.0518519
3	1,078	36	.0333952
4	672	39	.0580357
5	360	29	.0805556
6	186	16	.0860215
7	200	13	.065
8	193	14	.0725389
9	124	15	.1209677
10	215	19	.0883721
11	758	31	.0408971
12	506	27	.0533597
13	319	21	.0658307
14	192	14	.0729167
15	207	15	.0724638
16	243	28	.1152263
17	158	18	.113924
18	215	19	.0883721
19	417	36	.0863309
20	230	26	.1130435
21	129	7	.0542636
22	102	12	.1176471
23	122	21	.1721312
24	137	22	.1605839
25	185	30	.1621622
26	211	23	.1090047
27	371	32	.0862534
28	201	23	.1144279
29	110	10	.0909091
30	61	7	.1147541
31	67	7	.1044776
32	99	13	.1313131
33	129	35	.2713178
34	113	14	.1238938
35	138	16	.115942
36	69	14	.2028985
37	61	14	.2295082
38	19	6	.3157895
39	22	4	.1818182
40	41	9	.2195122

```
.      table celda6, c(count NRytrab sum NRytrab mean NRytrab)
```

group(xti le6 ytrabt_8c)	N(NRytrab)	sum(NRytrab)	mean(NRytrab)
1	307	31	.1009772
2	355	29	.0816901
3	425	19	.0447059
4	103	11	.1067961
5	27	2	.0740741
6	14	3	.2142857
7	7	3	.4285714
8	6	2	.3333333
9	165	24	.1454545
10	251	17	.0677291
11	602	26	.0431894
12	226	17	.0752212
13	73	9	.1232877
14	28	1	.0357143
15	20	1	.05
16	24	2	.0833333
17	107	21	.1962617
18	200	18	.09
19	725	45	.062069
20	382	31	.0811518
21	170	15	.0882353
22	64	5	.078125
23	45	3	.0666667
24	41	2	.0487805
25	54	17	.3148148
26	145	20	.137931
27	634	34	.0536278
28	517	35	.0676983
29	285	24	.0842105
30	152	12	.0789474
31	120	10	.0833333
32	85	8	.0941176
33	42	17	.4047619
34	73	5	.0684932
35	376	27	.0718085
36	450	35	.0777778
37	424	31	.0731132
38	302	34	.1125828
39	426	43	.100939
40	557	72	.1292639

12.2. Número de donantes por celda, imputaciones ALQ

```
.      table celda0, c(count NRalq sum NRalq mean NRalq)
```

celda0	N (NRalq)	sum (NRalq)	mean (NRalq)
1	16,906	2878	.1702354

```
.      table celda2, c(count NRalq sum NRalq mean NRalq)
```

20 quantiles of psalq	N (NRalq)	sum (NRalq)	mean (NRalq)
1	846	31	.036643
2	845	57	.0674556
3	845	64	.0757396
4	846	72	.0851064
5	845	61	.0721893
6	845	86	.1017751
7	846	100	.1182033
8	845	129	.1526627
9	845	113	.1337278
10	845	114	.1349112
11	846	140	.1654846
12	845	156	.1846154
13	845	150	.1775148
14	846	165	.1950355
15	845	163	.1928994
16	845	204	.2414201
17	846	202	.2387707
18	845	266	.3147929
19	845	264	.312426
20	845	341	.4035503

```
.      table celda3, c(count NRalq sum NRalq mean NRalq)
```

20 quantiles of pmalq	N (NRalq)	sum (NRalq)	mean (NRalq)
1	846	137	.1619385
2	845	135	.1597633
3	845	166	.1964497
4	846	167	.1973995
5	845	171	.2023669
6	845	159	.1881657
7	846	140	.1654846
8	845	146	.1727811
9	845	156	.1846154
10	845	134	.1585799
11	846	132	.1560284
12	845	156	.1846154
13	845	154	.1822485
14	846	129	.1524823
15	845	141	.1668639
16	845	123	.1455621
17	846	120	.141844
18	845	122	.1443787
19	845	123	.1455621
20	845	167	.1976331

```
.      table celda8, c(count NRalq sum NRalq mean NRalq)
```

group(alq t_9c)	N (NRalq)	sum (NRalq)	mean (NRalq)
1	1,979	727	.3673573
2	1,510	234	.1549669
3	386	146	.3782384
4	2,045	255	.1246944
5	1,341	306	.2281879
6	2,652	288	.1085973
7	971	204	.2100927
8	2,206	242	.1097008
9	3,816	476	.1247379

```
.      table celda9, c(count NRalq sum NRalq mean NRalq)
```

group(xti le9 alqt_9c)	N (NRalq)	sum (NRalq)	mean (NRalq)
1	334	43	.1287425
2	290	10	.0344828
3	99	9	.0909091
4	357	20	.0560224
5	296	25	.0844595
6	553	18	.0325497
7	232	17	.0732759
8	439	26	.0592255
9	782	56	.0716113
10	305	81	.2655738
11	262	22	.0839695
12	68	21	.3088235
13	378	29	.0767196
14	285	56	.1964912
15	559	46	.0822898
16	205	26	.1268293
17	517	39	.0754352
18	802	56	.0698254
19	348	120	.3448276
20	271	36	.1328413
21	64	29	.453125
22	451	49	.1086475
23	262	53	.2022901
24	566	68	.1201413
25	178	37	.2078652
26	458	40	.0873362
27	783	91	.1162197
28	379	141	.3720317
29	323	60	.1857585
30	78	35	.448718
31	426	67	.157277
32	251	73	.2908367
33	541	71	.1312384
34	180	57	.3166667
35	429	55	.1282051
36	774	123	.1589147
37	613	342	.5579119
38	364	106	.2912088
39	77	52	.6753247
40	433	90	.2078522
41	247	99	.4008097
42	433	85	.1963048
43	176	67	.3806818
44	363	82	.2258953
45	675	150	.2222222

```
.      table celda10, c(count NRalq sum NRalq mean NRalq)
```

group(xti le10 alqt_9c)	N (NRalq)	sum (NRalq)	mean (NRalq)
1	970	253	.2608247
2	614	78	.1270358
3	129	40	.3100775
4	592	77	.1300676
5	277	48	.1732852
6	453	50	.1103753
7	113	17	.1504425
8	139	19	.1366906
9	95	23	.2421053
10	463	188	.4060475
11	452	72	.159292
12	118	47	.3983051
13	565	61	.1079646
14	348	71	.204023
15	653	71	.1087289
16	210	41	.1952381
17	351	31	.0883191
18	221	34	.1538462
19	245	112	.4571429
20	232	44	.1896552
21	81	34	.4197531
22	463	57	.1231102
23	346	82	.2369942
24	663	70	.1055807
25	257	52	.2023346
26	571	59	.1033275
27	523	68	.1300191
28	185	107	.5783784
29	138	26	.1884058
30	38	15	.3947369
31	266	34	.1278196
32	242	68	.2809917
33	577	52	.0901213
34	255	56	.2196078
35	632	68	.1075949
36	1,048	121	.115458
37	116	67	.5775862
38	74	14	.1891892
39	20	10	.5
40	159	26	.163522
41	128	37	.2890625
42	306	45	.1470588
43	136	38	.2794118
44	513	65	.1267056
45	1,929	230	.1192328

12.3. Descripción de base de datos imputada EPS 2015

La base de datos "eps6-impute-data03.dta" tiene 16.906 observaciones y 18 variables. Las variables que comienzan con la sigla "NR" corresponden a los indicadores de los valores imputados (ej. NRteduc), también conocidos como "banderas de imputación" (*imputation flags*). Los códigos "1" están asociados a los valores imputados y los códigos "0" a los valores reportados por los entrevistados. Las variables con los sufijos "_ime" e "_ihd" corresponden a las variables con valores imputados según los métodos de medias/medianas condicionadas (ej. teduc_ime0) y hot deck respectivamente (ej. teduc_ihd0). La variable "IdEncuesta" corresponde al folio único asignado a cada entrevistado la EPS 2015. Con esta variable se puede ligar la base de datos "eps6-impute-data03.dta" con cualquiera de las bases de datos de la EPS 2015.

Tabla A1. Estadísticas descriptivas de variables en la base de datos "eps6-impute-data03.dta"

Variable	Obs	Mean	Std. Dev.	Min	Max
IdEncuesta	16,906	32367.83	28930.25	102	74995
NRteduc	16,906	.0214717	.1449547	0	1
NRteduc_cd	171	1	0	1	1
teduc	16,543	4.707913	1.785577	1	8
teduc_cd	16,714	4.697918	1.786012	1	8
teduc_ihd3	16,906	4.692713	1.787807	1	8
NRytrab	9,009	.0844711	.2781084	0	1
NRytrabt	9,009	.005883	.0764791	0	1
ytrab	8,248	422894.3	442362.4	10000	9000000
ytrabt	8,956	5.183452	2.443729	1	12
ytrabt_hd1	9,009	5.17982	2.441789	1	12
ytrab_ihd6	9,009	425217.8	442596	10000	9000000
NRalq	16,906	.1702354	.3758506	0	1
NRalqt	16,906	.0295753	.1694175	0	1
alq	14,028	184796.6	198257.5	10000	5000000
alqt	16,406	9.476228	3.135566	1	13
alqt_hd7	16,906	9.479179	3.136745	1	13
alq_ihd10	16,906	179573.3	199878.4	10000	5000000

12.4. Libro de Códigos de Base Imputada EPS 2015

```

-----
IdEncuesta                                     Identificador del encuestado
-----

      type:  numeric (long)

      range:  [102,74995]                units:  1
unique values: 16,906                  missing .:  0/16,906

      mean:    32367.8
      std. dev: 28930.3

      percentiles:      10%      25%      50%      75%      90%
                        3040      7309      15133.5      65096      71105
-----

NRteduc                                     (unlabeled)
-----

      type:  numeric (byte)

      range:  [0,1]                      units:  1
unique values: 2                          missing .:  0/16,906

      tabulation:  Freq.  Value
                  16,543  0
                  363    1
-----

NRteduc_cd                                   (unlabeled)
-----

      type:  numeric (byte)

      range:  [1,1]                      units:  1
unique values: 1                          missing .:  16,735/16,906

      tabulation:  Freq.  Value
                  171    1
                  16,735  .
-----

teduc                                     Nivel Educacional - Categorica
-----

      type:  numeric (byte)
      label:  teducl

      range:  [1,8]                      units:  1
unique values: 8                          missing .:  363/16,906

      tabulation:  Freq.  Numeric  Label
                  296      1  Ninguna
                  2,288    2  BasicaInc
                  1,719    3  BasicaCom
                  2,427    4  MediaInc
                  4,761    5  MediaCom
                  2,214    6  TecnicaSup
                  1,647    7  UnivInc
                  1,191    8  UnivCom
                   363      .

```

```
-----
teduc_cd                                Tramo Nivel Educacional - Imp. Cold Deck
-----
```

```

      type: numeric (byte)
      label: teducl

      range: [1,8]                      units: 1
unique values: 8                      missing .: 192/16,906

```

```

tabulation: Freq.  Numeric  Label
              297         1  Ninguna
              2,341       2  BasicaInc
              1,747       3  BasicaCom
              2,454       4  MediaInc
              4,804       5  MediaCom
              2,225       6  TecnicaSup
              1,653       7  UnivInc
              1,193       8  UnivCom
              192         .

```

```
-----
teduc_ihd3                            Tramo Nivel Educacional - Imp. HotDeck: Celda3 PredLineal
-----
```

```

      type: numeric (byte)
      label: teducl

      range: [1,8]                      units: 1
unique values: 8                      missing .: 0/16,906

```

```

tabulation: Freq.  Numeric  Label
              304         1  Ninguna
              2,380       2  BasicaInc
              1,774       3  BasicaCom
              2,488       4  MediaInc
              4,839       5  MediaCom
              2,251       6  TecnicaSup
              1,664       7  UnivInc
              1,206       8  UnivCom

```

```
-----
NRytrab                                (unlabeled)
-----
```

```

      type: numeric (byte)

      range: [0,1]                      units: 1
unique values: 2                      missing .: 7,897/16,906

```

```

tabulation: Freq.  Value
              8,248  0
              761   1
              7,897  .

```

```
-----
NRytrabt                                (unlabeled)
-----
```

```

      type: numeric (byte)

      range: [0,1]                      units: 1
unique values: 2                      missing .: 7,897/16,906

```

```

tabulation: Freq.  Value
              8,956  0
              53    1
              7,897  .

```

```
-----
ytrab                                Monto Ingreso Laboral - Original
-----
```

```

      type:  numeric (float)

      range:  [10000,9000000]          units:  1
unique values: 403                    missing .. 8,658/16,906

      mean:    422894
      std. dev: 442362

percentiles:      10%      25%      50%      75%      90%
                  150000   250000   310000   500000   750000

```

```
-----
ytrabt                                Tramo Ingreso Laboral - Original
-----
```

```

      type:  numeric (byte)

      range:  [1,12]                  units:  1
unique values: 12                    missing .. 7,950/16,906

      mean:    5.18345
      std. dev: 2.44373

percentiles:      10%      25%      50%      75%      90%
                  3         4         5         6         9

```

```
-----
ytrabt_hd1                            Tramo Ingreso Laboral - Imp. HotDeck: Celda1 Edad*Sex
-----
```

```

      type:  numeric (byte)

      range:  [1,12]                  units:  1
unique values: 12                    missing .. 7,897/16,906

      mean:    5.17982
      std. dev: 2.44179

percentiles:      10%      25%      50%      75%      90%
                  3         4         5         6         9

```

```
-----
ytrab_ihd6                            Monto Ingreso Laboral - Imp. HotDeck: Celda6 YTRABT*PredMean
-----
```

```

      type:  numeric (float)

      range:  [10000,9000000]          units:  1
unique values: 403                    missing .. 7,897/16,906

      mean:    425218
      std. dev: 442596

percentiles:      10%      25%      50%      75%      90%
                  140000   250000   318000   500000   760000

```

```
-----
NRalq                                (unlabeled)
-----
```

```

      type:  numeric (byte)

      range:  [0,1]                  units:  1
unique values: 2                    missing .. 0/16,906

      tabulation:  Freq.  Value
                  14,028  0

```

2,878 1

NRalqt (unlabeled)

type: numeric (byte)

range: [0,1] units: 1

unique values: 2 missing : 0/16,906

tabulation: Freq. Value

16,406	0
500	1

alq Alquiler efectivo o imputado

type: numeric (float)

range: [10000,5000000] units: 1

unique values: 185 missing : 2,878/16,906

mean: 184797

std. dev: 198258

percentiles:

10%	25%	50%	75%	90%
70000	100000	150000	200000	300000

alqt Tramo de Alquiler efectivo o imputado

type: numeric (byte)

range: [1,13] units: 1

unique values: 13 missing : 500/16,906

mean: 9.47623

std. dev: 3.13557

percentiles:

10%	25%	50%	75%	90%
5	8	10	12	13

alqt_hd7 Tramo Alquiler Imputado - Imp. HotDeck: Celda7 Tipoviv*Piezas

type: numeric (byte)

range: [1,13] units: 1

unique values: 13 missing : 0/16,906

mean: 9.47918

std. dev: 3.13675

percentiles:

10%	25%	50%	75%	90%
5	8	10	12	13

alq_ihd10 Monto Alquiler Imputado - Imp. HotDeck: Celda10 Tramo*PredMean

type: numeric (float)

range: [10000,5000000] units: 1

unique values: 185 missing : 0/16,906

mean: 179573

std. dev: 199878

percentiles:	10%	25%	50%	75%	90%
	60000	100000	150000	200000	300000

Centro UC

Encuestas y Estudios Longitudinales