



Centro UC
Encuestas y Estudios
Longitudinales

Diseño Muestral y Factores de Expansión de la VI Ronda EPS

Tabla de contenido

1	INTRODUCCIÓN	3
2	ANTECEDENTES	4
3	DETERMINACIÓN DE LA MUESTRA PARA LA VI RONDA EPS	7
4	SELECCIÓN DE LA MUESTRA DE REFRESCO PARA LA VI RONDA EPS	9
4.1	DISEÑO MUESTRAL DE LA ENCUESTA DE PROTECCIÓN SOCIAL	9
4.2	DISEÑO MUESTRAL DE LA EPS 2002	10
4.2.1	POBLACIÓN OBJETIVO	10
4.2.2	DISEÑO METODOLÓGICO	10
4.2.3	MARCO MUESTRAL	11
4.2.4	DISEÑO MUESTRAL POR CLUSTER, ESTRATIFICACIÓN EN DOS ETAPAS	12
4.3	MUESTRA REFRESCO VI RONDA EPS	17
5	RESULTADOS DEL TRABAJO DE CAMPO DE LA VI RONDA EPS	19
6	FACTORES DE EXPANSIÓN	21
6.1	FACTORES DE EXPANSIÓN DE LA MUESTRA DE CORTE TRANSVERSAL	24
6.1.1	FACTOR DE EXPANSIÓN BASE	27
6.1.2	FACTOR DE AJUSTE POR NO RESPUESTA	28
6.1.3	POST-ESTRATIFICACIÓN	50
6.1.4	ANÁLISIS ESTADÍSTICO DEL FACTOR DE EXPANSIÓN	53
6.2	FACTORES DE EXPANSIÓN DE LA MUESTRA LONGITUDINAL	53
6.2.1	PANEL 2002-2004-2006-2009-2015	53
6.2.2	PANEL 2004-2006-2009-2015	54

1 Introducción

La Encuesta de Protección Social (EPS) ha sido diseñada desde el inicio como una encuesta longitudinal, donde la unidad de análisis y seguimiento es el individuo seleccionado. La encuesta fue aplicada por primera vez el año 2002 con representatividad a nivel de afiliados al sistema de pensiones (AFP o INP), su segunda ronda a fines de 2004 y comienzos de 2005, en la cual una nueva muestra de no afiliados al sistema de pensiones fue incorporada junto con una actualización (refresco) de los afiliados al sistema de AFP, para de esta forma en el año 2004 representar toda la población de 18 años y más. Una tercera ronda fue levantada a fines del año 2006 y comienzos del 2007, la cuarta ronda del estudio fue levantada entre Abril y Diciembre de 2009, la quinta ronda fue levantada entre Octubre de 2012 y Agosto de 2013, sin embargo esta ronda fue publicada con reparos debido a los malos resultados del trabajo de campo (baja tasa de respuesta) y a la falta de consistencia con rondas anteriores en la selección de la muestra de refresco. Entre los meses de abril y julio del año 2016 fue levantada la sexta ronda de la encuesta, donde se intentó contactar y entrevistar a todas las personas pertenecientes al panel, independientemente de la última ronda en que hayan sido entrevistados, y además se seleccionó una muestra de refresco para incorporar todas las personas que cumplieron 18 años desde la última actualización de la muestra en el año 2004. Esta encuesta es realizada por encargo de la Subsecretaría de Previsión Social del Ministerio del Trabajo y Previsión Social. El Cuadro N°1.1 a continuación presenta las principales características de las 6 rondas de la EPS realizadas hasta la fecha.

Cuadro N°1.1
Descripción del Trabajo de Campo (EPS2002 – EPS2015)

Ronda EPS	Año	Periodo de Trabajo de Campo	Duración	Tamaño Muestral	Entrevistas logradas
1	2002	Mayo 2002 - Enero 2003	8 meses	30,687	16,309
2	2004	Noviembre 2004 - Mayo 2005	6 meses	21,674	16,727
3	2006	Noviembre 2006 - Julio 2007	8 meses	19,822	16,443
4	2009	Abril 2008 - Abril 2009	12 meses	19,512	14,463
5	2012	Septiembre 2012 - Agosto 2013	11 meses	30,730	16,214
6	2015	Abril 2016 - Julio 2016	4 meses	33,644	16,906

Fuente: Elaboración propia

Nota: Si bien los datos de la V Ronda fueron publicados, no se recomienda el uso estadístico de ellos, dado los problemas en el desarrollo del trabajo de campo y la selección de la muestra de refresco.

El objetivo de este informe es presentar el diseño muestral de la VI Ronda EPS, el que básicamente contempla el seguimiento de la muestra panel y la selección de una muestra de refresco para representar a Junio de 2015 la población de 18 años y más, así como el cálculo de los factores de expansión de corta transversal y longitudinales.

2 Antecedentes

La EPS es una encuesta longitudinal del tipo panel fijo más nacimientos¹. Un **panel fijo** involucra el intento de recolectar datos de encuesta de las mismas unidades en múltiples ocasiones. Después de la selección inicial de la muestra, no se realizan adiciones a la muestra original. En principio, las únicas pérdidas de elegibilidad de la muestra son los fallecidos e impedidos física o mentalmente, en este último caso existen dos tipos de personas “impedidas”, aquellos que de manera temporal se encuentran en una situación que les impide responder, por ejemplo, hospitalización, cárcel, viaje, etc, y aquellos que se encuentran en una situación permanente que les impide responder la encuesta, por ejemplo, discapacidad cognitiva, sordera, etc. Un **panel fijo más nacimientos** es como el panel fijo, con la diferencia de que se van agregando regularmente al panel muestras con “nacimientos” de la población. Típicamente, en cada ronda de recolección de datos se agrega una muestra de las unidades que han “nacido” en la población desde la última vez que se recolectaron datos de la misma. Este diseño es preferible a un panel fijo, si es que hay un número no trivial de nacimientos en una población durante la vida del panel, y si existe el deseo de representar a la población de corte transversal en cada ronda de recolección de datos, así como también a la población longitudinal de “sobrevivientes” de la primera ronda de la encuesta.

En general, los paneles fijos se usan cuando se selecciona una única muestra, y la seguimos para que entregue información acerca de cambios en sus características. El panel fijo, más nacimientos, se utiliza cuando se desea contar además con estimaciones de corte transversal en forma adicional a estimaciones de cambio longitudinal.

En virtud de los antecedentes antes presentados, y de las consideraciones técnicas que definen el tipo de diseño de estudio que es la Encuesta de Protección Social, se propuso la siguiente muestra para la VI Ronda EPS 2015:

1. Seguir a todas las personas que fueron entrevistadas alguna vez en la EPS, independientemente de si hubieran sido o no contactadas en una o más rondas previas. Al ser un panel fijo, esta estrategia es fundamental para la calidad del panel y su permanencia en el tiempo. El siguiente cuadro, muestra la distribución de la muestra panel a la cual se hizo seguimiento en la VI Ronda EPS, bajo los supuestos de tasa de respuesta ahí presentados, se puede proyectar la cantidad de entrevistas del panel a ser realizadas. Naturalmente, se excluye aquellas personas fallecidas

¹ Los nacimientos son las personas que pasan a formar parte de la población objetivo, en el caso de la EPS la población objetivo corresponde a las personas residentes en Chile (en las 15 regiones del país excluyendo isla de Pascua y Juan Fernández) que tengan 18 años y más.

donde se entrevistó a algún sobreviviente, dado que esta persona al fallecer deja de ser elegible en la población objetivo, y justamente se hace una entrevista a sus sobrevivientes para dar un cierre a cada uno de estos casos.

Cuadro N°2.1
Muestra Panel para la VI Ronda EPS

	n	Estimación TR	n proyectado
2002	914	10%	91
2002-2004	725	20%	145
2002-2004-2006	1146	35%	401
2002-2004-2006-2009	3363	43%	1,446
2002-2004-2006-2009-2012	5846	84%	4,911
2002-2004-2006-2012	490	84%	412
2002-2004-2009	339	43%	146
2002-2004-2009-2012	233	84%	196
2002-2006	432	35%	151
2002-2006-2009	544	43%	234
2002-2006-2009-2012	578	84%	486
2002-2006-2012	122	84%	102
2002-2009	233	43%	100
2002-2009-2012	95	84%	80
2004	232	20%	46
2004-2006	328	35%	115
2004-2006-2009	1058	43%	455
2004-2006-2009-2012	1670	84%	1,403
2004-2006-2012	127	84%	107
2004-2009	110	43%	47
2004-2009-2012	64	84%	54
Total	18,649		11,128

Fuente: Elaboración propia

2. Seleccionar una muestra que permitiera representar los “nacimientos” entre el 01 de Enero de 2004 y el 30 de Junio de 2015.


Al ser la EPS un **panel fijo + nacimientos** es importante, en algunas o todas las rondas, refrescar la muestra con la población que se incorpora a la población objetivo. El año 2004, la EPS comenzó a tener representatividad de toda la población de 18 años y más residente en Chile; en dicha ronda se hizo un seguimiento de la muestra de afiliados, que se complementó con una muestra de nuevos afiliados entre Septiembre de 2001 y Diciembre de 2003, y una muestra de no afiliados (a partir de un empadronamiento de viviendas). De esta manera, se logró que la muestra de la EPS representara a la totalidad de la población adulta del país.

En las siguientes rondas (2006 y 2009), no se hizo refresco de la muestra; es decir, las personas que en la población hubieran cumplido 18 años a partir de Enero de 2004 no fueron incorporadas en la muestra; por ello, si bien estas rondas sirven para obtener estadísticas de la dinámica de la población que tenía 18 años y más en el año 2003, no sirven para obtener estadísticas de corte transversal representativas de la población de 18 años y más del país.

Si bien, el año 2012, se hizo un refresco éste no cumplió con las características de diseño de la EPS: fue necesario descartarlo y no se utilizó.

De esta forma, para que la VI Ronda EPS 2015 representara a la población de 18 años y más a Junio de 2015, se seleccionó una muestra representativa de la población que cumplió 18 años entre Enero de 2004 y Junio de 2015. Esto fue equivalente a que, en cada ronda, se hubiera seleccionado una muestra para representar los nacimientos entre rondas (Figura N°2.1).

Figura N°2.1
Esquema Muestra EPS



Fuente: Elaboración propia

3 Determinación de la muestra para la VI Ronda EPS

Como se mencionaba en la sección anterior, una parte de la muestra de la VI Ronda EPS se compuso de las personas del Panel seleccionadas en el año 2002 o en el año 2004, y que fueron entrevistadas al menos en una ronda de la EPS, excluyendo la personas fallecidas. Esta parte de la muestra, estuvo compuesta por 18.649 personas, de las que 15.060 fueron individuos seleccionados y entrevistados en la primera ronda (R1) que se denominarán "Afiados 2002"; 2.673 fueron seleccionados y entrevistados como no afiliados por primera vez en el año 2004 (R2), que se denominarán "No Afiliado 2004"; y 916 fueron seleccionados y entrevistados por primera vez como nuevos afiliados en el año 2004 (R2), que se denominarán "Nuevo Afiliado 2004", estos nombres sirven para identificar la ronda de origen

de selección del entrevistado. La distribución de esta muestra, según presencia en las distintas rondas del estudio, se presentó en el Cuadro N°2.1.

También, como se mencionaba en la sección anterior para la VI Ronda EPS 2015 se propuso seleccionar una muestra de refresco que permitiese (a Junio de 2015) contar con una muestra representativa de las población de 18 años y más; el objetivo, era seleccionar una muestra que representara a la población que cumplió 18 años entre Enero de 2004 y Junio de 2015, considerando que el último refresco (válido) fue realizado en Diciembre de 2003.

A partir del marco muestral administrativo proporcionado por la Subsecretaría de Previsión Social (SPS), se identificó un total de 3.463.970 personas nacidas entre el 01 de Enero de 1986 y el 30 de Junio de 1997, los que corresponden a las personas que cumplieron 18 años entre el 01 de Enero de 2004 y el 30 de Junio de 2015. En el Cuadro N°3.1, se caracteriza este marco muestral según edad, estatus de afiliación al sistema de pensiones, y estatus de defunción.

Cuadro N°3.1

Caracterización Marco Muestral de Personas Nacidas entre el 01 de Enero de 1986 y el 30 de Junio de 1997

Edad al 30/06/2015	N	Afiliados	% Afiliados	Fallecidos	% Fallecidos
18	271,469	78,081	28.8	3,942	1.5
19	275,968	142,351	51.6	4,381	1.6
20	288,233	186,164	64.6	4,812	1.7
21	294,056	210,337	71.5	5,184	1.8
22	300,691	227,399	75.6	5,780	1.9
23	311,034	244,690	78.7	6,507	2.1
24	321,057	262,676	81.8	7,058	2.2
25	325,719	275,607	84.6	7,758	2.4
26	323,809	279,496	86.3	8,278	2.6
27	312,509	272,973	87.3	8,713	2.8
28	298,187	261,151	87.6	8,446	2.8
29	141,238	123,627	87.5	4,188	3
Total	3,463,970	2,564,552	74	75,047	2.2

Fuente: Elaboración propia a partir de "*Base Universo Personas*" proporcionada por la SPS

Para determinar el tamaño de muestra, del refresco a seleccionar, a partir del marco muestral administrativo se consideraron los siguientes antecedentes:

- En el año 2002 se entrevistaron un total de 17.246 personas afiliadas al sistema de pensiones (16.263 entrevistados vivos y 983 entrevistados fallecidos).

- b. En el año 2004 se entrevistaron 3.830 nuevas personas incorporadas a la muestra (940 nuevos afiliados y 2.860 no afiliados)
- c. Así, sumando ambas muestras, se obtiene que estos 21.076 individuos representan a las 14.745.660 personas en el marco muestral administrativo proporcionado por la SPS² que cumplieron 18 años antes de Enero de 2004.
- d. Utilizando esta misma fracción ($21.076/14.745.660=0.0014293$) se obtuvo que en la VI Ronda EPS 2015 deberían entrevistarse (vivos+fallecidos) 4.951 personas pertenecientes a la población de aquellos que cumplieron 18 años y más entre el 01 de Enero de 2004 y el 30 de Junio de 2015, este número se obtiene al aplicar la fracción 0.0014293 a la población de 3,463,970 personas que cumplieron 18 años entre el 01 de Enero de 2004 y el 30 de Junio de 2015.
- e. Teniendo en consideración que la muestra proveniente de registros administrativos no cuenta con la información de contacto ideal o más actualizada, se propuso seleccionar una muestra de 15.000 individuos para el refresco de la VI Ronda EPS 2015.

4 Selección de la muestra de refresco para la VI Ronda EPS

La selección de la muestra, se hizo a través del mismo diseño utilizado en la selección de la muestra de afiliados en el año 2002, el refresco de afiliados y muestra de no afiliados. Se consideraron, como Unidades Primarias de Muestreo, las mismas comunas definidas en el diseño original del año 2002 y replicado en las muestras del año 2004.

4.1 Diseño muestral de la Encuesta de Protección Social

En su diseño original, la EPS, fue pensada como una encuesta de carácter longitudinal para generar una muestra representativa de la población afiliada al sistema de pensiones; en principio, pueden existir afiliados al sistema de pensiones que tengan menos de 18 años de edad (esta restricción de edad no fue impuesta en el diseño original de la muestra del año 2002). El año 2004 se amplió la población objetivo de la EPS, incorporándose a los no afiliados al sistema de pensiones; para la selección de la muestra de no afiliados, se consideró un marco muestral de individuos que, al menos, tuviera 18 años a Diciembre de 2003. De esta manera, a partir del año 2004 la EPS se basa en una muestra que es representativa de la población total de 18 años o más (a Diciembre de 2003).

² El marco muestral proporcionado por la SPS cuenta con 18.603.560 individuos, de los cuales 393.930 nacieron después del 30 de Junio de 1997, los que fueron excluidos ya que tienen menos de 18 años de edad al 30 de Junio de 2015. De los restantes 18.209.630 individuos que tenían 18 años y más al 30 de Junio de 2015, 3.463.970 cumplieron 18 años entre el 01 de Enero de 2004 y el 30 de Junio de 2015, y los restantes 14.745.660 cumplieron 18 años antes del 01 de Enero de 2004.

4.2 Diseño Muestral de la EPS 2002

El diseño metodológico de la selección de la muestra fue realizado por el Departamento de Economía de la Facultad de Ciencias Económicas y Administrativas (Universidad de Chile), institución que tiene una extensa experiencia en el diseño y aplicación de encuestas representativas en Chile. En dicha oportunidad, destacó la participación en el equipo del Departamento de Economía (en calidad de consultor) del Sr. Steven Heeringa³. Asimismo, en el desarrollo de esta tarea, destacó la estrecha coordinación de la contraparte técnica del proyecto conformada por la División de Planificación y Estudios de la Subsecretaría de Previsión Social.

4.2.1 Población objetivo

La población objetivo de la primera ronda de la EPS, contempló a la población chilena afiliada al sistema de pensiones, lo que incluye afiliados al antiguo sistema de pensiones (sistema de reparto o INP) y los afiliados al sistema de pensiones vigente desde 1981 (sistema de capitalización individual o AFP). Se excluyó, explícitamente, de la población objetivo a los miembros de las Fuerzas Armadas y del orden (por contar con su propio sistema de seguridad social); y a un pequeño porcentaje de la población chilena que residen en áreas de difícil acceso.

4.2.2 Diseño Metodológico

La muestra representativa a la que se aplicó la primera encuesta, en el año 2002, se obtuvo a partir del universo de afiliados al sistema de pensiones tanto de capitalización individual como del sistema de reparto (actualmente en extinción), información proporcionada por la Superintendencia de Administradoras de Fondos de Pensiones y por el Instituto de Normalización Previsional.

Para ello, la Superintendencia de AFP y el INP proporcionaron una base de datos *innominada* de todos los afiliados al sistema previsional de capitalización individual, es decir, se omitió todo campo que permitiera la identificación personal de los individuos. Esto constituyó el marco muestral para la primera ronda de la EPS, el año 2002.

Dado que el objetivo del trabajo a realizar es el diseño de una muestra representativa a nivel nacional que permita la sistematización y análisis de la información sobre densidad de cotizaciones en el sistema de capitalización individual, se consideró como población de

³ Experto en diseños muestrales complejos, PhD. y Director de la Unidad de Diseño y Análisis de Encuestas del Institute for Social Research de la Universidad de Michigan

referencia a todos los afiliados desde 1981 hasta agosto de 2001 registrados en los archivos administrativos de las siete AFP que estaban vigentes en el sistema, así como también en el INP.

Se procedió, entonces, a seleccionar una “muestra histórica” de todos los individuos afiliados al sistema en 1981 o después, que a agosto de 2001, estuvieran en alguna de las siguientes condiciones:

- (1) trabajando,
- (2) cesantes o fuera de la fuerza de trabajo,
- (3) pensionados o
- (4) fallecidos.

Es necesario enfatizar que, conceptualmente, los pensionados y un subgrupo de los afiliados fallecidos debían ser incluidos en la población de referencia, por cuanto éstos formaron parte del universo de afiliados al sistema en algún momento del tiempo después de 1981. Su actual pensión de vejez, o de sobrevivencia, que causaron es el resultado del desempeño previsional durante la vida activa. Luego, el no incluirlos en la muestra representativa censuraría los datos relativos al patrón de comportamiento de las cohortes de edad al que esos individuos pertenecen, comprometiendo la representatividad de la muestra seleccionada.

4.2.3 Marco Muestral

La Superintendencia de Administradoras de Fondos de Pensiones y el Instituto de Normalización Previsional proporcionaron al Departamento de Economía información acerca de la totalidad de los afiliados al sistema. En el Cuadro N°4.1 se muestra la composición de la población afiliada, al sistema de pensiones, a Enero de 2002.

El marco muestral -referencia para la selección de la muestra- de 8.074.673 afiliados al sistema de pensiones fue construido a partir de la combinación de las bases de datos proporcionadas por el INP y la Superintendencia de AFP. Utilizando el número de RUT, se chequearon los duplicados, se realizó un análisis para detectar la causa por la cual se generó el duplicado, luego los duplicados fueron eliminados de acuerdo a reglas de decisión determinadas por el equipo de trabajo a cargo del diseño muestral.

Además del número de RUT, el marco muestral contaba con las siguientes variables:

- Sistema de pensiones (AFP o INP)
- Comuna
- Región de residencia
- Estatus en el sistema de pensiones (activo, pensionado o fallecido)

- Sexo
- Edad
- Fecha de afiliación

Cuadro 4.1
Marco Muestral Encuesta de Protección Social

Estatus de Afiliación	AFP	INP	Total
Activos	6,161,463	965,318	7,126,781
Pensionados	362,203	381,321	743,524
Fallecidos	70,149	134,219	204,368
Total	6,593,815	1,480,858	8,074,673

Fuente: Bravo, D., Heeringa, S., Quijada, S. y Vásquez, J. (2011)

4.2.4 Diseño muestral por cluster, estratificación en dos etapas

En contraste con otras encuestas para estudiar la población chilena, como por ejemplo la encuesta CASEN, la selección de la muestra de la EPS no hubiera sido eficiente si es que esta hubiese sido seleccionada utilizando un diseño muestral basado en áreas geográficas, dado que el objetivo era obtener una muestra representativa de afiliados al sistema de pensiones (personas) y no una muestra representativa de hogares.

Una primera alternativa, consistió en seleccionar de manera aleatoria a los individuos afiliados al sistema de pensiones a partir del marco muestral construido usando las bases de datos del INP y de la Superintendencia de AFP; sin embargo, esta metodología hubiera generado una muestra con una excesiva dispersión geográfica y, por lo tanto, menos eficiente en términos de costos.

Así, para obtener una muestra representativa de los afiliados al sistema de pensiones, se consideró como mejor opción la utilización de un diseño en dos etapas estratificado por *clusters* (Kish, 1965, *Survey Sampling*). El diseño muestral, en dos etapas, asegura que cada afiliado elegible en el universo de individuos afiliados *tendrá similar probabilidad de ser seleccionado* y, al mismo tiempo, provee una forma más eficiente de agrupamiento de la muestra.

En consideración con la decisión anterior, y teniendo en cuenta la información disponible para cada afiliado del marco muestral, se seleccionó la variable *comuna* como la unidad más pequeña y fehaciente para formar los clusters (agrupamientos) de los individuos en los registros del sistema de pensiones. El muestreo bietápico, estuvo basado en una primera etapa en selección de comunas. En la segunda etapa, se estratifica a los afiliados en las comunas seleccionadas en la 1º etapa, según diversas características relevantes, tal como se indica más adelante.

Primera Etapa: Selección de comunas

Las comunas pertenecientes al Gran Santiago más San Bernardo y Puente Alto fueron incluidas con probabilidad igual a uno en la primera etapa, así como también las comunas con más de 60.000 habitantes; es decir, las que representan las mayores ciudades de Chile. Coyhaique, como capital de la XI región, también fue incluida con certeza, a pesar de tener una población de 45.485 habitantes en el año 2000⁴.

Por lo tanto, 81 comunas fueron seleccionadas con probabilidad uno lo que (en conjunto) representa aproximadamente un 72% del total de la población chilena⁵.

Del resto de las 285 comunas del país incluidas en la encuesta Casen 2000, 32 fueron elegidas en la primera etapa de selección. Para ello, se estratificaron las comunas según región, ingreso per cápita y población. Esto es, todas las comunas pertenecientes a una misma región se ordenaron según el ingreso per cápita de los habitantes en forma descendente.

Con este orden, se formaron grupos de comunas que en conjunto tuvieron 100.000 habitantes aproximadamente⁶; luego, en cada región, se formaron entre 1 y 6 estratos de comunas con una desviación estándar intra-regional del número de habitantes en cada estrato entre 4.134 y 7.893 y una desviación estándar nacional de 15.216. El que los estratos tengan tamaños poblacionales parecidos, hace que la primera etapa sea estadísticamente más eficiente.

De cada estrato se seleccionó 1 comuna que representara a toda la población de las restantes comunas en el estrato. Entonces, el objetivo primero de la definición de los estratos es agrupar comunas similares entre sí. Dadas las diferencias geográficas y de actividad económica entre las regiones, se intentó respetar los límites regionales formando estratos para comunas dentro de una misma región. Asimismo, como variable relacionada con la condición socio-económica de la comuna, se utilizó el ingreso per cápita y se agruparon las comunas con ingreso per cápita similares⁷.

⁴ La Selección de comunas auto-representativas fue hecha en base a la población de cada comuna reportada en la encuesta CASEN 2000. Coyhaique se incluyó ya que ninguna ciudad de la región de Aysén cuenta con 60.000 o más.

⁵ Según información proveniente de la Encuesta CASEN 2000.

⁶ Además del ingreso per cápita promedio de la comuna, se formaron estratos según años de escolaridad promedio de la población y con la tasa de pobreza. Asimismo, como una alternativa a la agrupación en torno a 100.000 habitantes, se intentó agrupar comunas que sumaran 70.000 individuos. Finalmente, la combinación ingreso per-cápita y 100.000 habitantes resultó ser la combinación con mejores propiedades estadísticas. La información de ingreso per-cápita, escolaridad y tasa de pobreza se obtiene de la Encuesta Casen.

⁷ El ingreso per-cápita de la comuna se estima a través de la encuesta Casen 2000.

Una vez formados los estratos (32), se seleccionó una comuna por estrato con *probabilidad proporcional al tamaño (PPT)* para cada comuna en un estrato. Se procedió de la siguiente forma:

1. Se calculó la población acumulada del estrato.
2. Se generó un número aleatorio, con distribución uniforme entre 1 y el tamaño del estrato.
3. Se ubicó el número aleatorio en los intervalos de población acumulada formados por las comunas del estrato.
4. La comuna seleccionada fue aquella que contenía, en su intervalo, el número aleatorio.

Por ejemplo, supongamos que hemos formado el siguiente estrato de comunas de la quinta región:

Cuadro N°4.2
Ejemplo estratos para la quinta región

Región	Comuna	Población	Ingreso pc	Acum	Inferior	Superior
5	LOS ANDES	55,236	223,843	55,236	1	55,236
5	SANTO DOMINGO	7,450	185,980	62,686	55,237	62,686
5	RINCONADA	6,406	167,489	69,092	62,687	69,092
5	PAPUDO	4,410	159,913	73,502	69,093	73,502
5	EL QUISCO	11,232	156,500	84,734	73,503	84,734
5	PANQUEHUE	6,267	155,970	91,001	84,735	91,001
5	CALLE LARGA	9,179	149,410	100,180	91,002	100,180
5	ALGARROBO	10,555	145,728	110,735	100,181	110,735

Las comunas están ordenadas de mayor a menor ingreso per-cápita. Se crea una columna con la población acumulada, vemos que la última comuna (Algarrobo) acumula una población total del estrato de 110.735; posteriormente, se debe generar un número aleatorio uniforme entre 1 y 110.735, supongamos que este número es igual a 74.567, tenemos que ubicar este número en el intervalo de población de cada comuna, en este caso el número aleatorio se ubica en el intervalo de la comuna El Quisco, por lo cual ésta sería la comuna seleccionada para representar el estrato.

La razón entre el tamaño (población) comunal y el tamaño (población) del estrato corresponde a la probabilidad con la cuál fue seleccionada esta comuna (f_1).

Es importante mencionar, que las dos variables utilizadas en la primera etapa de selección (población comunal e ingreso per cápita), fueron obtenidas a partir de la encuesta CASEN 2000 y no de los datos de los afiliados al sistema previsional. Se adoptó esta estrategia,

debido a dos razones: (1) al momento de seleccionar las comunas no se contaba con los registros de los afiliados para conocer el real tamaño de cada comuna; y, más importante, (2) los datos institucionales de los afiliados que se obtuvieron para la selección de individuos (segunda etapa de la selección de la muestra), no incluían la condición socio-económica, como por ejemplo, el ingreso, los años de educación, etc.

Segunda Etapa: Selección de los afiliados

La segunda etapa de selección, consistió en elegir a los afiliados dentro de cada comuna seleccionada (ya fuera auto-representativa o no auto-representativa). A diferencia de la primera etapa, en este proceso se utilizaron los datos proporcionados por las Administradoras de Fondos de Pensiones. Un tamaño muestral del orden de 20.000 casos, parecía razonable considerando la indudable y clara importancia para el análisis y diseño de políticas relativas al sistema de pensiones. Esta fue, de hecho, la recomendación de tamaño muestral realizada por el Dr. Steve Heeringa, más allá del tamaño de la población chilena o de cada país en general, el tamaño muestral debe ser tal que permita llegar al nivel de desagregación y detalle necesario para obtener la representatividad adecuada de ciertos grupos de interés a la hora de fundamentar y evaluar propuestas específicas. El tamaño de la muestra de referencia fue de 30.000 casos para considerar las no respuestas o problemas de direcciones.

Así, considerando el número deseado de afiliados a seleccionar y el total de afiliados en las comunas seleccionadas, se calculó la tasa de muestreo total:

$$f = \frac{n \text{ muestral}}{N \text{ poblacional}} = f_1 \cdot f_2 = 0.003802$$

Ya calculado f_1 , se obtiene f_2 que representa la tasa a la que se seleccionará a los individuos en cada comuna.

Finalmente, dentro de cada comuna seleccionada, se ordena a los afiliados según las siguientes variables:

- (1) condición del afiliado (activo, pensionado, fallecido);
- (2) sexo y
- (3) edad o fecha de afiliación para los afiliados al sistema antes o después de 1981, respectivamente.

Una vez que los afiliados estuvieron ordenados según estos criterios, se seleccionaron aplicando el intervalo de selección para cada comuna, definido como el recíproco de f_2 .

Siguiendo el ejemplo anterior, la comuna El Quisco fue seleccionada para representar el estrato 1 de la quinta región, la probabilidad con la que esta comuna fue seleccionada es:

$$f_1 = \frac{11.232}{110.735} = 0.1014$$

De esta forma, la probabilidad con la que los individuos de esta comuna deben ser seleccionados es:

$$f_2 = \frac{f}{f_1} = \frac{0.00367}{0.1014} = 0.0362$$

En la comuna hay un total de 11.232 individuos, por lo cual se deben seleccionar un total de 406 personas.

$$n = 11.232 \times 0.0362 = 406$$

Estos 406 casos se pueden seleccionar mediante un muestreo aleatorio simple sistemático, para esto el intervalo (paso) de selección corresponde al inverso de f_2 , en este caso es 28. Entonces, una vez ordenados los individuos de la comuna seleccionada de acuerdo a los criterios antes mencionados, se genera un número aleatorio uniforme entre 1 y 28, supongamos que sale el número 11, esto significa que la persona 11 de este listado es la primera seleccionada de esta comuna, luego la segunda persona seleccionada es la persona en la posición $11+28=39$, y así sucesivamente hasta barrer todo el listado. El resultado, será una muestra de 406 individuos.

Se debe tener presente que, en la primera fase, la selección de las comunas de la formación de los estratos se hace a partir de la mejor estimación que se tenga de la población por comunas y sus características, razón por la cual se utilizó la Encuesta Casen 2000. Dado que esta era la única información disponible a nivel de comunas, con información sociodemográfica que permite una mejor agrupación de comunas para la conformación de estratos homogéneos.

Luego, en la segunda etapa, se procede a seleccionar a los individuos del listado proveniente de los registros administrativos (marco muestral); por esto, se requiere ajustar la población de cada comuna del estrato a las poblaciones de las comunas según el marco muestral donde efectivamente se hizo la selección, ya que la población efectiva esta dada por este marco muestral. Así, a partir de la población efectiva en las comunas, estratos se realiza el cálculo de f_1 , f_2 , paso y n de cada comuna.

Es importante señalar, que la metodología de selección de la muestra en dos etapas podría ser menos eficiente que una selección aleatoria estratificada. Sin embargo, para este proyecto en particular, el efecto de seleccionar a los afiliados por *clusters* (comuna seleccionada en la primera etapa) es atenuado por dos características del diseño: primero, más del 70% de los afiliados residen en las comunas auto representativas y, dado que no se realiza más agrupamiento entre comunas, esta gran mayoría de afiliados no está sujeta a agrupamientos adicionales; segundo, para el restante 30% de la población, que se encuentra en las comunas no auto-representativas, no se hizo un agrupamiento geográfico localizado dentro de cada comuna, esto es, la comuna es la unidad geográfica más pequeña que se utilizó. En los diseños muestrales multi-etápicos, además de la primera etapa de selección de comunas, se utiliza una segunda etapa de muestreo según áreas locales de residencia dentro de cada comuna (por ejemplo, los segmentos en las encuestas Casen). Esta etapa adicional, aumenta la varianza muestral e introduce la correlación entre estas últimas unidades de agrupación. En el archivo Excel "Factor de expansión Base EPS.xls" en la hoja "Selecc_R1" se presenta la selección de las comunas, la muestra objetivo en cada una de ellas, y las probabilidades de selección de primera y segunda etapa.

En resumen, se espera que la pérdida en precisión del diseño en dos etapas sea muy pequeña en relación a las significativas ganancias en términos de costo-eficiencia de la muestra finalmente seleccionada.

4.3 Muestra refresco VI Ronda EPS

La selección de la muestra de refresco para la VI Ronda EPS 2015, se hizo a través del mismo diseño utilizado en la selección de la muestra de afiliados en el año 2002, y el refresco de afiliados y muestra de no afiliados del año 2004: utilizando, como Unidades Primarias de Muestreo, las mismas comunas definidas en el diseño original del año 2002 y replicado en las muestras del año 2004.

Para la selección de la muestra de refresco, se solicitó a registro civil información de direcciones y comuna para el marco muestral de 3.463.970 personas nacidas entre el 01 de Enero de 1986 y el 30 de Junio de 1997.

El Registro Civil, entregó de vuelta una base de datos con el identificador de comuna para 3.331.257 observaciones⁸. De las cuales 12.864 no estaban en la petición (marco muestral) original, por lo cual fueron eliminadas. De esta forma, para 145.577 observaciones no se tuvo información proveniente del Registro Civil.

⁸ El nombre de la base de datos es EPS_COMUNAS_MUESTRA.dta

La Subsecretaría de Previsión Social, también envió información de direcciones obtenidas del marco muestral administrado por la institución para complementar la información faltante; se lograron complementar 3.452 direcciones que no estaban disponibles en Registro Civil.

El resultado final, se presenta en el Cuadro N°4.3.

Cuadro N°4.3
Información de direcciones y comuna disponible para el marco muestral

Fuente	N	%
Registro Civil	3,318,393	95.8%
SPS	3,452	0.1%
No tiene info	142,125	4.1%
Total	3,463,970	100%

Fuente: Elaboración propia.

Con la información disponible por comuna se procedió a calcular la población de elegibles en cada una de ellas para, con esta información, poblar la planilla de selección de la muestra de refresco⁹.

La planilla de selección contiene las comunas que fueron utilizadas originalmente en el diseño muestral de la EPS, separando aquellas que fueron seleccionadas con probabilidad unitaria y aquellas que fueron seleccionadas para representar un estrato. La población distribuida en estas comunas suma un total de 3.250.561.

Como se mencionaba en la sección anterior, se determinó un tamaño muestral para el refresco de 15 mil personas con lo cual la fracción de muestreo fue de 0.00461459.

Utilizando esta información, y la información de población de cada comuna y de los estratos, se procedió a calcular f_1 (que es 1 para las comunas auto-representadas, e igual a la población de la comuna sobre la población del estrato para las comunas no auto-representadas). Determinado f_1 , se obtiene f_2 , dividiendo f en f_1 . El inverso de f_2 , determina el paso utilizado para la selección¹⁰.

La muestra final enviada a terreno fue de 14.995 personas, esta muestra se denominó "Refresco 2015".

⁹ El nombre de este archivo es "Factor de expansión Base EPS.xls2, en la hoja "Selecc_R6"

¹⁰ La selección se hace a través del do-file selección_refresco_6aRonda.do

5 Resultados del trabajo de campo de la VI Ronda EPS

El trabajo de campo de la VI Ronda de la EPS fue realizado entre los meses de abril y julio del año 2016. El Cuadro N°5.1 muestra un resumen del resultado del trabajo de campo en cuanto a la muestra contactada, la muestra lograda y la cantidad de entrevistados vivos, según tipo de muestra, distinguiendo entre el panel y el refresco, y dentro del panel separando a las personas según la presencia en rondas anteriores del estudio.

Cuadro N°5.1
Resultados del trabajo de campo VI Ronda EPS

	Muestra			Contacto			Logro			Entrevistados vivos			Fallecidos con cuestionario			Fallecidos sin cuestionario			Impedidos		
	n	n	%	n	n	%	n	n	%	n	n	%	n	n	%	n	n	%	n	n	%
Muestra Panel	18,649	12,352	66.2	11,163	59.9		10,128	57.5		692	3.7		271	1.5		72	0.4				
2002-2004-2006-2009-2012	5,846	4,837	82.7	4,553	77.9		4,399	77.3		108	1.8		21	0.4		25	0.4				
2002-2004-2006-2009	3,363	2,180	64.8	1,959	58.3		1,567	52.7		290	8.6		86	2.6		16	0.5				
2002-2004-2006-2012	490	327	66.7	298	60.8		290	60.2		6	1.2		1	0.2		1	0.2				
2002-2004-2006	1,146	502	43.8	405	35.3		328	30.7		50	4.4		24	2.1		3	0.3				
2002-2004-2009-2012	233	185	79.4	171	73.4		163	72.4		6	2.6		2	0.9			0.0				
2002-2004-2009	339	193	56.9	163	48.1		138	43.9		21	6.2		4	1.2			0.0				
2002-2004	725	275	37.9	202	27.9		164	23.9		20	2.8		15	2.1		3	0.4				
2002-2006-2009-2012	578	439	76.0	401	69.4		387	68.6		6	1.0		3	0.5		5	0.9				
2002-2006-2009	544	297	54.6	257	47.2		226	44.1		21	3.9		8	1.5		2	0.4				
2002-2006-2012	122	75	61.5	66	54.1		63	52.9		2	1.6		1	0.8			0.0				
2002-2006	432	164	38.0	115	26.6		92	22.5		14	3.2		6	1.4		3	0.7				
2002-2009-2012	95	67	70.5	57	60.0		56	59.6			0.0		1	1.1			0.0				
2002-2009	233	109	46.8	88	37.8		77	34.7		7	3.0		2	0.9		2	0.9				
2002	914	240	26.3	156	17.1		120	13.7		13	1.4		21	2.3		2	0.2				
2004-2006-2009-2012	1,670	1,392	83.4	1,328	79.5		1,292	79.1		24	1.4		7	0.4		5	0.3				
2004-2006-2009	1,058	677	64.0	625	59.1		485	52.8		85	8.0		50	4.7		5	0.5				
2004-2006-2012	127	88	69.3	79	62.2		78	61.9		1	0.8			0.0			0.0				
2004-2006	328	140	42.7	104	31.7		83	27.0		6	1.8		15	4.6			0.0				
2004-2009-2012	64	49	76.6	44	68.8		42	67.7		2	3.1			0.0			0.0				
2004-2009	110	50	45.5	44	40.0		37	35.9		6	5.5		1	0.9			0.0				
2004	232	66	28.4	48	20.7		41	18.2		4	1.7		3	1.3			0.0				
Muestra Refresco	14,995	7,753	51.7	6,844	45.6		6,778	45.4		27	0.2		7	0.0		32	0.2				
Total	33,644	20,105	59.8	18,007	53.5		16,906	51.9		719	2.1		278	0.8		104	0.3				

Fuente: Elaboración propia

Del total de 33.644 personas pertenecientes a la muestra de la VI Ronda, se lograron contactar 20.105 personas, de las cuales 12.352 fueron personas pertenecientes al panel y 7.753 personas pertenecientes a la muestra de refresco.

Se considera como logro tanto a las personas contactadas y entrevistadas, como aquellas que se logró un contacto pero no fue posible entrevistar porque se encontraba fallecida, o impedida física y/o mentalmente para responder la encuesta. De esta forma, el porcentaje de logro fue de un 53.5% (18.007 personas), siendo en el panel 59.9% y en el refresco 45.6%.

Con respecto a los entrevistados vivos, se lograron un total de 16.906 entrevistas: 10.128 de la muestra panel y 6.778 de la muestra refresco. Como porcentaje de la muestra, pero excluyendo a los fallecidos o impedidos, esto representa un 51.9%.

El Cuadro N°5.2 presenta las tasas de respuesta, cooperación y rechazo según tipo de muestra y participación longitudinal.

La tasa de respuesta (RR) corresponde a la cantidad de entrevistados sobre el total de personas en la muestra, pero excluyendo las personas fallecidas o impedidas para

responder, así en el caso de la sexta ronda de la EPS 2015 la tasa de respuesta en la muestra panel fue de 57.5% y en la muestra de refresco 45.4%; cabe destacar, que existe gran variabilidad en la tasa de respuesta en la muestra panel dependiendo de la presencia o participación que han tenido las personas a lo largo del estudio. Por ejemplo, para aquellas personas que ingresaron a la muestra en el año 2002 y han participado en todas las rondas del estudio, la tasa de respuesta es 77.3%, y 79.1% en las personas que ingresaron en el año 2004 y han participado en todas las rondas; pero en aquellas personas que, por ejemplo, sólo habían sido entrevistadas en el año 2002, la tasa de respuesta es 13.7%.

Cuadro N°5.2
Tasa de respuesta, cooperación y rechazo de la VI Ronda EPS

	Responde	RR	COOP	Rechaza	REF
	N	%	%	N	%
Muestra Panel	10,128	57.5	89.5	917	5.2
2002-2004-2006-2009-2012	4,399	77.3	93.9	251	4.4
2002-2004-2006-2009	1,567	52.7	87.6	173	5.8
2002-2004-2006-2012	290	60.2	90.9	21	4.4
2002-2004-2006	328	30.7	77.2	71	6.6
2002-2004-2009-2012	163	72.4	92.1	12	5.3
2002-2004-2009	138	43.9	82.1	24	7.6
2002-2004	164	23.9	69.2	49	7.1
2002-2006-2009-2012	387	68.6	91.1	33	5.9
2002-2006-2009	226	44.1	85.0	23	4.5
2002-2006-2012	63	52.9	87.5	9	7.6
2002-2006	92	22.5	65.2	36	8.8
2002-2009-2012	56	59.6	84.8	9	9.6
2002-2009	77	34.7	78.6	15	6.8
2002	120	13.7	58.8	54	6.2
2004-2006-2009-2012	1,292	79.1	95.3	55	3.4
2004-2006-2009	485	52.8	90.3	33	3.6
2004-2006-2012	78	61.9	89.7	7	5.6
2004-2006	83	27.0	69.7	25	8.1
2004-2009-2012	42	67.7	89.4	5	8.1
2004-2009	37	35.9	86.0	5	4.9
2004	41	18.2	69.5	7	3.1
Muestra Refresco	6,778	45.4	88.2	570	3.8
Total	16,906	51.9	89.0	1487	4.6

Fuente: Elaboración propia.

Nota: se excluyen de los cálculos a las personas fallecidas (CDF=231) o impedidas (CDF=232).

La tasa de cooperación (COOP) corresponde a la proporción de personas entrevistadas sobre el total de personas contactadas; en este caso, también se excluyeron del denominador a las personas fallecidas o impedidas, de esta forma la tasa de cooperación corresponde a las personas entrevistadas sobre el total de personas contactadas y con posibilidades de contestar la encuesta. En la VI Ronda, se obtuvo una tasa de cooperación de 89%, siendo 89.5% en la muestra panel y 88.2% en la muestra refresco, nuevamente se presentan diferencias importantes en la tasa de cooperación en la muestra panel dependiendo de la

participación que han tenido los entrevistados a lo largo del estudio, en aquellas personas que han participado en todas las rondas desde su selección, la tasa de cooperación es cercana al 95%.


La tasa de rechazo (REF) corresponde a la proporción de la muestra que rechaza el estudio, en este caso también se excluyen del denominador a los fallecidos e impedidos. En la VI Ronda de la EPS 2015, se obtuvo una tasa de rechazo del 4.6%, siendo 5.2% en la muestra panel y 3.8% en la muestra refresco. En este caso, también se obtienen menores tasa de rechazo en la muestra panel (con mayor participación a lo largo del estudio).

6 Factores de expansión

Para que los análisis y estudios basados en encuestas con diseño muestral probabilístico tengan validez sobre toda la población objetivo, se debe utilizar un ponderador en la estimación de cualquier variable de interés, que da cuenta del número de personas de la población que representa un individuo que participa en dicha encuesta. Este ponderador se conoce como “factor de expansión”. Así, dado los datos recolectados para una muestra s^t , se pueden obtener estimaciones para la población U^t (por ejemplo, el promedio de la variable y^t que fue medida en el momento t), para esto se utiliza el factor de expansión.

En el Diagrama N° 6.1, podemos apreciar cómo la muestra a través del factor de expansión logra representar a la población. En este ejemplo, se obtiene una muestra estratificada, en el primer estrato se seleccionan 10 individuos de una población de 100, de esta forma la probabilidad de selección es 0.10, el factor de expansión entonces es el inverso de la probabilidad de selección, así cada uno de los 10 individuos seleccionados en este estrato tiene un factor de expansión igual a 10, al sumar los ponderadores de estos 10 individuos se obtiene la población de 100. En el estrato 2 también se seleccionan con probabilidad 0.10 y el factor de expansión es 10, los 5 individuos de la muestra suman sus ponderadores a la población de 50. En el tercer estrato se selecciona una muestra de 4 de una población de 80, la probabilidad de selección es 0.05, y el ponderador es 20, al sumas la muestra ponderada se obtiene la población de 80.

Diagrama N° 6.1: Factor de expansión para representar la población



Fuente: Factores de expansión en encuestas longitudinales, J. Vásquez (2016). CISS-BID.

En una encuesta longitudinal, en general, se calculan factores de expansión de corte transversal y factores de expansión longitudinales. El factor de expansión de corte transversal considera toda la muestra de personas entrevistadas, en el momento t , para representar a la población en este mismo momento del tiempo.

Sin embargo, el factor de expansión longitudinal considera la muestra de personas entrevistada en distintos momentos del tiempo que pueden ser de interés para el análisis longitudinal, para representar a la población; por ejemplo, si una encuesta panel tiene rondas en 2006, 2009, 2012 y 2015, un posible factor de expansión longitudinal es para representar las personas entrevistadas en 2009 y 2015, teniendo como objetivo analizar la dinámica de variables claves y sus cambios en estos años. Otro análisis de interés podría ser la muestra entrevistada en todos los años, para estudiar cambios en variables en todos estos años.

En el Diagrama N° 6.2, se presentan los distintos factores de expansión que es posible obtener sólo considerando las tres primeras rondas del estudio de la Encuesta de Protección Social. En la primera ronda, en el año 2002, se seleccionó una muestra para representar a las personas afiliadas al sistema de pensiones, así, en esta primera ronda sólo fue necesario computar un factor de expansión que es para representar el corte transversal de afiliados al sistema de pensiones en el año 2002. En este caso los factores de expansión representan


a la población de afiliados del país únicamente. En el año 2004, se hizo un seguimiento de las personas entrevistadas en el año 2002, además se agregó muestra de refresco para capturar los nuevos afiliados al sistema de pensiones y a los no afiliados al sistema de pensiones; de esta forma, la muestra de panel entrevistada en el año 2002 más la muestra de refresco tenía por objetivo representar la población de 18 años y más del año 2004. Así, en la segunda ronda, se computó el factor de expansión de corte transversal para representar la población de 18 años y más al 2004, y además se construyó el factor de expansión para la muestra longitudinal de afiliados entrevistados en el año 2002 y 2004. El año 2006 no se adicionó muestra de refresco y los esfuerzos estuvieron concentrados en entrevistar, nuevamente, la muestra de personas ya entrevistada en el año 2004 y/o 2002. Es así como, en el año 2006, es posible calcular los factores de expansión de corte transversal para representar la población de 18 años y más al año 2006 (considerando a todas las personas entrevistadas en esta ronda), y además es posible calcular tres factores de expansión longitudinal: factor longitudinal afiliados 2002-2004-2006, factor de expansión longitudinal afiliados 2002-2006 y factor de expansión longitudinal población 18 años y más 2004-2006. Cuando se emplea cada uno de estos factores de expansión, dependerá de los objetivos de análisis; en el primer caso, interesa estudiar variables que cambian en el tiempo para la población de afiliados en el sistema de pensiones (por ejemplo, cómo ha cambiado la densidad de cotización en estos tres años); en el segundo caso, también nos interesa obtener estadísticas para la población de afiliados al sistema de pensiones pero estudiar cambios en las variables entre el año 2002 y 2006, la diferencia con el primer caso se da (principalmente) porque en las encuestas longitudinales la muestra que responde todas las rondas es menor que la muestra que responde dos de ellas, una consecuencia de esto es que resulta mayor el tamaño muestral al estudiar cambios sólo entre 2002 y 2006, otro ejemplo podría ser el caso que justo se haya implementado una política pública en el año 2004 y queremos ver su efectividad analizando el antes y el después; el tercer factor de expansión, es para la población total de 18 años y más, ya que en el año 2004 en la EPS se incorporó la muestra de no afiliados y el estudio pasó a ser representativo de la población de 18 años y más, en este caso por ejemplo, nos podría interesar estudiar cambios en la tasa de participación en el sistema de pensiones entre 2004 y 2006.

Mientras más rondas se hayan levantado del estudio, existen mayores posibilidades de cálculo de factores de expansión longitudinal; en general, se definen sólo algunos de ellos (los que resulten claves para el análisis de interés), como en los ejemplos antes mencionados.

Para la VI Ronda de la EPS 2015, se calcularon tres factores de expansión:

- (a) Factor de expansión de corte transversal
- (b) Factor de expansión longitudinal 2002-2004-2006-2009-2015
- (c) Factor de expansión longitudinal 2004-2006-2009-2015

Diagrama Nº 6.2
Factores de expansión Encuesta de Protección Social
2002, 2004 y 2006



Fuente: Factores de expansión en encuestas longitudinales, J. Vásquez (2016). CISS-BID.

6.1 Factores de expansión de la muestra de corte transversal

Los factores de expansión para la muestra de corte transversal de la VI Ronda EPS 2015, se calcularon tomando como factor base el inverso de la probabilidad de selección ajustado por la no respuesta en la ronda de origen del seleccionado. Así, en esta VI Ronda se disponen de 4 tipos de muestras (según su origen):

- 1- Afiliados 2002: corresponde a la muestra de afiliados al sistema de pensiones seleccionados para ser entrevistados en la primera ronda de la EPS, realizada en el año 2002. El factor de expansión base, corresponde al inverso de la probabilidad de selección ajustado por la no respuesta que se obtuvo en cada una de las comunas relativas a los conglomerados seleccionados; este ajuste por no respuesta, es simplemente el ratio entre la muestra seleccionada en la comuna y la muestra lograda en la comuna. (Ver Hoja "Fact_Sel_R1" en el archivo Excel "Factor de Expansión Base EPS.xls").
- 2- No Afiliados 2004: corresponde a la muestra de personas no afiliadas al sistema de pensiones, seleccionadas para ser entrevistadas en la segunda ronda de la EPS realizada en el año 2004, y así completar una muestra representativa de la población de 18 años y más. El factor de expansión base, al igual que en el caso anterior, corresponde al inverso de la probabilidad de selección ajustado por la no respuesta

en la ronda de origen del seleccionado (2004); este ajuste por no respuesta es, simplemente, el ratio entre la muestra seleccionada en la comuna y la muestra lograda en la comuna. (Ver Hoja "Fact_Sel_R2noafi" en el archivo Excel "Factor de Expansión Base EPS.xls").

- 3- Nuevos Afiliados 2004: corresponde a la muestra de afiliados entre Septiembre de 2001 y Diciembre de 2003, se trata del refresco de la muestra de afiliados seleccionados en la primera ronda; el factor de expansión base, al igual que en el caso anterior, corresponde al inverso de la probabilidad de selección ajustado por la no respuesta en la ronda de origen del seleccionado (2004). Como en los casos anteriores, este ajuste por no respuesta es simplemente el ratio entre la muestra seleccionada en la comuna y la muestra lograda en la comuna. (Ver Hoja "Fact_Sel_R2nuevos" en el archivo Excel "Factor de Expansión Base EPS.xls").
- 4- Refresco 2015: corresponde a la muestra de refresco seleccionada para compensar el envejecimiento del panel que fue actualizado, por última vez, en Diciembre de 2003; de esta forma, esta muestra representa a la población de personas que cumplieron 18 años de edad entre Enero de 2004 y Junio de 2015 (de esta forma se pudo contar, en la VI Ronda EPS 2015, con una muestra que representa a la población de 18 años y más a Junio de 2015). El factor de expansión base, al igual que en los casos anteriores, corresponde al inverso de la probabilidad de selección ajustado por la no respuesta de la comuna de selección. (Ver Hoja "Fact_Sel_R6" en el archivo Excel "Factor de Expansión Base EPS.xls").

El Cuadro N° 6.1 presenta la muestra nominal, la muestra contactada y los entrevistados, según tipo de muestra.

Cuadro N° 6.1

Distribución de la muestra nominal, contactados y entrevistados según tipo de muestra

Tipo de muestra	Muestra nominal	Vivos no impedidos		Fallecidos	Impedidos
		Contacto	Respuesta/Contacto		
Afiliados 2002	15,060	9,069	8,070	759	62
No afiliados 2004	2,673	1,714	1,591	194	9
Nuevos afiliados 2004	916	534	467	10	1
Refresco 2015	14,995	7,687	6,778	34	32
Total	33,644	19,004	16,906	997	104

Fuente: Elaboración propia

Se lograron un total de 18.007 casos, el logro incluye los entrevistados vivos más las personas fallecidas (con o sin entrevista a familiar aplicada a algún sobreviviente) y las personas impedidas física o mentalmente para responder la encuesta.

Los entrevistados vivos alcanzaron un total de 16.906 casos, los que se distribuyeron entre 10.128 de la muestra panel y 6.778 de la muestra refresco. A estos 16.906 se les calculó el

ponderador o factor de expansión para representar la población de 18 años y más a Junio de 2015; para lo cual, se procedió de la siguiente manera:

- 1- Se obtuvo el factor de expansión base, según el origen de la selección (2002, 2004 o 2015).
- 2- Para cada uno de los tipos de muestras, por separado, se estimó un modelo de no respuesta para generar los ajustes por no respuesta en base a la metodología de *propensity*. La estimación de este modelo contempló: primero, estimar un modelo de contacto en función de variables explicativas que estuvieran disponibles tanto para los entrevistados en esta ronda como para los no entrevistados¹¹, y posteriormente estimar un modelo de respuesta condicional en el contacto.
- 3- Estimados ambos modelos, e independientemente de si la persona fue entrevistada o no en la VI Ronda 2015, se obtuvo la probabilidad de contacto y la probabilidad de respuesta condicional en contacto predicha para cada persona en función de sus características; el producto de estas probabilidades, corresponde a la probabilidad predicha de respuesta incondicional en contacto o *propensity*. Ambos modelos se estimaron con el factor de expansión base a través de la metodología *logit*.
- 4- Se construyeron deciles de la muestra utilizando el *propensity*, y se calculó el valor promedio del *propensity* en cada decil; el inverso de este promedio, correspondió al ajuste por no respuesta.
- 5- Una vez completado este proceso, para cada tipo de muestra, se expandió la muestra total (sin distinguir por tipo) utilizando el factor de expansión base ajustado por la no respuesta, y se comparó la distribución de la muestra expandida con las proyecciones de poblaciones del INE a Junio 2015. Se crearon celdas por tramos de edad, sexo y regiones, y se calcularon ajustes de post-estratificación en cada una de estas celdas. Las celdas utilizadas son las siguientes:
 - Sexo
 - o Hombre
 - o Mujer
 - Tramos de edad:
 - o 18-29
 - o 30-49
 - o 50+
 - Regiones:
 - o XV-I-II-III
 - o VI

¹¹ Se utilizaron como regresores: sexo, tramos de edad, nivel educacional, tipo de sistema de pensiones (AFP o INP), si la persona se encuentra pensionada o no, regiones y las presencias en cada una de las rondas de la EPS.

- V
- VI
- VII
- VIII
- IX
- X-XIV
- XI-XII
- RM

En el Cuadro N°6.2 se presenta la población proyectada a Junio de 2015 según el Instituto Nacional de Estadísticas (INE), para cada una de las celdas definidas.

Cuadro N° 6.2
Proyección de la población de 18 años y más a Junio 2015 según sexo, edad y región

	Hombres			Mujeres			Total
	18-29	30-49	50+	18-29	30-49	50+	
XV-I-II-III	155,397	233,339	182,770	139,713	206,558	180,633	1,098,410
IV	76,496	104,869	100,144	74,664	105,824	111,497	573,494
V	182,078	245,834	247,911	173,823	246,196	298,855	1,394,697
VI	86,320	127,210	129,152	83,512	125,861	135,463	687,518
VII	101,281	139,801	145,340	100,902	143,507	155,334	786,165
VIII	213,452	282,549	282,356	210,206	294,983	316,692	1,600,238
IX	100,261	130,083	129,693	100,466	135,689	143,527	739,719
X-XIV	123,531	176,446	163,533	118,054	171,506	174,410	927,480
XI-XII	26,243	41,819	37,720	23,365	37,937	36,238	203,322
RM	714,882	1,069,099	895,242	699,665	1,086,319	1,084,731	5,549,938
Total	1,779,941	2,551,049	2,313,861	1,724,370	2,554,380	2,637,380	13,560,981

Fuente: Elaboración propia en base a proyecciones del INE a Junio de 2015

A continuación, se describen cada una de estas etapas en mayor detalle.

6.1.1 Factor de expansión base

Tal como se mencionaba anteriormente, el factor de expansión base corresponde al inverso de la probabilidad de selección en la muestra de origen de la persona incluyendo un ajuste por no respuesta (comunal) geográfico en la unidades primarias de muestreo aplicado en la primera ronda.

En la planilla Excel "Factor de expansión Base EPS.xls", se adjuntan las planillas de selección para cada una de las rondas 2002, 2004 y 2015 que define el factor de expansión base para cada una de las personas en la muestra de la VI Ronda 2015 dependiendo de su origen (selección, por primera vez, para participar en el estudio).

6.1.2 Factor de ajuste por no respuesta

Dos métodos son los más populares para ajustar por no respuesta. El primero consiste en establecer celdas homogéneas mediante el cruce de variables auxiliares, y calcular la tasa de respuesta en cada una de estas celdas, el inverso de esta tasa de respuesta corresponde al factor de ajuste por no respuesta; este método es utilizado cuando no existen muchas variables disponibles tanto para los que responden como los que no responden, entonces la generación de las celdas es simple, sin embargo, una desventaja de este método es que se requiere una cantidad mínima de observaciones en cada celda (lo que supone una gran cantidad de observaciones a ser distribuidas en cada celda). El segundo método, corresponde al de propensity score que, en vez de formar celdas, estima mediante un modelo de probabilidad la propensión a que una persona responda; este método tiene la ventaja de utilizar mayor cantidad de información (todas las variables disponibles). A continuación se presentan ambos métodos, aunque para la VI Ronda EPS 2015 se utilizó el método propensity por las ventajas en cuanto a la cantidad de variables a utilizar.

Método de ajuste por celdas

Como se mencionaba en el párrafo anterior, este método se utiliza cuando se dispone de una cantidad razonable de observaciones pero no existe mucha información (variables) disponible tanto para las personas que responden como las que no responden.

Este método consiste en separar la muestra en $c = 1, 2, \dots, C$ grupos excluyentes entre ellos, o *celdas de ajuste por no respuesta*, que se forman en base a una o más variables auxiliares que deben estar disponibles tanto para las personas que responden la encuesta como para las que no responden; las celdas, son formadas a través de la tabulación cruzada de estas variables y deben ser homogéneas con respecto a las mismas: el objetivo, es formar celdas donde las unidades que la conforman tengan la misma propensión a responder.

Para cada celda se construye un factor de ajuste por no respuesta, el que se obtiene de dividir la suma de los ponderadores base de toda la muestra entre la suma de los ponderadores base de las unidades que responden. Sea $\sum_{i \in n_c} w_i^{base}$ la suma de los ponderadores base de las unidades i , tanto que responden como que no responden, en la celda c , y sea $\sum_{i \in r_c} w_i^{base}$ la suma de los ponderadores base de las unidades i que responden en la celda c , entonces el factor de ajuste por no respuesta de todas las unidades i en la celda c que responden será:

$$f_{nr,c} = \frac{\sum_{i \in n_c} w_i^{base}}{\sum_{i \in r_c} w_i^{base}}$$

e igual a cero para los que no responden.

De esta forma, el ponderador ajustado por no respuesta es igual a:

$$w^{nr} = f_{nr,c} \cdot w^{base}$$

Este método requiere que el tamaño de muestra sea lo suficientemente grande como para que cada celda tenga una estimación estable de la tasa de respuesta. Cuando las celdas tienen pocas observaciones el factor de ajuste por no respuesta es muy elevado, y se pueden producir bastantes diferencias entre los factores de ajustes de las distintas celdas; esto, generalmente, aumentará el error cuadrático medio, tanto a través del sesgo como la varianza de los factores. Por ello, existen ciertas reglas que usualmente se utilizan a la hora de formar las celdas: (1) que el número mínimo de personas que responden en cada celda no sea menor a 20 y (2) tienen que haber menos personas que no responden que las que responden de manera que el factor de ajuste por no respuesta sea menor a 2 (Lepidus & Williams, 2001).

Método de Propensity Score

Esta metodología fue sugerido por David, Little, Samuhel, & Triest en 1983, como una simple extensión de la teoría de Propensity Score de Rosenbaum y Rubin (1983), desarrollada en el contexto de matching para estudios observacionales.

La respuesta a una encuesta es modelada como la realización de un proceso de variable latente, se tiene una variable indicador (o binaria) que toma valor 1 si la persona responde la encuesta y 0 sino responde la encuesta:

$$R_i = \begin{cases} 1 & \text{Si responde} \\ 0 & \text{No responde} \end{cases}$$

Y existe una variable latente R_i^* que es continua pero no observada, de manera tal que en el proceso de decisión individual de responder o no la encuesta, uno observa que la persona responde la encuesta si $R_i^* > 0$, se puede pensar que esta variable latente representa la "motivación" de la persona a responder la encuesta. Esta variable latente, puede ser modelada linealmente en función de variables explicativas y un error:

$$R_i^* = x_i' \beta + u_i$$

De esta forma, la probabilidad de que la unidad i responda la encuesta se puede modelar de la siguiente manera:

$$\begin{aligned} p(x_i) &= \Pr(R_i^* > 0) = \Pr(x_i' \beta + u_i > 0) \\ &= \Pr(u_i > -x_i' \beta) \\ &= 1 - F(-x_i' \beta) = F(x_i' \beta) \end{aligned}$$

Donde $F(\cdot)$ es una función de probabilidad acumulada; bajo el supuesto de que es normal el modelo de respuesta binaria, el modelo se denomina "PROBIT", y en el caso de que sea logística: "LOGIT".

La ventaja de esta metodología es que puede utilizar toda la información disponible, tanto para las personas que responden como para las que no responden, no existiendo limitaciones por el tamaño de las celdas (como en la metodología anterior). Además, el factor de ajuste por no respuesta obtenido por esta metodología tenderá a ser más estable y "suave".

Una vez estimado el modelo para la probabilidad de responder, ya sea por la metodología PROBIT o LOGIT, es posible predecir para cada una de las personas (independientemente de que respondan o no) cuál es la probabilidad de responder dadas sus características (x_i):

$$\hat{p}(x_i) = F(x_i' \hat{\beta})$$

El *propensity*, puede ser utilizado de dos maneras para obtener el factor de ajuste por no respuesta:

- (1) De manera individual, considerando el inverso de $\hat{p}(x_i)$ como factor de ajuste por no respuesta.
- (2) Estratificando o creando celdas a partir de $\hat{p}(x_i)$, y usar el mismo factor de ajuste para todas las unidades en la celda; por ejemplo, el inverso de la tasa de respuesta de la celda o el inverso del propensity promedio de la celda. Usualmente, se recomiendan 5 celdas; cuando las muestras son más grandes, se pueden crear más celdas y ayudar a que estas sean más homogéneas en las variables explicativas y propensity score.

Al igual que con la metodología de celdas, el ponderador ajustado por no respuesta es igual a:

$$w^{nr} = f_{nr} \cdot w^{base}$$

En la VI Ronda EPS 2015, se utilizó la metodología de propensity para obtener los ajustes por no respuesta; para ello, se estimaron por separado los modelos de respuesta de cada uno de los tipos de muestras antes definidos. En todos los casos, se estimó primero un modelo de probabilidad de contacto mediante la metodología logit y, luego, un modelo de probabilidad de respuesta condicional en contacto.

6.1.2.1 Afiliados 2002

Una parte de la muestra panel de la VI Ronda EPS 2015, se compuso de afiliados 2002 que fueron seleccionados para participar por primera vez en el estudio dicho año. Esta parte de la muestra panel, consistió de 15.060 personas (de las que 821 era personas fallecidas o impedidas física y/o mentalmente para responder la encuesta, por lo que fueron excluidas para la estimación de los modelos de probabilidad de contacto y de respuesta condicional en contacto). Así, se consideró una sub-muestra de 14.239 personas de la muestra de afiliados EPS 2002 para la estimación de los ajustes por no respuesta con la metodología *propensity*.

Para el modelo de probabilidad de contacto y de probabilidad de respuesta condicional en contacto, se utilizaron variables explicativas que están disponibles tanto para las personas que responden la encuesta como las que no responden; se asume que, estas variables explicativas, tienen algún grado de causalidad y correlación con la probabilidad de respuesta. En el caso de los afiliados 2002, fue posible obtener información del marco muestral administrativo y de la primera ronda del estudio (EPS 2002); las variables utilizadas fueron las siguientes:

- Tramos de edad: utilizando la edad calculada, a Junio de 2015, en base a la fecha de nacimiento obtenida del marco muestral administrativo se definieron los siguientes tramos de edad, de manera tal que esta muestra quede bien distribuida en estas categorías de edad:
 - 18-44 años (categoría base en la estimación del modelo)
 - 45-54 años
 - 55-64 años
 - 65 años y más
- Región: se generan 15 variables binarias (o dummies) para cada una de las regiones del país, se excluye del modelo la dummy correspondiente a la región metropolitana quedando esta categoría como base para la interpretación del modelo. La región corresponde a la última región de entrevista, la que está asociada a la dirección de contacto para la VI Ronda EPS 2015.
- Sexo: se utiliza la variable binaria que toma valor 1 para los hombres y 0 para las mujeres, de esta forma la categoría base son las mujeres. Esta información se obtiene del marco administrativo.
- Nivel educacional: se definieron tres niveles educacionales en base la información de la EPS 2002:

- Menor a media completa (categoría base en la estimación del modelo)
 - Media completa
 - Superior
- Participación en ronda anteriores: se generan categorías de acuerdo a la participación de las personas (entrevistas) en las rondas 2002, 2004, 2006, 2009 y 2012, luego se definen variables dummies para cada una de estas categorías:
 - 2002-2004-2006-2009-2012 (categoría base en la estimación del modelo)
 - 2002-2004-2006-2009
 - 2002-2004-2006-2012
 - 2002-2004-2006
 - 2002-2004-2009-2012
 - 2002-2004-2009
 - 2002-2004
 - 2002-2006-2009-2012
 - 2002-2006-2009
 - 2002-2006-2012
 - 2002-2006
 - 2002-2009-2012
 - 2002-2009
 - 2002
 - Pensionado: dummy que toma valor 1 si la persona se encuentra pensionada a Junio de 2015, esta información se obtiene del marco muestral administrativo.
 - Afiliado AFP: dummy que toma valor 1 si la persona se encuentra afiliada al sistema de AFP y 0 si se encuentra afiliada al sistema de INP a Junio de 2015, esta información se obtiene del marco muestral administrativo.
 - Número de cotizaciones en la cuenta obligatoria del sistema de AFP: cantidad de cotizaciones en la cuenta obligatoria del sistema de AFP a Junio de 2015, esta información se obtiene del marco muestral administrativo.

El Cuadro N° 6.2, muestra los efectos marginales estimados de cada una de estas variables explicativas sobre la probabilidad de contacto y sobre la probabilidad de respuesta condicional en contacto de las personas de la muestra "Afiliados 2002".

Los resultados sobre la probabilidad de contacto muestran que:

- Los hombres tienen 3.4 puntos porcentuales menos de probabilidad de contacto que las mujeres.

- Las personas entre 45 y 54 años de edad tienen 5.6 puntos porcentuales más de probabilidad de contacto que las personas menores de 45 años, las personas entre 55 y 64 años 9.4 puntos porcentuales más, y las personas de 65 años y más 5.4 puntos porcentuales más de probabilidad de contacto; así, las personas menores de 45 años de edad son el grupo con menor probabilidad de contacto.
- Las personas de la región XIV son las únicas que no tienen diferencia significativa en la probabilidad de contacto con respecto a las personas de la región metropolitana, en todas las otras regiones la probabilidad de contacto es superior; la región con mayor probabilidad de contacto, es la XI donde en promedio tienen 16.9 puntos porcentuales más de probabilidad de contacto que las personas de la región metropolitana.
- El número de cotizaciones obligatorias en el sistema de AFP, a Junio de 2015, no es una variable estadísticamente significativa para explicar la probabilidad de contacto.
- El sistema de pensiones (AFP o INP), tampoco es una variable estadísticamente significativa en explicar la probabilidad de contacto.
- El estar pensionado aumenta en 10.5 puntos porcentuales la probabilidad de contacto.
- El nivel de participación en rondas anteriores, en general, es una variable estadísticamente significativa. Solamente las personas que han participado en las rondas 2002-2004-2009 y 2012 no muestran una diferencia significativa con respecto a las que han participado en todas las rondas, todas las otras categorías tienen menor probabilidad de contacto.

Con respecto a la probabilidad de respuesta condicional en contacto:

- El sexo y la edad, no son variables significativas en la probabilidad de respuesta condicional en contacto.
- A mayor nivel educacional, menor es la probabilidad de respuesta condicional en contacto: las personas con educación media completa tienen 4.1 puntos porcentuales menos de probabilidad y las personas con educación superior 4.7 puntos porcentuales menos de probabilidad, que las personas con educación menor a media completa, de responder una vez que fueron contactadas.

Cuadro N° 6.3

Efectos marginales sobre probabilidad de contacto y respuesta condicional en contacto
Tipo de muestra: Afiliados 2002

	Probabilidad de contacto		Probabilidad de respuesta/contacto	
	Efecto marginal	p-value	Efecto marginal	p-value
Hombre	-0.034	0.001	0.001	0.862
45-54 años	0.056	0.000	0.010	0.222
55-64 años	0.094	0.000	0.010	0.294
65 años y más	0.054	0.008	-0.028	0.100
Media completa	-	-	-0.041	0.000
Superior	-	-	-0.047	0.000
I	0.161	0.000	0.014	0.546
II	0.080	0.002	-0.024	0.239
III	0.145	0.000	-0.003	0.883
IV	0.084	0.000	0.033	0.005
V	0.034	0.024	-0.019	0.090
VI	0.109	0.000	0.020	0.077
VII	0.125	0.000	-0.002	0.901
VIII	0.048	0.001	0.014	0.116
IX	0.082	0.000	0.016	0.235
X	0.126	0.000	0.020	0.063
XI	0.169	0.000	0.074	0.000
XII	0.121	0.001	0.003	0.901
XIV	0.050	0.124	-0.034	0.254
XV	0.095	0.007	0.006	0.826
Nº Cotizaciones	0.000	0.267	0.000	0.814
Pensionado	0.105	0.000	0.043	0.000
Afiliado AFP	-0.003	0.889	-0.001	0.952
2002-2004-2006-2009	-0.274	0.000	-0.077	0.000
2002-2004-2006-2012	-0.203	0.000	-0.036	0.125
2002-2004-2006	-0.436	0.000	-0.186	0.000
2002-2004-2009-2012	-0.065	0.139	-0.045	0.194
2002-2004-2009	-0.322	0.000	-0.140	0.000
2002-2004	-0.479	0.000	-0.292	0.000
2002-2006-2009-2012	-0.089	0.001	-0.029	0.144
2002-2006-2009	-0.322	0.000	-0.112	0.000
2002-2006-2012	-0.254	0.000	-0.055	0.249
2002-2006	-0.479	0.000	-0.325	0.000
2002-2009-2012	-0.137	0.021	-0.105	0.061
2002-2009	-0.413	0.000	-0.171	0.002
2002	-0.560	0.000	-0.384	0.000
N	14,239		9,069	
Pseudo-R2	0.1531		0.0902	
Probabilidad predicha	0.65		0.91	

Fuente: Elaboración propia

Notas: las estimaciones se hacen con los factores de expansión base, mediante metodología logit. El modelo de probabilidad de contacto no incluye las dummies de nivel educacional.

- Las personas de la IV y XI regiones son las únicas que en promedio tienen mayor probabilidad de respuesta condicional en contacto que las personas de la región metropolitana: 3.3 puntos porcentuales y 7.4 puntos porcentuales más, respectivamente.
- El número de cotizaciones en el sistema de AFP y el sistema de pensiones (AFP o INP), no son variables estadísticamente significativas.

- Las personas pensionadas tienen 4.3 puntos porcentuales más de probabilidad de respuesta condicional en contacto que las personas no pensionadas.
- Con respecto a la participación en rondas anteriores de la EPS, las personas que participaron en la ronda 2012 pero no en todas las rondas, no muestran diferencia significativa en la probabilidad de respuesta condicional en contacto con respecto a las personas que han respondido en todas las rondas. Mientras más lejana fue la última vez que participaron, menor es la probabilidad de respuesta condicional en contacto.

Una vez estimados ambos modelos, se utiliza cada uno de ellos para obtener la probabilidad predicha de contacto y la probabilidad predicha de respuesta condicional en contacto en función de las características de cada persona; estas probabilidades, se predicen tanto para los que respondieron la VI Ronda 2015 como para los que no respondieron:

Probabilidad predicha de contacto:

$$\hat{p}_C(x_i) = F(x_i' \hat{\beta}_C)$$

Probabilidad predicha de respuesta condicional en contacto:

$$\hat{p}_{R/C}(x_i) = F(x_i' \hat{\beta}_{R/C})$$

Donde $\hat{\beta}_C$ y $\hat{\beta}_{R/C}$, corresponden a los coeficientes estimados en los modelos logit respectivos.

Luego, la probabilidad de respuesta incondicional en contacto (*propensity*) es igual a:

$$propensity = \hat{p}_R(x_i) = \hat{p}_C(x_i) \cdot \hat{p}_{R/C}(x_i)$$

El *propensity*, es utilizado para hacer grupos de individuos con tasa de respuesta homogénea; esto se hace mediante la construcción de deciles, a través del valor calculado del *propensity*¹².

El Cuadro N° 6.3 muestra los valores mínimos, máximos y promedio de los *propensity* en cada decil.

¹² Para la construcción de los deciles también se utiliza la muestra ponderada con los factores de expansión base.

Cuadro Nº 6.3
Máximo, mínimo y promedio del *propensity* por decil
Tipo de muestra: Afiliados 2002

Decil	Mínimo	Promedio	Máximo
1	0.069	0.135	0.193
2	0.193	0.253	0.321
3	0.321	0.378	0.421
4	0.421	0.464	0.507
5	0.507	0.556	0.604
6	0.604	0.648	0.683
7	0.683	0.710	0.736
8	0.736	0.757	0.780
9	0.780	0.800	0.818
10	0.818	0.849	0.938

Fuente: Elaboración propia

El inverso de los valores promedio del propensity, por decil, es utilizado como factor de ajuste por no respuesta; este ajuste, es el mismo para todas las personas del decil. Luego, el factor de expansión ajustado por la no respuesta se obtiene de multiplicar el factor de expansión base (de cada persona) por este factor de ajuste.

El do-file "Factores de Ajuste por No Respuesta_Afiliados 2002.do", realiza la estimación de los modelos y cálculo de los factores de ajuste por no respuesta.

6.1.2.2 Nuevos afiliados 2004

Otro componente de la muestra panel de la VI Ronda EPS 2015, fue la sub-muestra de nuevos afiliados 2004 correspondiente a las personas que fueron seleccionadas para participar por primera vez en el estudio el año 2004 (con el objeto de refrescar la muestra de afiliados seleccionada en el año 2002). Esta sub-muestra consistió de 916 personas, de las que 11 se encontraban fallecidas o impedidas física y/o mentalmente para responder la encuesta (por lo que fueron excluidas para la estimación de los modelos de probabilidad de contacto y de respuesta condicional en contacto); de esta manera, la sub-muestra utilizada para la estimación de los ajustes por no respuesta con la metodología *propensity* fue de 905 personas correspondiente a nuevos afiliados 2004.

Para los modelos de probabilidad de contacto y de probabilidad de respuesta condicional en contacto, se utilizaron variables explicativas que están disponibles tanto para las personas que responden la encuesta como las que no responden, y que a su vez tienen algún grado de causalidad y correlación con la probabilidad de respuesta. Para esta sub-muestra, fue posible obtener información del marco muestral administrativo, así como de la ronda EPS 2004. Las variables utilizadas fueron las siguientes:

- Tramos de edad: utilizando la edad calculada a Junio de 2015 en base a la fecha de nacimiento obtenida del marco muestral administrativo, se definieron los siguientes tramos de edad, de manera tal que esta muestra quedara bien distribuida en estos grupos:
 - 18-34 años (categoría base en la estimación del modelo)
 - 35-44 años
 - 45 y más años

Estos tramos de edad, se diferencian con respecto a los de la muestra "Afiliados 2002" porque se definen de acuerdo a las características de esta muestra: es más joven que la anterior.

- Región: se generaron 15 variables binarias (o dummies) para cada una de las regiones del país, se excluye del modelo la dummy correspondiente a la región metropolitana quedando esta categoría como base para la interpretación del modelo. La región corresponde a la última región de entrevista, la que está asociada a la dirección de contacto para la VI Ronda EPS 2015.
- Sexo: se utiliza la variable binaria que toma valor 1 para los hombres y 0 para las mujeres, de esta forma la categoría base son las mujeres. Esta información se obtiene del marco administrativo.
- Nivel educacional: se definieron tres niveles educacionales en base la información de la EPS 2004:
 - Menor a media completa (categoría base en la estimación del modelo)
 - Media completa
 - Superior
- Año de la última entrevista: corresponde a la última ronda de la EPS (la más reciente) en que la persona fue contactada y entrevistada, se generan dummies para los años:
 - 2012 (categoría base en la estimación del modelo)
 - 2009
 - 2006
 - 2004

Debido a que esta sub-muestra consta de solo 900 observaciones (aproximadamente), no se pueden generar dummies con tanto detalle de participación longitudinal como en el caso de la muestra "Afiliados 2002".

- Número de cotizaciones en la cuenta obligatoria del sistema de AFP: cantidad de cotizaciones en la cuenta obligatoria del sistema de AFP a Junio de 2015, esta información se obtiene del marco muestral administrativo.

En este caso, no se utilizó la variable pensionado ya que es una muestra más joven que la de "Afiliados 2002", tampoco se utilizó la variable de sistema de afiliación ya que todos son pertenecientes al sistema de AFP.

El Cuadro Nº 6.4, muestra los efectos marginales estimados de cada una de estas variables explicativas sobre la probabilidad de contacto y sobre la probabilidad de respuesta condicional en contacto de las personas de la sub-muestra "Nuevos afiliados 2004".

Los resultados sobre la probabilidad de contacto muestran que:

- Los hombres tienen 11.5 puntos porcentuales menos de probabilidad de contacto que las mujeres.
- Las personas entre 35 y 44 años de edad, tienen 14.1 puntos porcentuales más de probabilidad de contacto que las personas menores de 35 años, y las personas de 45 años y más tienen 12.8 puntos porcentuales más de probabilidad de contacto.
- Las personas de las regiones II, X, XI, XII, XIV y XV no tienen diferencias significativas en la probabilidad de contacto, respecto a las personas de la región metropolitana. Las personas residentes en las otras regiones, tienen mayor probabilidad de contacto que las personas de la región metropolitana.
- El número de cotizaciones obligatorias en el sistema de AFP a Junio de 2015, en esta sub-muestra, es estadísticamente significativo y de signo negativo lo que indica que mientras mayor es el número de cotizaciones menor es la probabilidad de contacto.
- Las personas entrevistadas por última vez en el año 2009 tienen 32.4 puntos porcentuales menos de probabilidad de contacto que las personas que fueron entrevistadas por última vez en el año 2012, las que fueron entrevistadas por última vez en el 2006 tiene 36.2 puntos porcentuales menos, y las que fueron entrevistadas únicamente en el 2004 tienen 54 puntos porcentuales menos de probabilidad de contacto que las personas entrevistadas por última vez en el año 2012.

Con respecto a la probabilidad de respuesta condicional en contacto:

- Los hombres tienen 6.8 puntos porcentuales menos de probabilidad de respuesta condicional en contacto que las mujeres.
- Las personas entre 35 y 44 años de edad tienen 9.7 puntos porcentuales más de probabilidad de respuesta condicional en contacto que las personas menores de 35 años, y las personas de 45 años y más tienen 5.8 puntos porcentuales más de probabilidad de respuesta condicional en contacto que las personas menores de 35 años de edad.

- El nivel educacional no es estadísticamente significativo al predecir la probabilidad de respuesta condicional en contacto.
- El número de cotizaciones en el sistema es estadísticamente significativo, e indica que a mayor número de cotizaciones mayor es la probabilidad de respuesta condicional en contacto.
- Las personas que respondieron por última vez en el 2009, no tienen diferencia significativa en la probabilidad de respuesta condicional en contacto respecto a las personas entrevistadas por última vez en el año 2012. Las personas entrevistadas en 2006 por última vez, tienen 17.1 puntos porcentuales menos de probabilidad de respuesta condicional en contacto que las personas entrevistadas por última vez en el 2012, y las personas entrevistadas sólo en el 2004, 24 puntos porcentuales menos.

Cuadro Nº 6.5

Efectos marginales sobre probabilidad de contacto y respuesta condicional en contacto
Tipo de muestra: Nuevos afiliados 2004

	Probabilidad de contacto		Probabilidad de respuesta/contacto	
	Efecto marginal	p-value	Efecto marginal	p-value
Hombre	-0.115	0.050	-0.068	0.037
35-44 años	0.141	0.063	0.097	0.000
45 años y más	0.128	0.053	0.058	0.023
Media completa	-	-	-0.061	0.187
Superior	-	-	-0.048	0.188
I	0.394	0.074	-	-
II	-0.003	0.105	-	-
III	0.367	0.065	-	-
IV	0.131	0.097	-	-
V	0.096	0.075	-	-
VI	0.060	0.089	-	-
VII	0.208	0.065	-	-
VIII	0.100	0.069	-	-
IX	0.092	0.083	-	-
X	-0.046	0.106	-	-
XI	-0.234	0.230	-	-
XII	0.244	0.154	-	-
XIV	0.245	0.122	-	-
XV	0.100	0.143	-	-
Nº Cotizaciones	-0.001	0.000	0.001	0.004
2009	-0.324	0.047	-0.054	0.164
2006	-0.362	0.064	-0.171	0.035
2004	-0.540	0.036	-0.240	0.086
N	905		534	
Pseudo-R2	0.1848		0.1136	
Probabilidad predicha	0.55		0.91	

Fuente: Elaboración propia

Notas: las estimaciones se hacen con los factores de expansión base mediante metodología logit. El modelo de probabilidad de contacto, no incluye las dummies de nivel educacional. Y el modelo de probabilidad de respuesta condicional en contacto no incluye las dummies regionales, dado que estas no son estadísticamente significativas.

Una vez estimados ambos modelos se empleó cada uno de ellos para obtener la probabilidad predicha de contacto y la probabilidad predicha de respuesta condicional en contacto en función de las características de cada persona, estas probabilidades se predicen tanto para los que respondieron la VI Ronda 2015 como para los que no respondieron:

Probabilidad predicha de contacto:

$$\hat{p}_C(x_i) = F(x_i' \hat{\beta}_C)$$

Probabilidad predicha de respuesta condicional en contacto:

$$\hat{p}_{R/C}(x_i) = F(x_i' \hat{\beta}_{R/C})$$

Donde $\hat{\beta}_C$ y $\hat{\beta}_{R/C}$, corresponden a los coeficientes estimados en los modelos logit respectivos.

Luego, la probabilidad de respuesta incondicional en contacto (*propensity*) es igual a:

$$propensity = \hat{p}_R(x_i) = \hat{p}_C(x_i) \cdot \hat{p}_{R/C}(x_i)$$

El *propensity* es utilizado para hacer grupos de individuos con tasa de respuesta homogénea, esto se hace mediante la construcción de deciles a través del valor calculado del *propensity*.

El Cuadro N° 6.6 muestra los valores mínimos, máximos y promedio de los *propensity* en cada decil.

Cuadro N° 6.6
Máximo, mínimo y promedio del *propensity* por decil
Tipo de muestra: Nuevos afiliados 2004

Decil	Mínimo	Promedio	Máximo
1	0.030	0.090	0.141
2	0.146	0.179	0.215
3	0.216	0.261	0.295
4	0.295	0.332	0.385
5	0.386	0.436	0.477
6	0.478	0.516	0.557
7	0.557	0.603	0.625
8	0.625	0.677	0.723
9	0.724	0.764	0.798
10	0.799	0.840	0.945

Fuente: Elaboración propia

El inverso de los valores promedios del *propensity*, por decil, son utilizados como factor de ajuste por no respuesta; este ajuste es el mismo para todas las personas del decil. Luego,

el factor de expansión ajustado por la no respuesta se obtiene de multiplicar el factor de expansión base por este factor de ajuste.

El do-file "Factores de Ajuste por No Respuesta_Nuevos Afiliados 2004.do" realiza la estimación de los modelos y cálculo de los factores de ajuste por no respuesta.

6.1.2.3 No afiliados 2004

El último componente de la muestra panel de la VI Ronda EPS 2015, fue la sub-muestra de no afiliados 2004 corresponde a las personas que fueron seleccionadas para participar por primera vez en el estudio en el año 2004 (pensados como complemento de la muestra de afiliados, para obtener una muestra representativa de la población de 18 años y más al año 2004). Esta sub-muestra consistió de 2.673 personas, de las que 203 se encontraban fallecidas o impedidas física y/o mentalmente para responder la encuesta (estas personas fueron excluidas para la estimación de los modelos de probabilidad de contacto y de respuesta condicional en contacto). De esta forma, se utilizó una muestra de 2.470 personas de la muestra de no afiliados 2004 para la estimación de los ajustes por no respuesta con la metodología *propensity*.

Para el modelo de probabilidad de contacto y de probabilidad de respuesta condicional en contacto, se utilizaron variables explicativas que estaban disponibles tanto para las personas que respondieron la encuesta como las que no respondieron, y que se asume tienen algún grado de causalidad y correlación con la probabilidad de respuesta. Para esta muestra, fue posible obtener información del marco muestral administrativo y de la primera ronda del estudio (EPS 2004). Las variables utilizadas, fueron las siguientes:

- Tramos de edad: utilizando la edad calculada a Junio de 2015 en base a la fecha de nacimiento obtenida del marco muestral administrativo se definen los siguientes tramos de edad, para que esta muestra quede bien distribuida en los grupos de edad:
 - 18-34 años (categoría base en la estimación del modelo)
 - 35-44 años
 - 45-54 años
 - 55-64 años
 - 65 años y más
- Región: se generan 15 variables binarias (o dummies) para cada una de las regiones del país, se excluye del modelo la dummy correspondiente a la región metropolitana quedando esta categoría como base para la interpretación del modelo. La región corresponde a la última región de entrevista, la que está asociada a la dirección de contacto para la VI Ronda EPS 2015.

- Sexo: se utiliza la variable binaria que toma valor 1 para los hombres y 0 para las mujeres, de esta forma la categoría base son las mujeres. Esta información se obtiene del marco administrativo.
- Nivel educacional: se definen tres niveles educacionales en base a la información de la EPS 2004:
 - Menor a media completa (categoría base en la estimación del modelo)
 - Media completa
 - Superior
- Participación en rondas anteriores: se generan categorías de acuerdo a la participación de las personas (entrevistas) en las rondas 2004, 2006, 2009 y 2012, luego se definen variables dummies para cada una de estas categorías:
 - 2004-2006-2009-2012 (categoría base en la estimación del modelo)
 - 2004-2006-2009
 - 2004-2006-2012
 - 2004-2006
 - 2004-2009-2012
 - 2004-2009
 - 2004
- Pensionado: dummy que toma valor 1 si la persona se encuentra pensionada a Junio de 2015, esta información se obtiene del marco muestral administrativo.
- Afiliado AFP: dummy que toma valor 1 si la persona se encuentra afiliada al sistema de AFP y 0 si se encuentra afiliada al sistema de INP a Junio de 2015, esta información se obtiene del marco muestral administrativo. A pesar de que esta muestra fue originalmente seleccionada como no afiliados al sistema de pensiones, en el transcurso del estudio se podrían haber afiliado; por tanto, esta variable representa su situación a Junio de 2015 en el sistema de pensiones.
- Número de cotizaciones en la cuenta obligatoria del sistema de AFP: cantidad de cotizaciones en la cuenta obligatoria del sistema de AFP a Junio de 2015, esta información se obtiene del marco muestral administrativo. A pesar de que esta muestra fue originalmente seleccionada como no afiliados al sistema de pensiones, en el transcurso del estudio se podrían haber afiliado: esta variable representa su situación a Junio de 2015 en el sistema de pensiones.

En el Cuadro Nº 6.6 se muestran los efectos marginales estimados, de cada una de estas variables explicativas, sobre la probabilidad de contacto y sobre la probabilidad de respuesta condicional en contacto de las personas de la sub-muestra "No afiliados 2004".

Los resultados sobre la probabilidad de contacto indican que:

- Los hombres tienen 3.7 puntos porcentuales menos de probabilidad de contacto que las mujeres, pero esta diferencia es significativa sólo al 10% de nivel de significancia.
- Las personas entre 35 y 44 años de edad no tienen diferencias significativas con las personas menores de 35 años en la probabilidad de contacto, como tampoco con las personas de 65 años y más. Sin embargo, las personas entre 45 y 54 años de edad tienen 11.3 puntos porcentuales más de probabilidad de contacto que las personas menores de 35 años y las personas entre 55 y 64 años 12.8 puntos porcentuales más.
- Las personas de las regiones IV, XI, XII, XIV y XV no tienen diferencias significativas, en la probabilidad de contacto, respecto a las personas de la región metropolitana. Las personas residentes en las otras regiones, tienen mayor probabilidad de contacto que las personas de la región metropolitana.
- El número de cotizaciones obligatorias en el sistema de AFP no es estadísticamente significativo.
- Las personas pensionadas tienen 13.7 puntos porcentuales más de probabilidad de contacto que las personas que no se encuentran pensionadas.
- Las personas afiliadas al sistema de AFP, a Junio de 2015, tienen 8 puntos porcentuales menos de probabilidad de contacto que las personas no afiliadas al sistema de pensiones.

Cuadro N° 6.7

Efectos marginales sobre probabilidad de contacto y respuesta condicional en contacto
Tipo de muestra: No afiliados 2004

	Probabilidad de contacto		Probabilidad de respuesta/contacto	
	Efecto marginal	p-value	Efecto marginal	p-value
Hombre	-0.037	0.097	-0.013	0.304
35-44 años	0.026	0.444	0.003	0.852
45-54 años	0.113	0.000	0.008	0.633
55-64 años	0.128	0.000	0.013	0.468
65 años y más	0.025	0.533	-0.005	0.856
Media completa	-	-	-0.022	0.218
Superior	-	-	-0.074	0.021
I	0.205	0.000	-	-
II	0.110	0.006	-	-
III	0.164	0.001	-	-
IV	-0.017	0.726	-	-
V	0.110	0.000	-	-
VI	0.148	0.000	-	-
VII	0.068	0.062	-	-
VIII	0.066	0.012	-	-
IX	0.074	0.021	-	-
X	0.092	0.005	-	-
XI	-0.149	0.173	-	-
XII	0.096	0.229	-	-
XIV	0.037	0.528	-	-
XV	0.101	0.177	-	-
Nº Cotizaciones	0.000	0.589	0.000	0.046
Pensionado	0.137	0.000	0.032	0.084
Afiliado AFP	-0.080	0.001	0.007	0.631
2004-2006-2009	-0.271	0.000	-0.038	0.020
2004-2006-2012	-0.176	0.009	-0.008	0.804
2004-2006	-0.454	0.000	-0.219	0.000
2004-2009-2012	-0.125	0.242	-0.090	0.190
2004-2009	-0.436	0.000	-0.171	0.059
2004	-0.556	0.000	-0.247	0.001
N	2,470		1,714	
Pseudo-R2	0.1872		0.1260	
Probabilidad predicha	0.73		0.95	

Fuente: Elaboración propia.

Notas: las estimaciones se hacen con los factores de expansión base mediante metodología logit; el modelo de probabilidad de contacto no incluye las dummies de nivel educacional, y el modelo de probabilidad de respuesta condicional en contacto no incluye las dummies regionales.

- Las personas que han participado en las rondas 2004, 2009 y 2012 son las únicas que no tienen diferencia significativa en la probabilidad de contacto con las personas que han sido entrevistadas en todas las rondas, para el resto mientras menor participación en el estudio menor es la probabilidad de contacto.

Con respecto a la probabilidad de respuesta condicional en contacto:

- El sexo y la edad no son variables significativas.
- Las personas con educación superior, tienen 7.4 puntos porcentuales menos de probabilidad de respuesta condicional en contacto que las personas con educación menor a media completa.
- El número de cotizaciones en el sistema es estadísticamente significativo, e indica que a mayor número de cotizaciones mayor es la probabilidad de respuesta condicional en contacto.
- Los pensionados tienen mayor probabilidad de respuesta condicional en contacto, pero esta diferencia es significativa sólo al 10%.
- Mientras más antigua fue la última participación de la persona en el estudio, menor es la probabilidad de respuesta condicional en contacto; por ejemplo, las personas que participaron en 2004 y 2006 tienen 21.9 puntos porcentuales menos de probabilidad de respuesta condicional en contacto que aquellos que han participado en todas las rondas.

Una vez estimados ambos modelos se utiliza cada uno de ellos para obtener la probabilidad predicha de contacto, y la probabilidad predicha de respuesta condicional en contacto en función de las características de cada persona; estas probabilidades, se predicen tanto para los que respondieron la VI Ronda 2015 como para los que no respondieron:

Probabilidad predicha de contacto:

$$\hat{p}_C(x_i) = F(x_i' \hat{\beta}_C)$$

Probabilidad predicha de respuesta condicional en contacto:

$$\hat{p}_{R/C}(x_i) = F(x_i' \hat{\beta}_{R/C})$$

Donde $\hat{\beta}_C$ y $\hat{\beta}_{R/C}$, corresponden a los coeficientes estimados en los modelos logit respectivos.

Luego, la probabilidad de respuesta incondicional en contacto (*propensity*) es igual a:

$$propensity = \hat{p}_R(x_i) = \hat{p}_C(x_i) \cdot \hat{p}_{R/C}(x_i)$$

El *propensity*, es utilizado para hacer grupos de individuos con tasa de respuesta homogénea, esto se hace mediante la construcción de deciles a través del valor calculado del *propensity*.

El Cuadro Nº 6.7 muestra los valores mínimos, máximos y promedio de los *propensity* en cada decil.

Cuadro N° 6.8
Máximo, mínimo y promedio del *propensity* por decil
Tipo de muestra: No afiliados 2004

Decil	Mínimo	Promedio	Máximo
1	0.044	0.152	0.249
2	0.249	0.325	0.410
3	0.411	0.487	0.555
4	0.556	0.605	0.645
5	0.646	0.678	0.716
6	0.716	0.744	0.775
7	0.775	0.806	0.826
8	0.827	0.847	0.861
9	0.861	0.878	0.893
10	0.893	0.913	0.952

Fuente: Elaboración propia

El inverso de los valores promedio del propensity, por decil, se emplean como factor de ajuste por no respuesta; este ajuste, es el mismo para todas las personas del decil. Luego, el factor de expansión ajustado por la no respuesta se obtiene de multiplicar el factor de expansión base por este factor de ajuste.

En el do-file "Factores de Ajuste por No Respuesta_No Afiliados 2004.do" está programada la estimación de los modelos, y el cálculo de los factores de ajuste por no respuesta.

6.1.2.4 Refresco 2015

La muestra de refresco 2015 corresponde a las personas seleccionadas para participar en esta VI Ronda EPS 2015, con el objetivo de refrescar la muestra y poder representar la población de 18 años y más a Junio de 2015. Esta muestra consistió en 14.995 personas, de las cuales 66 se encontraban fallecidas o impedidas física y/o mentalmente para responder la encuesta (estas personas fueron excluidas para la estimación de los modelos de probabilidad de contacto y de respuesta condicional en contacto). De esta forma, se utilizó una muestra de 14.929 personas de la muestra de refresco 2015 para la estimación de los ajustes por no respuesta con la metodología *propensity*.

Para el modelo de probabilidad de contacto y de probabilidad de respuesta condicional en contacto, se utilizaron variables explicativas que estaban disponibles tanto para las personas que respondieron la encuesta como las que no respondieron, que a su vez tienen algún grado de causalidad y correlación con la probabilidad de respuesta. Para esta muestra, solo fue posible obtener información del marco muestral administrativo:

- Edad: se utiliza la edad calculada a Junio de 2015, en base a la fecha de nacimiento obtenida del marco muestral administrativo. A diferencia de las muestras anteriores,

se empleó directamente la variable edad, ya que la muestra está formada por un grupo relativamente homogéneo: personas jóvenes entre 18 y 29 años de edad.

- Región: se generan 15 variables binarias (o dummies) para cada una de las regiones del país, se excluye del modelo la dummy correspondiente a la región metropolitana quedando esta categoría como base para la interpretación del modelo. La región corresponde a la última región de entrevista, la que está asociada a la dirección de contacto para la VI Ronda EPS.
- Sexo: se utiliza la variable binaria que toma valor 1 para los hombres y 0 para las mujeres, de esta forma la categoría base son las mujeres. Esta información se obtiene del marco administrativo.
- Afiliado AFP: dummy que toma valor 1 si la persona se encuentra afiliada al sistema de AFP y 0 si se encuentra afiliada al sistema de INP a Junio de 2015, esta información se obtuvo del marco muestral administrativo.
- Número de cotizaciones en la cuenta obligatoria del sistema de AFP: cantidad de cotizaciones en la cuenta obligatoria del sistema de AFP a Junio de 2015; esta información, se obtuvo del marco muestral administrativo.

El Cuadro Nº 6.8, muestra los efectos marginales estimados de cada una de estas variables explicativas sobre la probabilidad de contacto y sobre la probabilidad de respuesta condicional en contacto de las personas de la muestra "Refresco 2015".

Los resultados sobre la probabilidad de contacto muestran que:

- Los hombres tienen 5.2 puntos porcentuales menos de probabilidad de contacto que las mujeres.
- Cada año adicional de edad, disminuye en 2.3 puntos porcentuales la probabilidad de contacto. Si bien parece un resultado contradictorio al obtenido en las otras muestras, ha que tener presente que la muestra de refresco es de personas jóvenes (entre 18 y 29 años) y este efecto marginal se debe interpretar como que dentro de este grupo de personas jóvenes un año más de edad disminuye la probabilidad de contacto.
- En todas las regiones la probabilidad de contacto es superior a la región metropolitana.
- Mientras mayor es el número de cotizaciones mayor es la probabilidad de contacto.
- Los afiliados al sistema de AFP tienen 2.8 puntos porcentuales más de probabilidad de contacto que los no afiliados.

Con respecto a la probabilidad de respuesta condicional en contacto:

- Los hombres tienen 2.4 puntos porcentuales menos de probabilidad de respuesta condicional en contacto que las mujeres.
- A mayor edad menor es la probabilidad de respuesta condicional en contacto, por cada año adicional de edad, la probabilidad se reduce en 0.5 puntos porcentuales.

- Las personas de las regiones II, III, V, VI, VIII, X, XI y XII no tienen diferencias significativas con las personas de la región metropolitana en la probabilidad de respuesta condicional en contacto.
- Los afiliados al sistema de AFP tienen 3.1 puntos porcentuales más de probabilidad de respuesta condicional en contacto, que los no afiliados al sistema de pensiones.

Cuadro Nº 6.9

Efectos marginales sobre probabilidad de contacto y respuesta condicional en contacto

Tipo de muestra: Refresco 2015

	Probabilidad de contacto		Probabilidad de respuesta/contacto	
	Efecto marginal	p-value	Efecto marginal	p-value
Hombre	-0.052	0.000	-0.024	0.003
Edad	-0.023	0.000	-0.005	0.000
I	0.258	0.000	0.058	0.001
II	0.087	0.000	-0.005	0.788
III	0.329	0.000	-0.049	0.083
IV	0.133	0.000	0.059	0.000
V	0.129	0.000	-0.001	0.963
VI	0.127	0.000	0.019	0.239
VII	0.152	0.000	0.048	0.000
VIII	0.101	0.000	0.007	0.543
IX	0.094	0.000	0.068	0.000
X	0.047	0.020	0.017	0.335
XI	0.212	0.000	0.018	0.620
XII	0.162	0.001	-0.015	0.720
XIV	0.178	0.000	0.041	0.089
XV	0.105	0.004	0.056	0.017
Nº Cotizaciones	0.001	0.000	-	-
Afiliado AFP	0.028	0.020	0.031	0.006
N	14,929		7,687	
Pseudo-R2	0.0267		0.0145	
Probabilidad predicha	0.47		0.88	

Fuente: Elaboración propia

Notas: las estimaciones se hacen con los factores de expansión base mediante metodología logit. El modelo de probabilidad de respuesta condicional en contacto, no incluye la variable del número de cotizaciones.

Una vez estimados ambos modelos, se utilizó cada uno de ellos para obtener la probabilidad predicha de contacto y la probabilidad predicha de respuesta condicional en contacto en función de las características de cada persona, estas probabilidades se predicen tanto para los que respondieron la VI Ronda 2015 como para los que no respondieron:

Probabilidad predicha de contacto:

$$\hat{p}_C(x_i) = F(x_i' \hat{\beta}_C)$$

Probabilidad predicha de respuesta condicional en contacto:

$$\hat{p}_{R/C}(x_i) = F(x_i' \hat{\beta}_{R/C})$$

Donde $\hat{\beta}_C$ y $\hat{\beta}_{R/C}$, corresponden a los coeficientes estimados en los modelos logit respectivos.

Luego, la probabilidad de respuesta incondicional en contacto (*propensity*) es igual a:

$$propensity = \hat{p}_R(x_i) = \hat{p}_C(x_i) \cdot \hat{p}_{R/C}(x_i)$$

El *propensity*, se emplea para hacer grupos de individuos con tasa de respuesta homogénea, esto se hace mediante la construcción de deciles a través del valor calculado del *propensity*.

El Cuadro Nº 6.9 muestra los valores mínimos, máximos y promedio de los *propensity* en cada decil.

Cuadro Nº 6.10
Máximo, mínimo y promedio del *propensity* por decil
Tipo de muestra: Refresco 2015

Decil	Mínimo	Promedio	Máximo
1	0.179	0.262	0.296
2	0.296	0.314	0.331
3	0.332	0.345	0.358
4	0.358	0.372	0.385
5	0.385	0.396	0.408
6	0.408	0.421	0.433
7	0.433	0.446	0.460
8	0.460	0.476	0.492
9	0.492	0.513	0.537
10	0.537	0.581	0.734

Fuente: Elaboración propia

El inverso de los valores promedios del *propensity*, por decil, son utilizados como factor de ajuste por no respuesta, este ajuste es el mismo para todas las personas del decil. Luego, el factor de expansión ajustado por la no respuesta se obtiene de multiplicar el factor de expansión base por este factor de ajuste.

En el do-file "Factores de Ajuste por No Respuesta_Refresco 2015.do", está la programación para la estimación de los modelos y el cálculo de los factores de ajuste por no respuesta.

6.1.3 Post-estratificación

Una vez ajustados por no respuesta los factores de expansión, el último paso consiste en aprovechar la disponibilidad de datos auxiliares (cuyos totales son conocidos para la población objetivo), estos datos permiten corregir los problemas de cobertura y reducir los errores estándar. Por datos auxiliares se entienden como aquella información que está disponible para el marco completo o la población objetivo, ya sea a nivel de individuos o en forma agregada; estos datos pueden venir del marco muestral, registros administrativos, estadísticas publicadas, u otras fuentes.

La post-estratificación es implementada al interior de celdas de calibración formadas por el cruce de todas las categorías de las variables auxiliares utilizadas, y permite construir ponderadores que puedan reproducir la población de cada celda. De esta forma, el ponderador final es:

$$w_i = d_i \cdot \frac{N_\gamma}{\hat{N}_\gamma}$$

Donde: $d_i = w_i^{nr}$ cuando se ha realizado un ajuste por no respuesta al ponderador base, N_γ es la población en el estrato (celda de calibración) γ , y $\hat{N}_\gamma$ es la población estimada en el estrato γ a través del ponderador:

$$\hat{N}_\gamma = \sum_{j \in s_\gamma} d_j$$

donde s_γ son las unidades muestrales en el estrato γ .

En la VI Ronda EPS se utilizaron las celdas de calibración formadas por las siguientes variables:

- Sexo
 - Hombre
 - Mujer
- Tramos de edad:
 - 18-29
 - 30-49
 - 50+
- Regiones:
 - XV-I-II-III
 - VI

- V
- VI
- VII
- VIII
- IX
- X-XIV
- XI-XII
- RM

Los datos poblaciones se obtuvieron de las proyecciones de población del INE a Junio de 2015, estos se presentan en el Cuadro N° 6.10.

Cuadro N° 6.11

Proyección de la población de 18 años y más a Junio 2015 según sexo, edad y región

	Hombres			Mujeres			Total
	18-29	30-49	50+	18-29	30-49	50+	
XV-I-II-III	155,397	233,339	182,770	139,713	206,558	180,633	1,098,410
IV	76,496	104,869	100,144	74,664	105,824	111,497	573,494
V	182,078	245,834	247,911	173,823	246,196	298,855	1,394,697
VI	86,320	127,210	129,152	83,512	125,861	135,463	687,518
VII	101,281	139,801	145,340	100,902	143,507	155,334	786,165
VIII	213,452	282,549	282,356	210,206	294,983	316,692	1,600,238
IX	100,261	130,083	129,693	100,466	135,689	143,527	739,719
X-XIV	123,531	176,446	163,533	118,054	171,506	174,410	927,480
XI-XII	26,243	41,819	37,720	23,365	37,937	36,238	203,322
RM	714,882	1,069,099	895,242	699,665	1,086,319	1,084,731	5,549,938
Total	1,779,941	2,551,049	2,313,861	1,724,370	2,554,380	2,637,380	13,560,981

Fuente: Elaboración propia en base a proyecciones del INE a Junio de 2015.

Por otra parte, el Cuadro 6.11 muestra la distribución de la muestra de personas entrevistadas en la VI Ronda EPS 2015 en estas mismas celdas, y el Cuadro 6.12 la muestra ponderada o expandida utilizando el factor de expansión con ajustes por no respuesta.

Cuadro N° 6.12

Muestra de personas entrevistadas vivas en la VI Ronda EPS

	Hombres			Mujeres			Total
	18-29	30-49	50+	18-29	30-49	50+	
XV-I-II-III	360	140	206	332	151	226	1,415
IV	174	86	144	161	106	152	823
V	343	181	303	357	209	388	1,781
VI	176	101	189	182	128	210	986
VII	227	150	246	260	138	225	1,246
VIII	357	204	441	402	242	423	2,069
IX	176	97	187	207	80	211	958
X-XIV	203	133	245	215	171	233	1,200
XI-XII	56	35	53	57	45	60	306
RM	1,240	562	981	1,347	706	1,286	6,122
Total	3,312	1,689	2,995	3,520	1,976	3,414	16,906

Fuente: Elaboración propia

Cuadro Nº 6.13

Muestra expandida de personas entrevistadas vivas en la VI Ronda EPS

	Hombres			Mujeres			Total
	18-29	30-49	50+	18-29	30-49	50+	
XV-I-II-III	333,494	223,722	261,102	292,879	209,847	256,394	1,577,438
IV	147,598	99,174	125,937	133,218	114,853	145,863	766,643
V	374,450	226,505	299,483	347,019	243,801	426,074	1,917,332
VI	176,850	100,438	138,369	155,076	111,473	226,933	909,139
VII	178,204	135,311	198,843	196,650	128,011	218,710	1,055,729
VIII	418,358	226,404	420,442	415,153	289,894	501,969	2,272,220
IX	180,712	113,351	190,971	196,813	97,956	250,763	1,030,566
X-XIV	248,278	146,041	210,766	238,845	186,723	228,133	1,258,786
XI-XII	50,625	40,994	47,807	47,456	45,740	72,453	305,075
RM	1,972,125	911,370	1,142,467	1,909,327	1,037,172	1,688,175	8,660,636
Total	4,080,694	2,223,309	3,036,187	3,932,436	2,465,470	4,015,467	19,753,563

Fuente: Elaboración propia, utilizando el factor de expansión base ajustado por la no respuesta con el método de propensity.

El ajuste de post-estratificación es, simplemente, el ratio entre la población y la muestra expandida en cada una de las celdas de calibración definida. Estos valores se presentan en el Cuadro Nº 6.13.

Cuadro Nº 6.14

Factor de ajuste por post-estratificación

	Hombres			Mujeres		
	18-29	30-49	50+	18-29	30-49	50+
XV-I-II-III	0.4660	1.0430	0.7000	0.4770	0.9843	0.7045
IV	0.5183	1.0574	0.7952	0.5605	0.9214	0.7644
V	0.4863	1.0853	0.8278	0.5009	1.0098	0.7014
VI	0.4881	1.2666	0.9334	0.5385	1.1291	0.5969
VII	0.5683	1.0332	0.7309	0.5131	1.1211	0.7102
VIII	0.5102	1.2480	0.6716	0.5063	1.0176	0.6309
IX	0.5548	1.1476	0.6791	0.5105	1.3852	0.5724
X-XIV	0.4976	1.2082	0.7759	0.4943	0.9185	0.7645
XI-XII	0.5184	1.0201	0.7890	0.4924	0.8294	0.5002
RM	0.3625	1.1731	0.7836	0.3664	1.0474	0.6425

Fuente: Elaboración propia.

Finalmente, el factor de expansión definitivo para la muestra de corte transversal de la VI Ronda EPS 2015 es el factor ajustado por no respuesta multiplicado por el factor de ajuste de post-estratificación; en el do-file "Postestratificacion.do" se encuentra la programación del factor de expansión definitivo.

6.1.4 Análisis estadístico del factor de expansión

El Cuadro Nº 6.14 muestra las estadísticas descriptivas básicas de los factores de expansión para la muestra de corte transversal de la VI Ronda EPS 2015 en cada una de sus etapas: factor base, factor con ajuste por no respuesta y factor final con ajuste por post-estratificación, para los 16.906 personas entrevistadas vivas en la EPS 2015.

Cuadro Nº 6.15

Factores de expansión base, con ajuste por no respuesta y final
Corte transversal EPS 2015

	Factor Base	Factor con Ajuste por No Respuesta	Factor Final EPS 2015
Casos Totales	16,906	16,906	16,906
Promedio	599	1,168	802
Desviación estándar	348	906	851
Suma ponderada	10,125,693	19,753,564	13,560,980
Cuantiles			
Mínimo	201	239	183
Percentil 10	397	569	370
Percentil 25	437	685	436
Mediana	477	944	556
Percentil 75	553	1,338	853
Percentil 90	1,223	1,907	1,401
Máximo	6,519	24,975	29,297

Fuente: Elaboración propia.

Por otra parte, en el Cuadro Nº 6.15 se muestran algunas estadísticas básicas calculadas a partir de los datos de la VI Ronda EPS 2015, con los factores de expansión en sus distintas etapas.

Cuadro Nº 6.16

Estadísticas descriptivas y efecto del factor de expansión

	Factor Base	Factor con Ajuste por No Respuesta	Factor Final EPS 2015
Sexo	100	100	100
Hombre	43.5	47.3	49.0
Mujer	56.6	52.7	51.0
Tramos de edad	100	100	100
18-29	32.7	48.0	25.8
30-49	22.6	22.0	37.7
50+	44.7	30.0	36.5
% Afiliado (E1=1)	71.2	73.5	76.4
% Trabaja (B2=2)	50.4	54.6	57.8
% Independiente (B8=1 o B8=2)	29.5	28.1	29.1

Fuente: Elaboración propia

6.2 Factores de expansión de la muestra longitudinal

6.2.1 Panel 2002-2004-2006-2009-2015

En el Cuadro N° 6.1 se mostraba que la muestra de “Afiliados 2002” está compuesta por 15.060 personas (de las cuales 821 personas se encontraban fallecidas o impedidas física y/o mentalmente para responder la encuesta). De esta forma, la muestra “Afiliados 2002” en condiciones de responder la encuesta fue de 14.239 personas, de estos 5.966 fueron entrevistados en las rondas 2002, 2004, 2006, 2009 y 2015.

Para calcular el factor de expansión de esta muestra panel, se siguió un procedimiento bastante similar al implementado para el cálculo de los factores de expansión transversales:

- Se comienza con los factores base obtenidos en la primera ronda de la EPS (2002).
- Se realiza un ajuste por la probabilidad de pertenecer a este panel, es decir, por la probabilidad de haber contestado en todas las rondas del estudio. Este modelo se estima mediante la metodología logit en función de variables explicativas como sexo, edad, región, estatus en el sistema de pensiones y nivel educacional.
- Una vez estimado el modelo, se utiliza para obtener para cada observación la probabilidad predicha de responder en todas las rondas del estudio (*propensity*), que a su vez se emplea para generar deciles, y luego el factor de ajuste corresponde al inverso del *propensity* promedio del decil.
- Un vez generado el factor de expansión con ajuste por probabilidad de estar en panel, se hace una post-estratificación por celdas.

En la carpeta “Factor Panel EPS 2002-2004-2006-2009-2015” se adjuntan los do-files y Excel utilizado para el cálculo de este factor de expansión.

6.2.2 Panel 2004-2006-2009-2015

En el Cuadro N° 6.1 se mostraba que la sub-muestra de “Afiliados 2002” está compuesta por 15.060 personas (de las cuales 821 se encontraban fallecidas o impedidas física y/o mentalmente para responder la encuesta). De esta manera, la sub-muestra “Afiliados 2002” en condiciones de responder fue de 14.239 personas, de las cuales 5.966 fueron entrevistados en las rondas 2004, 2006, 2009 y 2015. La sub-muestra de “Nuevos afiliados 2004” está compuesta por 916 personas (de las que 11 personas se encontraban fallecidas o impedidas física y/o mentalmente para responder la encuesta). De esta forma, la sub-muestra “Nuevos afiliados 2004” en condiciones de responder la encuesta es de 905 personas, de éstas 383 fueron entrevistadas en las rondas 2004, 2006, 2009 y 2015. La sub-muestra de “No afiliados 2004” está compuesta por 2.673 personas (de ellas, 203 se encontraban fallecidas o impedidas física y/o mentalmente para responder la encuesta). De esta forma, la sub-muestra “No afiliados 2004” en condiciones de responder la encuesta es de 2,470 personas, de estos 1,394 han sido entrevistados en las rondas 2004, 2006, 2009 y 2015.

Para calcular el factor de expansión de esta muestra panel se sigue un procedimiento bastante similar al implementado para el cálculo de los factores de expansión de corte transversal:

- Se comienza con los factores bases obtenidos en la primera ronda de la EPS, 2002 para la muestra "Afiliados 2002" y 2004 para las muestras "Nuevos Afiliados 2004" y "No Afiliados 2004".
- Se realiza un ajuste por la probabilidad de pertenecer a este panel, es decir, por la probabilidad de haber contestado en todas las rondas del estudio. Este modelo se estima mediante la metodología logit en función de variables explicativas como sexo, edad, región, estatus en el sistema de pensiones y nivel educacional. La estimación se hace por separado por tipo de muestra.
- Una vez estimado el modelo, se utiliza para obtener por cada observación la probabilidad predicha de responder en todas las rondas del estudio (o *propensity*), la que a su vez se emplea para generar deciles, y luego el factor de ajuste corresponde al inverso del *propensity* promedio del decil.
- Un vez generando el factor de expansión con ajuste por probabilidad de estar en panel, se hace una post-estratificación por celdas.

En la carpeta "Factor Panel EPS 2004-2006-2009-2015" se adjuntan los do-files y Excel utilizado para el cálculo de este factor de expansión.

Centro UC

Encuestas y Estudios Longitudinales