



Informe de Tratamiento de Datos

**VIII RONDA ENCUESTA DE
PROTECCIÓN SOCIAL**



**CHILE
AVANZA
CONTIGO**

Contenido

1. INTRODUCCIÓN	3
2. VALIDACIONES Y EDICIÓN.....	4
2.1 Generalidades de las validaciones y edición	4
2.2 Bases crudas y la construcción de las bases de datos finales	4
2.3 Bases de datos entregadas	5
2.3.1 Acerca de las variables codificadas.....	6
2.3.2 Acerca de las variables editadas	7
2.4 Validaciones	7
2.4.1 Outliers	9
3. IMPUTACIONES	11
3.1 Consideraciones previas	11
3.2 Mecanismos de pérdida de datos.....	12
3.3 Eliminación de variables de tramo en la recolección de información.....	13
3.4 Imputación de nivel educacional.....	13
3.5 Imputación de variables de ingreso y arriendo.....	14
3.5.1 Imputación de ingreso promedio mensual laboral	19
3.5.2 Imputación de arriendo.....	20
3.6 Consideraciones finales sobre imputaciones	22
4. REFERENCIAS.....	23
5. ANEXOS	25
5.1 ANEXO 1 – Edición de la base de datos.....	25

1. INTRODUCCIÓN

La creación de las bases de datos de la EPS VIII Ronda implicó un exhaustivo proceso de validación y edición para asegurar la calidad y consistencia de los datos. Utilizando el software nativo de IPSOS, iField, las bases de datos fueron inicialmente generadas y descargadas en formato SPSS, para luego ser migradas a Stata. Este proceso técnico garantizó que las bases nativas fueran adecuadamente tratadas y estructuradas para su posterior análisis.

El tratamiento de las bases de datos desde su versión 'cruda' se realizó íntegramente en Stata 14 MP. Este proceso comenzó con una revisión detallada de las bases crudas, que incluían información de contacto, datos recolectados en las entrevistas y llaves para cruzar información pública con el levantamiento realizado. A través de un software desarrollado en Stata, las bases crudas de vivos, personas fallecidas y en situación de discapacidad se transformaron en bases finales sin intervención humana, siguiendo una lógica de estructura 'wide' para datos contemporáneos y 'long' para datos que involucraban múltiples episodios o personas.

Finalmente, los archivos generados se entregaron en formato Stata '.dta', con nombres que indican claramente a qué módulo del cuestionario pertenecen y si están dirigidos al entrevistado(a) u hogar. La codificación de variables se llevó a cabo para estandarizar la información heterogénea proporcionada por los(as) entrevistados(as), y se realizaron ediciones para corregir “*outliers*”, valores inconsistentes y otros errores, asegurando que los datos fueran fiables y utilizables para análisis estadísticos exhaustivos.

2. VALIDACIONES Y EDICIÓN

2.1 Generalidades de las validaciones y edición

A continuación, se detallan y explican las acciones de validación y edición que fueron necesarias para la creación de las bases finales de datos de la EPS VIII Ronda. Las bases de datos fueron generadas a través del software nativo de IPSOS, iField. Estas bases nativas se descargaron en formato SPSS, y luego se migraron a Stata.

2.2 Bases crudas y la construcción de las bases de datos finales

El tratamiento total de las bases de datos, desde su versión “cruda”, es decir, la versión original generada por el software nativo de recolección de datos se ha realizado en Stata 14 MP. El proceso inició con la revisión de las bases iniciales (crudas), lo que incluyó la base de contacto, que describe el trabajo de campo y proporciona información sobre el resultado de cada visita a los hogares; la base de datos recolectada en las entrevistas; y las llaves que permiten cruzar información pública con el levantamiento de datos realizado¹.

El software desarrollado en Stata procesa los tres tipos de bases crudas correspondientes a los tres tipos de cuestionarios (vivos, personas fallecidas y en situación de discapacidad) y construye automáticamente las bases finales sin necesidad de intervención humana. Respecto a la estructura de las bases de datos generadas, se siguió la siguiente lógica:

- Si la información en un módulo específico es contemporánea para el Entrevistado(a), la base de datos resultante es de tipo '*wide*'. Esto significa que cada columna representa una variable independiente y cada fila corresponde a un Entrevistado(a), con toda su información contenida en una sola línea o registro de observación en la base de datos.
- Si la información involucra múltiples episodios o diferentes personas relacionadas con el(la) entrevistado(a), la base de datos resultante es de tipo '*long*'. En este caso, cada columna sigue representando una variable independiente, pero cada fila se refiere a una persona o episodio asociado con un entrevistado(a), por lo que puede haber muchas líneas o registros de observaciones dentro de la base de datos que hacen referencia al mismo entrevistado(a). Cada uno de estos registros o filas se identifica con la variable '*orden*', que indica el orden en que se debe presentar la información según las instrucciones de cada módulo en el cuestionario.

¹ Todos los contrastes que implicaron el uso de información proveniente de olas anteriores se hicieron empleando información pública que se puede acceder desde la web de la SPS.

Como ejemplo de este último caso, en el “módulo I: Historia Individual” del cuestionario de Vivos, el módulo se dividió en 3 partes debido a que la información contenida en él tenía tres núcleos bien definidos: (i) información contemporánea del Entrevistado(a) ('wide'), (ii) enumeración de información de parejas ('long'), y (iii) enumeración de información de hijos(as) ('long').

En definitiva, cada base de datos tiene una estructura particular que se adapta al tipo de información que contiene. En general, los programas utilizados para el análisis y estudio estadístico de datos cuentan con funciones que permiten cambiar fácilmente los formatos de las bases de datos, en caso de que la forma en que se entregan (o se hacen disponibles públicamente) no se ajuste a los objetivos del usuario.

2.3 Bases de datos entregadas

Los archivos generados durante el proceso están en formato Stata '.dta'. Las etiquetas utilizadas en los archivos corresponden al nombre de los módulos de cada cuestionario de la encuesta y a quién está dirigido el cuestionario (entrevistado(a), hogar u otro). En todos los casos, es la persona entrevistada quien responde la encuesta, o un informante idóneo en los casos de personas fallecidas o personas en situación de discapacidad. Los archivos de las bases de datos tienen los siguientes sufijos que expresan su contenido:

- MODULO_X_Contenido.dta: corresponde a la base de datos del módulo de referencia en formato Stata 14.

En la Tabla 2.1 se expone cada una de las bases de datos entregadas. En esta, se identifica si forma parte del cuestionario de fallecidos, personas en situación de discapacidad o vivos. Dentro de la misma, también se identifica el módulo al que corresponde cada base de datos. Adicionalmente, también está la columna “Tipo de registro” que identifica la combinación que hace un registro único, por ejemplo, si la base de datos representa a cada persona una única vez (un registro por persona) o si una observación es única con el identificador de la persona y la variable orden (definida en el anterior ítem).

Tabla 2.1. Listado de bases de datos entregadas

Orden	Cuestionario	Base de datos	Módulo	Tipo de registro
1	Vivos	MODULO_A_Carreras	Módulo A	Registros duplicados (<i>long</i>)
2	Vivos	MODULO_A_Entrevistado	Módulo A	Registros únicos
3	Vivos	MODULO_B_Historia_Laboral	Módulo B	Registros duplicados (<i>long</i>)
5	Vivos	MODULO_B_Situacion_Actual	Módulo B	Registros únicos
6	Vivos	MODULO_C_Entrevistado	Módulo C	Registros únicos
7	Vivos	MODULO_D_Entrevistado	Módulo D	Registros únicos
8	Vivos	MODULO_E_Entrevistado	Módulo E	Registros únicos

9	Vivos	MODULO_F_Entrevistado	Módulo F	Registros únicos
10	Vivos	MODULO_G_Entrevistado	Módulo G	Registros únicos
11	Vivos	MODULO_H_Entrevistado	Módulo H	Registros únicos
12	Vivos	MODULO_Hogar	Módulo Hogar	Registros duplicados (<i>long</i>)
13	Vivos	MODULO_I_Entrevistado	Módulo I	Registros únicos
14	Vivos	MODULO_I_Hijos	Módulo I	Registros duplicados (<i>long</i>)
15	Vivos	MODULO_I_Parejas	Módulo I	Registros duplicados (<i>long</i>)
16	Vivos	MODULO_J_Entrevistado	Módulo J	Registros únicos
17	Vivos	MODULO_L_Entrevistado	Módulo L	Registros únicos
18	Vivos	MODULO_L_CDH	Módulo L	Registros duplicados (<i>long</i>)
19	Vivos	MODULO_L_CFH	Módulo L	Registros duplicados (<i>long</i>)
20	Vivos	MODULO_Q_Entrevistado	Módulo Q	Registros únicos
21	PSD	MODULO_A_Hogar	Módulo A	Registros duplicados (<i>long</i>)
22	PSD	MODULO_P	Módulo P	Registros únicos
23	PSD	MODULO_P_Historia_Laboral	Módulo P	Registros duplicados (<i>long</i>)
24	Fallecidos	MODULO_A_Hogar	Módulo A	Registros duplicados (<i>long</i>)
25	Fallecidos	MODULO_M	Módulo M	Registros únicos
26	Fallecidos	MODULO_M_Historia_Laboral	Módulo M	Registros duplicados (<i>long</i>)

Fuente: elaboración propia.

2.3.1 Acerca de las variables codificadas

La encuesta de la EPS en su VIII Ronda requirió un trabajo exhaustivo y extenso de codificación que se realizó de dos maneras:

- La codificación de las glosas de las variables de ocupación principal y de actividad económica del lugar de trabajo de los entrevistados, basándose en las nomenclaturas CINE, CIUO-08, CIUO-08.CL y CIIU Rev.4. y CISE.
- La codificación de preguntas abiertas o semiabiertas, que en su mayoría incluyen descripciones de situaciones diferentes a las establecidas en las categorías ofrecidas por el o la encuestador(a) a través de un 'tarjetero'. Estas alternativas son parte del diseño del cuestionario y, en general, son cubren de manera exhaustiva las posibles situaciones. Sin embargo, las personas entrevistadas pueden no entender la pregunta, no prestar atención a las alternativas disponibles en el tarjetero o sentir la necesidad de dar algún detalle adicional que consideran no está representado en estas opciones.

Para mayor detalle del proceso de codificación, véase el reporte especialmente desarrollado sobre este proceso ('EPS 2023 - Reporte de Codificación EPS VIII.docx').

2.3.2 Acerca de las variables editadas

En general, hay tres tipos de ediciones sobre las variables: *outliers*, valores inconsistentes con el contexto y valores inconsistentes. En la sección "Anexos" se explica el contenido de cada uno de estos y se detallan las variables donde se incurrió en cada una.

2.4 Validaciones

Siendo la EPS una encuesta compleja, tanto por el contenido y profundidad de sus preguntas, como por el esfuerzo que implica para el entrevistado responderlas, los datos recolectados requieren asegurar su calidad, completitud, homogeneidad y adecuación de la información recolectada a los criterios establecidos y a las buenas prácticas.

Una parte de este proceso corresponde a la validación de datos que permite asegurar que todas las piezas de información cumplan con la calidad y los criterios establecidos en cuanto al flujo de los cuestionarios (orden y correspondencia de las preguntas), filtros de entrada, rangos de respuesta, valores extremos (*outliers*) y valores raros (incoherentes con el contexto). La validación se realiza en dos etapas del trabajo:

- **concomitante**, es decir, al tiempo que se está recolectando la información, mediante las validaciones, controles de saltos de cuestionario, y verificación de rangos de respuestas.
- **Ex post**, mediante la aplicación de mallas de validación generales que corroboran la correspondencia y rangos de las respuestas, flujo del cuestionario, y coherencia global de la información recolectada. En esta etapa, las bases de datos pueden ser sujetas de edición para asegurar cuadratura o coherencia de la información recolectada.

Estos ajustes realizados a las bases de datos permiten obtener una encuesta que se comporta como una unidad informativa tal y como fue concebida.

Nótese que, en todos los casos, las actividades se desarrollan a partir de las validaciones, que corresponden a las actividades que establecen la manera en que serán tratadas las situaciones que se consideran anómalas.

El trabajo de validación expost se realizó mediante programación de mallas de validación tipo batch, las que permiten ser replicadas en las distintas validaciones parciales. Ipsos utilizó el programa STATA para la malla de validación, cuyo código fue construido en base a un archivo Excel de apoyo que contenía los criterios de revisión.

La malla de validación programada por Ipsos permite:

- Incluir validaciones lógicas complejas
- Automatización de ejecución de reportes y de validación.
- Validar según tipos de preguntas
- Generar un reporte de validación, de acuerdo con las inconsistencias encontradas en la ejecución de la malla Batch, pudiendo con ello detectar rápidamente cuál es la pregunta y registro donde se ha producido una inconsistencia.
- Obtención de resumen de casos no válidos, vacíos o incompletos
- Detectar valores fuera de rango.

El funcionamiento general de la malla de validación es el siguiente:

- Mediante un código en STATA, se valida cada variable para determinar si cuenta con información en los casos en que correspondía una respuesta.
- Se identifica aquellos casos en que la respuesta no se encuentra dentro de los valores válidos
- Se identifica aquellas variables que cuentan con respuesta cuando no debería haber, siguiendo el flujo lógico de la encuesta.

Para cada chequeo lógico, pregunta a pregunta, se genera una variable auxiliar que registra la revisión y que asume valores 0 (ausencia de error) y valores 1 (error). Con esto es posible detectar la casilla específica y el caso que tiene alguna anomalía que es necesario subsanar.

La siguiente tabla muestra cómo se generan las variables auxiliares para detección de errores de flujo y rango, tomando como ejemplo algunas variables del módulo A:

Tabla 2. Ejemplo de construcción de reglas de validación de flujo y rango				
Nombre de Variable	Flujo	Comandos (=0 si OK, =1 si ERROR)	Comandos (=0 si OK, =1 si ERROR)	Respuestas Válidas
a2_a	!=.	gen aux_a2_a=0 if (a2_a!=.)	replace aux_a2_a=1 if (a2_a==.)	1-3
a8	!=. if (a2_a==1 a2_a==3)	gen aux_a8=0 if (a8!=.) & (a2_a==1 a2_a==3)	replace aux_a8=1 if (a8==.) & (a2_a==1 a2_a==3)	1-2

a9	!=. if (a2_a==1 a2_a==3)	gen aux_a9=0 if (a9!=.) & (a2_a==1 a2_a==3)	replace aux_a9=1 if (a9==.) & (a2_a==1 a2_a==3)	1-120
a8_a	!=. if (a9>4)	gen aux_a8_a=0 if (a8_a!=.) & (a9>4)	replace aux_a8_a=1 if (a8_a==.) & (a9>4)	1-6:88:99
a8_a_e	!= "" if (a8_a==6)	gen aux_a8_a_e=0 if (a8_a_e!="") & (a8_a==6)	replace aux_a8_a_e=1 if (a8_a_e=="") & (a8_a==6)	
a8_b	!=. if (a9>4) & ((a8==1 & a8_a==2) (a8==2 & a8_a==1) (a8_a==5 a8_a==6))	gen aux_a8_b=0 if (a8_b!=.) & (a9>4) & ((a8==1 & a8_a==2) (a8==2 & a8_a==1) (a8_a==5 a8_a==6))	replace aux_a8_b=1 if (a8_b==.) & (a9>4) & ((a8==1 & a8_a==2) (a8==2 & a8_a==1) (a8_a==5 a8_a==6))	1-2:88:99

Fuente: elaboración propia.

La tabla contiene distintas columnas con las que se construyen las reglas de validación, que incluyen las condiciones de entrada a la pregunta (filtro), los rangos de la variable y la corrección en el caso de que la pregunta por el flujo de la encuesta no deba tener valores. Finalmente, el proceso genera una variable auxiliar, dicotómica, donde 0=no existe error, y 1=contiene error.

2.4.1 Outliers

Los *outliers* o valores extremos, son respuestas que se encuentran fuera de rangos razonables para la distribución de una variable (ya sea por encima o por debajo de la distribución). En general estos valores se deben a errores de tipeo del encuestador o de reporte del Entrevistado(a), y que no generan resultados plausibles. Mayoritariamente, estos casos se marcan como 'No sabe' para que el usuario de la base decida si someterlos a procesos de imputación o validaciones más exhaustivas. Los cortes se definen con una lógica especial para cada caso, dependiendo de la pregunta y los valores que representan.

Caso distinto opera para las variables de arriendo e ingreso, donde las imputaciones de los *outliers* siguen las reglas explicadas más adelante en el capítulo de imputaciones.

Para todas las variables “Especifique”, los valores numéricos, o combinaciones de valores numéricos con alfanuméricos en sus respuestas, fueron tratados en la codificación. Por lo tanto, la variable original contiene estos datos tal como fueron recolectados, mientras que la variable de codificación contiene los valores codificados en que esas respuestas numéricas fueron pasadas a “No sabe”.

Al final de este reporte, se anexa una lista de ediciones e imputaciones que no siguen un criterio genérico estadístico, sino que más bien un análisis caso a caso que resulta de la revisión particular de cada caso en

3. IMPUTACIONES

3.1 Consideraciones previas

Como toda encuesta compleja, la Encuesta de Protección Social VIII Ronda ha requerido de ajustes posteriores al resultado del trabajo de campo. Estos ajustes se realizan para asegurar calidad, completitud y adecuación de la información recolectada a los criterios establecidos y a las buenas prácticas. Dado que las encuestas son el producto del trabajo de personas y el aporte de información de los(as) entrevistados(as), se encuentran sujetas a la falibilidad habitual de cualquier acción humana.

Para resolver el problema de no respuesta al ítem, es decir, cuando las personas deciden no entregar información en alguna pregunta particular, se han realizado imputaciones siguiendo los procedimientos detallados en esta sección. Las razones para la no respuesta al ítem son variadas: dificultades para entender la pregunta, falta de concentración en el momento, dificultades para lograr condensar y resumir o sintetizar la información, esfuerzo involucrado en la elaboración de la respuesta, problemas de memoria, etc. El resultado es información incompleta, que habitualmente se codifica como “No Sabe / No Responde”. Sin embargo, esa información puede ser vital para entender el comportamiento de la población.

Es por ello por lo que se recurre a las imputaciones, es decir, a obtener información a través de distintos métodos estadísticos para lograr completar el conjunto informativo generado por la encuesta y poder hacer inferencia estadística. Son diversos los métodos disponibles en la literatura, y todos tienen sus ventajas y desventajas, y , éstas parten con los supuestos empleados para declarar la validez de una imputación.²

En la EPS, tradicionalmente, se han imputado variables como la edad (apoyado en registros administrativos), el nivel educativo, los ingresos laborales y los arriendos (reales o estimados) pagados por la vivienda principal del entrevistado. Esta última variable es de las más complicadas y con mayor tasa de no respuesta, ya que implica imaginar, si es que no se arrienda efectivamente la vivienda, cuál sería el precio pagado por arriendo de una vivienda de similares condiciones en el sector. Esto pone una presión importante en los entrevistados, que terminan no respondiendo a la pregunta.

En este informe, se propone y muestra una forma de abordar la imputación de datos en base a buenas prácticas observadas en otras encuestas, y a la calidad de datos que la EPS ha logrado reunir. Se imputan tres variables de la EPS VIII Ronda: nivel educativo máximo alcanzado, ingresos laborales promedio mensuales y arriendo (real o supuesto) promedio mensual pagado por la vivienda habitada por la persona entrevistada.

A continuación, se presentan los supuestos detrás del comportamiento de la información faltante, para luego abordar la imputación de educación, ingresos y arriendo en la presente encuesta.

² Existe una amplia literatura para recorrer. Algunos clásicos que se sugiere revisar incluyen Allison (2001), Carlin et al. (2003, 2008), Lee y Carlin (2010), Marchenko y Eddings (2011), Rubin (1987, 1996), Schafer (1997), Medina y Galván (2007), Little y Rubin (1987, 2002), Van Buuren (2017), entre otros referentes en la materia.

3.2 Mecanismos de pérdida de datos

Como se mencionó anteriormente, las razones para no responder pueden ser muchas. Sin embargo, sin importar las razones particulares de no respuesta que se observen, ni el patrón que esta siga en el cuestionario, se debe precisar qué tipo pérdida de información se está observando, pues de ella dependerá la metodología más apropiada para imputar. En la literatura, se reconocen ampliamente tres casos (Wood et al., 2019):

- 1) Pérdida aleatoria (*"Missing at random"* o MAR), definida por Rubin (1976): este tipo de pérdida de información implica que el dato faltante no depende de variables no observadas, pero puede deberse (explicarse) por la información contenida en variables observadas. Por ejemplo, si los hombres son más o menos propensos a responder alguna pregunta sobre ingresos, o si tienden a exagerar o sub-dimensionar la respuesta, o si las mujeres son menos propensas a revelar su situación de salud en la encuesta que los hombres (no respuesta parcial), se puede decir que el mecanismo de pérdida de información que se observa es MAR.
- 2) Pérdida totalmente aleatoria (*"Missing completely at random"* o MCAR): en este caso, la pérdida de información no está relacionada con información observable o no observable. En particular, las razones son enteramente ajenas a la encuesta en sí. Por lo tanto, la información faltante (total o parcial) es simplemente un subconjunto de la información total que sí se logró recolectar.
- 3) Pérdida no aleatoria (*"Missing not at random"* o MNAR): este tipo de pérdida de información es estudiada por Little y Rubin (2014), quienes aseguran que cuando la información no observada que tiene la persona entrevistada es el factor que determina la información aportada por el entrevistado en la encuesta, entonces se debe modelar la pérdida de información (por ejemplo, se pueden utilizar imputaciones múltiples) para reemplazar esta información perdida y evitar sesgos en los resultados. Sin embargo, se debe tener conocimiento (o información) previa sobre la observación, algo que está disponible para los participantes en olas anteriores de la EPS, pero no es posible obtener para las 5.020 observaciones de Nacimientos 2023.

Las variables que se imputan en esta ronda se encuentran en el cruce de las tres categorías. El nivel educativo no reportado puede deberse más a problemas de comprensión o deseo de no evidenciar alguna situación (por ejemplo, analfabetismo o baja escolaridad o nivel educativo no finalizado).

Por su parte, los ingresos generalmente están atados a múltiples sesgos en sus reportes, algunos de ellos convertidos en datos faltantes. Lo mismo sucede con los arriendos, en especial si el informante no está pagando arriendo y, en su lugar, debe reportar una estimación de ese monto.

En todo caso, frente a esta incertidumbre acerca del mecanismo originador de los datos, conviene utilizar técnicas robustas a pérdidas de información MNAR, que sería el caso más nocivo. Por esta razón, en el caso de las variables de ingresos y arriendos, se emplean imputaciones múltiples, que han probado ser

mecanismos muy resilientes (y, para muchos, los únicos adecuados actualmente) para controlar la pérdida de datos no aleatoria (van Buuren, 2017).

3.3 Eliminación de variables de tramo en la recolección de información

En esta ola de la encuesta, se han observado mayores tasas de no respuesta al ítem, principalmente por la eliminación de los tramos en las variables en las que se pregunta por un monto (ingresos, gastos, arriendos, entre otros).

En el periodo de ajuste de cuestionario se consensuó con la contraparte la eliminación de las tablas de tramos, para los casos en que una persona señalaba no querer responder. Este cambio se debe, entre otras razones, a la revisión del “Enfoque de Derechos” de la encuesta, debido a que se presiona a las personas para que den una respuesta aun en el caso de que han señalado no tener la disposición a responder.

Dicho de otro modo, la aplicación de los principios de este enfoque implica que no ha existido en la encuesta preguntas que permitan insistir con la recolección de datos cuando una respuesta a resultado en No Sabe / No responde.

Sin embargo, este cambio también se debe a la complejidad para los cálculos de indicadores de monto, ya que para cada persona que responde un tramo se debía calcular un valor imputado (típicamente la media de este mismo tramo), lo que también incluía distorsiones en los indicadores.

Como resultado, en la presente versión de la EPS no se tiene información de tramos de variables cuantitativas como arriendo (real o presunto), ingresos laborales, gastos de diversa índole, etc. Por lo tanto, se pierde una fuente de información adicional que estaba presente en las olas anteriores de la encuesta.

Tómese por caso la variable arriendo para tener una noción de los efectos del “Enfoque de Derechos” en la pérdida de información: históricamente, las tasas de no respuesta para este ítem de la EPS han estado alrededor del 20% hasta la ola 2020. Sin embargo, en la presente ola esta tasa de no respuesta al ítem se alzó a 34,8%. En rondas anteriores, los tramos de arriendo (variable auxiliar preguntada después de obtener un No sabe / No responde) cubría tasas de no respuesta de entre 12% y 18%, logrando que la no respuesta al ítem rondara el 20% en promedio.

3.4 Imputación de nivel educacional

El nivel educativo es una variable clave para entender el contexto socioeconómico de los entrevistados, y suele ser información que éstos entregan sin mayores inconvenientes. Sin embargo, en esta ronda, se observaron algunos casos de información faltante.

Dado que la variable educación típicamente se utiliza en niveles para realizar análisis, se decidió construir la variable de tramos de educación. Esta variable se construyó en base a las variables de curso y nivel máximo de educación alcanzado, según auto-reporte de la persona entrevistada. La variable fue definida en 5 tramos educativos: Ninguna educación (0), Básica (1), Media (2), Técnica Superior (3) y Universitaria (4).

Toda la información no reportada (No sabe / No responde) se pasó a dato perdido. Esto resultó en 81 casos faltantes (0,5% de no respuesta).

Para completar los valores faltantes, se llevó a cabo una imputación *cold deck*, empleando información consistente reportada en rondas anteriores de la EPS. La consistencia se chequeó en cada caso para asegurarse de que la educación (curso y nivel) se mantenía o se incrementaba entre olas, siguiendo la lógica del proceso educativo.

En la siguiente tabla se muestra la distribución de frecuencias inicial, las donaciones de cada ola, desde la más reciente hasta la más antigua, y la distribución final.

Tabla 3.1. EPS 2023 – Imputación de tramos de educación

	EPS 2023		Donación EPS 2020	Donación EPS 2015	Donación EPS 2012	Donación EPS 2009	Donación EPS 2006	Donación EPS 2004	Donación EPS 2002	EPS 2023 Imputada	
	N. Obs.	% Obs.	N. Obs.	N. Obs.	N. Obs.	N. Obs.	N. Obs.	N. Obs.	N. Obs.	N. Obs.	% Obs.
Ninguno	99	0.63	3	1						103	0.65
Básica	2371	15.02	9	13	2		1			2396	15.18
Media	7251	45.93	10	9	2	6	3			7281	46.12
Técnica Superior	2413	15.28	2	1			1			2417	15.31
Universitaria	3573	22.63	2	4	1	1	1	1	2	3585	22.71
Total	15707	99.49								15782	99.96
<i>Missing</i>	81	0.51	55	27	22	15	9	8	6	6	0.04
Donación			26	28	5	7	6	1	2		
Total	15788	100								15788	100

Fuente: elaboración propia.

El proceso de imputación *cold deck* no fue suficiente para cubrir los déficits de información del tramo educativo. Tal como puede observarse en las últimas columnas de la Tabla 3.1, la variable de tramo educativo se encuentra incompleta para esta encuesta, faltando 6 casos que corresponden a personas encuestadas por primera vez en la ronda actual.

3.5 Imputación de variables de ingreso y arriendo

Las variables de ingreso y arriendo presentan, habitualmente, mayores tasas de no respuesta al ítem. Adicionalmente, algunos de los valores reportados aparecen como valores extremos (*outliers*) o sospechosos de ser el resultado de ingreso erróneo del dato en los sistemas de levantamiento de encuestas. Para evitar que los datos ausentes o aquellos erróneamente reportados generen distorsiones en la medición, se recurre a la imputación para obtener variables con mejor comportamiento estadístico, que no distorsionan la distribución original de los datos, al tiempo que mejoran la inferencia estadística.

En la presente ronda de la encuesta, se revisaron las siguientes variables:

- Ingreso laboral promedio mensual del último trabajo: variable **b12** en montos
- Arriendo estimado mensual: variable **d8_a** en montos

En la Tabla 3.2, se muestran los datos faltantes para cada variable que resultan de la no respuesta y de la determinación de *outliers* o datos no fiables.

Tabla 3.2. Datos faltantes de ingresos y arriendos en la EPS 2023

Panel A. Datos faltantes para Arriendo Mensual (15.788 obs.)

Variable	Obs=.	Obs>.	Obs<.	Obs<.		
				Unique values	Min	Max
arriendo	5,659		10,129	>500	100022.2	5000283

Panel B. Datos faltantes para Ingreso Promedio Mensual del entrevistado ocupado (7.861 obs.)

Variable	Obs=.	Obs>.	Obs<.	Obs<.		
				Unique values	Min	Max
ing_lab	1,123		6,738	>500	100023	9500002

Nota: observaciones sin datos ("Obs=.") corresponden a valores No Sabe / No Responde y *outliers* (valores fuera del rango razonable definido para este estudio: \$100.000 < *ingreso laboral* < \$10.000.000 ; \$100.000 < *arriendo mensual* < \$6.000.000).

Fuente: elaboración propia.

En el caso de los arriendos, la pérdida de información alcanzó al 35,8% de la muestra (5.659 casos sobre 15.788), mientras que los ingresos laborales presentaron una pérdida de información de 14,3% (1.123 casos sobre 7.861). Se consideró que todos aquellos que declaraban tener ocupación (7.888 casos) y no eran de

la categoría “trabajo de familiar no remunerado” (27 casos), debían tener respuesta en este ítem (7.861 casos). Nótese también que se introdujo un “ruido” a los valores declarados dado que los redondeos en el reporte de estas cifras son habituales. El ruido introducido en ambas variables corresponde a valores uniformes entre \$0 y \$1.000, lo que no cambia la sustancia del reporte de los entrevistados, pero agrega variabilidad a la estimación estadística.

Para realizar la imputación se adoptó el método de imputaciones múltiples con ecuaciones encadenadas, que es bastante robusto a MNAR y otros mecanismos más complejos de pérdida de datos.³ Las imputaciones múltiples, si bien pueden aparecer como una estrategia complicada, son una buena forma de resolver el problema de datos faltantes generando la menor distorsión posible. Además, han demostrado ser muy eficientes en muchos entornos, mejorando la calidad de los estimadores sin poner en riesgo el sesgo.

En sí, la imputación múltiple es una metodología de simulación que permite completar múltiples veces los sets de datos. Siguiendo las reglas de Rubin (1987, 1996), es posible obtener estimadores robustos e insesgados. Se debe tener en cuenta que la imputación múltiple es un procedimiento sencillo de reemplazo de información faltante por múltiples versiones de un mismo dato. Dado esto, se puede partir de la imputación tradicional, replicarla y aplicar las reglas de Rubin para obtener mejores estimadores. Las reglas de Rubin también ayudan a controlar la incertidumbre causada por los datos faltantes, por lo que el conjunto de datos también mejora.

Sin embargo, al contrario de otros métodos como *cold deck*, *hot deck*, medias predictivas, etc., esta metodología no está interesada en un valor particular del dato faltante, sino más bien en su distribución y cómo ésta contribuye a explicar la distribución conjunta de la población. Entonces, el foco no está en una imputación, sino en el uso de múltiples imputaciones para resolver un conjunto predictivo del comportamiento poblacional. Puesto en términos prácticos, no nos interesa, por ejemplo, el salario promedio mensual no declarado de un entrevistado(a), sino el promedio y la varianza de salarios de los entrevistados de la encuesta.

Para imputar los salarios y el arriendo, se usó la variante de ecuaciones encadenadas (conocida como MICE) que permite retroalimentar, iteración tras iteración, el sistema de imputación, apoyando cada nueva imputación en los valores obtenidos anteriormente. Si bien es intensiva en cómputo, tiene la ventaja de ser muy flexible y generar estimadores eficientes (Carlin et al., 2003).

Los modelos que se emplearon incluyeron variables sociodemográficas (sexo, edad, educación, composición del hogar), del mercado laboral (CIUO, CIIU), previsionales, propiedad de la vivienda, y participación en la EPS (para controlar por posibles sesgos MNAR). Dadas las características de las dos variables imputadas, se utilizaron regresiones censuradas que establecieron las siguientes cotas:

³ En Chile, esta metodología se emplea en la Encuesta Financiera de Hogares del Banco Central de Chile, y fue introducida en la ronda anterior de la EPS para la imputación de estos mismos conceptos.



$$\$100.000 < \text{ingreso laboral} < \$10.000.000$$

$$\$100.000 < \text{arriendo mensual} < \$6.000.000$$



Dado que la imputación múltiple con ecuaciones encadenadas es un proceso iterativo cuando la pérdida de datos no es monótona, se debe chequear la convergencia de las series encadenadas para asegurar que no haya comportamientos anómalos (por ejemplo, divergencia persistente de la media de las imputaciones, o cambios bruscos en su varianza). Para ello, se realizó un ejercicio de imputación simulada con 50 réplicas cuyos resultados, en términos de media y desviación standard de las imputaciones de ambas variables, se muestran en la Figura 3.3.

Figura 3.3. Convergencia de imputaciones de ingreso laboral y arriendo

Panel A. Ingreso laboral



Panel B. Arriendo estimado



Fuente: elaboración propia.

Si bien se ha discutido mucho el tema, no hay un acuerdo sobre el número de réplicas a utilizar en la imputación. En general, éstas van entre 5 y 20 como sugerencia, aunque algunos establecen que “más es mejor”, y que debería haber tantas réplicas como celdas individuales faltantes se deban imputar. Sin

embargo, los tiempos de cómputo establecen límites razonables a éstas. En el caso de la EPS 2023, siguiendo las sugerencias más habituales, se incluyeron 6 réplicas.⁴

Los datos completos, que se encuentran en la base de datos de imputaciones, quedaron configurados según se muestra en la Tabla 3.4.

Tabla 3.4. Resultado final del proceso de imputación de ingresos laborales y arriendos

```
Multivariate imputation          Imputations =      6
Chained equations                added =      6
Imputed: m=1 through m=6        updated =      0

Initialization: monotone        Iterations =     60
                                burn-in =     10

Conditional imputation:
  ing_lab_new: no incomplete out-of-sample observations

  ing_lab_new: interval regression
  arriendo_new: interval regression
```

Variable	Observations per <i>m</i>			Total
	Complete	Incomplete	Imputed	
ing_lab_new	14665	1123	864	15788
arriendo_new	10129	5659	3677	15788

(Complete + Incomplete = Total; Imputed is the minimum across *m* of the number of filled-in observations.)

Note: Right-hand-side variables (or weights) have missing values; model parameters estimated using listwise deletion.

Nota: el reporte se encuentra expresado en idioma inglés, ya que es la salida oficial del *software* empleado para realizar las imputaciones, Stata 17.


Fuente: elaboración propia.

El comportamiento de las cadenas de imputaciones, en donde se puede ver la convergencia de cada una de las réplicas imputadas, se puede observar en la Figura 3.5.


⁴ Agregar más replicas sólo requiere cambiar un parámetro en el modelo y correr nuevamente el software, por lo que es trivial incluir más casos. En la Encuesta Financiera de Hogares del Banco Central de Chile, por ejemplo, se emplean 30 réplicas, aunque no se ha podido justificar adecuadamente la razón de esa cantidad.

Figura 3.5. Comportamiento de la convergencia de las cadenas de imputación

Panel A. Ingreso laboral



Panel B. Arriendo estimado




Fuente: elaboración propia.

3.5.1 Imputación de ingreso promedio mensual laboral

Para el caso de los ingresos mensuales, el comportamiento de las distribuciones original, imputada, y completada para cada una de las iteraciones, tiene el siguiente aspecto:

Figura 3.6. Comportamiento de las imputaciones – Ingreso Laboral Promedio Mensual




Fuente: elaboración propia.

3.5.2 Imputación de arriendo

En el caso de los arriendos, las distribuciones se comportan según se muestra en la Figura 3.7.

Figura 3.7. Comportamiento de las imputaciones – Arriendo estimado de la vivienda particular



Fuente: elaboración propia.

Para mostrar el efecto que tiene la incorporación de información imputada, se puede observar la Tabla 3.8. Allí, se muestra la distribución del ingreso promedio mensual y del arriendo estimado mensual obtenido con y sin ponderaciones (es decir, dependiendo de si tomamos en cuenta o no los factores de expansión de corte transversal), e incorporando o no información imputada. Nótese, por ejemplo, que los montos de ingreso mensual promedio son mayores cuando se aplican ponderaciones e imputaciones, pues una de las razones de pérdida de información es que las personas tienden a ocultar sus ingresos si estos son altos. Este fenómeno recibe el nombre de reversión a la media: las personas tienden a reportar un valor promedio para alguien en su condición, antes que el verdadero valor de la variable en cuestión.

Tabla 3.8. Comparación de los efectos de las ponderaciones e imputaciones

Método Variable	N. Obs	Media	Error Std.	[Intervalo Conf. 95%]	
Sin Ponderaciones, Sin Imputaciones					
Ingreso promedio mensual laboral	14665	311.2191	4.1916	303.0031	319.4351
Arriendo de vivienda (similar)	10129	362.5184	2.4990	357.6199	367.4169
Sin Ponderaciones, Con Imputaciones					
Ingreso promedio mensual laboral	15529	342.0215	4.3307	333.5255	350.5174
Arriendo de vivienda (similar)	13806	381.0796	2.3499	376.4017	385.7575
Con Ponderaciones, Sin Imputaciones					
Ingreso promedio mensual laboral	14665	414.2251	10.7469	392.8381	435.6121
Arriendo de vivienda (similar)	10129	376.9623	8.5701	359.9074	394.0173
Con Ponderaciones, Con Imputaciones					
Ingreso promedio mensual laboral	15529	456.2639	12.3970	431.5622	480.9657
Arriendo de vivienda (similar)	13806	397.3470	6.7547	383.8061	410.8878

Fuente: elaboración propia.

3.6 Consideraciones finales sobre imputaciones

En esta propuesta de imputaciones, se incorporaron nuevamente las imputaciones múltiples como técnica más robusta y cada vez más extendida en el tratamiento moderno de datos (esta técnica fue introducida en el tratamiento de imputaciones en la EPS 2020). El uso de esta técnica se ha hecho más sencillo dado que la mayoría de los *softwares* estadísticos incorporan procedimientos para procesar el conjunto informativo. Sin embargo, la intensidad computacional sigue siendo un tema a tener en cuenta si se lo compara con otros métodos uni- y multi-variados de imputación única, como *hotdeck* o medias predictivas.

La ganancia con esta metodología se encuentra en la inferencia. Mejores y más robustos indicadores permiten tener una mejor aproximación a los fenómenos, sin depender de los valores específicos de las imputaciones.

Se destaca el hecho de que, en general, es más útil para los investigadores contar con herramientas, orientaciones e información que les permitan hacer sus propias imputaciones, que entregar sets de datos imputados, como se hace con algunas encuestas. Esto implica dejar información suficiente a disposición del usuario para que lleve adelante los procesos.

4. REFERENCIAS

- Allison, P. D. (2001). *Missing Data*. Thousand Oaks, CA: Sage.
- Card, D. y N. A. Smith (2015). "Automated Coding of Open-Ended Survey Responses," draft paper.
- Carlin, J. B., J. C. Galati, y P. Royston (2008). A new framework for managing and analyzing multiply imputed data in Stata. *Stata Journal* 8: 49—67.
- Carlin, J. B., N. Li, P. Greenwood, y C. Coffey (2003). Tools for analyzing multiple imputed datasets. *Stata Journal* 3: 226—244.
- Dillman, D. A., & Christian, L. M. (2005). "Survey mode as a source of instability in responses across surveys," *Field Methods*, 17(30), 30-52.
- Emde, M., & Fuchs, M. (2012). "Using adaptive questionnaire design in open-ended questions: A field experiment," Paper presented at the American Association for Public Opinion Research (AAPOR) 67th Annual Conference, San Diego, USA.
- Giorgetti, D., I. Prodanof y F. Sebastiani (2002). "Automated Coding of Open-ended Surveys: Technical and Ethical Issues," International Conference on Universal Knowledge and Language. ICUKL-2002, Goa, India, 25-29 November 2002.
- Organización Internacional del Trabajo (s.f) Estructura de la CIUO-08 y concordancias previas con la CIUO-88. Recuperado de: <https://www.ilo.org/public/spanish/bureau/stat/isco/isco08/index.htm>
- INE (2008) CIUO 08.CL Clasificador Chileno de Ocupaciones. Recuperado de: http://webanterior.ine.cl/docs/default-source/publicaciones/2018/ciuo-08.cl-clasificador-chileno-de-ocupaciones.pdf?sfvrsn=50bd58d2_4
- Lee, K. J., y J. B. Carlin (2010). Multiple imputation for missing data: Fully conditional specification versus multivariate normal imputation. *American Journal of Epidemiology* 171: 624—632.
- Little, R. J., y D. Rubin (1987). *Statistical analysis with missing data*, New York, Wiley.
- Little, R. J., y D. Rubin (2002), *Statistical analysis with missing data* (2nd Ed.), New York, Wiley.
- Little, R. J. y D. Rubin (2020). *Statistical analysis with missing data* (3rd ed.). John Wiley & Sons: Boston, MA.
- Marchenko, Y. V., y W. D. Eddings (2011). A note on how to perform multiple-imputation diagnostics in Stata. *Webpage*: <http://www.stata.com/users/ymarchenko/midiagnote.pdf>
- Medina, F. y M. Galván (2007). Imputación de datos: teoría y práctica. *Serie Estudios Estadísticos y Prospectivos*, No. 54, CEPAL.

- Naciones Unidas (2009) Clasificación Industrial Internacional Uniforme de todas las actividades económicas (CIIU). Informes Estadísticos, Serie M, No.4/Rev.4. Recuperado de: https://unstats.un.org/unsd/publication/SeriesM/seriesm_4rev4s.pdf
- Rubin, D. B. (1987). Multiple Imputation for Nonresponse in Surveys. New York: Wiley.
- Rubin, D. B. (1996). Multiple imputation after 18+ years. *Journal of the American Statistical Association* 91: 473—489.
- Rubin, D. (1976). *Inference and missing data*. Biometrika, Vol. 581—592.
- Schafer, J. L. (1997). *Analysis of Incomplete Multivariate Data*. Boca Raton, FL: Chapman & Hall/CRC.
- Schonlau M. y M. P. Couper (2016). "Semi-automated categorization of open-ended questions," *Survey Research Methods* (2016), Vol. 10(2):143-152.
- Van Buuren, S. (2017). *Flexible imputation of missing data*. (Sec. Ed.) Boca Raton, FL: CRC Press
- Wood, Josepiah, Gregory Matthews, Jennifer Pellowski y Ofer Harel (2019). "Comparing Different Planned Missingness Designs in Longitudinal Studies." *Sankhya B*, Vol. 81:226—250.
- Züll, C. (2016). "Open-Ended Questions," *GESIS Survey Guidelines*. Mannheim, Germany: GESIS – Leibniz Institute for the Social Sciences. doi: 10.15465/gesis-sg_en_002.

5. ANEXOS

5.1 ANEXO 1 – Edición de la base de datos

La edición de la base de datos se realizó bajo 3 circunstancias:

- *Outliers*: valores extremos, ya sea por encima o por debajo de la distribución, que hemos considerado resultado de errores de tipeo del encuestador o de reporte del Entrevistado(a), y que no generan resultados plausibles. En general, estos casos se marcan como 'No sabe' para que el usuario de la base decida si someterlos a procesos de imputación o validaciones más exhaustivas. Sin embargo, los *outliers* de las variables de arriendo e ingreso promedio mensual son imputadas siguiendo las reglas explicadas previamente.
- Valores inconsistentes con el contexto: se trata de información que se puede compartir o contrastar con otras variables de la encuesta y que lleva a la conclusión de que no son correctas o, al menos, plausibles.
- Valores inconsistentes: son aquellos valores que pueden interpretarse como una falta de intención de entregar una respuesta (por ejemplo, información expresada en 'Especifique' que no es contrastable con la realidad) o valores que no concuerdan con el contexto económico reportado en la encuesta (por ejemplo, un gasto familiar en educación de \$56 millones para una familia con ingresos de menos de un millón de pesos promedio mensuales).

A continuación, se detalla la edición realizada módulo por módulo en el cuestionario a personas vivas.

Módulo A – Entrevistado(a)

- Se verificó que la variable a9 (edad) sea consistente con la fecha de nacimiento. Es por este motivo que, en aquellos casos que el cálculo derivado de la resta entre la fecha de aplicación de la entrevista y la fecha de nacimiento arrojó una diferencia, se procedió a una edición. Esto ocurrió solamente en 11 casos.
- Se creó la variable auxiliar “escolaridad_ed” que contiene una estimación de los años de escolaridad de los Entrevistado(a)s(as) basados en la combinación de máximo nivel educativo alcanzado (a12_n) y máximo curso aprobado en el nivel (a12_c). Esta nueva variable contiene los códigos 80 “Ninguno”, 88 “No responde” y 99 “No sabe”.
- Se corrigieron 23 casos inconsistentes relacionados a la variable A8 y A8b acerca de orientación sexual y de género. Estos casos fueron asignados con el valor “88” No responde.

Módulo A – Carrera

- Se ajustaron las fechas de inicio y termino de carrera de 181 casos que indicaron haber terminado sus estudios superiores el mismo año en que iniciaron (variables a15_a y a15_b). Se consideró como reemplazo la duración mínima de 1 año.
- Se ajustaron 3 casos en los que las personas declararon haber terminado su educación (a15_b) antes de la fecha de inicio(a15_a). Se invirtieron los años declarados.
- Se ajustó 1 caso donde la persona indicó que financió sus estudios superiores con 9 fuentes de financiación distintas. Esto fue reemplazado con la opción 9 “No Sabe”.
- Se ajustaron 9 casos que indicaron que se titularon (a19) antes de terminar la carrera (a15_b). Se invirtieron los años declarados.

Módulo B – Historia Laboral

- Situación laboral:
 - Existen 20 casos que no tenían información en la fecha de inicio, pero que se podían deducir de la respuesta de las otras historias laborales.
 - Existen 35 casos que no tenían información en la fecha de término, pero que se podían deducir de la respuesta de las otras historias laborales.
 - Hay 3 casos que no tenían información en b5, para los cuáles se les asignó un “no responde”
 - Hay 7 casos que no tenían información en b0, en estos casos se les asignó un “no responde”.
- Codificaciones de empleo, actividad y situación ocupacional:
 - Se realizaron codificaciones en función de la información que se logró recuperar en terreno. Los detalles se encuentran en la sección “Codificación de variables seleccionadas”.
 - En el caso de la CIU rev. 4 a un dígito, se utiliza una codificación alfanumérica. Por lo tanto, para aplicar la descripción completa, se creó una variable auxiliar llamada CIU_1dig_cat que recupera la misma información en codificación numérica. Las etiquetas aplicadas corresponden a las categorías alfanuméricas junto con la descripción propia de cada categoría. De esta manera, se dispone de una variable con la codificación original y una variable con codificación numérica, útil para tabulaciones e informes donde es importante la descripción de cada categoría de actividad.

Módulo B – Situación Actual

- Variables no propias de la base: Se incorporaron a la base, las variables b2_a y b8 para último episodio laboral ya que sirven de referencia para tabulaciones, cruces y chequeos de consistencia.

Módulo C – Entrevistado(a)

- Para realizar la validación y edición de esta base, se incorporaron las variables b2_a y b8 de la base de datos de la última historia laboral disponible de cada entrevistado(a).
- La condición de entrada para contestar la pregunta C30 en las variables C30_6 y C30_7 es tener más de 65 años. En 2 casos, el script aplicó un salto a pesar de que el Entrevistado(a) contaba con esta condición. En ambas situaciones, se codificó la alternativa “No responde”.
- Los valores superiores a 18.000.000 en la variable C8_m fueron codificados en la alternativa 9 “No sabe” al ser considerados valores muy altos.
- Los valores superiores a 18.000.000 en la variable C22_e fueron codificados en la alternativa 9 “No sabe” al ser considerados valores muy altos.
- Los valores superiores a 10.000.000 en la variable C30_m_g fueron codificados en la alternativa 9 “No sabe” al ser considerados valores muy altos.
- Los valores superiores a 15.000.000 en la variable C34 fueron codificados en la alternativa 9 “No sabe” al ser considerados valores muy altos.
- Los valores superiores a 3.000.000 en la variable C33_m_g fueron codificados en la alternativa 9 “No sabe” al ser considerados valores muy altos.

Módulo D – Entrevistado(a)

- La condición de entrada para contestar la pregunta D9_a_2 es que la vivienda propia es de otro integrante del hogar (D_9_1=3). En un caso, el script aplicó un salto en D9_a_2, a pesar de que efectivamente la vivienda era de otro integrante. Ante este escenario, se asignó un “No responde”.
- Los valores superiores a 8.000.000 en la variable d8_a fueron codificados en la alternativa 9 “No sabe” al ser considerados valores muy altos.
- Los valores superiores a 1.000.000 en la variable d12_b fueron codificados en la alternativa 9 “No sabe” al ser considerados valores muy altos.
- Los valores superiores a 10.000.000 en la variable d14 fueron codificados en la alternativa 9 “No sabe” al ser considerados valores muy altos.
- Se ajustaron 4 casos que declararon pagar en dividendos en d14, el mismo valor que tiene su vivienda (a17_a). La variable d14 fue reemplazada con un 9 “No sabe”.
- Se ajustaron 6 casos en los cuales las personas declaran, deber 1 o más millones en la variable d30_m, más que el valor total de los bienes declarados en d29_m. Se le asignó un valor 9 “No sabe”.
- Se ajustaron 12 casos en los cuales la persona entrevistada indica que hay una o más de una persona del hogar que es propietaria o socia de un negocio, pero en la pregunta d31_b no identifican quien

es la persona dueña o socia de un negocio. Se ajustaron las respuestas de las variables d31_b_1 a d31_b_5 con un 9 “No sabe”.

- Se ajustaron 16 casos en los cuales las personas indicaron que tienen deuda en su línea de crédito por más de 8 millones, variable d37m_2. Fueron codificados en la alternativa 9 “No sabe” al ser considerados valores muy altos.
- Se ajustaron 2 casos en los cuales las personas indicaron que tienen préstamos de consumo bancario por más de 80 millones, variable d37m_5. Fueron codificados en la alternativa 9 “No sabe” al ser considerados valores muy altos.
- Se ajustó un caso en el cual la persona indica que tiene un préstamo de consumo en financieras por más de 600 millones, variable d37m_6. Fueron codificados en la alternativa 9 “No sabe” al ser considerados valores muy altos.
- Existen 12 casos en los cuales las personas indicaron que tienen créditos educacionales por 33 o más millones (variable d37m_9). En la ronda anterior el máximo valor declarado fue de 22 millones. Fueron codificados en la alternativa 9 “No sabe” al ser considerados valores muy altos.
- Se ajustó 1 caso en el cual la persona indico que tiene un préstamo de parientes o amigos por 100 millones, variable d37m_10. Fueron codificados en la alternativa 9 “No sabe” al ser considerados valores muy altos.
- Se ajustaron 27 casos en los cuales las personas indicaron que si lograban conseguir el ingreso del hogar para 6 meses (d38_a), pero al responder las opciones de donde lo conseguirían, indican en todas las opciones registradas en las preguntas d38_c_* que no, este flujo es inconsistente. Se asignó la opción Sí en la variable d38_c_11 y la respuesta “No sabe” en la variable d38_c_11_e y d38_c_11_e_cod
- Se ajustaron 321 casos en los cuales las personas respondieron no sabe, no responde o indicaron que no podrían conseguir el ingreso del hogar para 6 meses (d38_a), pero al responder la pregunta d38_b, respondieron que podrían conseguir más de la mitad, la mitad o menos de la mitad, razón por la que deberían haber respondido en las preguntas d38_c_* la opción si, no sabe o no responde en al menos una de las alternativas de la pregunta d38_c_*. Se asignó la opción Sí en la variable d38_c_11 y la respuesta “No sabe” en la variable d38_c_11_e y d38_c_11_e_cod

Módulo E – Entrevistado(a)

- Variables no propias de la base: Se incorporaron a la base, las variables C17_1, C17_2 y C17_3 (Estado de jubilación), a8 (sexo) y a9 (edad), ya que sirven de referencia para tabulaciones, cruces y chequeos de consistencia.
- La condición de entrada para contestar la pregunta E69 (Postulación al bono por hijo) es ser mujer de 65 años o más. En un caso, el script aplicó un salto en E69. En esta situación, se asignó un “No responde”.
- A modo de referencia, en esta ronda de la EPS la variable e57 hace referencia a la pregunta “¿Cumple usted con los requisitos para acceder a una Pensión Garantizada Universal o PGU?”. En la

VI Ronda (2015) existía otra pregunta con la misma numeración que detalla los beneficios que tendrían los familiares si el entrevistado fallece.

- Fueron ajustadas la cantidad de personas a la que se pregunta sobre su postulación al bono por hijo e69, debido a que es mayor a la cantidad de personas que debe haber por el filtro (si respondieron si a la pregunta e66).
- Fueron corregidas las respuestas de la pregunta e69, debido a que hay 13 personas de sexo masculino a los que se les pregunta postulación al bono por hijo y esta pregunta debe realizarse sólo a mujeres.

Módulo F – Entrevistado(a)

- Para realizar la validación de esta base, se incorporaron las variables a8 (sexo) y a9 (edad) de cada entrevistado(a).
- La condición de entrada para contestar la pregunta F54_e_2 (realización del examen de la próstata) es ser hombre. En un caso, el script aplicó un salto en esta pregunta, ante lo cual se asignó un “No responde”.
- Se ajustó 1 caso donde existía respuesta en F5 cuando se responde F1 = 8. Fue asignado a valor missing debido a ser un error de flujo.

Módulo G – Entrevistado(a)

- La condición de entrada para contestar la pregunta G11 (n° de capacitaciones finalizadas) es haber realizado alguna durante un periodo determinado. En dos casos, el script aplicó un salto en esta pregunta, ante esto, se asignó un “No responde”.
- Se ajustaron 20 casos donde en la variable “G.10 Desde la última vez que respondió la encuesta (Panel) o desde que tenía 15 años (Nacimiento), ¿ha recibido algún tipo de capacitación laboral, sindical, recreacional u otro curso de nivelación educacional (básico, medio CH o medio TP)?”, la pregunta “G.11 ¿Cuántos cursos de capacitación ha realizado en este periodo?” contiene la respuesta 0. Estos valores fueron recodificados con la opción 9 “No sabe”.

Módulo L – Entrevistado(a)

- Variables no propias de la base: Se incorporó a la base de datos la variable auxiliar “npersonas2” que indica la cantidad de personas que conforman el hogar del entrevistado. Esto permite hacer chequeos de consistencia.

- En el procesamiento, se creó una variable adicional de chequeo de consistencia, denominada L1_check, que se encuentra en las bases intermedias, y que tiene en cuenta que algunos hogares pueden tener registrado un número de miembros mayor a 1, pero en la práctica, estos miembros no viven en el hogar, y el hogar es, *de facto*, unipersonal.
- Se revisó cada uno de los registros del módulo, contrastando con la estructura del hogar remanente (personas que aun permanecen dentro del hogar), se hicieron los ajustes de casos que fueron reportados como cuidados fuera del hogar y correspondían a personas miembros del hogar, doble reporte de personas cuidadas, y personas cuidadas fuera del hogar que antes pertenecían al hogar.
- En general, la información reportada era suficiente para completar adecuadamente los registros de las personas cuidadas. Esto permitió reconstruir el módulo sin pérdida de información.
- Se hicieron ajustes de consistencia las preguntas L.1, L.2, L.14 y L.21, en función del ajuste del reporte de personas cuidadas dentro y fuera del hogar.
- El chequeo exhaustivo del módulo permitió crear 3 bases de datos, en las que la base de datos Módulo_L_Entrevistado contiene información sobre el Entrevistado individual. Las otras dos bases de datos contienen información sobre personas cuidadas dentro del hogar (Módulo_L_CDH) y fuera del hogar (Módulo_L_CFH).

Módulo L – CDH

- Esta base de datos contiene información sobre cada persona dentro del hogar que es declarada como “cuidada” por la persona entrevistada. Se incorporaron en esta base de datos variables de relación de parentesco con la persona entrevistada, sexo y edad, que han sido tomadas del módulo Hogar y que permiten completar la caracterización de las personas cuidadas dentro del hogar sin necesidad de recurrir a información traída desde otra base de datos.
- Los registros de esta base de datos sólo son posibles para personas entrevistadas que no habitan en hogares unipersonales (condición de entrada a variable L.1).

Módulo L – CFH

- Esta base de datos contiene información sobre cada persona cuidada fuera del hogar que ha sido declarada como tal por la persona entrevistada. La base de datos contiene toda la caracterización de la persona cuidada junto a aspectos relacionados con el cuidado de la persona.
- Se corrigieron manualmente 111 declaraciones de relaciones de parentesco de la persona cuidada con la persona cuidadora ya que era evidente la mala interpretación de la pregunta. Entre los errores más habituales estaba el confundir la relación de parentesco de la persona cuidada respecto al cuidador, reportando este relación en lugar de la relación entre el cuidador y la persona cuidada (por ejemplo, se reportaba que la persona cuidada era el nieto, cuando era el abuelo, y el nieto era

el cuidador). Se debe revisar la redacción de esta pregunta (tal vez agregar una ejemplificación), para lograr mayor precisión en la respuesta entregada en la encuesta, sin necesidad de recurrir a un ajuste manual basada en la información complementaria entregada por la persona entrevistada.

- En la variable L.18 , la cantidad de horas máximas que deberían estar registradas es 168 (24 horas los 7 días de la semana). El valor superior a este número (11000 horas) fue ajustado ya que correspondía a un error de tipeo. Quedó fijado en 110 horas.

Módulo H – Entrevistado(a)

- Variables no propias de la base: Se incorporó a la base, la variable auxiliar “muestra” que indica el tipo de muestra: Panel o Nacimiento. Dado que este módulo lo responden los “Nacimientos”, sirve para validar que se hayan aplicado las preguntas a este segmento.

Módulo Hogar

- Variables no propias de la base: Las variables a1 (nombre de pila), a2_a (pertenencia al hogar), a8 (sexo), a9 (edad) y npersonas2 (N° personas del hogar), no están contenidas en este módulo según la composición del cuestionario, sin embargo, al tratarse de un módulo que describe al resto de los integrantes del hogar, se hace necesario contar con esta información que está presente en la base cruda, no solo para efectos informativo, sino que también de validación de flujo.

Módulo I Hijos

- Se ajustó la variable año de nacimiento (i21_anio), que debería contener sólo información de los hijos nacidos desde 2020 en adelante o desde la última ronda entrevistado; pero hay años de nacimientos de hijos registrados desde 1968. Para realizar el ajuste, se consideró la última ronda de la encuesta contestada. Todos los casos fuera de rango fueron eliminados de la base de datos.