



Informe Técnico

VIII RONDA ENCUESTA DE PROTECCIÓN SOCIAL



**CHILE
AVANZA
CONTIGO**

Contenido

1. Introducción	4
2. Muestreo en EPS VIII Ronda	6
2.1. Muestra de panel	9
2.2. Muestra de nacimientos.....	11
2.2.1. Marco muestral	12
2.2.2. Tamaño muestral	13
2.2.3. Selección de la muestra	14
3. Atrición en la EPS VIII Ronda	18
3.1. Razones de no respuesta.....	19
3.2. Atrición por olas.....	20
3.3. Comportamiento de variables seleccionadas a través de las olas.....	27
3.3.1. Distribución geográfica	28
3.3.2. Distribución de sexo	30
3.3.3. Distribución de edad	31
3.3.4. Piramide poblacional	33
3.3.5. Distribución del estado civil	35
3.3.6. Distribución de personas afiliadas al sistema de pensiones	37
3.4. Conclusiones sobre atrición	39
4. Factores de expansión de corte transversal.....	41
4.1. Configuración de la muestra de la EPS 2023.....	42
4.2. Ajustes por atrición y no respuesta	44
4.3. Post-estratificación de los factores de corte transversal.....	55
4.4. Factores de expansión finales de corte transversal.....	61
5. Factores de expansión longitudinales: Paneles en la EPS VIII Ronda	65
5.1. Panel 2002-2004-2006-2009-2015-2020-2023.....	65
5.2. Panel 2004-2006-2009-2015-2020-2023	71
5.3. Panel 2015-2020-2023	72
5.4. Ajustes adicionales a los factores de expansión.....	74
6. Estimación de varianza y errores muestrales	76
6.1. Error de muestreo	76
6.2. Errores muestrales en la EPS VIII Ronda	77
6.3. Coeficiente de variación.....	82
6.4. Intervalos de confianza.....	82

6.5. Efecto diseño	83
7. Cálculo de indicadores para la EPS VIII Ronda	85
7.1. Obtención de indicadores de corte transversal y longitudinales	85
7.2. Enfoque práctico	85
7.3. Estimador de totales	86
7.4. Estimador de razones (<i>ratios</i>)	88
7.5. Estimador de medias y proporciones	89
7.6. Estimador de cuantiles	90
7.7. Ejemplos prácticos de estimación	90
7.7.1. Plan de muestreo.....	91
7.7.2. Estimaciones para una variable dicotómica.....	91
7.7.3. Estimaciones para una variable politómica	97
7.7.4. Estimaciones para una variable continua discretizada	101
7.7.5. Estimaciones para una variable continua.....	105
Referencias.....	113
Anexo A: Ajustes al marco muestral original de Nacimientos EPS 2023	115
A.1. Nombres de comunas que no corresponden a comunas	115
A.2. Comuna excluida del muestreo original (2002).....	116
A.3. Comunas con región errónea	116
A.4. Comunas sin número de región que no tienen un nombre de comuna que permita identificar unívocamente la localización	116
A.5. Observaciones sin información de región, pero con información de comuna.....	116

1. Introducción

La Encuesta de Protección Social (EPS) 2023, en su VIII Ronda, representa un esfuerzo significativo de la Subsecretaría de Previsión Social de Chile para recolectar información exhaustiva y actualizada sobre el comportamiento previsional de las personas chilenas. Este informe técnico tiene como objetivo principal proporcionar una visión detallada y comprensiva de los diversos aspectos abordados en esta ronda de la encuesta, ofreciendo a los y las investigadores/as, formuladores/as de políticas y otros interesados/as un recurso valioso para entender y mejorar el sistema previsional chileno.

La EPS, desde su primera implementación, ha sido una herramienta crucial para recopilar datos sobre las prácticas y percepciones previsionales de la población chilena. Con cada nueva ronda, se han introducido mejoras metodológicas y se han ampliado los objetivos de análisis, permitiendo una comprensión más profunda de las tendencias y desafíos en el ámbito previsional. La VIII Ronda no es la excepción, incorporando innovaciones tanto en el diseño muestral como en el análisis de datos para garantizar una representación precisa y fiable de la población objetivo.

Este informe está estructurado en varias secciones, cada una dedicada a un aspecto específico de la encuesta y su análisis. A continuación de esta introducción, se examina la construcción de la muestra para la VIII Ronda de la EPS, destacando la complejidad del proceso. Se abordan aspectos como la muestra de panel y la muestra de nacimientos, explicando el marco muestral utilizado, el tamaño de la muestra y los criterios de selección. Esta sección es crucial para entender cómo se asegura la representatividad de los datos recopilados y cómo se gestionan las diversas fuentes de sesgo potencial. Vale la pena notar que en esta ronda de la EPS se incorporan nuevas observaciones para representar la población de 18 y más años que se pueden considerar en situación de incorporarse a la fuerza laboral desde julio de 2015 hasta junio de 2023.

En la tercera sección se analiza el comportamiento de los y las participantes en términos de atrición y no respuesta. Esta sección investiga las razones por las cuales algunas personas entrevistadas no respondieron o dejaron de participar a lo largo del tiempo, examinando cómo estas dinámicas afectan la calidad y representatividad de los datos. Para ello se exploran las diversas causas de la no respuesta y su impacto en la encuesta, se analiza la pérdida y recuperación de participantes a través de las diferentes olas de la encuesta, estudiándose el comportamiento de algunas variables relevantes a lo largo del tiempo debido a la atrición. También se presentan conclusiones y recomendaciones para mitigar los efectos de la atrición en futuros estudios.

En la cuarta sección se detallan los ajustes realizados a los factores de expansión para corregir la no respuesta y la atrición, asegurando que los datos sean representativos de la población general.

Se explica el proceso de post-estratificación y los factores de expansión finales utilizados en los análisis. En la quinta sección, se continua con la descripción del proceso de obtención de los factores de expansión longitudinales necesarios para el análisis de los paneles de datos. Se abordan los diferentes paneles incluidos en la EPS VIII Ronda y los ajustes adicionales realizados para garantizar la representatividad a lo largo del tiempo. Se proponen 3 paneles para esta ola:

- Panel 2002-2004-2006-2009-2015-2020-2023
- Panel 2004-2006-2009-2015-2020-2023
- Panel 2015-2020-2023

La sexta sección se destina a tratar la estimación de varianza y errores muestrales, debido a que la precisión y validez de las estimaciones son fundamentales en el análisis de encuestas. Esta sección aborda los errores muestrales, el efecto diseño y los métodos para calcular la varianza y los intervalos de confianza, proporcionando una comprensión completa de la precisión de los datos.

La última sección describe la metodología para calcular diversos indicadores a partir de los datos de la encuesta. Se explican los estimadores de totales, razones, medias, proporciones y cuantiles, y se proporcionan ejemplos prácticos de cómo aplicar estos métodos en el análisis de datos.

En conclusión, la Encuesta de Protección Social 2023 - VIII Ronda proporciona una base sólida para el análisis del comportamiento previsional de la población chilena. A través de un diseño meticuloso y ajustes cuidadosos, esta ronda de la encuesta ofrece datos valiosos que pueden informar políticas públicas y mejorar la comprensión de las prácticas previsionales en Chile. Este informe técnico no solo detalla los métodos y resultados de la encuesta, sino que también proporciona un recurso integral para investigadores/as y formuladores/as de políticas interesados/as en el desarrollo y mejora del sistema previsional chileno.

2. Muestreo en EPS VIII Ronda

La muestra de la EPS se ha realizado siguiendo una metodología de “panel fijo + nacimientos”, es decir, en cada ocasión que se agregó muestra, se hizo debido a la actualización del marco muestral (o para extenderlo, como sucedió en 2004, para representar la población total del país de 18 o más años). Así, en la primera ronda (2002), sólo se incluyó población afiliada al sistema de pensiones representativa del perfil demográfico del país para mayores de 18 años.¹ En el 2004, se incorporaron dos muestras: una muestra correspondió a la actualización del marco muestral de la EPS I Ronda incorporando a quienes habían cumplido 18 años en el período 2002-2004. La otra muestra se incorporó para extender el marco muestral para que la encuesta tuviera representatividad nacional para mayores de 18 años, hayan o no estado afiliados/as al sistema de pensiones. Por lo tanto, esta segunda muestra incorporó a mayores de 18 años al 2004 que no estaban afiliados/as al sistema. En el año 2012, se decidió incorporar una muestra para actualizar el marco muestral; sin embargo, la nueva muestra fue descartada por razones de calidad estadística. En el año 2015 se incluyó una nueva actualización del marco muestral incorporando a quienes habían cumplido 18 años entre 2004 y 2015.

En la VII Ronda (2020), no se incluyeron nacimientos ni actualización del marco muestral y sólo se buscó fortalecer el vínculo con el panel. Esa ronda, en particular, sufrió los efectos de tres fenómenos conjuntos: (i) efecto del Estallido Social de Octubre de 2019, (ii) el advenimiento de la pandemia de COVID-19, y (iii) la necesidad de instrumentar cambios metodológicos para hacer frente a las restricciones de movilidad y contacto impuestas debido al COVID-19. En la ronda actual, se retomó la iniciativa de agregar nueva muestra a la encuesta a través de la incorporación de “nacimientos” (incorporación de personas al criterio de selección de la encuesta) ocurridos entre julio de 2015 y junio de 2023.

La selección de la muestra de 2002 se realizó a través de un proceso en dos etapas para lograr obtener un total de 20.000 observaciones: en primer término, se seleccionaron *clusters* geográficos (comunas de inclusión forzosa más comunas de inclusión probabilística), mientras que en la segunda etapa se seleccionó a los entrevistados según su condición de afiliado/a al sistema, sexo y edad. De esta manera, se configuró una muestra representativa de estos aspectos de la población de cada *cluster*, obteniéndose idéntica probabilidad de selección para cada entrevistado/a dentro del *cluster* condicional en estas características². Las incorporaciones de

¹ Nótese que si bien esta población fue enunciada como población objetivo según surge de los informes de las primeras olas, en la muestra de 2002 aparecen 16 casos con edades inferiores a 18 años. Esto se puede deber a que, en realidad, el marco muestral tomado fue el conjunto de personas inscritas en el sistema de pensiones de la época. Dado que para trabajar y participar del sistema de pensiones se puede tener menos de 18 años, esto explicaría la presencia de estos casos que no siguen la regla enunciada por el estudio original.

² Véase Lohr (2010), capítulo 8.

muestra en 2004 y 2015 siguieron el mismo diseño, manteniendo la estructura de clusters y selección de unidades primarias de muestreo.

En la presente ronda, en favor de mantener el diseño muestral y consistencia de la representación de la población en edad laboral (18 y más años), se adoptó una estrategia similar, la cual se detalla más adelante en esta sección.

Si bien el marco muestral y los detalles de selección original de cada muestra de panel que conforma la EPS, se pueden encontrar en el Informe Técnico de la EPS VI Ronda, y se omiten aquí debido al público conocimiento de esta información, vale la pena resumir los puntos más salientes:

- Según el documento “Diseño muestral y factores de expansión VI Ronda EPS” de la SPS – Centro UC Encuestas y Estudios Longitudinales de 2016 (en adelante, “Diseño 2015”), las cuatro muestras que estaban incluidas en la EPS fueron realizadas tomando como distribución de la población de Chile las correspondientes a la obtenidas en las CASEN 2000 y 2003 (Diseño 2015, pp. 9).
- Hasta la VI Ronda de la EPS, se pueden diferenciar cuatro muestras, según su ronda de incorporación y población objetivo:
 1. **Afiliados/as 2002 – EPS I Ronda**
 2. **Nuevos/as Afiliados/as 2004 – EPS II Ronda**
 3. **No afiliados/as 2004 – EPS II Ronda**
 4. **Nuevos/as mayores de 18 años y más 2015 – EPS VI Ronda³**
- A estas muestras se le fueron deduciendo los/as fallecidos/as entrevistados en cada ronda y otras depuraciones como entrevistados viviendo en el extranjero, lo que implicó ajustes proporcionales al tamaño en cada ronda para dar cuenta de la reducción del marco muestral. Estos ajustes se hicieron entre las rondas II y VI de la EPS.

Para realizar la VII Ronda de la EPS, se aplicaron ajustes similares a las olas anteriores, dando lugar a un conjunto de 24.882 observaciones disponibles. Finalmente, en esta VIII Ronda, se dedujeron de esas observaciones 623 fallecidos y 529 personas en situación de discapacidad (PSD), para disponer de una muestra nominal de panel de 23.730 observaciones para la presente ronda.

³ Dado que los “nacimientos” corresponden a todos los que se incorporaron a la población en edad de trabajar entre 2004 (última fecha de incorporación de nueva muestra a la EPS) y 2015, los nacimientos incluyen a personas con edades entre 18 y 32 años cumplidos a junio de 2015.

En esta VIII Ronda, adicionalmente, se incorpora una muestra de 15.146 observaciones que tuvieron la intención de dar origen a un contingente de 5.000 observaciones de nacimientos representando a las personas que se incorporan a la población en edad de trabajar. Esta nueva muestra de nacimientos da origen a la quinta muestra que conforma la EPS VIII Ronda:

5. Nuevos mayores de 18 años y más 2023 – EPS VIII Ronda

Dado que el conjunto de *clusters* de la EPS ha permanecido inalterado a través de las actualizaciones muestrales, se tomó esa información para determinar la importancia relativa de cada comuna en el muestreo.⁴ La selección de las comunas y los/as entrevistados/as dan origen al denominado “factor base”, es decir, el factor de expansión primigenio para el trabajo de muestreo de la EPS VIII Ronda.

Así, combinando observaciones disponibles de panel y la incorporación de “Nacimientos 2023”, la muestra total disponible para la EPS 2023 totaliza 38.876 observaciones. En la Tabla 2.1, se puede observar el resumen de la estructura numérica de las distintas muestras de panel a partir de la EPS 2020, y la adición de la muestra de nacimientos, que en su conjunto constituyeron la muestra disponible a abordar en la presente ronda. Nótese que la información de la muestra de la EPS 2020 resume el comportamiento de las tres encuestas realizadas en esa ola, v.g. las Encuestas Presencial, de Re-Entrevista y de Continuidad, según se explica la siguiente sección.

Tipo de Muestra	Afiliados/as 2002	Nuevos/as Afiliados/as 2004	No Afiliados/as 2004	Nacim. 2015	Nacim. 2023	Total
Muestra EPS 2020	14,632	918	2,554	6,778		24,882
Vivos	7,228	461	1,233	3,877		12,799
Fallecidos	491	8	115	9		623
PSD	367	5	108	49		529
*Otros	6,546	444	1,098	2,843		10,931

⁴ Nótese que, en la primera fase de la selección de comunas, tal como se explica en el documento de Diseño 2015, se empleó información poblacional basada en la CASEN 2000 que era la mejor información disponible en el momento (el Censo se realizó en 2002). Adicional a esto, en una segunda etapa, se pasa del “número de habitantes por comuna” al “número de afiliados/as por comuna”, ajustando de esta manera los cálculos de probabilidades de selección al marco muestral de la encuesta (es decir, al listado de personas proveniente de los registros administrativos que cumplían restricciones de edad y afiliación/no afiliación al sistema de pensiones). Para la ampliación del marco muestral realizado en 2004, se recurrió a información poblacional proyectada a partir de la CASEN 2003, mientras que, para la actualización del marco muestral de 2015, se empleó información proporcionada por el Registro Civil. Para la nueva actualización del marco muestral de 2023, se sigue esta última metodología, originada en la información provista por el Registro Civil.

Muestra Nominal Panel 2023	13,774	905	2,331	6,720		23,730
Muestra Nominal Nacim. 2023					15,146	15,146
Muestra Nominal TOTAL 2023	13,774	905	2,331	6,720	15,146	38,876

Nota: ***Otros** se refiere a situaciones desconocidas debido a no contacto, no revisita o no respuesta en alguna de las 3 encuestas realizadas en el contexto de la EPS 2020. “**Nacim.**” se refiere a Nacimientos. La muestra de la EPS 2023 se construye a partir de la información recolectada en la EPS 2020 VII Ronda, más la adición de una muestra de “Nacimientos 2023”.

Fuente: elaboración propia.

2.1. Muestra de panel

La muestra de Panel para la EPS 2023 se origina en la muestra disponible en la EPS 2020. En esa ocasión, se contaba con 24.882 observaciones potenciales. La aplicación de las tres encuestas de la EPS 2020 permitió identificar 1.152 observaciones que se retiraron de la muestra por fallecimiento o situación de discapacidad sobreviniente. De esta manera, la muestra final de Panel asciende a 23.730 observaciones disponibles para encuestar en la presente Ronda, según se detalla en la Tabla 2.2.

La Tabla 2.2 refleja el hecho de que, en la VII Ronda, debido a los efectos de la sobreviniente pandemia de COVID-19, se realizaron 3 encuestas. La Encuesta Presencial fue la encuesta inicial por lo que la muestra completa de panel de 24.882 casos estaba disponible. Según el avance de campo al momento de suspenderse el estudio (ver Informe Técnico EPS VII Ronda), se habían logrado un total de 8.655 encuestas. En esta encuesta, se detectaron 516 fallecidos y 339 personas en situación de discapacidad (PSD) (véase panel “EPS 2020 PRESENCIAL” de la Tabla 2.2).

Sobre la muestra de 7.800 entrevistados/as vivos, más los 337 PSD⁵, se realizó la Encuesta de Re-Entrevista, en la que se detectaron 7 personas fallecidas y 28 PSD adicionales a los conocidos en la Encuesta Presencial (véase panel “EPS 2020 RE-ENTREVISTA” de la Tabla 2.2).

Las 16.227 observaciones que no contaban con cuestionario respondido en la Encuesta Presencial, constituyeron la muestra para la Encuesta de Continuidad. En esta Encuesta se detectaron 103 personas fallecidas y 162 PSD (véase panel “EPS 2020 CONTINUIDAD” de la Tabla 2.2).

⁵ Se dedujeron 2 casos por inconsistencias en respuestas. Ver Informe Técnico EPS VII Ronda.

Por lo tanto, tomando el marco muestral disponible en la EPS 2020 de 24.882, y deduciendo las personas fallecidas y PSD detectados en las tres encuestas de esa ronda, que totalizaron 623 y 529 observaciones, respectivamente, se contó con una muestra de panel de 23.730 observaciones para la presente ronda de la EPS (véase panel “EPS 2022 - Muestra Panel Disponible” de la Tabla 2.2).

Tabla 2.2. Determinación de la muestra EPS 2023 Panel según sub-muestra de origen

Tipo de Muestra	Afiliados/as 2002	Nuevos Afiliados/a s 2004	No Afiliados/as 2004	Nuevos 2015	Total
EPS 2020 PRESENCIAL					
Muestra Nominal	14632	918	2554	6.778	24882
Vivos/as	4505	245	805	2245	7800
Fallecidos/as	402	6	101	7	516
PSD	247	2	64	26	339
Total Encuestas	5154	253	970	2278	8655
EPS 2020 RE-ENTREVISTA					
Sub-Muestra Vivos/as EPS 2020 Presencial					
Muestra Total	4505	245	805	2245	7800
Muestra con Cobertura Telefónica	4473	245	800	2245	7763
Muestra Nominal	3197	195	604	1573	5569
Vivos/as	1201	74	235	572	2082
Fallecidos/as	4	0	0	0	4
PSD	19	0	8	1	28
Total, Encuestas a Vivos/as	1224	74	243	573	2114
Sub-Muestra PSD EPS 2020 Presencial					
Muestra Total	245	2	64	26	337
Muestra con Cobertura Telefónica	245	2	64	26	337
Muestra Nominal	245	2	64	26	337
Fallecidos/as	2	0	1	0	3
PSD	80	0	19	9	108
Total, Encuestas a PSD	82	0	20	9	111

EPS 2020 CONTINUIDAD					
Muestra Total	9478	665	1584	4500	16227
Muestra con Cobertura Telefónica	8961	647	1416	4482	15506
Muestra Nominal	8730	636	1379	4464	15209
Vivos/as	2746	216	436	1633	5031
Fallecidos/as	85	2	14	2	103
PSD	101	3	36	22	162
Total, Encuestas	2932	221	486	1657	5296
EPS 2022 - Muestra Panel Disponible					
Muestra Nominal 2020	14632	918	2554	6778	24882
(-) Fallecidos/as	491	8	115	9	623
(-) Fallecidos/as Presencial	402	6	101	7	516
(-) Fallecidos/as Continuidad	85	2	14	2	103
(-) Fallecidos/as Re-Entr.Vivos	4	0	0	0	4
(-) PSD	367	5	108	49	529
(-) PSD Presencial	247	2	64	26	339
(-) PSD Continuidad	101	3	36	22	162
(-) PSD Re-Entrevista	19	0	8	1	28
Muestra Nominal 2023 - Panel	13774	905	2331	6720	23730

Fuente: elaboración propia.

2.2. Muestra de nacimientos

La selección de la muestra de Nacimientos para la EPS 2023 se hizo a través del mismo diseño utilizado en la selección de la muestra de Afiliados en el año 2002, los nacimientos de afiliados y muestra de no afiliados de 2004, y los nacimientos de 2015. Se consideraron, como Unidades Primarias de Muestreo, las mismas comunas definidas en el diseño original del año 2002 y replicado en las muestras del año 2004 y 2015.

En la muestra de 2015, se sustituyó la comuna de Curaco de Vélez por Castro. Sin embargo, no se encontró en la documentación explicación al respecto. Por esta razón, en esta ronda se optó por mantener la sustitución.

También se detectaron dos casos de comunas que en 2002 constituían una comuna cada una, y que se escindieron en 2004: en la región de Tarapacá, Iquique (original) y Alto Hospicio (escisión), y en la región del Biobío, las comunas de Talcahuano (original) y Hualpén (escisión). A pesar de ello, las comunas en su conjunto siguen siendo parte del mismo estrato original correspondiente.

2.2.1. Marco muestral

En su diseño original, la EPS fue pensada como una encuesta de carácter longitudinal que emplearía una muestra representativa de la población afiliada al sistema de pensiones. En el muestreo original de 2002, existieron afiliados/as de menos de 18 años ya que era posible que afiliados/as al sistema de pensiones tuvieran esa edad (esta restricción de edad no fue impuesta en el diseño original de la muestra del año 2002).

En el año 2004, cuando se amplió la población objetivo de la EPS, incorporándose a los no afiliados/as al sistema de pensiones, se estableció que, para la selección de la muestra de no afiliados/as, el marco muestral sólo consideraría a personas que tuvieran, al menos, 18 años a diciembre de 2003. De esta manera, a partir del año 2004, la EPS se basa en una muestra que es representativa de la población total de 18 años o más.

En el año 2015, el marco muestral empleado consideró a todas las personas que hubieran cumplido sus 18 años entre el 1 de enero de 2004 y el 30 de junio de 2015.

Para 2023, se planteó el mismo razonamiento para determinar el marco muestral: se tomaron todas las personas registradas en el Registro Civil que cumplieron sus **18 años entre el 1 de julio de 2015 y el 30 de junio de 2023**.

La selección de la muestra de nacimientos para la VIII Ronda EPS 2023 se hizo empleando el mismo diseño utilizado en la selección de la muestra de afiliados en el año 2002, los nacimientos de afiliados y muestra de no afiliados del año 2004, y los nacimientos de 2015: se emplearon como Unidades Primarias de Muestreo (UPM) las mismas comunas definidas en el diseño original del año 2002 y replicado en las muestras del año 2004 y del 2015.

Para la selección de la muestra de nacimientos, la SPS solicitó al Registro Civil información de personas nacidas entre 1 de julio de 1997 y el 30 de junio de 2005. La lista de personas ascendió a 2.109.850, según se reporta en la Tabla 2.3.

De esta base de datos se eliminaron todos los casos de personas que fallecieron antes de cumplir los 18 años, es decir, se eliminó un total de 4.864 casos; también se eliminaron los nacimientos registrados en el extranjero o que no tenían información de localización. Se eliminaron todos los casos que presentaban algún tipo de inconsistencia en el registro de comuna y/o región y que no era posible imputar sin ambigüedades. Finalmente, se quitaron del marco muestral todos los

casos que pertenecían a comunas que habían sido excluidas de la cobertura de la muestra original de 2002. Con esto, el marco muestral depurado perdió un total de 76.268, quedando disponibles para muestreo 2.033.582 observaciones. En el Anexo A se detallan los ajustes realizados al marco muestral.

Tabla 2.3. Marco Muestral de Nacimientos EPS 2023

Descripción	Observaciones
Marco muestral total	2,109,850
(-) Fallecidos/as de menos de 18 años cumplidos al momento de fallecer	4,864
(-) Nacimientos en el extranjero	12,076
(-) Registros sin información de localización	25,131
(-) Nombres de lugares que no corresponden a comunas	73
(-) Comuna de Llanquihue, excluida en el muestreo original 2002	2,237
(-) Comunas con región incorrecta	7
(-) Comunas sin número de región que no tienen un nombre de comuna que permita identificar unívocamente la localización	7
(-) Eliminación de comunas no incluidas en la cobertura muestral inicial de 2002 (estrato 999)	31,873
Marco muestral depurado	2,033,582

Fuente: elaboración propia.

Con la información disponible por comuna se calculó la población de las unidades secundarias de muestreo (USM). Se empleó una planilla de selección que contenía las comunas que fueron utilizadas originalmente en el diseño muestral de la EPS, separando aquellas que fueron seleccionadas con probabilidad unitaria (auto-representadas) y aquellas que fueron seleccionadas para representar un estrato. La población distribuida en estas comunas sumó un total de 2.033.582 personas que cumplieron 18 años el 1 de julio de 2015 y el 30 de junio de 2023.

2.2.2. Tamaño muestral

Para conseguir el objetivo de obtener 5.000 cuestionarios de Nacimientos, teniendo en cuenta las tasas de no respuesta y no contacto de las rondas anteriores, se determinó una muestra a

llevar a terreno de 15.000 observaciones.⁶ Esta cantidad de observaciones aparece como suficiente para atender problemas de errores en los datos de contacto que se puedan conseguir para la muestra seleccionada. La fracción de muestreo para estas 15.000 observaciones es de 0.007376147.

Adicionalmente, y atendiendo a problemas de localización y antigüedad de los datos de contacto, se propuso a la SPS realizar una muestra de reemplazo 10.000 observaciones adicionales, muestreadas sin reemplazo, lo que implicó una fracción de muestreo de 0.004917431. Esta muestra de reemplazo sólo estuvo disponible para casos excepcionales cuando se encontrasen situaciones de evidente error en los datos de contacto (localizaciones de viviendas inexistentes, sustitución de viviendas por otro tipo de edificios o construcciones, etc.). Esta muestra se administró por separado de la muestra de terreno, tal como está indicado en las bases de la licitación. Sin embargo, su selección se realizó en conjunto con la muestra de terreno.⁷

Utilizando esta información, y la información de población de cada comuna y de los estratos⁸, se calculó la probabilidad de selección de las UPM, que denominamos:

$$f_1 = \begin{cases} 1 & \text{si es comuna auto-representada} \\ \frac{\text{población de la comuna}}{\text{población del estrato}} & \text{si es otra comuna} \end{cases}$$

A continuación, se determinó la fracción de muestreo intra-comunal, es decir, la probabilidad de selección de las USM:

$$f_2 = \frac{f}{f_1}$$

Donde f es la fracción de muestreo determinada anteriormente en función de los dos tamaños de muestra que se desea obtener.

2.2.3. Selección de la muestra

La selección de las dos muestras se realizó empleando un marco muestral depurado basado en la información provista por la SPS. Para seleccionar la muestra se realizaron las siguientes actividades:

⁶ Nótese que este tamaño obedece a la necesidad de obtener una muestra efectiva de nacimientos de 5.000 observaciones, para las que, en base a la experiencia en olas anteriores, se justificó triplicar el número muestreado para lograr esa meta efectiva. Adicionalmente, al realizarse el muestreo, y teniendo en cuenta redondeos y saltos en la técnica de selección, los 15.000 casos sirvieron como cota inferior (número mínimo de individuos seleccionados), siendo la muestra disponible algo mayor a esta cota.

⁷ Más información sobre el reemplazo de muestra se puede encontrar en el Informe de Trabajo de Campo EPS 2023.

⁸ Véase Informe Técnico EPS VI Ronda que contiene algunas explicaciones sobre la definición de estratos.

- 1) Se determinó la distribución de casos por comuna y región a partir del marco muestral original.
- 2) Las comunas y regiones fueron pareadas con las empleadas originalmente en el EPS para determinar los cambios y los problemas de localización de los individuos. La tarea incluyó la codificación y etiquetado de comunas y regiones, sexo y afiliación al sistema de pensiones.
- 3) Se determinó la edad de las personas fallecidas y se eliminaron todos los casos que tenían edad menor a 18 años cumplidos.
- 4) Se eliminaron las observaciones que presentaban problemas de localización según el detalle de la Tabla 1 anterior, y aquellas que no estaban dentro de la cobertura original de la EPS (véase la explicación en el Anexo A).
- 5) Se imputaron 408 regiones y/o comunas empleando la información disponible, atendiendo a que era posible hacerlo de manera inequívoca.
- 6) Estas tareas dieron origen el marco muestral depurado.
- 7) A partir de este marco muestral depurado, se procedió a calcular los parámetros para las dos muestras deseadas: muestra para terreno (15.000 observaciones, con subíndice "T") y muestra para reemplazo (10.000 observaciones, con subíndice "R"). Esto incluyó el cálculo de las fracciones de muestreo (f_T y f_R , respectivamente) y de las probabilidades de selección de UPM (f_{1T} y f_{1R} , respectivamente) y USM (f_{2T} y f_{2R} , respectivamente) para cada estrato/comuna.
- 8) Empleando la probabilidad de selección de la USM se obtuvo el "paso" y la "observación inicial" para cada estrato. El paso, o tamaño del salto sistemático en la selección, se obtuvo como

$$paso_i = 1/f_{2i}$$

Donde i corresponde al estrato particular de la muestra deseada. La observación inicial en cada estrato se obtuvo como un número entero entre 1 y el valor del paso para el estrato.

- 9) La muestra se seleccionó empleando muestreo aleatorio sistemático al interior de cada estrato, seleccionando en cada uno como primera observación la "observación inicial" anteriormente determinada, y sumando el "paso" hasta recorrer todas las observaciones disponibles. Las observaciones se encontraban ordenadas al interior de cada comuna en función de un indicador de fallecimiento (0 = No, 1 = Sí), situación de afiliación al sistema de pensiones (0 = No afiliado, 1 = Afiliado), y sexo (empleando la codificación adoptada

por el Registro Civil: 1 = Masculino, 2 = Femenino, 3 = No binario, 4 = Intersexual, 5 = Desconocido, 6 = Indeterminado). El marco muestral se describe en la Tabla 2.4.

Tabla 2.4. Características del marco muestral de Nacimientos EPS 2023

Panel A. Fallecido: Indicador de fallecimiento

Valores	Nro. Obs.	Porcentaje	Porcentaje Acumulado
0 No	2,028,687	99.8	99.8
1 Sí	4,895	0.2	100.0
Total	2,033,582	100.0	

Panel B. Afiliado al SP: Indicador de estado de afiliación al Sistema de Pensiones

Valores	Nro. Obs.	Porcentaje	Porcentaje Acumulado
0 No afiliado	809,300	39.8	39.8
1 Afiliado	1,224,282	60.2	100.0
Total	2,033,582	100.0	

Panel C. Sexo: Indicador de sexo declarado por Registro Civil

Valores	Nro. Obs.	Porcentaje	Porcentaje Acumulado
1 Masculino	1,039,100	51.1	51.1
2 Femenino	994,463	48.9	100.0
3 No binario	10	0.0	100.0
4 Intersexual	4	0.0	100.0
5 Desconocido	0	0.0	100.0
6 Indeterminado	5	0.0	100.0
Total	2,033,582	100.0	

Fuente: elaboración propia.

- 10) La aplicación del muestreo aleatorio sistemático entregó 15.152 observaciones para muestra de terreno y 10.051 observaciones para la muestra de reemplazo. El exceso de observaciones se debe a que el "paso" se truncó en su parte decimal para asegurar que, al menos, se obtuviera el 100% de muestra deseada en cada uno de los estratos. Por lo tanto, el efecto de este redondeo forzoso se vio en el incremento de la muestra seleccionada más allá de la cantidad teórica determinada.

- 11) Dado que las muestras para terreno y para reemplazo fueron determinadas sin reemplazo, toda vez que hubo coincidencia en la selección de una observación para ambas muestras, se desplazó la selección a la siguiente observación de la muestra para reemplazo, obteniéndose de esta forma dos muestras sin repeticiones.
- 12) Por último, se completó la información de selección muestral con sus respectivos ajustes, la cual constituye el conjunto de factores de expansión base.

El procedimiento permitió obtener dos muestras que fueron entregadas a la SPS para que gestionara su poblamiento (adición de domicilio). El poblamiento entregó 15.146 observaciones con direcciones útiles para la muestra de terreno. La muestra de reemplazo no fue empleada, finalmente.

En todo el proceso de determinación del marco muestral y selección de la muestra, se emplearon datos innominados que sólo poseían las características descritas en la Tabla 2.4, además de la comuna en que estaban localizadas, información mínima necesaria para llevar adelante el muestreo sistemático de unidades secundarias, tal como fue realizado en rondas anteriores de la encuesta.

3. Atrición en la EPS VIII Ronda

La atrición en encuestas longitudinales y de panel se refiere a la pérdida de los y las participantes a lo largo del tiempo. Este fenómeno es común en estudios que requieren el seguimiento de las mismas personas durante un período extendido, como es el caso de la EPS. La atrición puede surgir por varias razones, incluyendo cambios en la residencia de las personas encuestadas, falta de interés continuo en participar, problemas de salud, fallecimiento, o simplemente la incapacidad de localizar a los/as participantes en subsecuentes rondas de la encuesta. Este problema es especialmente prevalente en estudios de largo plazo, como la EPS, donde el compromiso requerido de los participantes puede ser considerable.

Las causas de la atrición son diversas y pueden estar relacionadas tanto con factores personales de las personas encuestadas como con aspectos metodológicos del estudio. Por ejemplo, los/as participantes pueden perder interés en el estudio si consideran que las encuestas son demasiado largas o intrusivas. Asimismo, la fatiga del encuestado o la encuestada, donde las personas se cansan de responder repetidas veces, también contribuye a la atrición. Desde una perspectiva metodológica, la calidad de las estrategias de seguimiento y mantenimiento del contacto con los/as participantes juega un papel crucial. Una gestión inadecuada de la base de datos de las personas encuestadas, la falta de incentivos adecuados y la ausencia de comunicación regular pueden aumentar la tasa de atrición.

La atrición tiene efectos significativos sobre la información muestral. Principalmente, puede introducir sesgos en los resultados si los/as participantes que abandonan el estudio difieren sistemáticamente de aquellos que permanecen. Esto afecta la representatividad de la muestra y puede comprometer la validez de las conclusiones del estudio. Por ejemplo, si las personas que abandonan son mayormente de un grupo socioeconómico particular, los resultados del estudio podrían no ser generalizables a esa población. Además, la pérdida de participantes puede reducir el tamaño efectivo de la muestra, afectando la potencia estadística del estudio y limitando la capacidad de detectar efectos significativos. Estas razones, y otras basadas en 20 años de experiencia de la EPS, ha llevado a implementar estrategias efectivas para minimizar la atrición, como ofrecer incentivos adecuados, diseñar cuestionarios amigables y mantener una comunicación regular con las personas participantes, garantizando así la integridad y robustez de los datos recolectados.

A continuación, se analizan las razones de no respuesta que pudieron haber afectado a la EPS 2023, para luego dar cuenta del comportamiento de la atrición por olas hasta llegar a la presente Ronda VIII. Para interpretar los posibles efectos de la atrición en la información basal de la encuesta, se exploran también algunas variables claves en busca de evidencias de patrones de comportamiento que pudiesen indicar sesgos causados por la atrición. Algunas de las variables a revisar incluyen distribución geográfica de la muestra, sexo y edad, junto al comportamiento de

la pirámide poblacional, estado civil, afiliación al sistema previsional y afiliación al sistema de salud, y situación de empleo. Esta sección termina con conclusiones sobre este fenómeno y cómo podrían estar afectando a los resultados de la encuesta en la presente ronda.

3.1. Razones de no respuesta

De acuerdo con Daniels y Hogan (2008), para entender el comportamiento de una muestra, es necesario diferenciar los distintos tipos de no respuesta que nos podemos encontrar. En particular, ellos diferencian, al menos, cinco tipos de pérdida de observaciones muestrales:

1. visitas perdidas, ya sea aleatoriamente o por razones relacionadas con la respuesta.
2. la salida de una persona participante del estudio ya sea que lo decida la misma persona o el investigador que lleva a cabo el estudio.
3. pérdida del entrevistado/a por imposibilidad de su seguimiento posterior por razones desconocidas o no reportadas.
4. fallecimiento o impedimento que no le permita continuar participando del panel (no atribuibles al estudio, en este caso).
5. pérdida por diseño, en que sólo un subgrupo de individuos es seleccionado/a para su seguimiento en el tiempo.

Un caso particular de pérdida de información es cuando el o la entrevistado/a participa intermitentemente en el estudio longitudinal, generando brechas informativas en su historia de participación. Pero, ya sea que las personas entrevistadas perdidas a lo largo del estudio longitudinal sean permanentes o intermitentes, hay varias estrategias para comprender los patrones de comportamiento y modelar las probabilidades de participación para realizar los ajustes correspondientes.⁹

Sin embargo, sin importar las razones particulares de no respuesta que se observen, ni el patrón de la no participación que muestre una persona particular, para hablar de aleatoriedad de la

⁹ Véase, por ejemplo, Albert (2000) y Albert et al. (2002), que construyen modelos con una variable aleatoria multinomial especificada para cada momento del tiempo, en que clasifican el comportamiento como “todavía participando”, “pérdida intermitente” y “pérdida permanente”. También Lin et al. (2004) tratan el problema de intermitencia en la participación con el uso del enfoque de patrón mixto latente.

También se puede modelar la no respuesta con el enfoque de pseudo-verosimilitud, como lo proponen Troxel et al. (1998), usando información de pérdida del mismo periodo condicional sólo en la no respuesta potencial para esa ola de la encuesta. Finalmente, Rotnitzky et al. (2001) realiza una revisión del tratamiento que se puede aplicar a no respuestas por causas múltiples.

muestra obtenida, debemos diferenciar tres casos largamente discutidos en la literatura (Wood et al., 2019):

1. Pérdida aleatoria ("*Missing at random*" o MAR): definida por Rubin (1976), este tipo de atrición implica que la pérdida de la observación no depende de variables no observadas, pero puede deberse (explicarse) por la información contenida en variables observadas. Por ejemplo, si los hombres son más o menos propensos a participar y continuar participando en el panel (atrición o no respuesta total), o si las mujeres son menos propensas a revelar su ingreso en la encuesta que los hombres (no respuesta parcial), podemos decir que el mecanismo de pérdida de información que observamos es MAR.
2. Pérdida totalmente aleatoria ("*Missing completely at random*" o MCAR): en este caso, la pérdida de información no está relacionada con información observable o no observable. En particular, las razones son enteramente ajenas a la encuesta en sí. Por lo tanto, la información faltante (total o parcial) es simplemente un subconjunto de la información total que sí se logró recolectar.
3. Pérdida no aleatoria ("*Missing not at random*" o MNAR): este tipo de pérdida de información es estudiada por Little y Rubin (2014), quienes aseguran que cuando la información no observada que tiene el o la entrevistado/a es el factor que determina su participación en la encuesta, entonces se debe modelar la pérdida de información (por ejemplo, se pueden utilizar imputaciones múltiples) para reemplazar esta información perdida y evitar sesgos en los resultados. Sin embargo, se debe tener conocimiento (o información) previa sobre la observación, algo que está disponible para todos los casos abordados en la EPS VIII Ronda, al tratarse solamente de observaciones de panel (sin refresco).

Cada una de estas formas de pérdida de información requieren un tratamiento. En particular, es posible que aun con tratamiento, en el caso de MNAR, no sea posible controlar los sesgos que se pueden presentar por la autoselección. En general, se espera que las pérdidas sean de tipo MAR y MCAR.

A continuación, se analiza el comportamiento de las muestras según un conjunto de variables que suelen determinar el comportamiento de autoselección de los y las participantes, y que se emplean en los modelos para ajuste de no respuesta.

3.2. Atrición por olas

En la presente ronda, se partió con una base de contactos potenciales de panel de 23.730 casos que podían ser abordados durante el estudio (potenciales entrevistados/as). Esta cifra surge de

la base de contactos de la ronda VII de la encuesta, que ascendía a 24.882 observaciones, de las que se dedujeron 1.152 casos (fallecidos/as y personas en situación de discapacidad en esa ronda). A ellos se sumaron 15.146 observaciones muestrales que constituyen la nueva muestra de Nacimientos 2023 incorporados en esta ronda.

En la Tabla 3.1 se muestra la antigüedad de la participación, es decir, la última vez que participaron según el panel al que pertenecen. Se puede observar que casi 19.000 observaciones han participado en las últimas 2 olas de la encuesta, lo que representa un 75,8% del total de la muestra panel disponible para encuestar en esta ronda.


Tabla 3.1. Origen de las observaciones disponibles en la EPS VIII Ronda

	Afiliados/as 2002	Nuevos Afiliados/as 2004	No Afiliados/as 2004	Nacimientos 2015	Nacimientos 2023	TOTAL
EPS 2002	550					550
EPS 2004	369	45	90			504
EPS 2006	681	60	100			841
EPS 2009	1211	108	230			1549
EPS 2012	1139	79	200			1418
EPS 2015	2596	152	478	2843		6069
EPS 2020	7228	461	1233	3877		12799
EPS 2023					15146	15146
TOTAL	13774	905	2331	6720	15146	38876

Fuente: elaboración propia.

Para facilitar la comparación, se muestra en la Figura 3.2 cómo se comportan las muestras. La muestra de Afiliados/as de 2002 y los Nacimientos de 2015 constituyen la muestra mayoritaria en panel por la construcción misma de la encuesta (ambas son las dos incorporaciones de muestra más importantes previo a 2023).

Figura 3.2. Composición de la muestra EPS VIII Ronda según última participación en la encuesta



Fuente: elaboración propia.

La atrición histórica que ha tenido la encuesta se muestra en la Figura 3.3, en sus distintos paneles. Cada panel representa, ya sea en términos de unidades observacionales o de porcentajes respecto de la ola de referencia, cómo fue evolucionando el número de participantes a través de las olas. Nótese que las sucesivas olas de la EPS han tenido distintos objetivos de levantamiento dependiendo de la coyuntura en que se realizaba la encuesta o del alcance presupuestario. Sin embargo, siempre se ha hecho un esfuerzo importante por mantener la participación de los y las panelistas en el tiempo.

Así, tomando como referencia los y las participantes de la EPS 2002, éstos tuvieron dos mermas importantes de participación, en 2004 y en 2012, respectivamente. En el primer caso, la merma se debió al objetivo de incorporación de nueva muestra en 2004 para aumentar la cobertura a toda la población de 18 y más años del momento. En 2012, la merma obedece al resultado del trabajo de campo de la V Ronda de la Encuesta que, finalmente, fue considerada un producto estadístico no logrado.

Los y las participantes de 2004 han ido disminuyendo su participación paulatinamente, a excepción de la merma importante de 2012, mencionada anteriormente. En la V Ronda se hizo un esfuerzo importante por recomponer la confianza de los y las panelistas y la relación con ellos/as, por lo que se observa una recuperación del 7.2% de la muestra (véanse los paneles “EPS 2004” en la Figura 3.3).

La Ronda de la EPS 2009 también tuvo un desempeño que se alejaba de lo ocurrido en las olas anteriores. Aun cuando no queda claro a partir de la lectura de los informes de esa ronda, es posible que los objetivos de levantamiento hayan sido más laxos también, admitiendo ese tamaño de muestra final, teniendo en cuenta especialmente que en esa ronda (que fue postergada al haber sido inicialmente pensada para 2008) se tuvo como objetivo la medición de la Reforma de Pensiones de 2008.

La V Ronda ejecutada en 2012 tuvo varios inconvenientes que fueron en detrimento del vínculo con panel de la EPS, además de no lograr incorporar una muestra de Nacimientos que venía a recomponer la representatividad del marco muestral debido al paso del tiempo. Esta encuesta fue considerada producto estadístico no logrado, pero su impacto en el comportamiento del panel se ha prolongado en el tiempo, constituyendo el episodio de mayor atrición en la historia de la encuesta.


En 2015, la VI Ronda de la encuesta trató de hacerse cargo de los efectos de la ola anterior y del envejecimiento del panel. Por un lado, se trabajó en el fortalecimiento de la relación con los y las panelistas y la relocalización de estos, mientras que, por otro lado, se agregó una muestra de Nacimientos para recomponer el marco muestral que no tenía incorporación de muestra válida desde 2004.

Finalmente, en 2020, se puso como objetivo la recuperación y fortalecimiento del panel de la EPS. Sin embargo, los efectos del estallido social de octubre de 2019, que afectaron el inicio de la encuesta en terreno, sumado al advenimiento de la pandemia de COVID-19, resultaron en la necesidad de realizar ajustes metodológicos e impidieron un trabajo más profundo de contacto con los y las panelistas. Aún así, la VII Ronda de la encuesta fue capaz de medir los efectos de estos episodios en el mercado del trabajo y en el comportamiento previsional de la población de Chile en 2020.


Por su parte, la presente ola de la encuesta ha tenido como objetivo reafirmar el vínculo con los panelistas al tiempo que incorpora nueva muestra para actualizar el marco muestral de 2015. En esta ola, la reducción de cobertura obedeció a un balance entre mantenimiento del panel e incorporación de nueva muestra, tal como sucedió en 2015.

Figura 3.3. Atrición por olas en la EPS 2023, en unidades observacionales y porcentajes


Panel A.1. EPS 2002: Número de Observaciones




Panel A.2. EPS 2002: Porcentajes Muestrales




Panel B.1. EPS 2004: Número de Observaciones




Panel B.2. EPS 2004: Porcentajes Muestrales




Panel C.1. EPS 2006: Número de Observaciones




Panel C.2. EPS 2006: Porcentajes Muestrales




Panel D.1: EPS 2009: Número de Observaciones




Panel D.2: EPS 2009: Porcentajes Muestrales




Panel E.1: EPS 2012: Número de Observaciones




Panel E.2: EPS 2012: Porcentajes Muestrales




Panel F.1: EPS 2015: Número de Observaciones




Panel F.2: EPS 2015: Porcentajes Muestrales



Panel G.1. EPS 2020: Número de Observaciones



Panel G.2. EPS 2020: Porcentajes Muestrales



Nota: para cada una de las olas anteriores a la EPS VIII Ronda, la atrición ha sido calculada sobre el total de casos efectivamente logrados, lo que implica que los niveles de atrición están subestimados. Por el momento, no se cuenta con información sobre cuáles fueron los objetivos de levantamiento en cada una de las olas anteriores para los paneles. Cada gráfico muestra el número de observaciones o el porcentaje muestral *versus* el año de la EPS.


Fuente: elaboración propia.

Como puede observarse en las sucesivas olas, el comportamiento de atrición en la EPS VIII Ronda no se muestra especialmente distinto a las ediciones anteriores. La EPS 2023 muestra niveles de atrición de entre 20% y 30% en las olas anteriores a 2012, con un repunte en esta ola por tamaño muestral menor (en realidad, en 2015 se observó la pérdida importante de observaciones de la encuesta 2012). En el caso de la atrición entre la EPS VI Ronda y la EPS VII Ronda, el impacto mayor se debe a que la atrición de la ola 2015 de la EPS fue cubierta por observaciones de refresco, obedeciendo a decisiones de diseño que incorporaron nueva muestra para actualizar el marco muestral por paso del tiempo.

Si se revisa la acumulación de atrición por ola previo a la EPS VIII Ronda, se observa que los niveles de atrición son similares entre olas, y que la composición de la muestra recolectada no tiene sub- o sobre-representación de los y las participantes de ninguna ola en particular, tal como surge de la Figura 3.4, que muestra la atrición acumulado a través de las olas.

Nótese también que, como ya se comentó, la excepción es la V Ronda de 2012 que tuvo mayores efectos en la pérdida de muestra debido a problemas con el trabajo de campo.

Figura 3.4. Atrición acumulada por ola hasta la EPS VIII Ronda



Fuente: elaboración propia.

3.3. Comportamiento de variables seleccionadas a través de las olas

A continuación, se amplía el análisis para observar si la atrición observada en la EPS VIII Ronda obedeció a algún patrón sistemático (MNAR). Se incluyen en este conjunto de variables el sexo y edad de la persona entrevistada (también representado a través de tramos etarios), región en la que habita, la calidad de afiliado al sistema previsional y el estado civil.

Las comparaciones que se realizan a continuación se abstraen de la representación a nivel país del fenómeno, ya que deseamos saber cuál es el desempeño de la muestra como tal, y no los agregados a nivel país que se obtendrían aplicando factores de expansión.

3.3.1. Distribución geográfica


Si bien la encuesta no ha sido diseñada para obtener inferencia a nivel de región, las características del mercado laboral y la alfabetización financiera varían de manera importante entre regiones, y es bueno que la encuesta cuente con una configuración regional adecuada o, al menos, comparable con versiones anteriores de la misma. En la Figura 3.5, se muestra la distribución regional de casos logrados en cada encuesta en términos porcentuales respecto al total de encuestas recabadas en la respectiva ola.


Como se puede observar, si bien en términos absolutos, la ronda anterior de la encuesta tuvo un mayor deterioro en la participación (ola 2020), ésta se ha recuperado en la VIII ronda, manteniendo el balance de la muestra. Sin embargo, cuando se revisa el desempeño relativo de las distintas muestras en términos porcentuales, en el segundo panel de la Figura 3.5, se observa que existen dos situaciones: regiones en que el estudio ha recogido relativamente más observaciones que en ocasiones anteriores, como en las regiones de la Araucanía, Aysén y Metropolitana, y regiones en que la participación se ha deteriorado, como en Valparaíso, O'Higgins, Maule y Biobío / Ñuble.¹⁰

Figura 3.5. Distribución de respuestas por región y por ola

¹⁰ Nótese que el levantamiento se vio afectado en alguna medida en la región de Valparaíso, especialmente en Viña del Mar y Villa Alemana debido al efecto de los incendios que se sucedieron trágicamente a inicios de enero de 2024.

Panel A. Número de observaciones logradas por región y por ola






3.3.2. Distribución de sexo

La segunda variable que observamos es la composición de sexo entre olas de la encuesta, como se muestra en la Figura 3.6. Con el avance de las olas de la Encuesta, se observó un desplazamiento de la composición de la muestra de los hombres hacia las mujeres. Sin embargo, este cambio fue paulatino y no apareció como un comportamiento anómalo particular en las rondas anteriores a la EPS VIII Ronda. De hecho, desde la EPS II Ronda, ola a ola, la composición ha ido cambiando en favor de la mujer aproximadamente un 2% por ola.

Por el contrario, en la EPS VIII Ronda se observa una estabilización de la composición de sexo de la muestra: se nota un leve incremento (1.1% adicional) en favor de los hombres.

Figura 3.6. Distribución de sexo de personas entrevistadas entre olas




Fuente: elaboración propia.

3.3.3. Distribución de edad

La tercera variable analizada corresponde a la edad. Esta variable es clave para entender, junto al sexo, cómo se comporta demográficamente la muestra. Los perfiles de edad que se han observado en cada ola desde el inicio de la EPS se muestran en la Figura 3.7. Los perfiles se han mantenido a través del tiempo, especialmente el “estrangulamiento” provocado por la no adición de muestra en 2012.

Las incorporaciones de muestra en 2015 y en 2023 han marcado un nuevo perfil etario que es razonable si pensamos en la necesidad de tener un panel de largo aliento en la encuesta. De hecho, se esperaría que las densidades de edades tuvieran una forma cuasi-triangular, con el cateto menor en la edad mínima de incorporación de muestra (18 años) de tal manera que, con el paso del tiempo, observemos una paulatina disminución de la altura de ese triángulo mostrando el envejecimiento de la muestra de ese panel particular.

Figura 3.7. Distribución de la edad por olas de la EPS



Nota: la línea punteada vertical indica 18 años. Las muestras 2002 y 2004 tuvieron casos con edad menor a 18 años, mientras que en 2015 y 2023 la edad mínima considerada fue estrictamente 18 años.

Fuente: elaboración propia.


Un análisis alternativo consiste en considerar el comportamiento de los grupos etarios que habitualmente son utilizados en el análisis para evitar las imperfecciones propias del reporte de la edad y para generar masa crítica en los distintos tramos.

Así, en la Figura 3.8, se puede observar que hay menor concentración de casos en el grupo de 35 a 44 años, que tiene una doble explicación: por un lado, es parte del efecto de envejecimiento del panel (que hoy ya tiene 22 años de antigüedad), por lo que esa escasez se asocia al grupo de jóvenes que comenzó en el panel en las primeras olas. Esta explicación también puede apoyarse en el crecimiento paulatino de los otros tramos etarios para la EPS VIII Ronda.

La segunda explicación viene por el lado de introducción del refresco en 2015 que produjo un quiebre en el perfil etario de la encuesta, generando una bimodalidad de la distribución de edades. Y eso se ve reflejado en un grupo de jóvenes adultos/as más acotado, flanqueado por jóvenes y adultos/as maduros/as.

Sin embargo, este comportamiento parece ser característico de la distribución actual del panel si es que tenemos en cuenta el comportamiento de la muestra en 2015, cuando se produce la gran contracción en este tramo etario que alimenta al mismo grupo en 2020, y se ve reforzado por la adición de nueva muestra en 2023. Nótese al respecto, la caída desde 23,5% para el grupo etario en 2009, a 11,4% en 2015, ola en la que también debemos sumar el efecto de la fallida incorporación de refresco joven en la EPS V Ronda (no representada en este gráfico).

Si bien este comportamiento no lleva a pensar en la edad como un mecanismo importante de autoselección, posiciona a la variable como un desafío para la continuación del estudio, ya que se hace evidente un “estrangulamiento” de la muestra entre el grupo de jóvenes y los/as adultos/as maduros/as.





3.3.4. Pirámide poblacional

Para observar de mejor manera los efectos demográficos de sexo y edad, se presenta en la Figura 3.9 la evolución de las pirámides poblacionales a través de las olas. Aquí se hace más evidente el

estrangulamiento de la muestra para los/as adultos/as de mediana edad desde la VI ronda en adelante.

Figura 3.9. Pirámides poblacionales a través de las olas





3.3.5. Distribución del estado civil

También se analiza el comportamiento de otra variable socio-demográfica importante como lo es el estado civil. Según se puede apreciar en la Figura 3.10, los resultados de las primeras 4 olas fueron similares, manteniéndose una estructura estable en el tiempo.


Sin embargo, se dio una variación importante en los casos de personas que declararon estar casadas, separadas con algún régimen y solteras. Dada la introducción del refresco en el 2015, el panel sufrió un brusco cambio en la composición de las categorías casado/a y soltero/a, obedeciendo a la entrada de jóvenes entre los que domina la soltería.

Pero la EPS VII Ronda comienza a evidenciar el paso del tiempo en el comportamiento del estado civil, incorporando más personas a la relación de pareja en detrimento de la soltería. Este es un comportamiento esperable que habla de la buena representatividad que tiene la muestra para medir este fenómeno observado en otras encuestas, y también a nivel censal.

En la EPS 2020 también se evidencia una mayor participación de la categoría que representa rompimiento de parejas (separaciones, divorcios y anulaciones), un fenómeno que ha sido estudiado y asociado a los efectos de la pandemia de COVID y los prolongados periodos de estrecha convivencia en el encierro.

Finalmente, en esta ronda de la encuesta las proporciones parecen ajustarse mejor a lo observado en 2015 con la adición de nueva muestra, aunque con una intensa participación de personas que se consideran solteras, sobrepasando la mitad de las personas encuestadas en la ronda.

Figura 3.10. Distribución del estado civil entre olas



Nota: AVP corresponde a acuerdo de vida en pareja bajo alguno de los regímenes vigentes en cada momento del tiempo.

Fuente: elaboración propia.


3.3.6. Distribución de personas afiliadas al sistema de pensiones

La siguiente variable de interés es la distribución de las personas afiliadas al sistema de pensiones. Esta es una variable relevante, ya que la encuesta fue originalmente pensada para estudiar el fenómeno previsional en Chile, y la condición de aportante al sistema previsional era un determinante de participación en la primera ola.

En la Figura 3.11 se presenta la condición de aportante al sistema previsional autoreportada. En ese sentido, se puede observar que, en 2002, los y las participantes declaran estar afiliado al sistema previsional casi en su totalidad, mientras que, a partir de 2004, el porcentaje de participantes (afiliados/as) al sistema previsional según el auto-reporte, ronda el 77%.


En la VII Ronda se observó un alza en el número de cotizantes respecto a las olas anteriores, pero estas cifras volvieron a caer en la ronda actual, dando cuenta de dos fenómenos que confluyen para explicar habitualmente la participación previsional: mayor juventud asociada a no

participación laboral, y mayores niveles de informalidad en los primeros trabajos (inserción en el mercado laboral de personas trabajadoras menos experimentados/as). Véase la Figura 3.11 para una comparación gráfica.



Finalmente, se presenta en la Figura 3.12, la proporción de cotizantes por sistema al que cotiza. Para realizar la gráfica, se han agrupado los sistemas como DIPRECA, CAPREDENA, y otros de cajas de trabajadores/as de distintas actividades ya que, en términos de volumen de cotizantes, son relativamente pequeños comparados con los y las cotizantes de AFPs e IPS. Este gráfico muestra que la estructura de la encuesta a través de las olas representa adecuadamente la participación en los distintos sistemas, evidenciándose un decrecimiento paulatino de las distintas categorías en pos del sistema privado de AFPs.

Figura 3.12. Distribución de las personas cotizantes según sistema de pensiones por olas



Fuente: elaboración propia.

3.4. Conclusiones sobre atrición

En conclusión, a pesar de los numerosos desafíos enfrentados durante la octava ronda de la Encuesta de Protección Social (EPS), los resultados obtenidos indican que la atrición y la no respuesta no son atribuibles a situaciones particulares identificables que pudieran sesgar los resultados del estudio, tanto para el corte transversal como para los paneles que se pueden desprender de él. Este hallazgo basado en la evidencia anterior es significativo, ya que implica que los factores que típicamente introducen sesgos MNAR (*Missing Not At Random*) en las encuestas no tuvieron un impacto relevante en esta ronda de la EPS. En consecuencia, las variables comunes que suelen explicar la aparición de sesgos en levantamientos similares no desempeñaron un papel crucial en la presente ola de la encuesta.

Este contexto favorable permite realizar ajustes en los factores de expansión partiendo de una base no sesgada, lo cual es fundamental para asegurar la representatividad de los resultados. La

ausencia de sesgos significativos en la muestra garantiza que los datos recopilados continúen reflejando con precisión a la población adulta de Chile en aspectos críticos como el mercado laboral y la previsión. De esta manera, los resultados de la EPS VIII Ronda proporcionan una visión fiel y actualizada de la realidad socioeconómica del país, permitiendo a las personas investigadoras y a los y las responsables de políticas públicas contar con información robusta y confiable para la toma de decisiones.

Además, la estabilidad y representatividad de la muestra en esta ronda reafirman la validez de las metodologías empleadas y refuerzan la confianza en los procedimientos de recolección y análisis de datos. Esto no solo beneficia a la EPS, sino que también sienta un precedente positivo para futuros estudios longitudinales en Chile y otros contextos similares. En resumen, a pesar de los obstáculos iniciales, la EPS VIII Ronda ha demostrado ser una herramienta eficaz y precisa para el análisis de la evolución del mercado laboral y la previsión social en Chile, proporcionando datos esenciales para el desarrollo de políticas informadas y basadas en evidencia.

4. Factores de expansión de corte transversal

Debido a las características inherentes de la encuesta realizada, es común que algunos individuos no respondan por diversas razones. Esto significa que los factores de expansión iniciales (o factores base) no son apropiados para ponderar a los y las participantes finales de la encuesta, lo que dificulta una representación precisa de la población. Las causas de la no respuesta varían según el tipo de encuesta, la metodología empleada, la cobertura alcanzada y las características de la muestra recolectada. Por lo tanto, es crucial ajustar los factores de expansión de las encuestas obtenidas para que representen adecuadamente a la población, tanto de manera transversal como longitudinal, evitando la aparición de sesgos sistemáticos en los datos obtenidos.

Aunque existe un consenso general sobre la necesidad de corregir estos errores, la discusión se inicia temprano con el dilema de qué tipo de ponderación o factores de expansión deben emplearse en las estimaciones. En este contexto, la discusión sobre la efectividad del uso de factores de expansión basados en el diseño (los más cercanos a los factores de selección originales) frente a los factores basados en modelos, como los que se han obtenido para esta ronda de la encuesta y que se describen a continuación, es frecuente. La elección de uno u otro depende del tipo de análisis que se esté realizando y del alcance de la inferencia que se quiera hacer.

A pesar de que la opinión predominante es que los factores basados en modelos son generalmente más adecuados, los factores basados en el diseño pueden ser útiles en ciertas circunstancias específicas. Por ejemplo, cuando no se dispone de información suficiente para estimar modelos que corrijan el comportamiento de la muestra, o cuando se produce una pérdida repentina de la representatividad de la muestra. En tales casos, los factores de expansión basados en el diseño pueden funcionar adecuadamente.

Sin embargo, es común realizar ajustes a los factores base basándose en el conocimiento sobre la elegibilidad, cobertura y no respuesta de los y las participantes seleccionados/as para la encuesta. En este contexto, la información más relevante es aquella que se posee para llevar a cabo estimaciones y realizar ajustes a los factores de expansión, empleando un enfoque basado en modelos.¹¹ Este enfoque permite una mayor precisión al abordar las particularidades de la muestra y corregir las desviaciones observadas.

A continuación, se describen los ajustes realizados a los factores de expansión en la VIII Ronda de la EPS. Estos ajustes no solo abordaron el problema de la no respuesta, sino que también implicaron la modificación de los factores de expansión iniciales para que los totales se aproximaran más fielmente a la población del país que se pretendía representar. Para lograr esto,


¹¹ Véase Lohr (2010).

se utilizó una técnica de post-estratificación, la cual permite ajustar los datos de la encuesta para que coincidan mejor con las características demográficas de la población objetivo.

Este proceso de post-estratificación es esencial para garantizar que las estimaciones derivadas de la encuesta sean representativas y reflejen con precisión la estructura de la población. Los ajustes realizados a los factores de expansión permiten así una corrección más efectiva de las desviaciones y sesgos que podrían haberse introducido debido a la no respuesta o a la cobertura incompleta. En resumen, estos ajustes son fundamentales para obtener datos más fiables y útiles para el análisis.

4.1. Configuración de la muestra de la EPS 2023

En la Figura 4.1 se presenta esquemáticamente la estructura y comportamiento de la muestra de la encuesta, incluyendo la forma en que se originan los marcos muestrales de cada submuestra de la EPS 2023. Tal como se explicó anteriormente, la EPS 2023 posee 5 submuestras originadas en distintos momentos del tiempo y representando a poblaciones mutuamente excluyentes, por lo que el tratamiento de los factores de expansión de cada muestra se realiza teniendo en cuenta el marco muestral que origina cada submuestra.



Fuente: Elaboración propia.

En la parte derecha de la Figura 4.1, se muestra la configuración de la muestra producto del desarrollo de la encuesta de la presente ronda. Los cuadros sombreados con color gris a la izquierda del esquema indican los ajustes a los factores de expansión que se hacen necesarios para incorporar posibles sesgos debido a las situaciones representadas en el esquema.

En primer término, la muestra de la EPS VIII Ronda está constituida por cinco sub-muestras, a las que se le deben deducir las personas fallecidas y personas en situación de discapacidad (PSD), ya que ambos grupos de entrevistados/as son escindidos de la muestra para rondas futuras.¹² En esta encuesta, la muestra se completa con los denominados “vivos” que corresponden a las personas que continúan en el panel para rondas futuras y que completan el cuestionario más completo.

La deducción de fallecidos y PSD requiere que cada sub-muestra de la EPS VIII Ronda sea ajustada proporcionalmente para incorporar el tamaño de las observaciones excluidas debido al fallecimiento o situación de discapacidad sobreviniente dentro de cada *cluster*. De esta manera, las observaciones de “vivos” ex ante representan a toda la población. Estos factores ajustados configuran, en definitiva, los factores de expansión base para esta muestra, FE^{Base} .

En la Tabla 4.2 se muestra el comportamiento de la muestra, la representatividad de los factores en cada etapa, los ajustes a tamaños muestrales sobrevinientes, y el total final de encuestados/as por cada una de la sub-muestras de la presente encuesta. Esta tabla será referida profusamente en las explicaciones siguientes.

Además de presentar el comportamiento de la muestra completa, la Tabla 4.2 utiliza el mismo esquema de desagregación para cada sub-muestra de la EPS, y también para los y las entrevistados/as que respondieron cuestionarios de Vivos, Fallecidos y PSD. Nótese que, en los últimos dos casos, el o la entrevistado/a es alguien vinculado/a¹³ con la persona que forma parte del panel y que, por razones obvias, no puede responder por sí mismo la encuesta. También vale la pena notar que se detectaron fallecidos y PSD que no respondieron la encuesta: estos casos corresponden a los códigos de disposición final (“CDF”) 231 para fallecidos, y 237 y 238, para PSD temporales y permanentes, respectivamente. Esta información fue recolectada durante el

¹² Estos dos tipos de entrevistados/as completan cuestionarios diferenciados sobre la situación del entrevistado, entorno familiar y actividad laboral.

¹³ Durante el trabajo de campo, los y las encuestadores/as debían asegurarse, según los protocolos establecidos en este estudio, de que la persona que respondía por fallecidos/as o PSD tenía conocimiento suficiente de la situación de estos.

trabajo de campo y, si bien no son encuestas logradas, es información relevante al momento de estimar ajustes a los factores de expansión (véase la Sección 4.2).

Tabla 4.2. Encuesta 2023: comportamiento de la muestra

Tipo de Muestra	Afiliados 2002	Nuevos Afiliados 2004	No Afiliados 2004	Nacimientos 2015	Nacimientos 2023	Total
Muestra Nominal 2023	13,774	905	2,331	6,720	15,146	38,876
Visitados	10,633	657	1,770	4,939	9,091	27,090
Responde/Rechaza Visitado	7,765	436	1,356	3,296	5,487	18,340
Responde Resp/Rech, Visitado	7,223	400	1,312	3,070	5,097	17,102
Vivos	12,764	886	2,114	6,692	15,054	37,510
Visitados	9,623	638	1,553	4,911	8,999	25,724
Responde/Rechaza Visitado	6,789	417	1,141	3,269	5,410	17,026
Responde Resp/Rech, Visitado	6,247	381	1,097	3,043	5,020	15,788
Fallecidos	719	15	152	10	20	916
Visitados	719	15	152	10	20	916
Sin encuesta (CDF 231)	25	0	1	1	7	34
Responde/Rechaza Visitado	694	15	151	9	13	882
Responde Resp/Rech, Visitado	694	15	151	9	13	882
PSD	291	4	65	18	72	450
Visitados	291	4	65	18	72	450
Sin encuesta, temporales (CDF 237)	4	0	0	0	3	7
Sin encuesta, permanentes (CDF 238)	5	0	1	0	5	11
Responde/Rechaza Visitado	282	4	64	18	64	432
Responde Resp/Rech, Visitado	282	4	64	18	64	432
Total Encuestas	7,223	400	1,312	3,070	5,097	17,102

Fuente: elaboración propia.

4.2. Ajustes por atrición y no respuesta

Para realizar los ajustes a los factores de expansión finales, se trató cada sub-muestra por separado, y luego se las reunió nuevamente para los ajustes finales de post-estratificación. El procedimiento seguido fue el siguiente:

PASO 1: Se tomaron los factores de expansión base provenientes de la ola en que se hizo la selección muestral respectiva. Esos factores base se encuentran ajustados por la probabilidad inicial de no respuesta (es decir, no son exactamente los factores de diseño, sino que aquellos resultantes del ajuste proporcional de la muestra original al resultado de campo de la primera ronda de levantamiento de cada sub-muestra, sin que medien otros ajustes). A modo de ejemplo, en la EPS I Ronda se seleccionaron 30.000 observaciones, con un objetivo de levantamiento de 20.000 encuestas, de las que se recolectaron 17.246 encuestas. Sin embargo, de éstas sólo correspondieron a Vivos un

total de 16.032 encuestas que, desde entonces, conforman el denominado Panel Afiliados 2002.

PASO 2: A los factores de expansión base se le realizó un ajuste proporcional al tamaño por pérdida de muestra¹⁴ entre la ola original, y las observaciones disponibles dentro del conjunto de contactos entregados por la SPS. Estos 24.882 posibles entrevistados y entrevistadas son el resultado de la depuración de la base original de contactos conformada a través de las olas, deducidas las personas fallecidas y otras pérdidas de muestra (por ejemplo, mudanzas al exterior del país del entrevistado). Se identifica a ésta como la muestra nominal de la EPS VIII Ronda. Siguiendo con el ejemplo de la submuestra Afiliados 2002, según se reporta en la Tabla 4.2, de 16.032 casos originales que conformaron la primera muestra lograda, tuvimos a disposición 13.774 casos nominales debido a las sucesivas deducciones de fallecidos/as y PSD.

PASO 3: Se realizó un segundo ajuste proporcional al tamaño para lograr que los/as entrevistados/as que respondieron el cuestionario de Vivos representen el universo adecuadamente. Este ajuste obedece a lo que se denomina muestra efectiva, es decir, el conjunto de potenciales entrevistados y entrevistadas Vivos, después de deducir de la base de contactos aquellos casos en que se conoce fehacientemente que los entrevistados están fallecidos o en situación de discapacidad, en virtud del resultado del trabajo de campo. Para el ejemplo de los Afiliados 2002, esa muestra nominal se redujo de 13.774 a una muestra efectiva de 12.798 (se dedujeron 694 entrevistados/as fallecidos/as y 282 PSD) potenciales personas entrevistadas vivas a incluir en el ajuste por no respuesta.¹⁵

¹⁴ Los ajustes proporcionales se emplean cuando no existe una interpretación razonable de que la pérdida de muestra está relacionada con la encuesta, su contenido, o su ejecución. Para la EPS, entonces, es razonable asumir que un fallecimiento o situación de discapacidad sobreviniente temporal o permanente no está relacionado con la encuesta, por lo que la realización de un ajuste proporcional no distorsiona las probabilidades de cada individuo de participar en la encuesta. Más aun, con ese ajuste se logra redistribuir el peso que tienen las unidades muestrales perdidas entre el resto de los entrevistados participantes, sin distorsionar los tamaños de *cluster* ni su probabilidad de selección. Nótese que este razonamiento no es general: si, por ejemplo, la encuesta fuese sobre prevalencia de una enfermedad mortal, la causa del fallecimiento sería informativo respecto de la encuesta, por lo que se debería incorporar esa información en los factores de expansión ajustados.

¹⁵ Los ajustes de los pasos 2 y 3 corresponden a atrición en sentido propio, ya que no existe (hasta donde es posible conocer) que exista autoselección. En los pasos siguientes, el ajuste es por atrición por no respuesta, o simplemente, ajuste por no respuesta.

PASO 4: Cuando se llevó a cabo el levantamiento de la encuesta, 6.033 personas de la muestra de Nacimientos 2023 no fueron visitados/as. Por lo tanto, no se tiene ninguna información sobre ellos y ellas a excepción de la información básica del marco muestral. Si bien se estima que estos hogares no diferían de manera particular de los hogares que sí fueron visitados, se realiza un ajuste a los factores de expansión por cobertura del marco muestral (mayor al necesario) asumiendo que no existió ningún tipo de decisión de parte de los y las entrevistados/as que los llevó a no participar. En este caso, si bien es un ajuste de las probabilidades de selección, se realiza de manera proporcional para redistribuir los pesos originales de la selección muestral entre las personas visitadas.

PASO 5: Dentro del grupo de personas entrevistadas que fueron visitadas, se debe ajustar por la probabilidad de responder o rechazar ya que se sabe que aquellos y aquellas que responden o rechazan definitivamente el cuestionario, típicamente difieren entre sí (autoselección). Por lo tanto, los factores de expansión deben ser ajustados siguiendo la lógica de los ajustes por no respuesta. Para ello, se estima un modelo de propensión de respuesta/rechazo basado en regresión logística para obtener la probabilidad de responder/rechazar, condicional en haber sido visitado (teniendo en cuenta aspectos del trabajo de campo, como el número de visitas realizadas para lograr la encuesta), es decir, se estima la $Pr(Responder|Visitado)$.

Para llevar a cabo este ajuste se probaron varias especificaciones del modelo logístico. El poder explicativo de todos ellos resultó bajo si observamos el Pseudo R^2 propuesto por McFadden. De todos modos, esto también es indicio de que la información con que habitualmente se cuenta para llevar adelante el muestreo y el trabajo de campo, no influyó en el desarrollo del trabajo de campo ni en la probabilidad de responder.

A continuación, a modo de ejemplo, se muestra la estimación de los efectos marginales para la sub-muestra Afiliados 2002, basado en 13.774 observaciones que cumplieran la condición de visita, y de la cuáles, 7.222 respondieron efectivamente la encuesta, con 710 rechazos, y el resto de los casos clasificados con distintos CDF:

Tabla 4.3. Ejemplo de resultado de estimación de la probabilidad de Responder-Rechazar Ser Visitado en la EPS 2023, Afiliados 2002				
Variable Explicada: d_RespRech	Modelo 1	Modelo 2	Modelo 3	Modelo 4
grupo_etario_2023 (categoría base: Edad menos de 45)				
Edad 45-54	0.103	0.12	0.0983	0.104

		(0.0943)	(0.0945)	(0.0946)	(0.0942)
	Edad 55-64	0.329*** (0.0939)	0.364*** (0.0939)	0.338*** (0.0938)	0.331*** (0.0937)
	Edad 65-74	0.542*** (0.0985)	0.601*** (0.0982)	0.559*** (0.0976)	0.545*** (0.0982)
	Edad 75 o más	0.477*** (0.1100)	0.544*** (0.1100)	0.480*** (0.1090)	0.477*** (0.1100)
macrozona (categoría base: R. Met.)					
	Norte				-0.161* (0.0672)
	Centro				-0.465*** (0.0473)
	Sur				0.223*** (0.0632)
sexo (categoría base: Mujer)					
	Hombre	-0.235*** (0.0422)	-0.248*** (0.0420)	-0.251*** (0.0417)	-0.231*** (0.0421)
t_educ (categoría base: Ninguno)					
	Educación Básica	0.334 (0.2000)	0.372 (0.1910)		0.309 (0.1990)
	Educación Media	0.482* (0.2000)	0.497** (0.1910)		0.448* (0.1990)
	Educación Terciaria	0.448* (0.2080)	0.418* (0.2000)		0.413* (0.2070)
	Educación Universitaria	0.363 (0.2080)	0.32 (0.2000)		0.334 (0.2070)
region (categoría base: 13)					
	I. Tarapacá / XV. Arica y Parinacota	-0.139 (0.1320)	-0.0921 (0.1290)	-0.0796 (0.1290)	

II. Antofagasta	-0.196 (0.1270)	-0.195 (0.1260)	-0.179 (0.1250)
III. Atacama	-0.746*** (0.1420)	-0.740*** (0.1380)	-0.726*** (0.1380)
IV. Coquimbo	0.0891 (0.0917)	0.14 (0.0900)	0.135 (0.0903)
V. Valparaíso	-0.531*** (0.0682)	-0.478*** (0.0669)	-0.472*** (0.0669)
VI. O'Higgins	-0.409*** (0.0872)	-0.336*** (0.0855)	-0.345*** (0.0854)
VII. Maule	-0.445*** (0.0841)	-0.374*** (0.0815)	-0.383*** (0.0813)
VIII. Biobío / XVI. Ñuble	-0.427*** (0.0650)	-0.361*** (0.0643)	-0.365*** (0.0643)
IX. Araucanía	0.377*** (0.1010)	0.418*** (0.1000)	0.411*** (0.1000)
X. Los Lagos / XIV. Los Ríos	0.119 (0.0788)	0.15 (0.0781)	0.143 (0.0779)
XI. Aysén	0.582** (0.2230)	0.581** (0.2180)	0.570** (0.2190)
XII. Magallanes	-0.105 (0.1830)	-0.0909 (0.1820)	-0.0892 (0.1810)
olas_cat_2020 (categoría base: 2002 2004 2006 2009 2015 2020)			
2002	-1.280*** (0.1330)		-1.964*** (0.1210)
2002 2004	-1.059*** (0.1450)		-1.735*** (0.1350)
2002 2004 2006	-0.888*** (0.1210)		-1.568*** (0.1080)

2002 2004 2006 2009	-0.845*** (0.0902)	-1.517*** (0.0720)
2002 2004 2006 2009 2015	-0.352*** (0.0868)	-1.011*** (0.0665)
2002 2004 2006 2009 2020	0.680*** (0.0792)	-0.686*** (0.0790)
2002 2004 2006 2015	-0.397* (0.1700)	-1.074*** (0.1600)
2002 2004 2006 2015 2020	0.315* (0.1460)	-0.397** (0.1350)
2002 2004 2006 2020	-0.337* (0.1410)	-1.027*** (0.1310)
2002 2004 2009	-0.876*** (0.1990)	-1.561*** (0.1910)
2002 2004 2009 2015	-0.0872 (0.2110)	-0.760*** (0.2040)
2002 2004 2009 2015 2020	0.138 (0.1970)	-0.572** (0.1890)
2002 2004 2009 2020	-0.119 (0.2800)	-0.799** (0.2740)
2002 2004 2015	-0.482 (0.3020)	-1.168*** (0.2950)
2002 2004 2015 2020	0.641* (0.2980)	-0.0696 (0.2920)
2002 2004 2020	-0.196 (0.2080)	-0.900*** (0.2000)
2002 2006	-0.950*** (0.1660)	-1.640*** (0.1570)
2002 2006 2009	-0.767***	-1.450***

	(0.1530)	(0.1430)
2002 2006 2009 2015	-0.292 (0.1670)	-0.984*** (0.1580)
2002 2006 2009 2015 2020	0.464** (0.1440)	-0.225 (0.1330)
2002 2006 2009 2020	-0.163 (0.1770)	-0.850*** (0.1690)
2002 2006 2015	-0.817** (0.2860)	-1.491*** (0.2830)
2002 2006 2015 2020	0.796** (0.2660)	0.0859 (0.2600)
2002 2006 2020	-0.0864 (0.2360)	-0.774*** (0.2300)
2002 2009	-0.742** (0.2290)	-1.440*** (0.2220)
2002 2009 2015	-0.371 (0.2940)	-1.069*** (0.2930)
2002 2009 2015 2020	0.501 (0.3250)	-0.199 (0.3190)
2002 2009 2020	0.168 (0.2910)	-0.541 (0.2840)
2002 2015	-0.658* (0.3190)	-1.346*** (0.3140)
2002 2015 2020	0.216 (0.3230)	-0.519 (0.3210)
2002 2020	-0.478** (0.1680)	-1.160*** (0.1590)
ultima_EPS (categoría base: EPS 2002)		
EPS 2004	0.222	0.233

		(0.1720)	(0.1710)		
	EPS 2006	0.297*	0.300*		
		(0.1490)	(0.1490)		
	EPS 2009	0.366**	0.379**		
		(0.1330)	(0.1330)		
	EPS 2012	0.542***	0.560***		
		(0.1340)	(0.1340)		
	EPS 2015	0.883***	0.900***		
		(0.1230)	(0.1230)		
	EPS 2020	1.604***	1.623***		
		(0.1180)	(0.1180)		
pensionado (categoría base: no)					
	Sí	-0.04	-0.052	-0.0502	-0.0449
		(0.0988)	(0.0978)	(0.0973)	(0.0985)
cotizando (categoría base: no)					
	Sí	-0.0152	-0.024	-0.0212	-0.0192
		(0.0436)	(0.0434)	(0.0423)	(0.0435)
constante		-0.115	-1.434***	-0.992***	0.597**
		(0.2290)	(0.2400)	(0.1470)	(0.2210)
Observations		12746	12746	12746	12746
Pseudo R-squared		0.089	0.077	0.076	0.087
<i>Standard errors in parentheses</i>					
<i>* p<0.05, ** p<0.01, *** p<0.001</i>					
Fuente: elaboración propia.					

En la Tabla 4.4, se muestran los principales estadísticos de la distribución de la probabilidad de respuesta predicha a partir del modelo 1 anterior:¹⁶

Tabla 4.4. Ejemplo de distribución de probabilidad estimada de Responder-Rechazar | Ser Visitado en la EPS 2023, sub-muestra Afiliados 2002

Pr(d_RespRech)				
	Percentiles	Smallest		
1%	.2191215	.1609745		
5%	.2743497	.1609745		
10%	.3136238	.1609745	Obs	12,746
25%	.4046912	.1611354	Sum of wgt.	12,746
50%	.5478815		Mean	.5452293
		Largest	Std. dev.	.1694421
75%	.69291	.8596532		
90%	.7719304	.8596532	Variance	.0287106
95%	.7983525	.8596532	Skewness	-.0797444
99%	.8305504	.8596532	Kurtosis	1.882522

Nota: la tabla corresponde al reporte estadístico obtenido de la variable que representa la probabilidad estimada (*Propensity Score* estimado), sin procesamiento adicional, tal como es entregado por el software Stata 17.

Fuente: elaboración propia.

PASO 6: A continuación, se obtuvo la probabilidad incondicional de responder la encuesta de la VIII Ronda, es decir,

$$\Pr(\text{Respuesta}) = \Pr(\text{Responde}|\text{Visitado}) \cdot \Pr(\text{Visitado})$$

La siguiente tabla muestra la distribución de la probabilidad predicha para la sub-muestra Afiliados 2002:

¹⁶ El modelo se ha seleccionado en virtud del ajuste general expresado por Pseudo R^2 .

Tabla 4.5. Ejemplo de distribución de probabilidad incondicional estimada de Responder la EPS 2023, sub-muestra Afiliados 2002

Prop_Score				
	Percentiles	Smallest		
1%	.1356935	.0620374		
5%	.1888438	.0792175		
10%	.2296198	.0792175	Obs	12,746
25%	.3225526	.0806258	Sum of wgt.	12,746
50%	.4954325		Mean	.4884761
		Largest	Std. dev.	.1893399
75%	.654739	.8697919		
90%	.7370903	.8697919	Variance	.0358496
95%	.7676381	.8697919	Skewness	-.0890683
99%	.817838	.8697919	Kurtosis	1.830632

Nota: la tabla corresponde al reporte estadístico obtenido de la variable que representa el *Propensity Score* estimado (probabilidad estimada), sin procesamiento adicional, tal como es entregado por el software Stata 17.

Fuente: elaboración propia.

PASO 7: una vez que se estimó la probabilidad de responder la encuesta, se realizó el ajuste por no respuesta. Si bien existen múltiples enfoques para llevarlo a cabo, y la literatura es prolífera en estos tópicos¹⁷, se optó por revisar la factibilidad de dos de ellos: (i) enfoque de ajuste por celdas, y (ii) enfoque de ajuste directo.

En el enfoque de ajuste por celdas, se debe decidir cómo agrupar las observaciones según algún criterio. Los criterios pueden ir desde características poblacionales, hasta métodos sofisticados de *clusterización*, *cópulas* y *random forest classification*. En el caso de la EPS VIII Ronda, se recurrió a un método bastante empleado en la práctica y que consiste en dividir la distribución de la probabilidad de no respuesta predicha en tramos idénticos. Para ello, se utilizaron tres alternativas: separación por deciles (10 partes iguales), ventiles (20 partes iguales) y percentiles (100 partes iguales) de la distribución del *propensity score* estimado. Dentro de cada separación, se toma un promedio simple

¹⁷ Véase Buuren (2017), Lohr (2010), Valliant et al. (2018), Valliant y Dever (2018), entre otros, que resumen varias de las alternativas disponibles.

de las probabilidades y se utiliza ese factor de ajuste para las observaciones dentro del *cluster*.

A continuación, se puede ver un ejemplo del comportamiento de la distribución del *propensity score* cuando se lo agrupa en ventiles, para la sub-muestra Afiliados 2002:

Tabla 4.6. Ejemplo de agrupación por ventiles de la probabilidad incondicional estimada de no respuesta de la EPS 2023, sub-muestra Afiliados 2002

	Ventil	Mínimo	Media	Máximo
1.	.1885397	.0620374	.1563647	.1883759
2.	.2296198	.1888438	.2095367	.2296198
3.	.2614219	.2296237	.246216	.2614219
4.	.2929426	.2615152	.2775649	.2929326
5.	.3225526	.2929577	.3075011	.3225526
6.	.3559235	.3226065	.3399679	.3557931
7.	.3886516	.3559235	.3722401	.3886516
8.	.4259049	.3890111	.4055838	.4257033
9.	.4626814	.4259049	.4428978	.4626814
10.	.4954325	.4627564	.4797654	.4954325
11.	.5313786	.4954406	.51335	.5313786
12.	.5652725	.5314714	.5491944	.5652725
13.	.5989431	.5656393	.5819191	.5989431
14.	.6283466	.5989661	.6136311	.6283466
15.	.6547424	.6284992	.6410804	.654739
16.	.6804538	.6547524	.6676032	.6804538
17.	.7080273	.6805246	.695971	.7080273
18.	.7370903	.7080899	.722643	.7370903
19.	.7678611	.7371014	.7526125	.7676381
20.	.8697919	.7679811	.7970759	.8697919

Fuente: elaboración propia.

El enfoque de ajuste directo, por su parte, simplemente implica que el *propensity score* obtenido se utiliza como denominador de los factores base de cada observación, “inflándolos” para que representen a la población completa.

Para determinar cuál de los métodos es más adecuado, se tuvieron en cuenta los efectos de los distintos ponderadores sobre el tamaño poblacional representado, y cómo éste conversaba con el tamaño poblacional original. También se tuvo en cuenta el rango intercuartílico, varianza y valores extremos resultantes de la aplicación de cada uno de estos ponderadores de probabilidad de responder la encuesta.

Finalmente, se utilizó alguno de estos factores para ajustar por no respuesta el factor de expansión. Las poblaciones representadas después de cada ajuste por no respuesta, y para la muestra total de personas que respondieron el cuestionario de VIVOS se pueden ver en la Tabla 4.7, en comparación con el factor base.

Tabla 4.7. Población representada por la muestra de la EPS 2023 VIVOS (sólo ajuste de factores de expansión)						
Tipo de Muestra	Afiliados 2002	Nuevos Afiliados 2004	No Afiliados 2004	Nacimientos 2015	Nacimientos 2023	Total
Total Encuestas VIVOS	6,247	381	1,097	3,043	5,020	15,788
Población representada originalmente	8,074,674	527,914	3,994,879	3,250,561	2,024,043	17,872,071
Factor expansión promedio original	1292.568273	1385.601050	3641.639927	1068.209333	403.195817	1132.003484
Población representada con ajuste por No Respuesta	8,063,279	526,426	3,998,689	3,242,785	2,024,043	17,855,222
Factor expansión promedio ajustado por NR	1290.744197	1381.696588	3645.113036	1065.653960	403.195817	1130.936306
Población representada post-estratificada	5,787,792	495,089	2,855,038	4,103,847	2,282,970	15,524,736
Factor expansión promedio post-estratificado	926.491436	1299.446982	2602.587056	1348.618797	454.774900	983.325076
Fuente: elaboración propia.						

Después de aplicar este procedimiento, que implicó ajustes sucesivos por muestra nominal, efectiva y no respuesta en sus distintos niveles, se logró representar casi 18 millones de personas de 18 y más años que habitaban Chile en los distintos momentos en que se crearon las muestras (representación nominal).

4.3. Post-estratificación de los factores de corte transversal

Aun cuando los factores de expansión han sido ajustados por atrición y no respuesta, no logran representar a la población contingente del momento de la encuesta. Por lo tanto, se realiza un

último ajuste para empatar la población representada con la inferencia que se puede realizar a partir de la muestra. Para hacer este procedimiento, se deben calibrar los factores de expansión.¹⁸

Los factores de expansión de la EPS VIII Ronda se han ajustado empleando post-estratificación por celdas poblacionales, como se hizo en las olas anteriores. En el procedimiento de post-estratificación, se determinan celdas de ajuste para las cuales es posible fijar (multidimensionalmente) la cantidad de personas que se deberían representar. Si bien el método es simple (sólo requiere el cálculo de proporciones), cuando las celdas se determinan con muchas variables o categorías, o cuando una determinada configuración deja una celda con pocas observaciones encuestadas, los ponderadores pueden “explotar”, es decir, pueden aumentar o disminuir bruscamente causando que los factores de expansión finales muestren exacerbaciones que pueden requerir *trimming* (es decir, “recortes” teniendo en cuenta máximos y mínimos de la distribución, varianzas, etc.) o construcción de pseudo-estratos y/o pseudo-clusters.

En el caso de esta ola de la EPS, se aplicó la post-estratificación por sexo, grupo etario y región como es tradición en la encuesta. Los totales poblacionales se tomaron de las proyecciones censales del INE, disponibles públicamente. La fecha que se tomó como referencia para esta encuesta fue el mes de septiembre de 2023, periodo anterior al inicio del levantamiento.¹⁹ Los totales poblacionales para los que se post-estratificó se muestran en la Tabla 4.8, representando unos 15,5 millones de personas de 18 y más años a septiembre de 2023.

Nótese que las proyecciones de población entregadas por el INE se refieren a junio de cada año. Por lo tanto, la información empleada en la post-estratificación de la EPS y mostrada en la Tabla 4.8, corresponde a una interpolación entre junio de 2023 y septiembre del mismo año. La interpolación se realizó asumiendo que la tasa de crecimiento entre 2023 y 2024 fue una tasa efectiva, por lo que la tasa de crecimiento del periodo se puede modelar como:²⁰

$$\bar{r} = \frac{1}{T} \ln \left(\frac{N_T}{N_0} \right)$$

Donde T es la cantidad de periodos de duración sobre el que se mide la tasa de crecimiento, N_T es la población al final del periodo, y N_0 es la población al inicio. Para el caso de la EPS, $T = 1$ año, por lo que la expresión anterior se reduce a:

¹⁸ La calibración puede tomar muchas formas, entre las que se sugiere particularmente la calibración iterativa por márgenes/totales poblacionales (también conocida como *raking*). Este tipo de calibración ha demostrado buenos comportamientos en contextos de encuestas complejas como la EPS, y tiene algunas ventajas técnicas que han sido discutidas en la literatura especializada. Sin embargo, en esta edición de la EPS, y siguiendo los términos contractuales, se ha utilizado el procedimiento de post-estratificación que es un tipo de calibración por celdas específicas (en lugar de los marginales o los totales).

¹⁹ El trabajo de campo se desarrolló entre el miércoles 11 de octubre de 2023 y el lunes 10 de junio de 2024.

²⁰ Véase Sadinle (2008).

$$\bar{r} = \ln \left(\frac{N_{2024}}{N_{2023}} \right)$$

Por su parte, empleando esta tasa de crecimiento, se puede obtener la población en el sub-periodo t mediante la siguiente expresión:

$$N(t) = N_0 \exp \left(t \cdot \left[\frac{\bar{r} \cdot T}{k} \right] \right)$$

Donde k es la cantidad de subperiodos dentro de T y t es el sub-periodo para el que se quiere interpolar. Por lo tanto, dado que el mes de septiembre es el tercer mes después de junio de cada año, la expresión anterior queda como:

$$N(5) = N_{2023} \exp \left(\frac{3 \cdot \bar{r}}{12} \right)$$

Tabla 4.8. Población de 18 años y más a Septiembre de 2023, según región, sexo y grupo etario

Región	Hombres						TOTAL	
	18-30	31-40	41-50	51-60	61-70	71+	TOTAL	Pobl.
I / XV	70,338	56,667	44,426	34,132	25,038	17,358	247,959	494,314
II	76,902	63,784	51,786	38,114	26,008	13,593	270,187	541,396
III	28,737	26,102	21,145	18,926	14,606	9,615	119,131	237,292
IV	78,521	63,560	56,046	51,152	39,841	33,005	322,125	666,111
V	189,450	145,721	127,204	117,325	100,181	84,941	764,822	1,582,566
VI	81,822	76,182	72,497	66,685	52,675	41,592	391,453	788,307
VII	97,627	80,967	77,335	73,281	59,524	47,348	436,082	900,414
VIII / XVI	191,777	151,575	140,365	142,194	108,581	85,889	820,381	1,716,250
IX	87,903	69,752	67,033	63,880	50,192	41,791	380,551	790,304
X / XIV	112,543	97,550	92,008	88,622	63,594	48,684	503,001	1,025,419
XI / XII	26,009	24,646	21,128	17,472	14,449	10,240	113,944	225,781
RM	834,865	760,108	579,403	462,355	342,002	240,863	3,219,596	6,556,582
Total	1,876,494	1,616,614	1,350,376	1,174,138	896,691	674,919	7,589,232	15,524,736

Región	Mujeres						TOTAL	
	18-30	31-40	41-50	51-60	61-70	71+	TOTAL	Pobl.
I / XV	64,743	53,543	42,831	34,826	27,246	23,166	246,355	494,314
II	74,168	62,228	50,456	37,224	27,164	19,969	271,209	541,396
III	27,150	24,851	19,661	18,587	15,232	12,680	118,161	237,292
IV	77,059	65,522	58,842	54,754	43,940	43,869	343,986	666,111
V	180,046	144,798	130,931	126,857	114,850	120,262	817,744	1,582,566
VI	77,997	75,547	70,798	66,421	54,930	51,161	396,854	788,307
VII	97,639	84,266	80,564	76,722	64,251	60,890	464,332	900,414
VIII / XVI	194,432	159,868	151,680	151,010	121,792	117,087	895,869	1,716,250
IX	90,386	74,407	70,132	65,694	53,499	55,635	409,753	790,304
X / XIV	114,130	98,917	91,018	86,344	66,626	65,383	522,418	1,025,419
XI / XII	23,603	24,372	20,293	16,947	14,381	12,241	111,837	225,781
RM	799,780	706,778	562,699	493,752	401,464	372,513	3,336,986	6,556,582
Total	1,821,133	1,575,097	1,349,905	1,229,138	1,005,375	954,856	7,935,504	15,524,736

Fuente: elaboración propia en base a proyecciones INE a Junio de 2023. Interpolación según Sadinle (2008).

En la Tabla 4.9, se puede muestra la cantidad de observaciones disponibles en cada celda de post-estratificación para los cuestionarios de Vivos de la presente encuesta:

Tabla 4.9. Muestra de entrevistados Vivos de la EPS 2023, según región, sexo y grupo etario

Región	Hombres						TOTAL	
	18-30	31-40	41-50	51-60	61-70	71+	TOTAL	Pobl.
I / XV	91	36	13	21	21	22	204	444
II	103	36	20	29	28	17	233	518
III	46	13	10	13	16	14	112	253
IV	129	50	43	55	45	58	380	804
V	232	77	42	66	80	96	593	1,351
VI	158	38	30	44	40	34	344	712
VII	153	29	36	48	59	64	389	825
VIII / XVI	284	90	59	107	122	135	797	1,720
IX	246	61	40	69	74	55	545	1,140
X / XIV	193	53	60	84	66	73	529	1,209
XI / XII	37	25	16	18	25	16	137	295
RM	1,277	327	268	345	388	313	2,918	6,517
Total	2,949	835	637	899	964	897	7,181	15,788

Región	Mujeres						TOTAL	
	18-30	31-40	41-50	51-60	61-70	71+	TOTAL	Pobl.
I / XV	107	42	16	26	30	19	240	444
II	118	44	27	39	38	19	285	518
III	55	18	13	20	19	16	141	253
IV	151	55	41	64	49	64	424	804
V	257	101	68	101	116	115	758	1,351
VI	143	49	41	53	44	38	368	712
VII	164	52	43	61	66	50	436	825
VIII / XVI	311	146	86	125	136	119	923	1,720
IX	264	83	40	62	71	75	595	1,140
X / XIV	255	82	70	104	92	77	680	1,209
XI / XII	57	20	17	22	23	19	158	295
RM	1,364	437	364	498	507	429	3,599	6,517
Total	3,246	1,129	826	1,175	1,191	1,040	8,607	15,788

Fuente: elaboración propia.

La organización de celdas (grupos etarios y agrupación de regiones) obedecen a la necesidad de minimizar los casos en que las celdas tuvieran menos de 15 observaciones disponibles cada una. Esto implicó que se agruparan (i) algunas regiones que administrativamente habían sido una sola región hasta hace algunos años, o (ii) regiones con baja densidad poblacional (regiones del sur).

Nótese el caso de la Región de los Ríos que se suma a la Región de los Lagos (regiones X y XIV), o las regiones más extremas que también se agrupan. Vale la pena destacar que, al menos para los casos de I + XV regiones, VII + XVI, y X + XIV regiones, se encontraban como una unidad administrativa al momento de hacer los muestreos. Y en el caso de los nuevos entrevistados incorporados en esta ronda, el muestreo siguió la agrupación (estratos y clusters) originales de 2002, por lo que la agrupación de las regiones es algo natural en la encuesta.

En el caso de las comunas del sur, XI + XII, la agrupación se debió a la baja densidad poblacional de tales regiones, una práctica habitual en las estadísticas chilenas.

Por su parte, la muestra, después de los diversos ajustes explicados en las secciones anteriores, representaba la distribución de población informada en la Tabla 4.10. Estas cifras corresponden a la distribución de población representada antes de la post-estratificación.

Tabla 4.10. Muestra expandida de entrevistados Vivos de la EPS 2023, según región, sexo y grupo etario (sin post-estratificación)

Región	Hombres						TOTAL	
	18-30	31-40	41-50	51-60	61-70	71+	TOTAL	Pobl.
I / XV	51,139	49,905	26,584	47,459	37,645	33,772	246,506	477,209
II	67,735	47,675	42,051	58,909	45,813	31,940	294,124	636,337
III	23,867	14,881	20,909	20,364	22,008	15,389	117,420	256,774
IV	68,301	52,047	49,483	69,152	45,418	48,859	333,259	699,920
V	147,790	131,791	109,333	142,271	132,896	153,414	817,495	1,823,108
VI	91,812	63,440	65,716	70,325	46,340	39,973	377,605	867,711
VII	102,912	53,666	78,484	93,037	106,115	101,582	535,795	1,073,180
VIII / XVI	177,290	112,322	114,728	177,665	177,275	220,448	979,727	2,140,720
IX	89,777	58,788	73,578	91,242	98,746	66,526	478,657	1,004,542
X / XIV	89,854	56,959	87,495	96,980	72,054	94,105	497,448	1,103,613
XI / XII	17,777	20,060	28,196	31,804	23,634	21,268	142,738	294,438
RM	647,730	476,499	617,903	571,747	542,268	448,148	3,304,294	7,477,669
Total	1,575,984	1,138,033	1,314,460	1,470,955	1,350,211	1,275,423	8,125,067	17,855,222

Región	Mujeres						TOTAL	
	18-30	31-40	41-50	51-60	61-70	71+	TOTAL	Pobl.
I / XV	52,931	33,375	30,570	38,937	46,769	28,120	230,703	477,209
II	68,548	44,364	59,372	74,176	62,187	33,565	342,213	636,337
III	27,587	21,711	17,550	25,334	21,989	25,184	139,355	256,774
IV	73,524	51,216	60,378	65,302	46,765	69,476	366,662	699,920
V	161,405	135,054	158,980	163,743	192,325	194,106	1,005,614	1,823,108
VI	76,068	64,390	88,643	67,952	88,064	104,991	490,106	867,711
VII	112,982	56,247	62,934	99,128	109,858	96,235	537,384	1,073,180
VIII / XVI	192,423	154,565	159,719	196,262	230,806	227,219	1,160,994	2,140,720
IX	98,786	62,214	76,349	70,740	101,497	116,298	525,885	1,004,542
X / XIV	117,278	77,229	101,451	112,527	105,104	92,577	606,165	1,103,613
XI / XII	27,778	14,011	22,319	30,309	23,467	33,815	151,700	294,438
RM	690,062	518,292	666,693	761,149	779,446	757,733	4,173,375	7,477,669
Total	1,699,373	1,232,667	1,504,959	1,705,559	1,808,277	1,779,319	9,730,155	17,855,222

Fuente: elaboración propia.

Al final del proceso, la realización del ajuste por post-estratificación implica obtener para cada celda, la proporción entre la población estimada por estrato y la población representada por la muestra en dicha celda. Esto entrega un factor que multiplica a los factores de expansión de la muestra. Si la población representada en la muestra es más grande que la población real, el ajuste de post-estratificación será menor a 1, y al multiplicarlo por los factores de expansión de los entrevistados y entrevistadas de la celda, les disminuirá el peso relativo en la muestra. Por el

contrario, si la población representada es mayor a la ajustada por no respuesta, entonces el factor de post-estratificación será mayor que 1 e incrementará la representatividad de los individuos de la celda particular. En la Tabla 4.11, se puede ver el factor de post-estratificación para cada celda.

Tabla 4.11. Coeficientes de ajuste de post-estratificación para entrevistados y entrevistadas Vivos de la EPS 2023, según región, sexo y grupo etario

Región	Hombres					
	18-30	31-40	41-50	51-60	61-70	71+
I / XV	1.375415	1.135487	1.671125	0.719183	0.665111	0.513977
II	1.135332	1.337900	1.231494	0.646994	0.567702	0.425578
III	1.204024	1.754012	1.011279	0.929376	0.663655	0.624794
IV	1.149632	1.221213	1.132635	0.739708	0.877205	0.675520
V	1.281884	1.105698	1.163454	0.824660	0.753831	0.553671
VI	0.891193	1.200848	1.103192	0.948238	1.136714	1.040509
VII	0.948650	1.508727	0.985355	0.787657	0.560941	0.466104
VIII / XVI	1.081716	1.349472	1.223459	0.800349	0.612501	0.389612
IX	0.979127	1.186505	0.911048	0.700119	0.508292	0.628188
X / XIV	1.252511	1.712624	1.051583	0.913813	0.882589	0.517336
XI / XII	1.463054	1.228640	0.749339	0.549361	0.611360	0.481482
RM	1.288909	1.595192	0.937693	0.808671	0.630688	0.537463

Región	Mujeres					
	18-30	31-40	41-50	51-60	61-70	71+
I / XV	1.223149	1.604261	1.401058	0.894430	0.582567	0.823815
II	1.081981	1.402665	0.849822	0.501833	0.436809	0.594936
III	0.984166	1.144634	1.120268	0.733676	0.692707	0.503501
IV	1.048081	1.279330	0.974558	0.838473	0.939585	0.631424
V	1.115491	1.072150	0.823570	0.774731	0.597166	0.619567
VI	1.025360	1.173278	0.798691	0.977471	0.623754	0.487292
VII	0.864200	1.498141	1.280125	0.773970	0.584856	0.632722
VIII / XVI	1.010441	1.034311	0.949670	0.769431	0.527681	0.515303
IX	0.914968	1.195990	0.918567	0.928662	0.527097	0.478383
X / XIV	0.973156	1.280830	0.897165	0.767321	0.633907	0.706255
XI / XII	0.849689	1.739434	0.909219	0.559136	0.612829	0.362003
RM	1.158997	1.363668	0.844015	0.648693	0.515063	0.491615

Fuente: elaboración propia.

4.4. Factores de expansión finales de corte transversal

Después de aplicar los factores de post-estratificación de la Tabla 4.11 a cada entrevistado o entrevistada, se obtuvieron los factores finales corregidos de corte transversal. A continuación, en la Tabla 4.12, se muestran estos factores para cada sub-muestra y para la muestra total, junto a las poblaciones representadas en cada *cluster*.

Tabla 4.12. Comportamiento de los factores de expansión de corte transversal de la EPS 2023, y de las poblaciones representadas por cada uno, según sub-muestras y muestra total

	Obs.	Media	Desv. Std.	Min.	Max.
Afiliados 2002					
Población por cluster					
Base	6,247	100,832	59,109	3,140	283,247
Nominal	6,247	100,832	59,109	3,140	283,247
Efectiva	6,247	100,832	59,109	3,140	283,247
Ajustada por No Respuesta	6,247	105,259	66,852	2,539	288,743
Post-estratificada	6,247	195,071	110,902	6,795	482,987
Factores de Expansión					
Base	6,247	462.900	160.274	301.000	2,644.000
EPS I Ronda	6,247	529.805	178.817	363.490	2,644.334
Ajustados por Muestra Nominal	6,247	579.245	193.823	381.063	2,644.334
Ajustados por Muestra Efectiva	6,247	628.836	224.107	393.355	2,644.334
Ajustados por No Respuesta	6,247	1,290.744	862.138	497.386	16,085.840
Post-estratificados	6,247	926.491	734.613	256.185	13,008.150
Nuevos Afiliados 2004					
Población por cluster					
Base	381	6,238	4,663	531	45,633
Nominal	381	6,238	4,663	531	45,633
Efectiva	381	6,238	4,663	531	45,633
Ajustada por No Respuesta	381	7,663	5,674	773	23,905
Post-estratificada	381	191,276	109,758	18,782	482,987
Factores de Expansión					
Base	381	597.387	321.537	307.317	3,995.124
EPS II Ronda	381	547.537	507.375	210.435	6,518.957
Ajustados por Muestra Nominal	381	549.644	508.641	210.435	6,518.957
Ajustados por Muestra Efectiva	381	559.947	508.243	220.956	6,518.957
Ajustados por No Respuesta	381	1,381.697	1,284.020	268.697	11,393.980
Post-estratificados	381	1,299.447	1,355.432	178.856	10,684.050
No Afiliados 2004					
Población por cluster					
Base	1,097	48,424	22,581	2,764	99,044
Nominal	1,097	48,424	22,581	2,764	99,044
Efectiva	1,097	48,424	22,581	2,764	99,044
Ajustada por No Respuesta	1,097	51,981	27,066	1,858	122,538

Post-estratificada	1,097	185,159	105,022	6,795	482,987
Factores de Expansión					
Base	1,097	845.473	327.709	392.697	3,250.604
EPS II Ronda	1,097	1,677.607	306.897	1,102.250	5,974.000
Ajustados por Muestra Nominal	1,097	1,703.930	309.439	1,102.250	5,974.000
Ajustados por Muestra Efectiva	1,097	1,885.761	387.911	1,102.250	7,965.333
Ajustados por No Respuesta	1,097	3,645.113	2,168.200	1,516.506	17,978.760
Post-estratificados	1,097	2,602.587	2,315.749	778.757	28,679.570
Nuevos 2015					
Población por cluster					
Base	3,043	39,754	25,147	5,507	117,213
Nominal	3,043	39,754	25,147	5,507	117,213
Efectiva	3,043	39,754	25,147	5,507	117,213
Ajustada por No Respuesta	3,043	41,876	27,082	1,062	120,922
Post-estratificada	3,043	190,964	112,239	11,680	482,987
Factores de Expansión					
Base	3,043	505.148	171.146	216.756	2,246.009
EPS VI Ronda	3,043	478.880	132.031	262.820	2,916.666
Ajustados por Muestra Nominal	3,043	482.909	132.941	262.820	2,916.666
Ajustados por Muestra Efectiva	3,043	485.504	134.250	262.820	2,916.666
Ajustados por No Respuesta	3,043	1,065.654	376.402	465.893	5,658.653
Post-estratificados	3,043	1,348.619	559.932	402.625	7,255.101
Nuevos 2023					
Población por cluster					
Base	5,020	24,326	14,536	2,104	66,524
Nominal	5,020	24,810	14,612	2,104	66,524
Efectiva	5,020	24,810	14,612	2,104	66,524
Ajustada por No Respuesta	5,020	24,810	14,612	2,104	66,524
Post-estratificada	5,020	195,429	116,806	6,795	482,987
Factores de Expansión					
Base	5,020	403.196	332.244	155.124	18,731.130
EPS VI Ronda	5,020	403.196	332.244	155.124	18,731.130
Ajustados por Muestra Nominal	5,020	403.196	332.244	155.124	18,731.130
Ajustados por Muestra Efectiva	5,020	403.196	332.244	155.124	18,731.130
Ajustados por No Respuesta	5,020	403.196	332.244	155.124	18,731.130
Post-estratificados	5,020	454.775	386.551	179.788	21,709.310
Muestra Completa EPS 2023					
Población por cluster					
Ajustada por No Respuesta	15,788	61,405	58,011	773	288,743

Post-estratificada	15,788	193,613	112,673	6,795	482,987
Factores de Expansión					
Ajustados por No Respuesta	15,788	1,130.936	1,158.710	155.124	18,731.130
Post-estratificados	15,788	983.325	1,019.015	178.856	28,679.570

Fuente: elaboración propia.

Nótese que cada uno de estos pasos se aplicó a cada sub-muestra detallada en la Tabla 4.2, a la que se remitió anteriormente. También vale la pena observar no sólo el comportamiento de la sub-muestra Afiliados 2002, que se ha usado como ejemplo para corroborar estos números, sino que también las otras cuatro sub-muestras y la muestra total de la encuesta de VIII Ronda. En resumen, los factores permitieron representar la población de Chile a septiembre de 2023 según lo mostrado en la última sección de la Tabla 4.7.

5. Factores de expansión longitudinales: Paneles en la EPS VIII Ronda

Dado que la EPS ha acumulado 8 rondas, las combinaciones de muestras longitudinales que se pueden generar son abundantes. Por lo tanto, es necesario decidir qué muestras longitudinales pueden ser interesantes de estudiar. Para ellas, se deben crear los factores de expansión longitudinales correspondientes.

En el presente contexto, sabiendo que las incorporaciones de muestra que ya lograron formar panel se dieron en las olas de 2002, 2004 y 2015, se propuso generar los siguientes factores longitudinales:

1. Factor longitudinal para la muestra presente en 2002-2004-2006-2009-2015-2020-2023
2. Factor longitudinal para la muestra presente en 2004-2006-2009-2015-2020-2023
3. Factor longitudinal para la muestra presente en 2015-2020-2023

Para generar los factores longitudinales, cada una de las sub-muestras originales es expandida para representar la población total que le corresponda (Participantes en 2002, Participantes en 2004, Participantes en 2015). Los factores, además, son corregidos por la propensión marginal a participar en cada ola, es decir, $Pr(participar\ en\ ola\ W)$, donde W es la ola particular o conjunto de olas, según corresponda.

5.1.Panel 2002-2004-2006-2009-2015-2020-2023

Para realizar el ajuste de los factores de expansión de los participantes en el panel 2002-2023, se estimó un modelo de propensión a participar en las siete olas de la EPS, alcanzando a un total 12.746 entrevistados, de los cuales 2.511 participaron del panel.²¹ La Tabla 5.1 muestra las estimaciones de cinco especificaciones del modelo de probabilidad de participación.

Tabla 5.1. Estimación de la probabilidad de participar en el Panel 2002-2004-2006-2009-2015-2020-2023					
Variable Explicada: d_Panel	Modelo 1	Modelo 2	Modelo 3	Modelo 4	Modelo 5
grupo_etario_2023 (categoría base: Edad menos de 45)					
Edad 45-54	0.0582	0.104	0.136	0.15	0.119
	(0.1320)	(0.1320)	(0.1290)	(0.1290)	(0.1320)

²¹ Se excluye la participación en la EPS 2012 por considerarse producto no logrado estadísticamente.

Edad 55-64	0.492*** (0.1330)	0.511*** (0.1330)	0.556*** (0.1260)	0.569*** (0.1260)	0.526*** (0.1330)
Edad 65-74	0.834*** (0.1350)	0.853*** (0.1350)	0.892*** (0.1290)	0.906*** (0.1280)	0.870*** (0.1350)
Edad 75 o más	0.915*** (0.1450)	0.910*** (0.1470)	0.910*** (0.1400)	0.918*** (0.1390)	0.919*** (0.1460)
region (categoría base: XIII. Metropolitana)					
I. Tarapacá / XV. Arica y Parinacota	0.0358 (0.1660)	0.0341 (0.1670)	0.0219 (0.1660)		
II. Antofagasta	-0.133 (0.1670)	-0.151 (0.1660)	-0.16 (0.1660)		
III. Atacama	-0.251 (0.1930)	-0.305 (0.1920)	-0.313 (0.1920)		
IV. Coquimbo	0.451*** (0.1050)	0.416*** (0.1060)	0.422*** (0.1060)		
V. Valparaíso	-0.109 (0.0862)	-0.131 (0.0867)	-0.138 (0.0865)		
VI. O'Higgins	0.264* (0.1030)	0.191 (0.1040)	0.188 (0.1040)		
VII. Maule	0.0523 (0.1010)	-0.00069 (0.1020)	0.0186 (0.1010)		
VIII. Biobío / XVI. Ñuble	0.427*** (0.0764)	0.389*** (0.0763)	0.391*** (0.0759)		
IX. Araucanía	0.664*** (0.1060)	0.634*** (0.1070)	0.633*** (0.1070)		
X. Los Lagos / XIV. Los Ríos	0.569*** (0.0873)	0.509*** (0.0878)	0.521*** (0.0872)		
XI. Aysén	-0.942* (0.3700)	-0.988** (0.3690)	-0.988** (0.3680)		
XII. Magallanes	0.16	0.163	0.197		

	(0.2120)	(0.2160)	(0.2150)		
sexo (categoría base: Mujer)					
Hombre	-0.460*** (0.0493)	-0.494*** (0.0500)	-0.437*** (0.0488)	-0.425*** (0.0487)	-0.482*** (0.0498)
e_civil (categoría base: Casado)					
Conviviente	-0.0518 (0.0763)	-0.0997 (0.0764)			-0.111 (0.0760)
Anulado(a)	-0.843* (0.4290)	-0.799 (0.4300)			-0.815 (0.4290)
Separado(a) unión legal	-0.547*** (0.1230)	-0.557*** (0.1230)			-0.565*** (0.1220)
Separado(a) unión hecho	-0.112 (0.1170)	-0.137 (0.1170)			-0.14 (0.1170)
Viudo(a)	-0.549*** (0.1620)	-0.587*** (0.1620)			-0.588*** (0.1610)
Soltero(a)	-0.150* (0.0666)	-0.125 (0.0668)			-0.124 (0.0666)
pensionado (categoría base: no)					
Sí	-0.236* (0.1120)	-0.203 (0.1120)	-0.226* (0.1120)	-0.236* (0.1130)	-0.212 (0.1120)
cotizando (categoría base: no)					
Sí	-0.158** (0.0500)	-0.0692 (0.0516)	-0.0696 (0.0514)	-0.078 (0.0512)	-0.077 (0.0514)
t_educ (categoría base: Ninguno)					
Educación Básica		0.515* (0.2300)	0.556* (0.2330)	0.504* (0.2330)	0.459* (0.2300)
Educación Media		0.401 (0.2300)	0.456 (0.2330)	0.386 (0.2330)	0.329 (0.2300)
Educación Terciaria		0.119 (0.2420)	0.168 (0.2450)	0.0878 (0.2450)	0.0364 (0.2420)
Educación Universitaria		-0.162	-0.103	-0.169	-0.232

	(0.2420)	(0.2450)	(0.2450)	(0.2420)
macrozona (categoría base: R. Met.)				
Norte			0.0788 (0.0812)	0.0839 (0.0814)
Centro			0.134* (0.0562)	0.132* (0.0564)
Sur			0.473*** (0.0708)	0.465*** (0.0710)
Constante	-1.677*** (0.1380)	-2.037*** (0.2690)	-2.235*** (0.2640)	-2.182*** (0.2640)
Observaciones	12746	12746	12746	12746
Pseudo R-squared	0.038	0.045	0.041	0.035
<i>Standard errors in parentheses</i>				
<i>* p<0.05, ** p<0.01, *** p<0.001</i>				
Fuente: elaboración propia.				

En la Tabla 5.2, se puede observar el comportamiento de la muestra para este panel, en que se rescatan 2.511 observaciones. También se puede ver el comportamiento promedio de los factores de expansión para la muestra seleccionada, después de ajuste por probabilidad de participación en el panel, y post-estratificados.

**Tabla 5.2. Panel 2002-2004-2006-2009-2015-2020-2023:
Comportamiento de la muestra y los factores de expansión**

Tipo de Muestra	Afiliados 2002
Muestra 2002	
Original (*)	16,309
Efectiva (**)	6,247
Muestra Panel 2002 2004 2006 2009 2015 2020 2023 (***)	2,511
Población representada originalmente en 2002	8,074,673
Factor expansión promedio original	3,215.720
Población representada con ajuste por Panel en 2002	8,036,944
Factor expansión promedio ajustado por Panel	3,200.694
Población representada post-estratificada en 2023	5,838,820
Factor expansión promedio post-estratificado	2,325.297

Nota: *Muestra original: corresponde a la muestra de VIVOS obtenida en la ola inicial del Panel. **Muestra efectiva: corresponde a la muestra de VIVOS obtenida en la ola inicial del Panel que también respondieron en 2023. *** Muestra 2002|2004|2006...: corresponde a la muestra que ha respondido TODAS las encuestas incluidas en el panel.

Fuente: elaboración propia.

La post-estratificación empleó los totales poblacionales de la Tabla 5.3. Nótese que los tramos de edad comienzan en 39 años, ya que este panel corresponde a los que tenían como mínimo 18 años en 2002. Por lo tanto, esto muestra la consistencia en el envejecimiento del panel. Geográficamente, se estratificó por macrozonas debido a la baja densidad de la muestra de panel en algunas regiones. De esta manera, se asegura que al menos haya 10 entrevistados/as en cada celda.

Adicionalmente, la estimación de tamaño poblacional tiene en cuenta que en 2002 sólo se representó a una parte de la población, aquella afiliada al sistema de pensiones vigente (tanto público como privado). La proporción de muestra representada versus el total de muestra se construye siguiendo la estructura que se hizo evidente en la EPS 2004, en la que se sumaron las sub-muestras de nuevos afiliados entre 2002 y 2004 y los no afiliados al sistema en 2004. De esta manera, la estructura de la muestra de la EPS 2004 permite dimensionar el impacto de la muestra de la EPS 2002 sobre el total, siendo ésta la mejor aproximación dada la información disponible en los distintos informes históricos de la EPS.

Adoptando la misma estructura, se puede obtener la proporción representada de la siguiente manera:

$$Prop.Afi2002 = \frac{Afi2002}{Afi2002 + NoAfi2004 + NacAfi2004} * 100 =$$

$$= \frac{5.787.792}{5.787.792 + 495.089 + 2.855.038} * 100 = \mathbf{63.338182\%}$$

donde *Prop.Afi2002* es la proporción de afiliados 2002 respecto al total de personas representadas (*Afi2002*: afiliados 2002; *NacAfi2004*: nuevos afiliados 2004; *NoAfi2004*: no afiliados 2004). La proporción obtenida se aplica a los totales poblacionales de 39 y más años a Septiembre de 2023, resultando en las proyecciones poblacionales mostradas en la Tabla 5.3.

Tabla 5.3. Proyección de población de 39 años y más a Septiembre de 2023, según macrozona, sexo y grupo etario

Macrozona	Hombres				Mujeres				TOTAL
	39-50	51-65	66+	TOTAL	39-50	51-65	66+	TOTAL	Pobl.
Norte	133,793	126,809	76,755	337,358	132,550	131,140	96,028	359,718	697,076
Centro	318,549	363,972	256,886	939,407	330,744	387,568	325,772	1,044,084	1,983,492
Sur	137,134	152,241	100,433	389,807	138,655	152,817	123,815	415,287	805,094
R. Met.	452,356	413,263	248,764	1,114,383	435,816	450,463	352,497	1,238,776	2,353,158
Total	1,041,832	1,056,285	682,838	2,780,955	1,037,765	1,121,989	898,111	3,057,866	5,838,820

Nota: Interpolación según Sadinle (2008). Macrozonas: Norte: regiones 15, 1, 2, 3 y 4. Centro: 5, 6, 7, 16 y 8. Sur: 9, 14, 10, 11 y 12. R. Met.: 13 (Región Metropolitana). La población representada corresponde a la proporción de personas de 39 años y más a Septiembre de 2023 que estarían afiliadas al Sistema de Pensiones (público + privado).

Fuente: elaboración propia en base a proyecciones INE a Junio de 2023.

Los factores de ajuste por post-estratificación resultantes son los siguientes:

Tabla 5.4. Coeficientes de ajuste de post-estratificación: Muestra Panel 2002 | 2004 | 2006 | 2009 | 2015 | 2020 | 2023 según macrozona, sexo y grupo etario

Macrozona geográfica	Hombres			Mujeres		
	39-50	51-65	66+	39-50	51-65	66+
Norte	1.210007	0.582538	0.493623	1.516535	0.607588	0.746456
Centro	1.402056	0.574871	0.429018	1.516479	0.736153	0.843050
Sur	1.244379	0.674767	0.509325	1.384581	0.690449	0.824281
R. Met.	1.373171	0.549259	0.430908	1.238091	0.471406	0.629690

Nota: Macrozonas: Norte: regiones 15, 1, 2, 3 y 4. Centro: 5, 6, 7, 16 y 8. Sur: 9, 14, 10, 11 y 12. R. Met. : 13 (Región Metropolitana).

Fuente: elaboración propia.

5.2.Panel 2004-2006-2009-2015-2020-2023

El panel 2004-2006-2009-2015-2020-2023 recibió el mismo tratamiento. Las tres sub-muestras que conforman el panel (Afiliados 2002, Nuevos Afiliados 2004, No Afiliados 2004) fueron tratadas en conjunto debido al bajo volumen de casos por clusters. La Tabla 5.5 presenta el comportamiento de la muestra y los factores de expansión longitudinales.

Tabla 5.5. Panel 2004-2006-2009-2015-2020-2023: Comportamiento de la muestra y los factores de expansión				
Tipo de Muestra	Afiliados 2002	Nuevos Afiliados 2004	No Afiliados 2004	Total
Muestra 2004				
Original (*)	12,927	940	2,860	16,727
Efectiva (**)	10,168	886	2,109	13,163
Muestra 2004 2006 2009 2015 2020 2023 (***)	2,511	159	586	3,256
Población representada originalmente	8,074,673	526,392	3,994,879	12,595,944
Factor expansión promedio original	3,215.720	3,310.642	6,817.200	3,868.533
Población representada con ajuste por Panel	8,182,118	484,720	3,932,825	12,599,663
Factor expansión promedio ajustado por Panel	3,258.510	3,048.553	6,711.305	3,869.675
Población representada post-estratificada	6,300,806	557,313	2,956,921	9,815,040
Factor expansión promedio post-estratificado	2,509.282	3,505.115	5,045.940	3,014.447
Nota: *Muestra original: corresponde a la muestra de VIVOS obtenida en la ola inicial del Panel. **Muestra efectiva: corresponde a la muestra de VIVOS obtenida en la ola inicial del Panel que también respondieron en 2023. *** Muestra 2004 2006...: corresponde a la muestra que ha respondido TODAS las encuestas incluidas en el panel.				
Fuente: elaboración propia.				

La post-estratificación empleó los totales poblacionales de la Tabla 5.6. Nótese que los tramos de edad comienzan en 37 años, ya que este panel corresponde a los que tenían como mínimo 18 años en 2004. Por lo tanto, esto muestra la consistencia en el envejecimiento del panel. Geográficamente, se estratificó por macrozonas debido a la baja densidad de la muestra de panel

en algunas regiones. De esta manera, se asegura que al menos haya 10 entrevistados/as en cada celda.

Tabla 5.6. Proyección de población de 37 años y más a Septiembre de 2023, según macrozona, sexo y grupo etario

Macrozona geográfica	Hombres				Mujeres				TOTAL
	37-50	51-65	66+	TOTAL	37-50	51-65	66+	TOTAL	Pobl.
Norte	250,487	200,210	121,183	571,880	248,075	207,048	151,611	606,734	1,178,614
Centro	587,246	574,648	405,579	1,567,473	609,350	611,903	514,338	1,735,591	3,303,064
Sur	252,686	240,362	158,566	651,614	256,276	241,272	195,482	693,030	1,344,644
R. Met.	856,431	652,470	392,755	1,901,656	819,328	711,203	556,531	2,087,062	3,988,718
Total	1,946,850	1,667,690	1,078,083	4,692,623	1,933,029	1,771,426	1,417,962	5,122,417	9,815,040

Nota: Interpolación según Sadinle (2008). Macrozonas: Norte: regiones 15, 1, 2, 3 y 4. Centro: 5, 6, 7, 16 y 8. Sur: 9, 14, 10, 11 y 12. R. Met.: 13.

Fuente: elaboración propia en base a proyecciones INE a Junio de 2023.

Los factores de ajuste por post-estratificación resultantes se muestran en la Tabla 5.7.

**Tabla 5.7. Coeficientes de ajuste de post-estratificación:
Muestra Panel 2004|2006|2009|2015|2020|2023
según macrozona, sexo y grupo etario**

Macrozona geográfica	Hombres			Mujeres		
	37-50	51-65	66+	37-50	51-65	66+
Norte	1.298742	0.802239	0.601170	1.552477	0.698058	0.534968
Centro	1.422264	0.734464	0.553756	1.268714	0.647749	0.552566
Sur	1.153180	0.845325	0.534228	1.187385	0.675693	0.476428
R. Met.	1.319602	0.847821	0.528914	1.377521	0.539486	0.517880

Nota: Macrozonas: Norte: regiones 15, 1, 2, 3 y 4. Centro: 5, 6, 7, 16 y 8. Sur: 9, 14, 10, 11 y 12. R. Met.: 13.

Fuente: elaboración propia.

5.3.Panel 2015-2020-2023

Se aplicaron los mismos procedimientos que en los paneles anteriores. La muestra y los factores de expansión longitudinales presentaron el siguiente comportamiento:

**Tabla 5.8. Panel 2015-2020-2023:
Comportamiento de la muestra y los factores de expansión**

Tipo de Muestra	Afiliados 2002	Nuevos Afiliados 2004	No Afiliados 2004	Nuevos 2015	Total
Muestra 2015					
Original (*)	14,632	918	2,554	6,778	24,882
Efectiva (**)	6,980	446	1,314	6,689	15,429
Responden 2015 2020 2023 (***)	3,195	186	648	2,105	6,134
Población representada originalmente	8,074,667	526,392	3,994,879	3,250,561	15,846,499
Factor expansión promedio original	2,527.282	2,830.065	6,164.937	1,544.210	2,583.388
Población representada con ajuste por Panel	8,111,562	516,173	3,983,281	3,234,476	15,845,492
Factor expansión promedio ajustado por Panel	2,538.830	2,775.124	6,147.039	1,536.568	2,583.223
Población representada post-estratificada	6,004,243	579,369	2,717,710	4,112,871	13,414,193
Factor expansión promedio post-estratificado	1,879.262	3,114.887	4,193.997	1,953.858	2,186.859

Nota: *Muestra original: corresponde a la muestra de VIVOS obtenida en la ola inicial del Panel. **Muestra efectiva: corresponde a la muestra de VIVOS obtenida en la ola inicial del Panel que también respondieron en 2023. *** Muestra 2004 | 2006...: corresponde a la muestra que ha respondido TODAS las encuestas incluidas en el panel.

Fuente: elaboración propia.

La post-estratificación empleó los totales poblacionales de la Tabla 5.9. Nótese que los tramos de edad comienzan en 26 años, ya que este panel corresponde a los que tenían como mínimo 18 años en 2015. Por lo tanto, esto muestra la consistencia en el envejecimiento del panel. Geográficamente, se estratificó por macrozonas para mantener la estrategia similar a los demás paneles que tienen menor cantidad de observaciones.

**Tabla 5.9. Proyección de población de 26 años y más a Septiembre de 2023,
según macrozona, sexo y grupo etario**

Macrozona geográfica	Hombres				Mujeres				TOTAL	
	26-35	36-50	51-65	66+	TOTAL	26-35	36-50	51-65	66+	TOTAL Pobl.
Norte	220,862	271,178	200,210	121,183	813,433	214,911	268,407	207,048	151,611	841,977
Centro	470,079	630,995	574,648	405,579	2,081,301	470,814	654,369	611,903	514,338	2,251,424
Sur	194,097	271,141	240,362	158,566	864,166	199,687	275,257	241,272	195,482	911,698
R. Met.	781,905	931,478	652,470	392,755	2,758,608	735,135	888,717	711,203	556,531	2,891,586
Total	1,666,943	2,104,792	1,667,690	1,078,083	6,517,508	1,620,547	2,086,750	1,771,426	1,417,962	6,896,685

Nota: Interpolación según Sadinle (2008). Macrozonas: Norte: regiones 15, 1, 2, 3 y 4. Centro: 5, 6, 7, 16 y 8. Sur: 9, 14, 10, 11 y 12. R. Met.: 13.

Fuente: elaboración propia en base a proyecciones INE a Junio de 2023.

Los factores de ajuste por post-estratificación resultantes se muestran en la Tabla 5.10.

Tabla 5.10. Coeficientes de ajuste de post-estratificación: Muestra Panel 2015 | 2020 | 2023, según macrozona, sexo y grupo etario

Macrozona geográfica	Hombres				Mujeres			
	26-35	36-50	51-65	66+	26-35	36-50	51-65	66+
Norte	1.273202	1.398853	0.772229	0.549512	1.232301	1.630035	0.643533	0.475543
Centro	1.189109	1.586003	0.798105	0.565249	1.044348	1.226892	0.623921	0.486885
Sur	1.227838	1.609583	0.926135	0.504892	1.032806	1.177976	0.645197	0.414369
R. Met.	1.550460	1.398517	0.896604	0.509525	1.247252	1.292465	0.515264	0.439000

Nota: Macrozonas: Norte: regiones 15, 1, 2, 3 y 4. Centro: 5, 6, 7, 16 y 8. Sur: 9, 14, 10, 11 y 12. R. Met.: 13.

Fuente: elaboración propia.

5.4. Ajustes adicionales a los factores de expansión

Los factores de expansión son un componente fundamental en el uso y análisis de una encuesta. La mayoría de los y las investigadores/as desarrollan sus propios factores de expansión específicos para las encuestas que analizan, ya que generalmente trabajan con porciones de la muestra que tienen sus propios factores de expansión. Estos factores de expansión se utilizan para asegurar que la muestra refleje adecuadamente la población general y permiten ajustar los datos para compensar posibles sesgos en la recolección de la información.

Uno de los principales problemas que los/as investigadores intentan solucionar es la aparición de factores de expansión con valores extremos. Es posible que estos factores sean significativamente grandes o pequeños, lo que puede distorsionar los resultados de la encuesta. Algunos/as investigadores/as prefieren "recortar" estos factores de expansión cuando presentan tamaños extremos notorios, un proceso conocido en la literatura como "*trimming*". Este proceso se realiza por varias razones: mejorar la estabilidad (reduciendo la varianza) de los estimadores, minimizar el impacto desproporcionado de ciertas observaciones (eliminando *outliers* en la cola superior de la distribución, es decir, "los más grandes"), y reconsiderar la contribución informativa de otras observaciones (eliminando *outliers* en la cola inferior de la distribución, es decir, "los más pequeños").

No obstante, uno de los problemas del *trimming* es que, al recortar los factores de expansión, se puede reducir la representatividad de la muestra. Esto sucede porque la contribución informativa de algunas observaciones se ve alterada en favor de un comportamiento más homogéneo, lo que

implica forzar una uniformidad que puede no ser representativa de la población general. En consecuencia, hay un equilibrio entre lograr una mayor estabilidad en los factores de expansión y mantener una precisión adecuada en la representatividad de la muestra respecto a la población.

Para abordar estos desafíos, se han propuesto diversas técnicas con el fin de reducir los tamaños extremos de los factores en la distribución, manteniendo al mismo tiempo un nivel aceptable de representatividad de la muestra. Entre estas técnicas se encuentran:

- *Colapsar categorías o celdas poblacionales*, lo que incluye la creación de pseudo-estratos y pseudo-clusters. Este enfoque ayuda a agrupar datos similares y reducir la varianza sin perder representatividad.
- *Fijar restricciones en los tamaños de los factores* obtenidos en procesos de ajustes poblacionales iterativos, como en el caso de la calibración iterativa en los márgenes ("*iterative proportional fitting*"). Este método asegura que los factores de expansión se mantengan dentro de un rango controlado durante múltiples iteraciones de ajuste.
- *Aplicar métodos bayesianos y de simulaciones de cadenas de Markov* (Monte Carlo Markov Chain, o MCMC). Aunque estos métodos son menos utilizados debido a su complejidad, pueden proporcionar estimaciones robustas y precisas cuando se implementan correctamente.

En cualquier caso, es fundamental proporcionar a los/as investigadores/as información suficiente, más allá de los datos propios de la encuesta, para que puedan calcular y ajustar sus propios conjuntos de factores de expansión *ad hoc*, adaptados al problema específico que están abordando. Esto les permitirá aplicar las técnicas más adecuadas y obtener resultados más precisos y representativos.

6. Estimación de varianza y errores muestrales

En esta sección, se discute el impacto del uso de muestreo complejo para encuestas y cómo esto afecta a la EPS VIII Ronda. Lo primero que se debe reconocer es que no existe encuesta (ni siquiera un censo) que no tenga problemas en la recolección de información. Por lo tanto, las encuestas requieren realizar ajustes a su representatividad y calidad de los datos y, además, deben ser capaces de representar los casos que no fueron efectivamente reportados en la encuesta.

6.1. Error de muestreo

El error de muestreo representa la imprecisión con que se mide un parámetro poblacional, θ , a partir de una muestra en vez de la población completa. Es decir, es la incertidumbre asociada al estimador $\hat{\theta}$ del parámetro poblacional. El parámetro poblacional puede ser el total de una característica en la población, medias, conteos, razones y proporciones, cuantiles de la distribución de la característica, etc. Lo importante es que, cualquiera sea el parámetro que se esté estimando, el error de muestreo se puede definir como:

$$\text{Error de muestreo} = \sqrt{V(\hat{\theta})}$$

donde $V(\cdot)$ es la varianza del estimador.

El error de muestreo depende de muchos factores. Algunos están asociados a la manera en que se **diseña el muestreo**, como, por ejemplo, el método de muestreo, el tamaño de la muestra, la naturaleza y distribución de la característica en la población, entre otros aspectos. Otros factores tienen que ver con la manera en que se **recolectan los datos**. Platek (1977) plantea que, al menos, hay tres grandes grupos de fuentes adicionales de incertidumbre:

- i. **Las personas que encuestan:** éstas se ven afectadas por las competencias, motivación, entrenamiento, carga de trabajo y método de recolección de datos.
- ii. **Las personas entrevistadas:** sufren la múltiple influencia de factores que determinan su respuesta, como la disponibilidad, el esfuerzo en responder, la motivación, y la posibilidad de ser identificado/a dentro de la encuesta (secreto estadístico).
- iii. **El contenido de la encuesta:** ésta puede implicar revelar información demográfica, económica o socioeconómica de distinta sensibilidad para el o la entrevistado/a, lo que puede generar no respuesta a la encuesta o al ítem.

Todas estas situaciones (y otras más estudiadas en la literatura²²) introducen error en los resultados y la inferencia que se pueda realizar a partir de la información de encuestas.

La complejidad que presenta la EPS en su conjunto lleva estos inconvenientes al límite:

- El diseño muestral de la EPS implica muestreo por *clusters* en dos etapas, sin reemplazos, con probabilidades desiguales de muestreo, ya que la probabilidad de ser muestreado depende no sólo del *cluster*, sino que también de la inversa de la proporción de población aportada por cada comuna a cada *cluster*, y cada *cluster* a la muestra total.
- La excepción está dada por las comunas auto-representadas que tienen probabilidad 1 de ser seleccionadas. Nótese, sin embargo, que aun en estos casos, la probabilidad de selección de cada observación depende del tamaño poblacional, que ha sido identificado como factor clave para determinar la contribución informativa a la muestra. Por lo tanto, la probabilidad de selección de cada observación es distinta dependiendo de un conjunto de factores que afectan el diseño muestral.

Desde un punto de vista técnico, si bien la obtención de los estimadores como medias, proporciones y totales puede ser algo más trivial, la situación es más dificultosa para determinar formas cerradas de la varianza (y, por ende, de los errores estándar) y la obtención de parámetros fiables para inferencia.

Sin embargo, a partir de los desarrollos de la literatura en la materia, en lo que sigue, se plantean maneras de obtener la varianza para cada una de las encuestas y estimadores habituales, con una forma cerrada basada en expansiones de Taylor (linealizaciones).^{23,24}

6.2. Errores muestrales en la EPS VIII Ronda

Como se mencionó anteriormente en la sección sobre muestreo, la selección de las personas entrevistadas corresponde a un muestreo por *clusters* en dos etapas, sin reemplazos, con probabilidades desiguales de muestreo, ya que la probabilidad de ser muestreado/a depende no sólo del *cluster*, sino que también de la inversa de la proporción de población aportada por cada comuna a cada *cluster*, y cada *cluster* a la muestra total. La excepción está dada por las comunas auto-representadas que tienen probabilidad 1 de ser seleccionadas, pero igualmente la probabilidad de selección de cada observación dentro de la comuna depende del tamaño

²² Véase Lohr (2010), capítulo 1.

²³ Las derivaciones que siguen se basan, en gran parte, en Lohr (2010). También Horvitz y Thompson (1952), Sen (1953), Yates y Grundy (1953), Särndal et al. (1992).

²⁴ En la literatura se han explorado largamente metodologías heurísticas como *bootstrap*, *jackknife*, *balanced repeated replications*, etc., que también pueden ser usadas con la EPS VIII Ronda.

poblacional, que es la clave para entender la contribución informativa de cada observación a la muestra.

Nótese que en la EPS se habla de estratos y de *clusters*, siendo los primeros las agrupaciones de comunas no-auto-representadas a partir de las cuales se elige un *cluster*. Sin embargo, dado que en cada estrato sólo se selecciona una comuna, hay una coincidencia entre lo que se denomina *cluster* y estrato. Por lo tanto, la agrupación principal es el *cluster*, en que se seleccionan las observaciones finales.

Para las comunas auto-representadas, la probabilidad de ser incluidas en la muestra es 1. Para las comunas no-auto-representadas, se forman estratos de aproximadamente 100.000 habitantes, según consta en las explicaciones del Diseño 2015. Por lo tanto, la probabilidad de que una comuna del estrato h sea incluida en la muestra es n_h/N_h , donde n_h es la población de tal comuna, y N_h es la población del estrato h . Así, cada comuna elegida en la muestra representa a N_h/n_h comunas de la población. Esto genera probabilidades distintas de selección para cada comuna, que se traducirán en probabilidades distintas de selección para cada unidad observacional.

Partiendo de esta estructura, se puede definir la probabilidad de que un individuo forme parte de la muestra: dado que la muestra es sin reemplazos, la probabilidad de que un individuo i sea elegido en primera instancia es:

$$\psi_i = \text{Pr}(\text{seleccionar la unidad } i \text{ en primera instancia})$$

La probabilidad de que un individuo k sea seleccionado en segunda instancia, por lo tanto, dependerá de la probabilidad de haber sido seleccionado en primera instancia:

$$\begin{aligned} & \text{Pr}(\text{unidad } i \text{ elegida primera, unidad } k \text{ elegida segunda}) = \\ &= \text{Pr}(\text{unidad } i \text{ elegida primera}) \text{Pr}(\text{unidad } k \text{ elegida segunda} | \text{unidad } i \text{ elegida primera}) = \\ &= \psi_i \frac{\psi_k}{1 - \psi_i} \end{aligned}$$

Nótese que, dado que no hay reemplazo, el orden de elección importa, por lo que la probabilidad de que el individuo k sea elegido primero no es igual a la probabilidad de que el individuo i sea elegido primero. De hecho, para el individuo k , la probabilidad está dada por:

$$\text{Pr}(\text{unidad } k \text{ elegida primera, unidad } i \text{ elegida segunda}) = \psi_k \frac{\psi_i}{1 - \psi_k}$$

Si sólo se debieran elegir dos unidades de la muestra, entonces la suma de estas probabilidades daría como resultado la probabilidad de que un determinado individuo i fuese parte de la muestra:

$$\Pr(\text{unidades } i \text{ y } k \text{ estén en la muestra}) = \pi_{ik} = \psi_i \frac{\psi_k}{1 - \psi_i} + \psi_k \frac{\psi_i}{1 - \psi_k}$$

En forma más general, la probabilidad de que la unidad primaria de muestreo i sea parte de la muestra es:

$$\pi_i = \sum_{\mathcal{S}: i \in \mathcal{S}} \Pr(\mathcal{S})$$

donde $\mathcal{S}$ es la muestra de n individuos tomada del universo finito $\mathcal{U} = \{1, 2, \dots, N\}$ de N individuos.

Sin embargo, dado que la muestra de la EPS 2023 se obtiene en dos etapas, se extiende este resultado de la siguiente manera: así, en la primera etapa se seleccionan *clusters*, por lo que el universo está constituido por N *clusters* tal que $i \in \mathcal{U} = \{1, 2, \dots, N\}$. A su vez, dentro de cada *cluster* se seleccionan observaciones j que corresponden a los entrevistados.

Asumiendo que y_{ij} es una característica asociada a la unidad j dentro del cluster i de la población, se desea estimar (inicialmente) el total de esta característica poblacional a través de:

$$t = \sum_{i=1}^N t_i = \sum_{i=1}^N \sum_{j=1}^{M_i} y_{ij} = \text{total poblacional}$$

donde N es el número de clusters en la población y M_i es el número de observaciones seleccionadas dentro del cluster i .

A partir de Horvitz y Thompson (1952), se puede obtener un estimador de la característica en la población total para una muestra como la de la presente encuesta. Dado que la muestra es en dos etapas, el estimador de la población en la primera etapa está dado por:

$$\hat{t}_{HT} = \sum_{i \in \mathcal{S}} \frac{t_i}{\pi_i} = \sum_{i=1}^N Z_i \frac{t_i}{\pi_i}$$

donde $Z_i = 1$ indica que el individuo i pertenece a la muestra, y 0 en otro caso. Se puede mostrar que este estimador es insesgado siguiendo el Teorema 6.2 (Lohr, 2010, pp.255) basado en Horvitz y Thompson (1952), es decir:

$$E[\hat{t}_{HT}] = \sum_{i=1}^N \pi_i \frac{t_i}{\pi_i} = t$$

La varianza de este estimador está dada por:

$$V(\hat{t}_{HT}) = \sum_{i=1}^N \frac{1 - \pi_i}{\pi_i} t_i^2 + \sum_{i=1}^N \sum_{\substack{k=1 \\ k \neq i}}^N \frac{\pi_{ik} - \pi_i \pi_k}{\pi_i \pi_k} t_i t_k = \frac{1}{2} \sum_{i=1}^N \sum_{\substack{k=1 \\ k \neq i}}^N (\pi_i \pi_k - \pi_{ik}) \left(\frac{t_i}{\pi_i} - \frac{t_k}{\pi_k} \right)^2$$

donde π_{ik} es la probabilidad conjunta de que i y j sean parte de la muestra, y se puede estimar mediante:

$$\sum_{\substack{k=1 \\ k \neq i}}^N \pi_{ik} = (n - 1) \pi_i$$

apoyado en el Teorema 6.1 en Lohr (2010, pp. 255).

Un estimador de esta varianza, sugerida por Horvitz y Thompson (1952), es:

$$\hat{V}_{HT}(\hat{t}_{HT}) = \sum_{i \in \mathcal{S}} (1 - \pi_i) \frac{t_i^2}{\pi_i^2} + \sum_{i \in \mathcal{S}} \sum_{\substack{k \in \mathcal{S} \\ k \neq i}} \frac{\pi_{ik} - \pi_i \pi_k}{\pi_i \pi_k} \frac{t_i}{\pi_i} \frac{t_k}{\pi_k}$$

Sustituyendo el estimador insesgado de la primera etapa para el *cluster* i , $\hat{t}_i$, iterativamente en el estimador de totales de Horvitz y Thompson (1952), se obtiene el estimador del total para la muestra en dos etapas:

$$\hat{t}_{HT}^{2S} = \sum_{i \in \mathcal{S}} \frac{\hat{t}_i}{\pi_i} = \sum_{i=1}^N Z_i \frac{\hat{t}_i}{\pi_i}$$

Horvitz y Thompson (1952) demostraron que este es un estimador insesgado de t así como también lo es $E[\hat{t}_i] = t_i$ para cada *cluster*.

La varianza de este estimador está dada por:

$$\begin{aligned} V(\hat{t}_{HT}^{2S}) &= \sum_{i=1}^N \frac{1 - \pi_i}{\pi_i} t_i^2 + \sum_{i=1}^N \sum_{\substack{k=1 \\ k \neq i}}^N \frac{\pi_{ik} - \pi_i \pi_k}{\pi_i \pi_k} t_i t_k + \sum_{i=1}^N \frac{V(\hat{t}_{HT})}{\pi_i} \\ &= \frac{1}{2} \sum_{i=1}^N \sum_{\substack{k=1 \\ k \neq i}}^N (\pi_i \pi_k - \pi_{ik}) \left(\frac{t_i}{\pi_i} - \frac{t_k}{\pi_k} \right)^2 + \sum_{i=1}^N \frac{V(\hat{t}_{HT})}{\pi_i} \end{aligned}$$

que es similar a la varianza de una etapa, pero incorpora incertidumbre por estimar los t_i en vez de medirlos directamente (variabilidad aportada por la *clusterización*).

El estimador de la varianza anterior es:

$$\hat{V}_{HT}(\hat{t}_{HT}^{2S}) = \sum_{i \in \mathcal{S}} (1 - \pi_i) \frac{\hat{t}_i^2}{\pi_i^2} + \sum_{i \in \mathcal{S}} \sum_{\substack{k \in \mathcal{S} \\ k \neq i}} \frac{\pi_{ik} - \pi_i \pi_k}{\pi_i \pi_k} \frac{\hat{t}_i}{\pi_i} \frac{\hat{t}_k}{\pi_k} + \sum_{i=1}^N \frac{\hat{V}_{HT}(\hat{t}_{HT})}{\pi_i}$$

Aun cuando la derivación teórica es directa, la aplicación de estos estimadores de la varianza requiere el conocimiento de la distribución conjunta de i y j para determinar

$$\pi_{ik} = \Pr(\text{clusters } i \text{ y } k \text{ están incluidos en la muestra})$$

y esto no suele ser trivial de computar. Por ello, generalmente se sugiere emplear el estimador de la varianza con reemplazo en su lugar:²⁵

$$\hat{V}_{HT,WR}(\hat{t}_{HT}^{2S}) = \frac{1}{n} \frac{1}{n-1} \sum_{i \in S} \left(\frac{n\hat{t}_i}{\pi_i} - \hat{t}_{HT} \right)^2 = \frac{n}{n-1} \sum_{i \in S} \left(\frac{\hat{t}_i}{\pi_i} - \frac{\hat{t}_{HT}}{n} \right)^2$$

Dado que, habitualmente, los analistas utilizan directamente los factores de expansión para realizar estos cálculos, podemos reescribir estos estimadores en términos de esos factores. Así, el factor de expansión de la primera etapa para el cluster i está dado por:

$$w_i = \frac{1}{\pi_i}$$

Y el estimador del total poblacional se puede reescribir como:

$$\hat{t}_{HT} = \sum_{i \in S} w_i \hat{t}_i$$

Para la segunda etapa, sin reemplazo, el factor de expansión está dado por:

$$w_{ij} = \frac{1}{\pi_{j|i}\pi_i}$$

donde

$$\pi_{j|i} = \Pr(\text{unidad } j \text{ del cluster } i \text{ está en la muestra} \mid \text{cluster } i \text{ está en la muestra}).$$

Por lo tanto, el estimador del total poblacional viene dado por:

$$\hat{t}_{HT}^{2S} = \sum_{i \in S} \sum_{j \in S_i} w_{ij} y_{ij}$$

donde $S_i \in S$ es la muestra correspondiente al cluster i . Reemplazando este estimador en el estimador de la varianza de dos etapas anterior, $\hat{V}_{HT,WR}(\hat{t}_{HT}^{2S})$, se tiene la correspondiente expresión para el mismo estimador, pero en términos de los factores de expansión.²⁶

²⁵ Esta varianza sólo depende de la Información de la primera etapa de selección, es decir, de la clusterización, por lo que el sub-muestreo al interior de cada cluster pasa a ser irrelevante.

²⁶ Los paquetes estadísticos estándar que trabajan con datos de encuestas, generalmente, tienen implementadas rutinas para resolver esta varianza a través del método de linealización con estimadores robustos (Sandwich).

Un ejemplo de comando en Stata 17 que instruye al sistema sobre las complejidades de la encuesta, es el siguiente:

```
svyset cluster_ID [pweight=factor_XS], strata(strata_ID),
singleunit(certainty)
```

El error estándar del estimador $\hat{t}_{HT}^{2S}$ es la raíz cuadrada de la varianza estimada:

$$SE(\hat{t}_{HT}^{2S}) = \sqrt{\hat{V}_{HT,WR}(\hat{t}_{HT}^{2S})}$$

6.3. Coeficiente de variación

El coeficiente de variación de un estadístico $\hat{\theta}$ está dado por la relación entre el error estándar y la media esperada del estimador:

$$CV(\hat{\theta}) = \frac{\sqrt{V(\hat{\theta})}}{E(\hat{\theta})}$$

Para los estimadores de totales poblacionales mostrados anteriormente, el coeficiente de variación está dado por:

$$CV(\hat{\theta}) = \frac{\sqrt{\hat{V}_{HT,WR}(\hat{t}_{HT}^{2S})}}{E[\hat{t}_{HT}^{2S}]}$$

6.4. Intervalos de confianza

Para los resultados obtenidos en esta sección, bajo condiciones bastante generales, se espera que los estimadores sigan asintóticamente una distribución normal estándar²⁷, es decir,

$$\frac{(\hat{\theta} - \theta)}{\sqrt{\hat{V}(\hat{\theta})}} \underset{\sim}{\text{asym.}} \mathcal{N}(0,1)$$

Por lo tanto, se puede construir un intervalo de confianza de aproximadamente 95% para el parámetro θ empleando:

$$\hat{\theta} \pm 1,96 \sqrt{\hat{V}(\hat{\theta})}$$

donde la varianza $\hat{V}(\hat{\theta})$ es alguna de las encontradas anteriormente.

donde `cluster_ID` es el indicador de cluster, `strata_ID` es el indicador de cluster, y `factor_XS` es el factor de corte transversal post-estratificado.

²⁷ Véase Binder (1983).

6.5. Efecto diseño

El efecto diseño es una medida que muestra el efecto del diseño de una encuesta sobre la varianza de un estimador (Gabler et al., 2006; Skinner, 1986). Esta es una medida importante en el diseño de las encuestas, en especial, cuando se plantea el uso de agrupaciones de muestra (estratos y clusters). Kish (1965) lo definió como:

$$deff(plan, \hat{\theta}) = \frac{\hat{V}_{plan}(\hat{\theta})}{\hat{V}_{SRS}(\hat{\theta})}$$

donde *plan* indica el plan de muestreo particular de la encuesta analizada, y *SRS* indica un plan alternativo hipotético basado en muestreo aleatorio simple. El estadístico $\hat{\theta}$ puede ser cualquiera de las medidas habituales, como media, total, proporción, ratio, cuantil, etc. Por lo tanto, esta es una medida que se debe estimar para cada variable e indicador (y subpoblación, si corresponde).

La interpretación es que si $deff > 1$, entonces el plan de muestreo genera un incremento en la incertidumbre *versus* una situación en que se habría aplicado un muestreo aleatorio simple. En el caso de los componentes de la EPS VIII Ronda, dado que incluyen clusterización y probabilidades desiguales de selección, esto impacta incrementando la varianza por encima del muestreo aleatorio simple.²⁸

El efecto diseño se puede relacionar con la inflación que sufre la varianza y los intervalos de confianza derivados de ellos cuando se aplican planes de muestreo complejo. Así, el intervalo de confianza ajustado por efecto diseño puede estimarse como:

$$\hat{\theta} \pm 1,96\sqrt{deff}\sqrt{\hat{V}(\hat{\theta})}$$

Por lo tanto, si $deff > 1$, el intervalo de confianza con el plan de muestreo complejo será más amplio (mayor imprecisión en la inferencia) que en un muestreo aleatorio simple.

Kish (1995) aproxima esta definición de $\sqrt{deff}$ con

$$deft(\hat{\theta}) = \frac{SE_{plan}(\hat{\theta})}{\frac{s}{\sqrt{n}}}$$

donde *s* es el error estándar del estimador proveniente de un muestreo aleatorio simple. Por lo tanto, *deft* puede ser usado en lugar de $\sqrt{deff}$ con similares resultados.

²⁸ Nótese que este resultado no es general. En ocasiones, estrategias de clusterización y utilización de probabilidades desiguales pueden llevar a mejorar la varianza (Lohr, 2010, capítulo 6). Sin embargo, no es un resultado habitual.

Algunos analistas suelen reportar el efecto de error de especificación del muestreo, ya que es un cálculo que suele estar disponible en los paquetes de software. Esta medida y su raíz cuadrada están dadas por:

$$meff(plan, \hat{\theta}) = \frac{\hat{V}_{plan}(\hat{\theta})}{\hat{V}(\hat{\theta})}$$

$$mefl(plan, \hat{\theta}) = \sqrt{meff}$$

donde $\hat{V}_{plan}(\hat{\theta})$ corresponde a la varianza estimada según las particularidades del plan de muestreo, y $\hat{V}(\hat{\theta})$ corresponde a una estimación *naive* de la varianza, es decir, una estimación que no tiene en cuenta factores de expansión, estratificación y/o clusterización.

Al igual que *deff* y *deft*, estas medidas son estimadas para un estadístico particular, por lo que cambian según el análisis que se realice. En la siguiente sección, se muestran algunos ejemplos para diferentes indicadores.

7. Cálculo de indicadores para la EPS VIII Ronda

A continuación, se analiza la metodología de cálculo de un conjunto de estimadores habituales que se podrían emplear con la EPS VIII Ronda. También se acompañan ejemplos de estimaciones obtenidas con la información relevada en esta ronda de la encuesta.

7.1. Obtención de indicadores de corte transversal y longitudinales

Como bien es sabido, en estadística y econometría, los métodos son bastante generales, y sus ajustes y adaptaciones, dependen de las características de los datos que se desean analizar. En ese sentido, la EPS brinda información de corte transversal y de corte longitudinal. Respecto a la información de corte transversal, ésta se encuentra contenida dentro de cada encuesta recabada en cada ronda de la EPS. Es información que representa la situación de ese momento del tiempo, y permite un análisis amplio del comportamiento poblacional contemporáneo.

La información de corte longitudinal se obtiene al combinar las encuestas obtenidas en las distintas rondas. Esta información puede ser tratada como un panel propiamente dicho al incluir sólo las observaciones que han respondido un determinado conjunto de rondas (por ejemplo, los paneles para los que se han construido factores de expansión, según se explica en la sección 5), o conjuntos de individuos de características similares que han respondido a través de las rondas (por ejemplo, pseudo-paneles con selección de observaciones por *matching*), u otras metodologías de construcción de paneles. En todos los casos, la intención es contar con un conjunto de información que describa el comportamiento de los individuos a través del tiempo.

Aún cuando la naturaleza de la información sea diferente entre el corte transversal y longitudinal, las metodologías aplicadas son similares: totales, medias y proporciones (condicionadas o no), razones o *ratios*, y cuantiles. A cada uno de ellos se le asocia un estimador de varianza (con su correspondiente error estándar e intervalo de confianza).

Los procedimientos que se detallan a continuación, por lo tanto, se pueden aplicar a los distintos tipos de información que ofrece la EPS en cada ronda, o en combinaciones de ellas. La variación se encuentra en la manera en que se tratan estos datos, incluyendo la adecuada definición de cada indicador punto, varianza y medidas asociadas correspondientes.

7.2. Enfoque práctico

Si bien las varianzas encontradas en la sección 6 tienen una forma cerrada, pueden ser computacionalmente muy intensivas de calcular. Y, en algunos casos, como se sugirió, se debe

recurrir a aproximaciones (por ejemplo, alternativas para muestras con reemplazo, para evitar la estimación de distribuciones conjuntas).

En general, los softwares disponibles para estimación de estadísticos de encuestas complejas (Stata, SAS, SPSS, SUDAAN, etc.) recurren a “atajos” que le permiten rápida y eficientemente estimar los parámetros de interés en las poblaciones. Así, estos softwares suelen utilizar una alternativa de linealización de funciones de varianza para encuestas desarrolladas por Demnati y Rao (2004), y que en sus comentarios incluye un paso-a-paso de Shah (2004), con la respectiva extensión a un conjunto de estimadores habituales en encuestas, incluyendo estadísticos y tests (pruebas de hipótesis).

La estrategia propuesta por Shah (2004) consiste en tres pasos sencillos computacionalmente:

1. Definir una variable linealizada para la observación j como:

$$z_j = \frac{\partial \hat{\theta}}{\partial w_j}$$

2. Definir el total ponderado de esta variable como

$$\hat{Z} = \sum_{j=1}^m w_j z_j$$

3. Estimar la varianza $V(\hat{Z})$ empleando el estimador de la varianza basado en el diseño muestral para el total $\hat{Z}$. Esta es una aproximación del estimador de la varianza $V(\hat{\theta})$.

De esta forma, sólo se trata de estimar funciones que están relacionadas con los totales a través de estas variables linealizadas, y se pueden emplear las varianzas linealizadas encontradas en las secciones 6.1 y 6.2 anteriores según el tipo de diseño muestral de que se trate.

Basados en esta estrategia, a continuación, se exponen los métodos de cálculo para totales, razones, medias y proporciones.²⁹

7.3. Estimador de totales

Sea Y_j una medida de interés para el individuo j de la población, donde $j = 1, \dots, M$ y M es el tamaño de la población. El total poblacional asociado a esta característica está dado por:

²⁹ La exposición se basa mayoritariamente en Eltinge y Sribney (1996), y en las secciones de métodos y formulas de los manuales del software Stata, SAS y R.

$$Y = \sum_{j=1}^M Y_j$$

Por otra parte, sea y_j la medida de interés para esa característica obtenida en la encuesta para el individuo $j = 1, \dots, m$ y m es el número de observaciones en la muestra de la encuesta. Entonces, el estimador $\hat{Y}$ del total poblacional es

$$\hat{Y} = \sum_{j=1}^m w_j y_j$$

Donde w_j son los factores de expansión con los correspondientes ajustes. Además, el estimador del número de individuos en la población es

$$\hat{M} = \sum_{j=1}^m w_j$$

La variable linealizada para el total es la variable de interés misma, obtenida en la muestra:

$$z_j(\hat{Y}) = y_j$$

Por lo tanto, para la EPS 2023, una expresión general para el estimador de totales es:

$$\hat{Y} = \sum_{i=1}^N \sum_{j=1}^{M_i} w_{ij} y_{ij}$$

Y el estimador de la varianza correspondiente está dado por:

$$\hat{V}(\hat{Y}) = \left(\frac{N}{N-1} \right) \sum_{i=1}^N (y_i - \bar{y})^2$$

donde N es el número de clusters, M_i es la cantidad de observaciones en el cluster i ,

$$y_i = \sum_{j=1}^{M_i} w_{ij} y_{ij}$$

$$\bar{y} = \frac{1}{N} \sum_{i=1}^N y_i$$

Y el estimador de la covarianza de dos variables Y y X está dado por:

$$\widehat{Cov}(\hat{Y}, \hat{X}) = \left(\frac{N}{N-1} \right) \sum_{i=1}^N (y_i - \bar{y})(x_i - \bar{x})$$

Donde x_i y $\bar{x}$ están definidas de manera similar a y_i e $\bar{y}$, respectivamente.

7.4. Estimador de razones (*ratios*)

Sean Y_j y X_j dos medidas de interés para el individuo j de la población, donde $j = 1, \dots, M$ y M es el tamaño de la población. La razón poblacional (*ratio*) asociado a estas características está dado por:

$$R = \frac{Y}{X} = \frac{\sum_{j=1}^M Y_j}{\sum_{j=1}^M X_j}$$

Por otra parte, sean y_j y x_j las medida de interés para esas características obtenidas en la encuesta para el individuo $j = 1, \dots, m$ y m es el número de observaciones en la muestra de la encuesta. Entonces, el estimador $\hat{R}$ de la razón poblacional es

$$\hat{R} = \frac{\hat{Y}}{\hat{X}}$$

Donde

$$\hat{Y} = \sum_{j=1}^m w_j y_j$$

$$\hat{X} = \sum_{j=1}^m w_j x_j$$

Donde w_j son los factores de expansión con los correspondientes ajustes.

La variable linealizada para la razón está dada por:

$$z_j(\hat{R}) = \frac{y_j - \hat{R}x_j}{\hat{X}} = \frac{\hat{X}y_j - \hat{Y}x_j}{\hat{X}^2}$$

El estimador general de la varianza para las razones (*ratios*) está dado por:

$$\hat{V}(\hat{R}) = \frac{1}{\hat{X}^2} \{ \hat{V}(\hat{Y}) - 2\hat{R}\widehat{Cov}(\hat{Y}, \hat{X}) + \hat{R}^2\hat{V}(\hat{X}) \}$$

donde $\hat{V}(\hat{Y})$, $\hat{V}(\hat{X})$ y $\widehat{Cov}(\hat{Y}, \hat{X})$ se pueden obtener para cada encuesta de la EPS 2023 utilizando los resultados introducidos en la sección 7.3 anterior.

7.5. Estimador de medias y proporciones

Los estimadores de medias y proporciones son similares. En el caso de las medias, la variable de interés toma cualquier valor (continuo o discreto). En el caso de las proporciones, la variable de interés toma valores discretos, pudiendo ser dicotómica (por ejemplo, conteniendo 0 y 1 para reflejar sexo) o politómica (conteniendo un número finito de categorías, por ejemplo, 5 tramos de nivel educativo alcanzado).

En términos de cálculo, se trata del mismo problema: todo se resuelve como si se tratase de una media. En el caso de las variables politómicas, el efecto se consigue pensando que cada categoría genera un variable dicotómica independiente que tiene 1 cada vez que se presenta la característica particular, y 0 en los demás casos.

Para obtener el estimador punto de una media procedemos de la siguiente manera: sea Y_j una medida de interés para el individuo j de la población, donde $j = 1, \dots, M$ y M es el tamaño de la población. La media poblacional asociada a esta característica está dada por:

$$\bar{Y} = \frac{Y}{M}$$

Donde Y y M fueron definidos en la sección anterior.

Por otra parte, sea y_j la medida de interés para esa característica obtenida en la encuesta para el individuo $j = 1, \dots, m$ y m es el número de observaciones en la muestra de la encuesta. Entonces, el estimador $\hat{Y}$ de la media poblacional es

$$\bar{y} = \frac{\hat{Y}}{\hat{M}}$$

Donde

$$\hat{Y} = \sum_{j=1}^m w_j y_j$$

$$\hat{M} = \sum_{j=1}^m w_j$$

Por lo tanto, la obtención de medias corresponde a la obtención de una razón en que una de las variables es un total poblacional y la otra es la estimación de la población en sí.

La variable linealizada del estimador de la media (y proporciones) es:

$$z_j(\bar{y}) = \frac{y_j - \bar{y}}{\hat{M}} = \frac{\hat{M}y_j - \hat{Y}}{\hat{M}^2}$$

El estimador general de la varianza para las medias (o proporciones) está dado por:

$$\hat{V}(\hat{R}) = \frac{1}{\hat{M}^2} \{ \hat{V}(\hat{Y}) - 2\hat{M}\widehat{Cov}(\hat{Y}, \hat{M}) + \hat{M}^2\hat{V}(\hat{M}) \}$$

donde $\hat{V}(\hat{Y})$, $\hat{V}(\hat{M})$ y $\widehat{Cov}(\hat{Y}, \hat{M})$ se pueden obtener según lo indicado en la sección 7.3 para la presente encuesta.

7.6. Estimador de cuantiles

La estimación de cuantiles sigue un esquema diferente al presentado hasta ahora.³⁰ Dado que el estimador de cuantiles depende de la muestra particular sin gozar de los beneficios de la estabilidad de la muestra aportados por ley de los grandes números y el teorema central del límite, se debe recurrir a procedimientos alternativos. La sugerencia práctica en este caso es estimar regresiones de cuantiles con estimadores de varianza que se obtienen por método de *bootstrap*. Esto implica que no hay formas cerradas del estimador de la varianza para los cuantiles.³¹

Cuando se realizan estas regresiones, típicamente se debe elegir el cuantil (por ejemplo, el cuantil 0,5 corresponde a la media). Dado que es una regresión, se debe realizar sólo en la constante para conseguir la medida del cuantil y su dispersión.³²

7.7. Ejemplos prácticos de estimación

A continuación, se presentan y comentan ejemplos de cálculo de estimadores de totales, medias, proporciones, razones y cuantiles para la encuesta de la VIII Ronda. Las estimaciones se realizaron empleando el software Stata 17 SE. La información proviene de las bases de datos de

³⁰ Véase Huang et al. (2017) para algunas aplicaciones y referencias.

³¹ Lohr (2010, capítulo 7) propone un método empírico basados en la estimación de las funciones de densidad y densidad acumulada de la variable de interés. Sin embargo, como bien señala, los resultados son, posiblemente, sesgados, especialmente para la varianza. Si, además, se suma a esto estratificación, clusterización y/o probabilidades desiguales de selección, la heterocedasticidad de los errores amentará este sesgo (Courbois and Urquhart, 2004).

³² Los procedimientos para estimar regresiones de cuantiles o inter-cuantiles son estándar en la mayoría de los software estadísticos. Algunas sugerencias de casos aplicados por tipo de software son:

- Stata: Cameron y Trivedi (2005, 2010).
- SAS: Gosset et al. (2002), Chen (2004), Rodriguez y Yao (2017), Lewis (2017).
- SUDAAN: aplicación de PROC DESCRIPT (<https://sudaanorder.rti.org/examples/DESCRIPT%20Example%202.pdf>).
- SPSS: comando QUANTILE REGRESSION (https://www.ibm.com/support/knowledgecenter/SSLVMB_sub/statistics_mainhelp_ddita/spss/regressio n/idh_quantile.html).

entrevistados/as que respondieron el cuestionario de Vivos. Los tramos educativos y la discretización de la variable que representa la densidad de cotizaciones fueron realizados previamente (véase Informe Final, sección Indicadores).

Los ejemplos incluyen el tratamiento de variables dicotómicas, politómicas, discretizadas y continuas, y dadas las características particulares de cada una de ellas, no todas las medidas son aplicables a cada una. Por lo tanto, para cada tipo de variable, se presenta el conjunto de estimadores más adecuado (por ejemplo, no se presenta la mediana de variables categóricas, de la misma forma que no se presentan proporciones de variables continuas).

7.7.1. Plan de muestreo

El primer paso en el proceso es establecer el plan de muestreo adecuado para la encuesta. En los ejemplos presentados a continuación, en particular, los factores de expansión fueron escalados a miles para reducir el tamaño de las expresiones numéricas resultantes y evitar las expresiones con notación científica. Sin embargo, este atajo obedece a necesidades de presentación y se puede evitar, volviendo a los resultados originales, empleando los factores de expansión sin ajuste por miles.

Ejemplo 7.1. Fijación del plan de muestreo

```
. * fijación de estructura de muestra y ponderaciones
. gen factor_XS_1000 = factor_XS / 1000 /* totales en miles */

.
. svyset cluster_ID [pw = factor_XS_1000], strata(strata_ID) singleunit(certainty)

Sampling weights: factor_XS_1000
                  VCE: linearized
                  Single unit: certainty
                  Strata 1: strata_ID
                  Sampling unit 1: cluster_ID
                  FPC 1: <zero>
```

7.7.2. Estimaciones para una variable dicotómica

Se eligió la variable “sexo” para hacer el ejemplo, ya que es un factor importante en la determinación del comportamiento laboral y previsional, como ha sido largamente estudiado en la literatura.

Ejemplo 7.2. Tabulación de una variable dicotómica

```
. * Tabulación de una variable dicotómica
```

```
. tab sexo, gen(sexo_)
```

Sexo	Freq.	Percent	Cum.
Hombre	7,181	45.48	45.48
Mujer	8,607	54.52	100.00
Total	15,788	100.00	

A continuación, se muestran estimaciones de totales. Dado que la codificación de la variable asigna “1” a hombres y “2” a mujeres, el resultado de totales en la primera salida es errónea, dando como total poblacional, más de 23 millones de habitantes, debido a que las mujeres se contabilizan dos veces. Por lo tanto, es importante conocer la codificación que presentan las variables para evitar reportes erróneos. Nótese también que, aunque se use la opción adecuada de separación de sub-poblaciones (empleando la variable auxiliar `aux_sexo`), no mejora el resultado debido a que los totales, en este software, se estiman empleando el valor de cada categoría.

Una solución lógica a este problema es generar sendas variables indicadoras (*dummies*) para cada categoría de la variable original. Esto se puede realizar usando el comando de generación de tabulaciones, como se ve en el ejemplo. Luego, se estima el total para cada una de esas variables indicadoras, obteniendo así los totales poblacionales correctos en la parte final del Ejemplo 7.3.

Una vez obtenidos los totales correctos, también se reporta el comportamiento del efecto diseño y del error de especificación.

Ejemplo 7.3. Totales de una variable dicotómica

```
. * Totales de una variable dicotómica
```

```
. svy: total sexo
```

```
(running total on estimation sample)
```

```
Survey: Total estimation
```

```
Number of strata = 33
```

```
Number of obs = 15,788
```

```
Number of PSUs = 113
```

```
Population size = 15,524.736
```

Design df = 80				

		Linearized		
		Total	std. err.	[95% conf. interval]
-----+-----				
sexo		23460.24	1364.666	20744.47 26176.01

Note: Strata with single sampling unit treated as certainty units.				
.				
. gen aux_sexo=sexo				
. svy: total sexo, over(aux_sexo)				
(running total on estimation sample)				
Survey: Total estimation				
Number of strata =	33	Number of obs =	15,788	
Number of PSUs =	113	Population size =	15,524.736	
		Design df =	80	

		Linearized		
		Total	std. err.	[95% conf. interval]
-----+-----				
c.sexo@aux_sexo				
1		7589.232	487.8233	6618.433 8560.031
2		15871.01	888.8298	14102.18 17639.84

Note: Strata with single sampling unit treated as certainty units.				
.				
. tab sexo, gen(sexo_)				
Sexo		Freq.	Percent	Cum.
-----+-----				
Hombre		7,181	45.48	45.48
Mujer		8,607	54.52	100.00
-----+-----				
Total		15,788	100.00	
.				
. svy: total sexo_*				
(running total on estimation sample)				
Survey: Total estimation				
Number of strata =	33	Number of obs =	15,788	
Number of PSUs =	113	Population size =	15,524.736	
		Design df =	80	

		Linearized					
		Total	std. err.	[95% conf. interval]			
-----+-----							
sexo_1		7589.232	487.8233	6618.433	8560.031		
sexo_2		7935.504	444.4149	7051.09	8819.918		

Note: Strata with single sampling unit treated as certainty units.							
. estat effects, deff deft meff meft							

		Linearized					
		Total	std. err.	DEFF	DEFT	MEFF	MEFT
-----+-----							
sexo_1		7589.232	487.8233	62.381	7.89816	62.8628	7.92861
sexo_2		7935.504	444.4149	51.7731	7.19536	52.173	7.22309

Note: Strata with single sampling unit treated as certainty units.							

En lo que sigue, se muestran estimaciones de proporciones y medias. Como ya fuera mencionado, estos indicadores son equivalentes, aunque difieren en la manera en que tratan la información categórica. Mientras la media intenta promediar todos los valores de las variables, la proporción reconoce los distintos valores (categorías) de la variable y estima una media para esa categoría asumiendo que el resto de las observaciones no la poseen. Por lo tanto, y tal como se muestra en las estimaciones, se puede obtener el mismo resultado de la estimación de proporciones si es que se generan dummies para cada categoría de la variable de interés y se estima, para cada una de ellas, la media correspondiente. Vale la pena notar que los resultados son idénticos en los dos casos.

En los resultados siguientes, se debe tener en cuenta la codificación de la variable sexo nuevamente: cuando se estima la media, ésta arroja un resultado superior a 1, ya que los dos valores posibles en la codificación de la variable sexo son 1 y 2. Por lo tanto, para interpretar los resultados como en las proporciones, se debe restar 1 a la media obtenida. Nuevamente, es muy importante conocer la codificación de la variable y el efecto de esta en las estimaciones.

Ejemplo 7.4. Proporciones y medias de una variable dicotómica

. * Proporciones de una variable dicotómica

. svy: proportion sexo

(running proportion on estimation sample)

Survey: Proportion estimation

```

Number of strata = 33      Number of obs   =    15,788
Number of PSUs   = 113    Population size = 15,524.736
                        Design df      =         80

```

		Linearized	Logit
	Proportion	std. err.	[95% conf. interval]
sexo			
Hombre	.4888477	.0046163	.4796658 .4980372
Mujer	.5111523	.0046163	.5019628 .5203342

Note: Strata with single sampling unit treated as certainty units.

```
. estat effects, deff deff meff meff
```

		Linearized				
	Proportion	std. err.	DEFF	DEFT	MEFF	MEFT
sexo						
Hombre	.4888477	.0046163	1.34637	1.16033	1.35677	1.1648
Mujer	.5111523	.0046163	1.34637	1.16033	1.35677	1.1648

Note: Strata with single sampling unit treated as certainty units.

```
.
. svy: proportion sexo_*
(running proportion on estimation sample)
```

Survey: Proportion estimation

```

Number of strata = 33      Number of obs   =    15,788
Number of PSUs   = 113    Population size = 15,524.736
                        Design df      =         80

```

		Linearized	Logit
	Proportion	std. err.	[95% conf. interval]
sexo_1			
0	.5111523	.0046163	.5019628 .5203342
1	.4888477	.0046163	.4796658 .4980372
sexo_2			
0	.4888477	.0046163	.4796658 .4980372
1	.5111523	.0046163	.5019628 .5203342

Note: Strata with single sampling unit treated as certainty units.

```
. estat effects, deff deff meff meff
```

		Linearized				
	Proportion	std. err.	DEFF	DEFT	MEFF	MEFT
sexo_1						
0	.5111523	.0046163	1.34637	1.16033	1.35677	1.1648
1	.4888477	.0046163	1.34637	1.16033	1.35677	1.1648
sexo_2						
0	.4888477	.0046163	1.34637	1.16033	1.35677	1.1648
1	.5111523	.0046163	1.34637	1.16033	1.35677	1.1648

Note: Strata with single sampling unit treated as certainty units.

.

*** Medias de una variable dicotómica**

. svy: mean sexo
(running mean on estimation sample)

Survey: Mean estimation

Number of strata = 33 Number of obs = 15,788
 Number of PSUs = 113 Population size = 15,524.736
 Design df = 80

	Linearized		
Mean	std. err.	[95% conf. interval]	
sexo	1.511152	.0046163	1.501966 1.520339

Note: Strata with single sampling unit treated as certainty units.

. estat effects, deff deft meff meft

	Linearized				
Mean	std. err.	DEFF	DEFT	MEFF	MEFT
sexo	1.511152	.0046163	1.34637	1.16033	1.35677 1.1648

Note: Strata with single sampling unit treated as certainty units.

.

. svy: mean sexo_*
(running mean on estimation sample)

Survey: Mean estimation

Number of strata = 33 Number of obs = 15,788
 Number of PSUs = 113 Population size = 15,524.736
 Design df = 80

		Linearized		
		Mean	std. err.	[95% conf. interval]

sexo_1		.4888477	.0046163	.479661 .4980345
sexo_2		.5111523	.0046163	.5019655 .520339

Note: Strata with single sampling unit treated as certainty units.				

. estat effects, deff deff meff meff

		Linearized				
		Mean	std. err.	DEFF	DEFT	MEFF MEFT

sexo_1		.4888477	.0046163	1.34637	1.16033	1.35677 1.1648
sexo_2		.5111523	.0046163	1.34637	1.16033	1.35677 1.1648

Note: Strata with single sampling unit treated as certainty units.						

7.7.3. Estimaciones para una variable política

Se eligió la variable “máximo nivel educativo alcanzado” para hacer el ejemplo, ya que es un factor importante en la determinación del comportamiento laboral y previsional, especialmente, en la explicación de la trayectoria de salarios a lo largo del ciclo de vida y en la determinación de la informalidad laboral.

La variable posee 5 categorías, como se ve a continuación, y se le aplican los mismos comentarios que a la variable “sexo”. Se debe tener precaución en el uso de medias y proporciones, especialmente si no se ha tratado adecuadamente el uso de los valores de codificación de las categorías. Para mostrar este problema, se presentan estimaciones que usan directamente la variable política, y otras en que se utilizan *dummies* para calcular adecuadamente los indicadores. Nótese también el sesgo que se produce en la medición cuando se utiliza la variable en forma directa, sin *dummies*, debido a que la categoría “Ninguno” tiene codificación “0”, por lo que todas las ponderaciones de la población con esa categoría, no se contabiliza en las sumatorias de “total t_educ” y “total t_educ, over(aux_t_educ)”.

Ejemplo 7.5. Estadísticos de una variable política

```
. * Tabulación de una variable política
. tab t_educ, gen(t_educ_)
```

Máximo nivel educacional alcanzado	Freq.	Percent	Cum.
Ninguno	180	1.14	1.14
Básica	2,371	15.02	16.16
Media	7,251	45.93	62.09
Técnica Superior	2,413	15.28	77.37
Universitaria	3,573	22.63	100.00
Total	15,788	100.00	

.

. * **Totales de una variable politómica**. **svy: total t_educ**

(running total on estimation sample)

Survey: Total estimation

Number of strata =	33	Number of obs =	15,788
Number of PSUs =	113	Population size =	15,524.736
		Design df =	80

	Total	Linearized std. err.	[95% conf. interval]
t_educ	37657.08	2418.169	32844.77 42469.39

Note: Strata with single sampling unit treated as certainty units.

.

. **gen aux_t_educ = t_educ**. **svy: total t_educ, over(aux_t_educ)**

(running total on estimation sample)

Survey: Total estimation

Number of strata =	33	Number of obs =	15,788
Number of PSUs =	113	Population size =	15,524.736
		Design df =	80

	Total	Linearized std. err.	[95% conf. interval]
c.t_educ@aux_t_educ			
0	0	(omitted)	
1	2399.626	124.1132	2152.633 2646.619
2	14070.11	863.8935	12350.91 15789.31

```

3 | 6926.08 495.3826 5940.237 7911.923
4 | 14261.27 1235.563 11802.42 16720.11

```

Note: Strata with single sampling unit treated as certainty units.

```

.
. svy: total t_educ_*
(running total on estimation sample)

```

Survey: Total estimation

```

Number of strata = 33          Number of obs   =    15,788
Number of PSUs   = 113        Population size = 15,524.736
                                Design df          =         80

```

```

-----
              |              Linearized
              |              Total   std. err.   [95% conf. interval]
-----+-----
t_educ_1 | 216.0446  38.25867   139.9074   292.1818
t_educ_2 | 2399.626  124.1132   2152.633   2646.619
t_educ_3 | 7035.056  431.9468   6175.454   7894.657
t_educ_4 | 2308.693  165.1275   1980.079   2637.308
t_educ_5 | 3565.317  308.8908   2950.604   4180.029
-----

```

Note: Strata with single sampling unit treated as certainty units.

```

. estat effects, deff deff meff meff

```

```

-----
              |              Linearized
              |              Total   std. err.   DEFF   DEFT   MEFF   MEFT
-----+-----
t_educ_1 | 216.0446  38.25867   6.98679   2.64325   8.50639   2.91657
t_educ_2 | 2399.626  124.1132   7.72128   2.77872   7.90596   2.81175
t_educ_3 | 7035.056  431.9468   49.3175   7.02264   49.2111   7.01506
t_educ_4 | 2308.693  165.1275   14.1082   3.75609   13.7941   3.71404
t_educ_5 | 3565.317  308.8908   35.3266   5.94361   35.6935   5.9744
-----

```

Note: Strata with single sampling unit treated as certainty units.

```

.
. * Proporciones de una variable politómica

```

```

. svy: proportion t_educ
(running proportion on estimation sample)

```

Survey: Proportion estimation

```

Number of strata = 33          Number of obs   =    15,788
Number of PSUs   = 113        Population size = 15,524.736
                                Design df          =         80

```

		Linearized	Logit
	Proportion	std. err.	[95% conf. interval]
t_educ			
Ninguno	.0139162	.0023584	.0099251 .0194806
Básica	.1545679	.0048232	.1452111 .1644116
Media	.4531514	.0105935	.4321659 .4743048
Técnica Superior	.1487106	.005279	.1385084 .1595252
Universitaria	.2296539	.0109266	.2086341 .2521168

Note: Strata with single sampling unit treated as certainty units.

. estat effects, deff deff meff meff

		Linearized				
	Proportion	std. err.	DEFF	DEFT	MEFF	MEFT
t_educ						
Ninguno	.0139162	.0023584	6.39909	2.52964	7.79087	2.79121
Básica	.1545679	.0048232	2.81039	1.67642	2.8776	1.69635
Media	.4531514	.0105935	7.14943	2.67384	7.134	2.67095
Técnica S..	.1487106	.005279	3.47523	1.8642	3.39787	1.84333
Universit~a	.2296539	.0109266	10.654	3.26405	10.7647	3.28096

Note: Strata with single sampling unit treated as certainty units.

. * Medias de una variable politómica

. svy: mean t_educ_*

(running mean on estimation sample)

Survey: Mean estimation

Number of strata = 33 Number of obs = 15,788
 Number of PSUs = 113 Population size = 15,524.736
 Design df = 80

		Linearized	
	Mean	std. err.	[95% conf. interval]
t_educ_1	.0139162	.0023584	.0092227 .0186096
t_educ_2	.1545679	.0048232	.1449695 .1641663
t_educ_3	.4531514	.0105935	.4320696 .4742332
t_educ_4	.1487106	.005279	.1382051 .1592162
t_educ_5	.2296539	.0109266	.2079092 .2513986

Note: Strata with single sampling unit treated as certainty units.

. estat effects, deff deff meff meff

		Linearized					
		Mean	std. err.	DEFF	DEFT	MEFF	MEFT
t_educ_1		.0139162	.0023584	6.39909	2.52964	7.79087	2.79121
t_educ_2		.1545679	.0048232	2.81039	1.67642	2.8776	1.69635
t_educ_3		.4531514	.0105935	7.14943	2.67384	7.134	2.67095
t_educ_4		.1487106	.005279	3.47523	1.8642	3.39787	1.84333
t_educ_5		.2296539	.0109266	10.654	3.26405	10.7647	3.28096

Note: Strata with single sampling unit treated as certainty units.

7.7.4. Estimaciones para una variable continua discretizada

Se eligió la variable “densidad de cotizaciones en el periodo Enero 2016 – Septiembre 2023” para hacer el ejemplo, ya que es uno de los aspectos importantes que recolecta la encuesta acerca del comportamiento previsional. Esta es un variable continua, con rango [0,1] que ha sido discretizada para su análisis. La discretización la convierte en una variable politómica de 7 categorías, en que las categorías extremas acumulan la mayor parte de las respuestas.

Dado que se trata, en definitiva, de una variable categórica, se le aplican los mismos comentarios y advertencias que a la variable dicotómica y politómica.

Ejemplo 7.6. Estadísticos de una variable continua discretizada				
. * Tabulación de una variable continua discretizada				
. tab den_cotiz, gen(den_cotiz_)				
Densidad de				
cotizaciones	Freq.	Percent	Cum.	
den = 0%	4,436	46.11	46.11	
0% < den < 20%	565	5.87	51.98	
20% <= den < 40%	479	4.98	56.96	
40% <= den < 60%	414	4.30	61.26	
60% <= den < 80%	279	2.90	64.16	
80% <= den < 100%	354	3.68	67.84	
den = 100%	3,094	32.16	100.00	
Total	9,621	100.00		
. * Totales de una variable continua discretizada				
. svy: total den_cotiz				

```
(running total on estimation sample)
```

```
Survey: Total estimation
```

```
Number of strata = 33          Number of obs   =      9,621
Number of PSUs   = 113        Population size = 10,499.368
                                Design df           =      80
```

```
-----
              |              Linearized
              |      Total   std. err.   [95% conf. interval]
-----+-----
den_cotiz |      41445.2   2716.832    36038.54    46851.87
-----
```

```
Note: Strata with single sampling unit treated as certainty
      units.
```

```
. estat effects, deff deff meff meff
```

```
-----
              |              Linearized
              |      Total   std. err.   DEFF      DEFT      MEFF      MEFT
-----+-----
den_cotiz |      41445.2   2716.832    84.0367    9.16715    88.5837    9.41189
-----
```

```
Note: Strata with single sampling unit treated as certainty units.
```

```
.
```

```
. gen aux_den_cotiz=den_cotiz
```

```
(6,167 missing values generated)
```

```
. svy: total den_cotiz,over(aux_den_cotiz)
```

```
(running total on estimation sample)
```

```
Survey: Total estimation
```

```
Number of strata = 33          Number of obs   =      9,621
Number of PSUs   = 113        Population size = 10,499.368
                                Design df           =      80
```

```
-----
              |              Linearized
              |      Total   std. err.   [95% conf. interval]
-----+-----
c.den_cotiz@aux_den_cotiz |
1 |      4338.931   263.2568    3815.034    4862.829
2 |      829.6001   67.18929    695.8891    963.311
3 |     1189.204    105.7573    978.7399    1399.667
4 |      1606.05    154.2326    1299.117    1912.982
5 |     1582.863    157.004    1270.416    1895.311
6 |     3116.983    308.0976    2503.849    3730.117
7 |     28781.57    1971.494    24858.17    32704.97
-----
```

```
Note: Strata with single sampling unit treated as certainty units.
```

```
. estat effects, deff deff meff meff
```

		Linearized					
Over		Total	std. err.	DEFF	DEFT	MEFF	MEFT

c.den_cotiz@							
aux_den_co~z							
1		4338.931	263.2568	24.9425	4.99425	0	0
2		829.6001	67.18929	2.59549	1.61105	0	0
3		1189.204	105.7573	2.98517	1.72777	0	0
4		1606.05	154.2326	3.5276	1.87819	0	0
5		1582.863	157.004	2.9425	1.71537	0	0
6		3116.983	308.0976	4.89262	2.21193	0	0
7		28781.57	1971.494	29.0541	5.39019	0	0

Note: Strata with single sampling unit treated as certainty units.

```
.
. svy: total den_cotiz_*
(running total on estimation sample)
```

Survey: Total estimation

```
Number of strata = 33          Number of obs  =      9,621
Number of PSUs   = 113          Population size = 10,499.368
                                Design df      =      80
```

		Linearized			
		Total	std. err.	[95% conf. interval]	
den_cotiz_1		4338.931	263.2568	3815.034	4862.829
den_cotiz_2		414.8	33.59464	347.9446	481.6555
den_cotiz_3		396.4012	35.25244	326.2466	466.5558
den_cotiz_4		401.5124	38.55815	324.7792	478.2456
den_cotiz_5		316.5727	31.4008	254.0831	379.0623
den_cotiz_6		519.4972	51.34961	417.3082	621.6862
den_cotiz_7		4111.653	281.6421	3551.168	4672.139

Note: Strata with single sampling unit treated as certainty units.

```
. estat effects, deff deff meff meff
```

		Linearized					
		Total	std. err.	DEFF	DEFT	MEFF	MEFT

den_cotiz_1		4338.931	263.2568	24.9425	4.99425	24.3393	4.93349
den_cotiz_2		414.8	33.59464	2.59549	1.61105	1.78174	1.33482
den_cotiz_3		396.4012	35.25244	2.98517	1.72777	2.2924	1.51407
den_cotiz_4		401.5124	38.55815	3.5276	1.87819	3.15067	1.77501

```
den_cotiz_5 | 316.5727 31.4008 2.9425 1.71537 3.05581 1.74809
den_cotiz_6 | 519.4972 51.34961 4.89262 2.21193 6.49264 2.54806
den_cotiz_7 | 4111.653 281.6421 29.0541 5.39019 31.7286 5.63281
```

Note: Strata with single sampling unit treated as certainty units.

```
.
. * Proporciones de variable continua discretizada
```

```
. svy: proportion den_cotiz
```

```
(running proportion on estimation sample)
```

Survey: Proportion estimation

```
Number of strata = 33          Number of obs = 9,621
Number of PSUs   = 113       Population size = 10,499.368
                               Design df      = 80
```

```
-----+-----
              |          Linearized          Logit
              | Proportion  std. err.      [95% conf. interval]
-----+-----
den_cotiz |
den = 0%  | .4132564 .0067953 .3998019 .4268418
0% < den < 20% | .0395071 .0025929 .0346583 .0450028
20% <= den < 40% | .0377548 .0021688 .033668 .0423159
40% <= den < 60% | .0382416 .0025521 .0334743 .0436571
60% <= den < 80% | .0301516 .0022228 .0260289 .0349039
80% <= den < 100% | .0494789 .0032428 .0434101 .0563461
den = 100% | .3916096 .0091273 .3736033 .4099158
-----+-----
```

Note: Strata with single sampling unit treated as certainty units.

```
. estat effects, deff deft meff meft
```

```
-----+-----
              |          Linearized          DEFF          DEFT          MEFF          MEFT
              | Proportion  std. err.
-----+-----
den_cotiz |
den = 0%  | .4132564 .0067953 1.83201 1.35352 1.7877 1.33705
0% < den .. | .0395071 .0025929 1.70438 1.30552 1.17002 1.08167
20% <= de.. | .0377548 .0021688 1.24551 1.11603 .956467 .977991
40% <= de.. | .0382416 .0025521 1.70357 1.30521 1.52154 1.23351
60% <= de.. | .0301516 .0022228 1.62544 1.27493 1.68804 1.29925
80% <= de.. | .0494789 .0032428 2.15103 1.46664 2.85448 1.68952
den = 100% | .3916096 .0091273 3.36373 1.83405 3.67336 1.9166
-----+-----
```

Note: Strata with single sampling unit treated as certainty units.

```
.
. * Medias de variable continua discretizada
```

```
. svy: mean den_cotiz_*
```

```
(running mean on estimation sample)
```

```
Survey: Mean estimation
```

```
Number of strata = 33          Number of obs   =      9,621
Number of PSUs   = 113        Population size = 10,499.368
                                Design df           =      80
```

		Linearized		
		Mean	std. err.	[95% conf. interval]
den_cotiz_1		.4132564	.0067953	.3997333 .4267795
den_cotiz_2		.0395071	.0025929	.0343472 .0446671
den_cotiz_3		.0377548	.0021688	.0334388 .0420708
den_cotiz_4		.0382416	.0025521	.0331628 .0433204
den_cotiz_5		.0301516	.0022228	.025728 .0345752
den_cotiz_6		.0494789	.0032428	.0430254 .0559324
den_cotiz_7		.3916096	.0091273	.3734458 .4097734

Note: Strata with single sampling unit treated as certainty units.

```
. estat effects, deff deft meff meft
```

		Linearized				
		Mean	std. err.	DEFF	DEFT	MEFF
den_cotiz_1		.4132564	.0067953	1.83201	1.35352	1.7877
den_cotiz_2		.0395071	.0025929	1.70438	1.30552	1.17002
den_cotiz_3		.0377548	.0021688	1.24551	1.11603	.956467
den_cotiz_4		.0382416	.0025521	1.70357	1.30521	1.52154
den_cotiz_5		.0301516	.0022228	1.62544	1.27493	1.68804
den_cotiz_6		.0494789	.0032428	2.15103	1.46664	2.85448
den_cotiz_7		.3916096	.0091273	3.36373	1.83405	3.67336

Note: Strata with single sampling unit treated as certainty units.

7.7.5. Estimaciones para una variable continua

Se eligió la variable “salario promedio mensual ponderado” para hacer el ejemplo, ya que es uno de los aspectos importantes que recolecta la encuesta acerca del comportamiento laboral. Esta es un variable continua que se construye tomando los salarios declarados durante los 12 meses anteriores a la encuesta, y se los pondera dependiendo de si la persona estaba o no trabajando. Así, si una persona se encontraba trabajando en un mes determinado, se toma ese salario para el mes. Si, por el contrario, la persona no estaba trabajando en ese mes, se le quita 1/12 a la ponderación de salarios, de tal manera que el promedio refleje adecuadamente el salario promedio mensual de los momentos en que estuvo trabajando.

En primera instancia, se presentan los resultados para medias salariales para toda la población sin ajuste por plan de muestreo. La media sin ponderar llega a \$458 mil aproximadamente, con un error estándar de \$395 mil.

Al aplicar el plan de muestreo a las estimaciones, se observa que el salario promedio mensual es de aproximadamente \$509 mil para toda la población. También se presentan los salarios promedio por sexo, donde se nota la diferencia entre el salario percibido por hombres y mujeres.

Ejemplo 7.7. Estadísticos de una variable continua

. * Descripción de una variable continua

. sum salario_prom

Variable	Obs	Mean	Std. dev.	Min	Max
-----+-----					
salario_prom	7,748	676506.3	946578.4	0	3.70e+07

. * Medias de una variable continua

. svy: mean salario_prom

(running mean on estimation sample)

Survey: Mean estimation

Number of strata =	33	Number of obs =	7,748
Number of PSUs =	112	Population size =	8,639.3565
		Design df =	79

	Linearized		
	Mean	std. err.	[95% conf. interval]
-----+-----			
salario_prom	778312.6	33776.48	711082.2 845543

Note: Strata with single sampling unit treated as certainty units.

. estat effects, deff deff meff meff

	Linearized					
	Mean	std. err.	DEFF	DEFT	MEFF	MEFT
-----+-----						
salario_prom	778312.6	33776.48	5.72157	2.39198	9.86519	3.14089

Note: Strata with single sampling unit treated as certainty units.

```
.
. svy: mean salario_prom, over(sexo)
(running mean on estimation sample)

Survey: Mean estimation

Number of strata = 33          Number of obs   =      7,748
Number of PSUs   = 112        Population size = 8,639.3565
                                Design df         =      79

-----+-----
                |               Linearized
                |               Mean   std. err.   [95% conf. interval]
-----+-----
c.salario_prom@sexo |
    Hombre |      868189    48191.9    772265.4    964112.6
    Mujer  |     661131.5   19646.32   622026.5    700236.6
-----+-----

Note: Strata with single sampling unit treated as certainty units.

. estat effects, deff deff meff meff

-----+-----
                |               Linearized
                |               Mean   std. err.   DEFF    DEFT    MEFF    MEFT
-----+-----
c. |
salario_prom@ |
    sexo |
    Hombre |      868189    48191.9    4.68974    2.16558    8.06656    2.84017
    Mujer  |     661131.5   19646.32    1.84461    1.35816    2.41039    1.55254
-----+-----

Note: Strata with single sampling unit treated as certainty units.
```

A continuación, se muestran los resultados para la estimación de razones. La razón (*ratio*) elegido fue el ingreso salarial promedio por miembro del hogar, que es usado en muchos estudios como una aproximación al gasto individual promedio. Esto nos permite ilustrar el uso de *ratios* entre una variable continua y una variable de conteo.

Las razones se presentan para la población y desagregadas por sexo, nivel educativo, y ambos a la vez, para mostrar alternativas de estimación por sub-poblaciones. Los mismos recaudos que se hicieron anteriormente respecto al uso de variables categóricas, aplican aquí para la determinación de las sub-poblaciones.

Ejemplo 7.8. Obtención de razones

```
. * Razones: salario promedio por miembro del hogar
```

```
.
```

```
. svy: ratio salario_prom/t_hogar
```

```
(running ratio on estimation sample)
```

```
Number of strata = 33          Number of obs   =      7,748
Number of PSUs   = 112        Population size = 8,639.3565
                                Design df        =      79
```

```
_ratio_1: salario_prom/t_hogar
```

```
-----
              |              Linearized
              |      Ratio   std. err.   [95% conf. interval]
-----+-----
_ratio_1 |    299186.7   13505.45    272304.7    326068.6
-----
```

Note: Strata with single sampling unit treated as certainty units.

```
. estat effects, deff deff meff meff
```

```
_ratio_1: salario_prom/t_hogar
```

```
-----
              |              Linearized
              |      Ratio   std. err.   DEFF    DEFT    MEFF    MEFT
-----+-----
_ratio_1 |    299186.7   13505.45    5.73723    2.39525    10.2571    3.20267
-----
```

Note: Strata with single sampling unit treated as certainty units.

```
.
```

```
. svy: ratio salario_prom/t_hogar, over(sexo)
```

```
(running ratio on estimation sample)
```

Survey: Ratio estimation

```
Number of strata = 33          Number of obs   =      7,748
Number of PSUs   = 112        Population size = 8,639.3565
                                Design df        =      79
```

```
_ratio_1: salario_prom/t_hogar
```

```
-----
              |              Linearized
              |      Ratio   std. err.   [95% conf. interval]
-----+-----
c._ratio_1@sexo |
  Hombre |    341458.8   19355.67    302932.3    379985.3
  Mujer  |    246861.8    7890.14    231156.9    262566.7
-----
```

Note: Strata with single sampling unit treated as certainty

units.

```
. estat effects, deff deft meff meft
```

```
_ratio_1: salario_prom/t_hogar
```

	Over	Ratio	Linearized std. err.	DEFF	DEFT	MEFF	MEFT
c._ratio_1@							
sexo							
Hombre		341458.8	19355.67	4.57142	2.13809	8.16155	2.85684
Mujer		246861.8	7890.14	1.90793	1.38128	2.62182	1.6192

Note: Strata with single sampling unit treated as certainty units.

```
.
. svy: ratio salario_prom/t_hogar, over(t_educ)
(running ratio on estimation sample)
```

Survey: Ratio estimation

Number of strata =	33	Number of obs =	7,748
Number of PSUs =	112	Population size =	8,639.3565
		Design df =	79

```
_ratio_1: salario_prom/t_hogar
```

		Ratio	Linearized std. err.	[95% conf. interval]	
c._ratio_1@	t_educ				
Ninguno		177578.2	42089.17	93801.83	261354.6
Básica		160618.4	5677.411	149317.8	171919
Media		220998	4366.098	212307.5	229688.5
Técnica Superior		280696.3	12592.6	255631.4	305761.3
Universitaria		519178.4	48343.79	422952.5	615404.3

Note: Strata with single sampling unit treated as certainty units.

```
. estat effects, deff deft meff meft
```

```
_ratio_1: salario_prom/t_hogar
```

	Over	Ratio	Linearized std. err.	DEFF	DEFT	MEFF	MEFT
c._ratio_1@							
t_educ							
Ninguno		177578.2	42089.17	.780969	.883724	.840206	.916628
Básica		160618.4	5677.411	1.89527	1.37669	2.19497	1.48154

Media	220998	4366.098	1.40638	1.18591	1.4453	1.20221
Técnica S..	280696.3	12592.6	1.54109	1.2414	1.51662	1.23151
Universit~a	519178.4	48343.79	6.00003	2.4495	10.651	3.26359

Note: Strata with single sampling unit treated as certainty units.

```
.
. svy: ratio salario_prom/t_hogar, over(sexo t_educ)
(running ratio on estimation sample)
```

Survey: Ratio estimation

Number of strata =	33	Number of obs =	7,748
Number of PSUs =	112	Population size =	8,639.3565
		Design df =	79

_ratio_1: salario_prom/t_hogar

		Linearized		
		Ratio	std. err.	[95% conf. interval]
c._ratio_1@sexo#t_educ				
Hombre#Ninguno		223515.6	79228.56	65815.04 381216.1
Hombre#Básica		176249.5	6829.278	162656.2 189842.9
Hombre#Media		258327.7	6067.38	246250.9 270404.5
Hombre#Técnica Superior		333026.8	18744.64	295716.5 370337.1
Hombre#Universitaria		615976.1	76058.62	464585.2 767367
Mujer#Ninguno		133553.3	17831.33	98060.88 169045.6
Mujer#Básica		130267.6	7970.776	114402.2 146133
Mujer#Media		169412.9	4865.909	159727.5 179098.2
Mujer#Técnica Superior		231575.2	13673.06	204359.7 258790.8
Mujer#Universitaria		418453.7	22059.41	374545.6 462361.9

Note: Strata with single sampling unit treated as certainty units.

```
. estat effects, deff deft meff meft
```

_ratio_1: salario_prom/t_hogar

		Linearized				
	Over	Ratio	std. err.	DEFF	DEFT	MEFF MEFT
c._ratio_1@						
sexo#t_educ						
Hombre #						
Ninguno		223515.6	79228.56	.737744	.85892	.574963 .758263
Hombre #						
Básica		176249.5	6829.278	1.618	1.27201	1.8068 1.34417
Hombre #						
Media		258327.7	6067.38	1.35245	1.16295	1.49429 1.22241
Hombre #						
Técnica S..		333026.8	18744.64	1.53035	1.23707	1.19001 1.09088

Hombre #						
Universit~a	615976.1	76058.62	4.57666	2.13931	6.89554	2.62594
Mujer #						
Ninguno	133553.3	17831.33	.832211	.912256	1.03663	1.01815
Mujer #						
Básica	130267.6	7970.776	1.85053	1.36034	2.2304	1.49345
Mujer#Media	169412.9	4865.909	1.04013	1.01987	.868904	.93215
Mujer #						
Técnica S..	231575.2	13673.06	1.04636	1.02292	1.22568	1.1071
Mujer #						
Universit~a	418453.7	22059.41	2.03214	1.42553	3.05928	1.74908

Note: Strata with single sampling unit treated as certainty units.						

Finalmente, se presentan ejemplos de estimaciones de medianas para el salario promedio ponderado. Si bien es posible estimar cualquiera de los cuantiles, los ejemplos usan el cuantil más habitualmente empleado. Las regresiones se realizan solamente empleando la constante como argumento, de tal forma que el coeficiente que acompaña a la constante corresponde al cuantil estimado. El error estándar y el intervalo de confianza de la constante son los correspondientes al cuantil estimado.

Existen dos particularidades del uso de Stata en la estimación de cuantiles. En primer lugar, en el uso del comando `qreg` (regresión de cuantiles), contrario al caso de los anteriores, se debe especificar el ponderador (*probability weights*) para que el software lo tome en cuenta al momento de realizar las estimaciones y refleje el diseño complejo de la encuesta.

En segundo lugar, si se desea estimar cuantiles para sub-poblaciones, es necesario estimar el cuantil para cada sub-población de manera independiente, condicionando como se muestra en el ejemplo para la variable “sexo” en la salida a continuación.

Ejemplo 7.9. Obtención de cuantiles de una variable continua

```
. * Cuantiles: mediana
. qreg salario_prom [pw = factor_XS_1000],q(0.5)

Iteration 1:  WLS sum of weighted deviations =  1.905e+09

Iteration 1:  Sum of abs. weighted deviations =  1.904e+09
Iteration 2:  Sum of abs. weighted deviations =  1.759e+09

Median regression                                Number of obs =      7,748
  Raw sum of deviations 1.76e+09 (about 550000)      Pseudo R2      =      0.0000
  Min sum of deviations 1.76e+09
```

salario_prom	Coefficient	Robust std. err.	t	P> t	[95% conf. interval]	
-----+-----						
_cons	550000	8020.28	68.58	0.000	534278.1	565721.9
-----+-----						
. * Cuantiles: mediana para hombres						
. qreg salario_prom if sexo==1 [pw = factor_XS_1000],q(0.5)						
Iteration 1: WLS sum of weighted deviations = 1.195e+09						
Iteration 1: Sum of abs. weighted deviations = 1.192e+09						
Iteration 2: Sum of abs. weighted deviations = 1.101e+09						
Median regression						
Raw sum of deviations 1.10e+09 (about 600000)				Number of obs = 4,033		
Min sum of deviations 1.10e+09				Pseudo R2 = 0.0000		
-----+-----						
salario_prom	Coefficient	Robust std. err.	t	P> t	[95% conf. interval]	
-----+-----						
_cons	600000	9844.105	60.95	0.000	580700.1	619299.9
-----+-----						
. * Cuantiles: mediana para mujeres						
. qreg salario_prom if sexo==2 [pw = factor_XS_1000],q(0.5)						
Iteration 1: WLS sum of weighted deviations = 6.787e+08						
Iteration 1: Sum of abs. weighted deviations = 6.788e+08						
Iteration 2: Sum of abs. weighted deviations = 6.337e+08						
Median regression						
Raw sum of deviations 6.34e+08 (about 500000)				Number of obs = 3,715		
Min sum of deviations 6.34e+08				Pseudo R2 = 0.0000		
-----+-----						
salario_prom	Coefficient	Robust std. err.	t	P> t	[95% conf. interval]	
-----+-----						
_cons	500000	5151.247	97.06	0.000	489900.5	510099.5
-----+-----						

Referencias

- Binder, D. A. (1983), "On the variances of asymptotically normal estimators from complex surveys," *International Statistical Review*, Vol. 51:279–292.
- Buuren, S.V. (2018). *Flexible Imputation of Missing Data*, segunda edición, CRC Press.
- Cameron, A. C., y P. K. Trivedi (2005), *Microeconometrics: Methods and Applications*. New York: Cambridge University Press.
- Cameron, A. C., y P. K. Trivedi (2010), *Microeconometrics Using Stata*. Revised edition, College Station, TX: Stata Press.
- Chen, C. (2004), "An Introduction to Quantile Regression and the QUANTREG Procedure," Paper 213-30, SUGI 30, SAS Institute.
- Courbois, J.-Y. P., y N. S. Urquhart (2004), "Comparison of survey estimates of the finite population variance," *Journal of Agricultural, Biological, and Environmental Statistics*, vol. 9(2):236–251.
- Demnati, A. y J.N.K. Rao (2004), "Linearization Variance Estimators for Survey Data," *Survey Methodology*, vol. 30(1):17-26.
- Eltinge, J. L. y W. M. Sribney (1996), "Estimation of means, totals, ratios, and proportions for survey data," *Stata Technical Bulletin*, May, STB-31.
- Gabler, S., S. Häder y P. Lynn (2006), "Design effects for multiple design samples," *Survey Methodology*, Vol. 32(1):115-120.
- Gosset, J. M., P. Simpson, J.G. Parker y W.L. Simon (2002), "How Complex Can Complex Survey Analysis Be with SAS?" Paper 266-27, SUGI 27, SAS Institute.
- Horvitz, D. G., y D. J. Thompson (1952), "A generalization of sampling without replacement from a finite universe," *Journal of the American Statistical Association*, vol. 47:663-685.
- Huang, Q., H. Zhang, J. Chen y M. He (2017), "Quantile Regression Models and Their Applications: A Review," *Journal of Biomtrics & Biostatitics*, vol 8(3).
- Kish, L. (1965). *Survey sampling*. NewYork:Wiley.
- Kish, L. (1995). *Methods for design effects*. *Journal of Official Statistics*, 11, 55–77.
- Lewis, T. H. (2017), *Complex Survey Data Analysis with SAS*, Chapman and Hall/CRC, .

- Lohr, S. L. (2010), "Sampling: design and analysis", 2da. edición, Brooks/Cole Cengage Learning.
- Platek, R. (1977), "Some factors affecting non-response," Survey Methodology, vol. 3:191-214.
- Rodriguez, R. N. y Y. Yao (2017), "Five Things You Should Know about Quantile Regression," Paper SAS525-2017, SAS Institute.
- Sadinle, M. (2008), "Metodología para interpolar tamaños poblacionales," Documentos de CERAC, No. 7.
- Särndal, C.-E., B. Swensson y J. Wretman (1992), Model assisted survey sampling. New York: Springer-Verlag.
- Sen, A. R. (1953), "On the estimate of the variance in sampling with varying probabilities," Journal of the Indian Society of Agricultural Statistics, vol. 5:119–127.
- Shah, B. V. (2004), "Comment to 'Demnati and Rao: Linearization Variance Estimators for Survey Data'," Survey Methodology, vol. 30(1):29.
- Skinner, C. J. (1986), "Design Effects of Two-Stage Sampling," Journal of the Royal Statistical Society. Series B (Methodological), Vol. 48(1):89-99.
- Valliant, R. y J. A. Dever (2018), Survey Weights: A Step-by-Step Guide to Calculation. Stata Press Publication, College Station:TX.
- Valliant, R., Dever, J. A., & Kreuter, F. (2018). Practical tools for designing and weighting survey samples. Cham, Switzerland: Springer.
- Yates, F., y P. M. Grundy (1953), "Selection without replacement from within strata with probability proportional to size," Journal of the Royal Statistical Society, Series B, vol. 109:12-30.

Anexo A: Ajustes al marco muestral original de Nacimientos EPS 2023

A.1. Nombres de comunas que no corresponden a comunas

La SPS decidió que se eliminaran estos **73 CASOS**.

COMUNA REPORTADA	REGIÓN REPORTADA	NRO. OBS.	Comentario
BELÉN	1	1	Corresponde a la comuna de Putre
EL SALVADOR	3	2	Corresponde a la comuna de Diego de Almagro
CARÉN	4	1	Corresponde a la comuna de Monte Patria
CAIMANES	4	1	Corresponde a la comuna de Los Vilos
TONGOY	4	17	Corresponde a la comuna de Coquimbo
CHINCOLCO	5	2	Corresponde a la comuna de Petorca
CURIMÓN	5	2	Su territorio se dividió entre las comunas de San Felipe y Los Andes
EL MANZANO	6	2	Corresponde a la comuna de Las Cabras
ENTRE LAGOS	10	7	Corresponde a la comuna de Puyehue
QUEHUE	10	1	Corresponde a la comuna de Castro
REUMÉN	10	1	Corresponde a la comuna de Paillaco
SHOSHUENCO	10	1	Corresponde a la comuna de Panguipulli: CHOSHUENCO
CUMPEO	7	4	Corresponde a la comuna de Río Claro
PUTÚ	7	4	Corresponde a la comuna de Constitución
LONTUE	7	7	Corresponde a la comuna de Molina
CARAMPANGUE	8	6	Corresponde a la comuna de Arauco
CERRO NEGRO	8	1	Corresponde a la comuna de Quillón
COPIULEMU	8	2	Corresponde a la comuna de Florida
LLICO DE ARAUCO	8	2	Corresponde a la comuna de Arauco
TOMECO	8	1	Corresponde a la comuna de Yumbel

ANTÁRTICA	12	8	Aunque es comuna, se suma a la comuna de Cabo de Hornos por razones administrativas
-----------	----	---	---

A.2. Comuna excluida del muestreo original (2002)

La comuna de Llanquihue no fue considerada en la selección de comuna de 2002, implicando una pérdida de **2237 CASOS**.

A.3. Comunas con región errónea

La SPS decidió que se eliminaran estos **7 CASOS**.

COMUNA REPORTADA	REGIÓN REPORTADA	NRO. OBS.	Comentario
LANCO	13	1	REGIÓN ERRÓNEA
NINHUE	13	1	REGIÓN ERRÓNEA
TALCA	13	1	REGIÓN ERRÓNEA
ÑUÑO A	6	1	REGIÓN ERRÓNEA
PAREDONES	2	1	REGIÓN ERRÓNEA
HUECHURABA	5	1	REGIÓN ERRÓNEA
PADRE LAS CASAS	6	1	REGIÓN ERRÓNEA

A.4. Comunas sin número de región que no tienen un nombre de comuna que permita identificar unívocamente la localización

La SPS decidió que se eliminaran estos **7 CASOS**.

COMUNA	REGIÓN REPORTADA	NRO. OBS.
SAN JOSÉ	0	7

A.5. Observaciones sin información de región, pero con información de comuna

Se imputaron las regiones de estos **408 CASOS** empleando información de la comuna o poblado.

REGIÓN IMPUTADA	COMUNA	REGIÓN REPORTADA	NRO. OBS.
4	ANDACOLLO	0	1
2	ANTOFAGASTA	0	6
15	ARICA	0	3
16	BULNES	0	1
5	CABILDO	0	1
5	ZAPALLAR: poblado CATAPILCO que	0	5

REGIÓN IMPUTADA	COMUNA	REGIÓN REPORTADA	NRO. OBS.
	corresponde a esta comuna		
5	CATEMU	0	1
13	CERRO NAVIA	0	1
11	CISNES	0	1
13	COLINA	0	1
8	CONCEPCIÓN	0	3
3	COPIAPÓ	0	3
8	CORONEL	0	1
10	CURACO DE VÉLEZ	0	1
7	CURICÓ	0	1
13	ESTACIÓN CENTRAL	0	3
9	FREIRE	0	1
1	IQUIQUE	0	2
13	LA FLORIDA	0	5
13	LA GRANJA	0	1
13	LAS CONDES	0	2
5	LIMACHE	0	1
13	LO PRADO	0	3
6	LOLOL	0	1
8	LOS ANGELES	0	1
13	MAIPÚ	0	1
14	MARIQUINA	0	1
2	MARÍA ELENA	0	1
7	MAULE	0	1
7	MOLINA	0	1
10	OSORNO	0	3
4	OVALLE	0	1
13	PEDRO AGUIRRE CERDA	0	2
13	PEÑAFLOL	0	1
13	PEÑALOLÉN	0	6
6	PICHILEMU	0	1
1	HUARA: poblado PISAGUA que corresponde a esta comuna	0	1
13	PUENTE ALTO	0	4
10	PUERTO MONTT	0	2
10	PUERTO VARAS	0	2
12	PUNTA ARENAS	0	1
6	QUINTA DE TILCOCO	0	1

REGIÓN IMPUTADA	COMUNA	REGIÓN REPORTADA	NRO. OBS.
13	RECOLETA	0	3
6	SAN FERNANDO	0	1
13	SAN JOAQUÍN	0	1
13	SAN PEDRO	0	1
8	SAN PEDRO DE LA PAZ	0	1
13	SAN RAMÓN	0	3
6	SAN VICENTE: registrado como SAN VTE TAGUA TAGUA	0	302
8	SANTA JUANA	0	1
13	SANTIAGO	0	3
14	MARIQUINA: registrado como SN JOSÉ DE MARIQUINA	0	6
13	TALAGANTE	0	1
9	TEMUCO	0	1
5	VALPARAÍSO	0	1
9	VILCÚN	0	1
5	VIÑA DEL MAR	0	2